

1 论文基本信息

题目	Fractal Generative Models（分形生成模型）
作者	Tianhong Li, Qinyi Sun, Lijie Fan, Kaiming He
关键词	Fractal, Generative Model, Autoregressive Model, Pixel-by-pixel Generation
一句话概括	把一个完整的生成模型抽象为“原子生成模块”，再递归调用它，形成具有自相似结构的分形生成架构。

摘要要点

传统模块化通常把神经网络分解为层、残差块或 Transformer block。本文进一步提出：不仅网络层可以模块化，**生成模型本身**也可以被当成模块。递归地调用这些原子生成模块，就会形成类似数学分形的自相似结构。作者以自回归模型作为原子模块，在逐像素图像生成任务上验证了似然估计和生成质量。

2 核心直觉：为什么叫“分形生成模型”

2.1 从普通模块化到生成模型模块化




图 1: 模块化层次的提升：从 layer/block 到 generative model。

DNN 中的 layer、ResNet 中的 residual block、Transformer 中的 attention block 都是模块化的例子。本文的创新点是把“一个生成步骤”甚至“一个生成模型”整体作为模块。这样，父生成器可以调用多个子生成器，子生成器继续调用更小的生成器，形成递归结构。

2.2 分形的类比



图 2: 数学分形的核心特征是递归规则与跨尺度自相似。分形生成模型将这一思想迁移到生成模型结构。

分形并不是简单的“很多层”，而是**同一种生成规则在不同尺度上重复出现**。在本文中，不同层级的生成器具有相似的功能：接收上一级输出，产生若干下一级输入，直到最终生成像素。

2.3 递归的最简单例子：阶乘

递归三要素

递归通常包含三部分：问题定义、基本情况、递归调用。阶乘满足

$$0! = 1, \quad n! = n \times (n - 1)!, \quad n > 0. \tag{1}$$

分形生成模型中的递归不是计算一个数，而是递归地生成数据块。

3 背景模型：自回归与扩散

3.1 自回归模型

自回归模型的基本思想是按照某个顺序逐步生成数据。对于序列 $x_1, x_2, \dots, x_N$ ，联合分布可以写成

$$p(x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i \mid x_1, x_2, \dots, x_{i-1}). \tag{2}$$

在图像中，如果直接把所有像素排成一个长序列，那么序列会非常长，计算代价非常高。




图 3: 逐像素自回归生成的直观示例。

3.2 扩散模型

扩散模型通常包含“逐步加噪”和“逐步去噪”两个方向。加噪过程把清晰图像变成噪声，去噪过程从噪声逐步恢复图像。它的模块化单元更接近“生成步骤”：每一步由一个神经网络预测噪声或去噪方向。

阶段	作用	模块含义
加噪	逐步向图像添加高斯噪声，最终得到接近纯噪声的样本	前向过程
去噪	从噪声出发，逐步预测并去除噪声，恢复清晰图像	生成过程

4 相关工作整理

方向	核心内容与本文关系
分形	自然界中云、树枝、雪花、晶体、染色质和蛋白质等都可能呈现分形或近分形特征。本文借用“递归规则 + 自相似结构”的思想来设计生成模型。

层次化表征	传统视觉中的可转向滤波器、拉普拉斯金字塔、SIFT，以及深度学习中的 SPPNet、FPN、Swin Transformer 都强调多尺度表示；但它们通常不是严格的递归生成结构。
层次化生成模型	VQ-VAE、latent codes、MegaByte、级联扩散、尺度空间自回归等方法也有层次性；本文不同点在于将生成模型本身当作可递归调用的原子模块。
模块化神经架构	GoogleNet 的 Inception module、ResNet 的 residual block、Transformer block、MAR、FractalNet 都体现模块化思想；本文把模块化层次提升到“完整生成模型”级别。

5 分形生成模型的数学形式

5.1 分形生成器

设第 i 层生成器为 g_i ，上一层给出一个输出 x_i 。分形生成器的作用是为下一层产生一组数据：

$$\{x_{i+1}\} = g_i(x_i). \quad (3)$$

这里的关键是：一个输入可以产生多个输出，因此随着层级加深，输出数量可以指数增长。




图 4: 一个分形生成器将一个上级输出展开为多个下级输出。

如果每层都产生 k 个输出，递归 n 层后可以覆盖 k^n 个基本变量。也就是说，模型只需要 $n = \log_k N$ 层，就能组织 N 个变量。

5.2 把自回归模型作为分形生成器

目标是建模 N 个随机变量的联合分布。若 $N = k^n$ ，直接用一个超长自回归模型会很贵。分形思想将其分为 k 个子块：

$$p(x_1, \dots, x_{k^n}) = \prod_{i=1}^k p(x_{(i-1)k^{n-1}+1}, \dots, x_{ik^{n-1}} \mid x_1, \dots, x_{(i-1)k^{n-1}}). \quad (4)$$

每个条件分布仍然包含 k^{n-1} 个变量，于是继续交给下一层自回归模型处理。反复递归后，每一层只面对长度大约为 k 的可控序列。

公式含义

上式不是简单地把一串像素切开，而是把“建模一个巨大联合分布”的任务分解成多个条件子问题。父模型负责粗粒度依赖，子模型负责更细粒度依赖；同一层的多个子问题可以并行处理，这是效率提升的重要来源。

5.3 复杂度直觉

单个长序列 Transformer 的注意力计算通常接近 $O(N^2)$ 。如果把 $N = k^n$ 个变量递归分解，模型在每层只处理较短序列，并把大量细粒度子问题拆到多个小模型中。于是它获得了两个好处：

- **计算更可控**：避免单个模型直接处理全部像素序列。
- **结构更贴近图像**：图像本身具有局部块、子图像、全局布局等多尺度结构。

6 图像生成实例

6.1 逐像素生成的挑战

RGB 图像的每个像素有 3 个通道， 256×256 图像共有 196608 个通道值。如果按普通自回归方式从第一个值一直排到最后一个值，序列过长，训练和采样都很困难。更重要的是，图像不是天然的一维文本序列，直接线性展开会破坏二维结构。

6.2 架构：父生成器到子生成器




图 5: 分形图像生成架构的简化重绘：每一层生成多个下一层输入。

在每个分形层级中，自回归模型接收上一层生成器的输出，并结合对应图像块或子块，经过 Transformer blocks 后产生下一层生成器所需的一组输出。最后一层用很轻量的 Transformer 对 RGB 通道做自回归预测，并使用 256 类交叉熵损失。

6.3 AR 与 MAR 两种实例

模型	生成顺序	特点
FractalAR	raster order, 类似 GPT 的因果 Transformer	顺序明确、实现直观，但生成顺序固定。
FractalMAR	random order, 类似 BERT 的双向 Transformer + masked autoregressive 思想	随机顺序更灵活, 实验中生成质量更好。

6.4 训练与生成策略

训练：广度优先

训练时从顶层自回归模型开始，逐层向下传递到像素级表示。最后一层预测 RGB 值，采用交叉熵损失；损失通过所有层级反向传播，实现端到端训练。

生成：深度优先

生成时从顶层开始，沿着某个分支不断向下，直到真实像素值被采样出来，再回到其他分支。这种深度优先遍历适合递归架构。

7 实验整理

实验主要在 ImageNet 64×64 与 256×256 上进行，评价维度包括似然估计、生成质量和条件逐像素预测。

7.1 模型配置与计算量

表 2: 不同分辨率下大模型的层级配置与计算量。

类别	层级	$64 \times 64 \times 3$	$256 \times 256 \times 3$
Seq. len.	g_1	256	256
	g_2	16	16
	g_3	3	16
	g_4	–	3
#layers	g_1	32	32
	g_2	8	8
	g_3	3	4
	g_4	–	1
hidden dim	g_1	1024	1024
	g_2	512	512
	g_3	128	256
	g_4	–	64
#params (M)	g_1	403	403
	g_2	25	25
	g_3	0.6	3
	g_4	–	0.1
#GFLOPs	g_1	215	215
	g_2	208	208
	g_3	15	419
	g_4	–	22

从表中可以看到， 256×256 相比 64×64 增加了更深的细粒度层级，但并不是把所有像素直接放到同一个巨大序列里。因此论文强调：得益于分形设计， 256×256 的总计算量约为 64×64 的两倍。

7.2 似然估计

表 3: ImageNet 64×64 无条件生成上的似然估计与计算量比较。NLL 单位为 bits/dim，越低越好。

模型	g_1	g_2	g_3	#GFLOPs	NLL ↓
AR, full-length	12288	–	–	29845	N/A
MAR, full-length	12288	–	–	29845	N/A
AR, 2-level	4096	3	–	5516	3.34
MAR, 2-level	4096	3	–	5516	3.36
FractalAR (3-level)	256	16	3	438	3.14
FractalMAR (3-level)	256	16	3	438	3.15

读表结论

更多分形层级带来了更低的计算量和更好的似然估计。尤其是 3-level 模型把 GFLOPs 从数千量级降到 438，同时 NLL 也更好。

7.3 生成质量

表 4: ImageNet 64×64 条件生成质量对比。FID 越低越好。

模型	类型	FID ↓
iDDPM	diffusion	2.92
StyleGAN-XL	GAN	1.51
Consistency Model	consistency	4.70
MAR	AR+diffusion	2.93
FractalAR	fractal	5.30
FractalMAR	fractal	2.72

表 5: ImageNet 256×256 生成质量对比。

模型	类型	参数量	FID ↓	IS ↑	Precision ↑
BigGAN-deep	GAN	160M	6.95	198.2	0.87
GigaGAN	GAN	569M	3.45	225.5	0.84
StyleGAN-XL	GAN	166M	2.30	265.1	0.78
ADM	diffusion	554M	4.59	186.7	0.82
Simple diffusion	diffusion	2B	3.54	205.3	–
VDM++	diffusion	2B	2.12	267.7	–
SiD ²	diffusion	–	1.38	–	–
JetFormer	AR+flow	2.8B	6.64	–	0.69
FractalMAR-B	fractal	186M	11.80	274.3	0.78
FractalMAR-L	fractal	438M	7.30	334.9	0.79
FractalMAR-H	fractal	848M	6.15	348.9	0.81

生成质量的理性解读

FractalMAR 在 64×64 上接近强基线，并在逐像素框架中取得较好结果；在 256×256 上，FID 仍落后于顶级 GAN/扩散模型，但它展示了逐像素生成路线的可行性。换言之，本文更像是提出一种新范式，而不是单纯刷新所有指标。

7.4 定性结果

图 6: 课件中保留的 ImageNet 256×256 逐像素生成结果。




图 7: 条件逐像素预测示例: 包含图像修复、外推、反裁剪和类别条件编辑等任务。

8 个人点评与创新点

8.1 论文创新点

1. **模块化层次提升**: 不是把网络层当模块, 而是把完整生成模型当作原子模块。
2. **递归生成架构**: 通过父生成器调用子生成器, 形成多尺度、自相似结构。
3. **逐像素生成的新可能**: 在不依赖 tokenizer 的情况下, 直接对原始像素进行生成建模。
4. **效率与结构兼顾**: 把长序列建模拆成分治式的层级子问题, 降低单层序列长度。

8.2 值得继续思考的方向

可作为自己汇报中的创新观点

分形生成模型的潜力不只在图像。只要数据存在“整体由局部组成、局部又有类似结构”的特征，就可以考虑分形生成。比如点云、蛋白质结构、图神经网络中的大图生成、机器人多层动作规划，都可能尝试把“子结构生成器”递归嵌入到“整体生成器”中。

8.3 局限性

- 目前主要以图像逐像素生成作为验证场景，其他非顺序结构数据上的效果仍需要进一步实验。
- 生成质量并未全面超过顶级扩散模型或 GAN，尤其在 256×256 FID 上仍有差距。
- 递归层级、子块划分、AR/MAR 选择等设计空间较大，工程调参成本不低。