

1 论文基本信息

题目	5% > 100%: Breaking Performance Shackles of Full Fine-Tuning
课件日期	2025-04-29
研究方向	参数高效微调 / 视觉适配
一句话概括	提出多认知视觉适配器 Mona, 以少量可训练参数对预训练视觉模型进行任务适配, 力图突破 “参数越多微调越好” 的惯性。

摘要要点

提出多认知视觉适配器 Mona, 以少量可训练参数对预训练视觉模型进行任务适配, 力图突破 “参数越多微调越好” 的惯性。本说明按 “研究问题—核心机制—基础公式—实验阅读—局限与优化” 的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层，而是识别现有范式中最影响**质量、效率、可靠性或可部署性**的瓶颈。结合论文所讨论的问题，可以将研究动机概括为以下几点：

- 研究背景预训练与微调范式在计算机视觉中的应用预训练模型的优势 Delta-Tuning 方法的发展现有 Delta-Tuning 方法的局限性 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 研究动机现有 Delta-Tuning 方法的不足 Mona-Tuning 的提出多认知视觉适配器 (Mona) 的设计目标 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks

理解重点

阅读这类论文时，应把 “问题是否真实存在” “方法是否直接解决该问题” “实验是否排除了其他解释” 分开判断。仅凭更大的模型、更多数据或更长训练得到的提升，不能自动视为结构创新带来的收益。

3 核心思想与整体流程

提出多认知视觉适配器 Mona, 以少量可训练参数对预训练视觉模型进行任务适配, 力图突破 “参数越多微调越好” 的惯性。从信息流角度看，其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- 研究背景预训练与微调范式在计算机视觉中的应用预训练模型的优势 Delta-Tuning 方法的发展现有 Delta-Tuning 方法的局限性 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks

- 研究动机现有 Delta-Tuning 方法的不足 Mona-Tuning 的提出多认知视觉适配器 (Mona) 的设计目标 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 实验 · 实验数据集 · 预训练模型 · 基线方法 · 实验结果 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- Mona-Tuning 方法多认知视觉适配器 (Mona) 的结构输入优化:LayerNorm 和可学习权重多认知视觉滤波器: DepthWise Convolutions 和 1×1 卷积跳跃连接的作用 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 输入优化 LayerNorm 的作用可学习权重的调整机制输入优化的公式 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 多认知视觉滤波器 DepthWise Convolutions 的优势多尺度卷积核的设计 1×1 卷积的作用 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 损失分析 Mona 的收敛速度与其他方法的对比 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks

结构解析

- 3 研究背景预训练与微调范式在计算机视觉中的应用预训练模型的优势 Delta-Tuning 方法的发展现有 Delta-Tuning 方法的局限性 5

下图补充展示模块连接、数据流或训练阶段之间的关系。

- 研究背景
- 预训练与微调范式在计算机视觉中的应用
 - 预训练模型的优势
 - Delta-Tuning 方法的发展
 - 现有 Delta-Tuning 方法的局限性




图 2: 模型结构、数据流或主要训练阶段。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式，并不替代原论文中的完整推导。

$$W' = W + \Delta W, \quad \Delta W = BA, \quad \text{rank}(\Delta W) \leq r$$

(1)

参数高效微调冻结原权重 W ，只学习低秩更新 BA 。相关方法的创新通常围绕稀疏、共享、路由或低维参数生成展开。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分：是输入表示、连接矩阵、条件变量、参数化方式、训练目标，还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- 实验结果 Monas 在 COCO 数据集上的性能 Monas 在其他数据集上的性能 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 实验 · 实验数据集 · 预训练模型 · 基线方法 · 实验结果 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 消融实验适配器中间维度的影响不同模型大小下的性能 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 实验数据集 · COCO 数据集 · ADE20K 数据集 · Pascal VOC 数据集 · DOTA/STAR 数据集 · 图像分类数据集: Oxford 102 Flower, Oxford IIIT Pet, VOC 2007 Classification 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 点评实验全面性能好就是最好的理论做研究应多考量泛化性 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks
- 损失分析 Monas 的收敛速度与其他方法的对比 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks

结果解读

• 14 实验结果 Monas 在 COCO 数据集上的性能 Monas 在其他数据集上的性能 5

下图用于直观呈现主要对比、消融、定性样例或效率结果。

头粒绍禾

- Mona 在 COCO 数据集上的性能
- Mona 在其他数据集上的性能

CV&NLP
RESEARCHER

Table 4: Results of baselines and our methods on three classification datasets. Swin-L is employed as the pre-trained model here. We present top-1 accuracy (%) and top-5 accuracy (%) of each dataset. The best result in each column is bolded.

Method	Flowers102		OxfordPets		VOC2007		Average	
	top-1 acc.	top-5 acc.	top-1 acc.	top-5 acc.	top-1 acc.	top-5 acc.	top-1 acc.	top-5 acc.
Baselines								
FULL	99.5772	99.8536	94.6579	99.6257	84.1276	96.9507	92.7876	98.8100
FIXED	99.3007	99.8374	94.2219	99.9182	85.0162	98.9499	92.8463	99.5685
BITFIT	99.5772	99.8211	95.3393	99.9182	85.6018	99.3336	93.5061	99.6910
NORMTUNING	99.5284	99.8374	95.2303	99.8910	85.5210	99.2528	93.4266	99.6604
PARTIAL-I	99.6585	99.8374	95.3938	99.8637	84.9354	98.6066	93.3292	99.4359
ADAPTER	99.5934	99.8536	95.3393	99.8092	87.0355	99.1317	93.9894	99.6144
LORA	99.5446	99.8536	95.1485	99.8910	85.7028	99.3134	93.4653	99.6860
ADAPTFORMER	99.5609	99.8536	95.2576	99.8365	86.2884	99.2730	93.7023	99.6544
LoRAND	99.5725	99.8536	95.3515	99.8910	86.6534	99.3741	93.8591	99.7062
Our Method								
MONA	99.6764	99.9024	95.4765	99.9182	86.9709	99.5057	94.0413	99.7592

图 3: 代表性实验对比、消融结果或定性样例。

实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时，结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**：论文围绕一个可识别的核心瓶颈展开，方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**：即使不完整复现模型，其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**：实验通常同时展示主结果、效率比较、案例或消融，使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益，并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析；在一个数据集上的最优配置不一定能直接迁移。
- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性，而不仅是离线平均指标。
- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合，验证不同优化是否互补。

7 结论

总体而言，提出多认知视觉适配器 Mona，以少量可训练参数对预训练视觉模型进行任务适配，力图突破“参数越多微调越好”的惯性。。进一步需要注意：结论 Mona-Tuning 的贡献未来工作方向 Mona-Tuning 在更多视觉任务中的应用结合其他方法优化 Mona-Tuning 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on

Visual Recognition Tasks; 研究背景预训练与微调范式在计算机视觉中的应用预训练模型的优势 Delta-Tuning 方法的发展现有 Delta-Tuning 方法的局限性 5%>100%:BreakingPerformance Shackles of Full Fine-Tuning on Visual Recognition Tasks。