

1 论文基本信息

题目	Exploring Diffusion Transformer Designs via Grafting
课件日期	2025-06-19
研究方向	扩散 Transformer / 架构编辑
一句话概括	把新模块“嫁接”到已有预训练 DiT 中, 用低成本局部训练评估架构设计, 避免每次创新都从头完整训练。

摘要要点

把新模块“嫁接”到已有预训练 DiT 中, 用低成本局部训练评估架构设计, 避免每次创新都从头完整训练。本说明按“研究问题—核心机制—基础公式—实验阅读—局限与优化”的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层, 而是识别现有范式中最影响**质量、效率、可靠性或可部署性**的瓶颈。结合论文所讨论的问题, 可以将研究动机概括为以下几点:

- 应用价值局限性与未来工作 Exploring Diffusion Transformer Designs via Grafting
- • 计算特性: 并行块提升 SM 利用率 (论文 6 章) 减少层间同步点 • 实测数据: 2 倍理论速度提升 (Table 6 备注) 适合大 batch 推理 • 内存优化: 减少中间激活存储更均衡的显存占用 Exploring Diffusion Transformer Designs via Grafting
- 局限性与未来工作 Exploring Diffusion Transformer Designs via Grafting • 现有局限: 仅处理 MHA/MLP(论文 8 章) 需预训练模型 • 技术瓶颈: 合成数据质量影响 (Figure D.4) 深度压缩的极限 • 未来方向: 自动化嫁接策略跨模态架构移植
- Exploring Diffusion Transformer Designs via Grafting 架构创新 = 从头训练? 这个认知该打破了!
- 传统流程: 新想法 → 完整训练 → 评估 (耗时耗力) 类比说明: 相当于每次改装汽车都要重造发动机论文突破: 对预训练模型进行编辑 (论文第 3 章)
- 为什么 GPU 更爱”宽扁”架构?

理解重点

阅读这类论文时, 应把“问题是否真实存在”“方法是否直接解决该问题”“实验是否排除了其他解释”分开判断。仅凭更大的模型、更多数据或更长训练得到的提升, 不能自动视为结构创新带来的收益。

3 核心思想与整体流程

把新模块“嫁接”到已有预训练 DiT 中, 用低成本局部训练评估架构设计, 避免每次创新都从头完整训练。从信息流角度看, 其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- Exploring Diffusion Transformer Designs via Grafting 架构创新 = 从头训练? 这个认知该打破了!
- 传统流程: 新想法 → 完整训练 → 评估 (耗时耗力) 类比说明: 相当于每次改装汽车都要重造发动机论文突破: 对预训练模型进行编辑 (论文第 3 章)
- 应用价值局限性与未来工作 Exploring Diffusion Transformer Designs via Grafting
- 生物嫁接 × AI 模型 = 突破性创新类比解析: 砧木: 预训练模型 (Baseline) 接穗: 新架构算子 (Hyena-X/Y 等, 论文 4.1 节) 形成层: 激活蒸馏关键差异: 植物嫁接 (南瓜砧木) 成功率 ≈95%, 模型嫁接 FID 变化仅 +0.37(Table 4 最佳案例) Exploring Diffusion Transformer Designs via Grafting
- 局限性与未来工作 Exploring Diffusion Transformer Designs via Grafting • 现有局限: 仅处理 MHA/MLP(论文 8 章) 需预训练模型 • 技术瓶颈: 合成数据质量影响 (Figure D.4) 深度压缩的极限 • 未来方向: 自动化嫁接策略跨模态架构移植
- Exploring Diffusion Transformer Designs via Grafting 从 Stable Diffusion 到 Sora: 扩散模型的爆发与瓶颈行业现状: 扩散模型已成为 AIGC 核心 (图像/视频生成) 核心矛盾: 模型越强 → 训练成本越高 (DiT-XL/2 需 7000K 迭代) 从头开始训练模型的成本过高数据支撑: Table 2 显示完整训练需 100%, 嫁接仅需 0.63%-10% training data
- 9%(Table 4) 替换策略: 交错替换优于全替换 (50% vs 100% 对比) 局部性强的层优先 (Figure 2 指导) Exploring Diffusion Transformer Designs via Grafting Attention Is All You Need

结构解析

- 2 从 Stable Diffusion 到 Sora: 扩散模型的爆发与瓶颈行业现状: 扩散模型已成为 AIGC 核心 (图像/视频生成) 核心矛盾: 模型越强 → 训练成本越高 (DiT-XL/2 需 7000K 迭代) 从头开始训练模型的成本过高数据支撑: Table 2 显示完整训练需……

下图补充展示模块连接、数据流或训练阶段之间的关系。

架构创新=从大训练：这个认知该打碎了！

- 传统流程：新想法→完整训练→评估（耗时耗力）
- 类比说明：相当于每次改装汽车都要重造发动机
- 论文突破：对预训练模型进行编辑（论文第3章）




Figure 5: Convert model depth → width via grafting: (a) Two sequential transformer layers. (b) Rewiring in parallel via grafting (includes skip connections).

图 2: 模型结构、数据流或主要训练阶段。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式，并不替代原论文中的完整推导。

$$x_t = \alpha_t x_0 + \sigma_t \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I) \quad (1)$$

扩散类方法把真实样本与噪声按时间混合，模型再学习逆向去噪、速度场或条件流。不同论文的主要差异通常落在表示空间、网络骨干和训练目标上。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分：是输入表示、连接矩阵、条件变量、参数化方式、训练目标，还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- 9%(Table 4) 替换策略: 交错替换优于全替换 (50% vs 100% 对比) 局部性强的层优先 (Figure 2 指导) Exploring Diffusion Transformer Designs via Grafting Attention Is All You Need
- 文生图实战方案: 替换层:7-27 层 MHA(论文 5 章) 新算子:Hyena-X(K=4) 训练数据:12k 合成样本结果: 速度 ↑:1.43 倍 (235.46ms → 164.58ms) 质量 ↓:GenEval
- 75(Table 5) 特殊技巧: 使用 LoRA(rank=64) 分层 clip norm(0.1/0.01) Exploring Diffusion Transformer Designs via Grafting
- 77 超越同类深度模型 (对比 Table 6 中 TinyDiT-D14) 参数仅增 6%(712M vs 675M) 硬件优势: 更适合 GPU 并行计算减少层间通信开销 Exploring Diffusion Transformer Designs via Grafting
- 77 vs 剪枝 2.86(Table 6) 从头训练需要 7000k 次迭代 (论文 2 章) 成本对比: 嫁接:10% 数据 +230K 步剪枝:100% 数据 +500K 步 (TinyDiT) 灵活性对比: 嫁接支持架构重组剪枝仅能减少参数 Exploring Diffusion Transformer Designs via Grafting

- 计算特性: 并行块提升 SM 利用率 (论文 6 章) 减少层间同步点 • 实测数据: 2 倍理论速度提升 (Table 6 备注) 适合大 batch 推理 • 内存优化: 减少中间激活存储更均衡的显存占用 Exploring Diffusion Transformer Designs via Grafting
- 深度压缩技术原理: 并行化相邻块 (论文 6 章”parallelizing every pair of blocks”) 线性合并输出 (Figure 5(b) 结构) 性能表现: FID

结果解读

- 7 注意力机制的替代方案候选方案: Hyena-X/Y (论文原创, $K=4$) 滑动窗口注意力 ($w=4$) Mamba-2 ($ds=64$) 性能对比: 最佳 FID: Hyena-Y 2.72 (vs 基线 2.27) 最大 FLOPs↓: Hyena-X 49.9

该部分以文字概括实验结论与比较条件, 避免用整页截图代替分析。实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时, 结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**: 论文围绕一个可识别的核心瓶颈展开, 方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**: 即使不完整复现模型, 其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**: 实验通常同时展示主结果、效率比较、案例或消融, 使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益, 并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析; 在一个数据集上的最优配置不一定能直接迁移。
- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性, 而不仅是离线平均指标。
- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合, 验证不同优化是否互补。

7 结论

总体而言, 把新模块“嫁接”到已有预训练 DiT 中, 用低成本局部训练评估架构设计, 避免每次创新都从头完整训练。。进一步需要注意: 局限性与未来工作 Exploring Diffusion Transformer Designs via Grafting • 现有局限: 仅处理 MHA/MLP(论文 8 章) 需预训练模型 • 技术瓶颈: 合成数据质量影响 (Figure D.4) 深度压缩的极限 • 未来方向: 自动化嫁接策略跨模态架构移植; 应用价值局限性与未来工作 Exploring Diffusion Transformer Designs via Grafting。