

1 论文基本信息

题目	DiC: Diffusion Models with 3×3 Convolutions
课件日期	2025-07-17
研究方向	卷积扩散模型 / 高效生成
一句话概括	以纯 3×3 卷积和结构重参数化思想构造高效扩散骨干, 说明卷积模型仍能在生成质量与吞吐量上具有竞争力。

摘要要点

以纯 3×3 卷积和结构重参数化思想构造高效扩散骨干, 说明卷积模型仍能在生成质量与吞吐量上具有竞争力。本说明按“研究问题—核心机制—基础公式—实验阅读—局限与优化”的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层, 而是识别现有范式中最影响**质量、效率、可靠性或可部署性**的瓶颈。结合论文所讨论的问题, 可以将研究动机概括为以下几点:

- 核心痛点: 自注意力机制计算量与图像尺寸平方成正比 (512x512 图像计算量是 256x256 的倍), 难以满足实时需求 (如视频生成)
- 扩散模型现状:Transformer 架构 (如 DiT、Stable Diffusion) 主导, 生成质量高但推理速度慢
- 初始挑战: 直接替换后模型性能差 (FID=29.31), 因 3x3 卷积感受野有限 (仅 3x3 区域), 难以捕捉全局信息
- 创新动机: 受 RepVGG 启发, 探索纯 3x3 卷积构建扩散模型, 利用其线性复杂度 (尺寸翻倍, 计算量仅翻倍)
- 现有方案局限:ToDo、PixArt-Σ 等仅优化注意力细节, 未突破“二次复杂度”瓶颈
- DiC 的研究背景与问题提出

理解重点

阅读这类论文时, 应把“问题是否真实存在”“方法是否直接解决该问题”“实验是否排除了其他解释”分开判断。仅凭更大的模型、更多数据或更长训练得到的提升, 不能自动视为结构创新带来的收益。

3 核心思想与整体流程

以纯 3×3 卷积和结构重参数化思想构造高效扩散骨干, 说明卷积模型仍能在生成质量与吞吐量上具有竞争力。从信息流角度看, 其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- 核心创新: 提出“结构重参数化”技术, 实现训练时多分支 (3x3 卷积 + 1x1 卷积 + 恒等映射) 与推理时单分支 (纯 3x3 卷积) 的转换
- 显著成果: 在 ImageNet 上首破 plain 模型 80% 准确率, 比 ResNet-50 快 83%, 内存占用降低 50%
- 对 DiC 的启示: 证明 3x3 卷积经优化后可媲美复杂模型, 为扩散模型提供“高效轻量”的设计思路
- 核心背景: 复杂 CNN (如 ResNet) 的多分支结构导致推理速度慢、内存占用高, 制约实际应用
- 关键方法: 通过代数运算将 BN 层参数融合到卷积核中, 消除分支冗余
- 经典工作 RepVGG 简介
- 架构选择: 采用 U-Net Hourglass 结构 (编码器 - 解码器), 通过下采样扩大感受野 (高层 3x3 卷积等效覆盖更大区域)

结构解析

- 3 经典工作 RepVGG 简介; 核心背景: 复杂 CNN (如 ResNet) 的多分支结构导致推理速度慢、内存占用高, 制约实际应用; 核心创新: 提出“结构重参数化”技术,

下图补充展示模块连接、数据流或训练阶段之间的关系。

Figure 2: Model structure, data flow or main training stages.

CV&NLP
RESEARCH

- 核心背景: 复杂 CNN (如 ResNet) 的多分支结构导致推理速度慢、内存占用高, 制约实际应用
- 核心创新: 提出“结构重参数化”技术, 实现训练时多分支 (3x3 卷积 + 1x1 卷积 + 恒等映射) 与推理时单分支 (纯 3x3 卷积) 的转换
- 关键方法: 通过代数运算将 BN 层参数融合到卷积核中, 消除分支冗余
- 显著成果: 在 ImageNet 上首破 plain 模型 80% 准确率, 比 ResNet-50 快 83%, 内存占用降低 50%
- 对 DiC 的启示: 证明 3x3 卷积经优化后可媲美复杂模型, 为扩散模型提供“高效轻量”的设计思路

图 2: 模型结构、数据流或主要训练阶段。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式, 并不替代原论文中的完整推导。

$$y(p) = \sum_{q \in \mathcal{N}(p)} K(p, q) x(q) \quad (1)$$

视觉骨干的核心是把邻域或全局位置 q 的信息聚合到位置 p 。不同方法通过动态卷积、物理扩散、大核或多分支结构改变核 $K(p, q)$ 的范围与适应性。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分：是输入表示、连接矩阵、条件变量、参数化方式、训练目标，还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- 与 DiT 对比: 同规模下, DiC-XL 在 ImageNet 256x256 的 FID (13.11) 远低于 DiT-XL/2 (20.05), IS (100.15) 更高 (表)
- 多模型对比: DiC-XL 的 FID (13.11) 显著低于 U-ViT-XL (18.35)、PixArt- α -XL/2 (24.75) 等 Transformer 模型 (表)
- 大尺寸表现: 512x512 分辨率下, DiC-XL 的 FID (15.32) 优于 DiT-XL/2 (20.94), 速度快倍 (表)
- 硬件效率: Winograd 优化使实际 FLOPs 减半, A100 上单卡吞吐量是 Transformer 模型的 5-8 倍
- 25 , 优于 DiT-XL/2 (2.27) 和 U-ViT-H (2.29), 吞吐量更高 (表)
- 可视化质量: 生成的 256x256/512x512 图像细节丰富 (图、图), 纹理、光影真实度高
- 96 , 媲美 DiT-XL/2 的 7M 步 (9.62), 训练成本降低 87% (表)

结果解读

- 19 DiC 的实验结果与性能验证 (一); 与 DiT 对比: 同规模下, DiC-XL 在 ImageNet 256x256 的 FID (13.11) 远低于 DiT-XL/2 (20.05),

该部分以文字概括实验结论与比较条件, 避免用整页截图代替分析。实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时, 结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**: 论文围绕一个可识别的核心瓶颈展开, 方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**: 即使不完整复现模型, 其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**: 实验通常同时展示主结果、效率比较、案例或消融, 使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益, 并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析; 在一个数据集上的最优配置不一定能直接迁移。
- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性, 而不仅是离线平均指标。

- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合，验证不同优化是否互补。

7 结论

总体而言，以纯 3×3 卷积和结构重参数化思想构造高效扩散骨干，说明卷积模型仍能在生成质量与吞吐量上具有竞争力。。进一步需要注意：核心贡献: 提出首个纯 3×3 卷积扩散模型 DiC , 通过 U-Net + 稀疏连接和条件改进, 在生成质量上超越 Transformer , 速度快 4-5 倍; 对行业影响: 推动扩散模型向实时化、轻量化发展, 使普通设备也能运行高清图像 / 视频生成, 加速 Sora 类技术的普及。