

1 论文基本信息

题目	Mixture-of-Recursions(MoR)
课件日期	2025-07-30
研究方向	递归 Transformer / 动态计算
一句话概括	将参数共享、token 级递归路由和递归缓存统一起来, 让不同 token 根据难度获得不同计算深度。

摘要要点

将参数共享、token 级递归路由和递归缓存统一起来, 让不同 token 根据难度获得不同计算深度。本说明按“研究问题—核心机制—基础公式—实验阅读—局限与优化”的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层, 而是识别现有范式中最影响**质量、效率、可靠性或可部署性**的瓶颈。结合论文所讨论的问题, 可以将研究动机概括为以下几点:

- Recursive Transformers 的局限: 固定递归深度,KV 缓存冗余
- MoR 的核心目标: 在单一框架中实现参数共享、自适应计算与高效缓存
- 前沿工作背景与动机——为什么需要 MoR ?
- 现有效率方案的不足: 参数共享与自适应计算难以兼顾
- 大模型困境: 规模增长导致训练部署成本激增
- 应用价值: 在降低成本的同时保持大模型性能

理解重点

阅读这类论文时, 应把“问题是否真实存在”“方法是否直接解决该问题”“实验是否排除了其他解释”分开判断。仅凭更大的模型、更多数据或更长训练得到的提升, 不能自动视为结构创新带来的收益。

3 核心思想与整体流程

将参数共享、token 级递归路由和递归缓存统一起来, 让不同 token 根据难度获得不同计算深度。从信息流角度看, 其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- Expert-choice 路由: 每个递归步骤选择 Top-k Token 继续计算

- 四种参数共享策略: Cycle、Sequence 及其 “Middle” 变体
- 支持深度批处理: 不同递归阶段的 Token 合并计算, 提升 GPU 利用率
- Token-choice 路由: 一开始为 Token 分配固定递归次数
- Middle-Cycle 策略: 保留首尾层独特参数, 中间层循环共享
- 路由机制: 轻量级路由器为每个 Token 分配递归深度
- 递归块设计: 复用共享层堆叠, 替代传统固定深度层

结构解析

- 5 经典工作回顾——Transformer 与递归模型基础; Transformer 核心结构: 自注意力机制与固定深度的层堆叠: (Vaswani et al.,

上述内容以文字方式保留方法结构, 避免把整张幻灯片作为独立页面嵌入正文。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式, 并不替代原论文中的完整推导。

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}} + M\right) V \quad (1)$$

注意力方法的关键变量是掩码或路由矩阵 M 。全注意力允许所有位置交互; 稀疏、递归或残差注意力通过限制连接、共享计算或选择历史状态降低成本。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分: 是输入表示、连接矩阵、条件变量、参数化方式、训练目标, 还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- 等规模对比: MoR 处理的训练 Token 更多 (如 167M 参数处理 27B Token, 基线 20B)
- 实验设置: 模型规模 135M-1.7B, 训练数据为教育类文本 (FineWeb- Edu)
- 核心指标: 验证损失 (NLL, 越低越好)、少样本准确率 (越高越好)、推理速度
- 关键结果: 相同计算量下, MoR 参数少 50%, 损失更低、准确率更高
- 推理提速: 动态退出 + 深度批处理, 吞吐量最高提升 2.06 倍
- ——实验结果 MoR 的性能与效率优势
- Recursive Transformers 的局限: 固定递归深度, KV 缓存冗余

结果解读

- 22 ——实验结果 MoR 的性能与效率优势; 实验设置: 模型规模 135M-1.7B, 训练数据为教育类文本 (FineWeb- Edu); 核心指标: 验证损失 (NLL,

该部分以文字概括实验结论与比较条件，避免用整页截图代替分析。实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时，结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**：论文围绕一个可识别的核心瓶颈展开，方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**：即使不完整复现模型，其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**：实验通常同时展示主结果、效率比较、案例或消融，使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益，并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析；在一个数据集上的最优配置不一定能直接迁移。
- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性，而不仅是离线平均指标。
- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合，验证不同优化是否互补。

7 结论

总体而言，将参数共享、token 级递归路由和递归缓存统一起来，让不同 token 根据难度获得不同计算深度。。进一步需要注意：MoR 的核心贡献: 统一参数共享、自适应路由与高效 KV 缓存; 对研究者的启示: 动态计算与参数共享结合是高效模型的重要方向。