

1 论文基本信息

题目	Why Language Models Hallucinate
课件日期	2025-09-26
研究方向	幻觉 / 评估机制 / 置信度
一句话概括	从预训练中的二分类误差与后训练评估激励解释语言模型为何倾向于猜测, 并讨论允许拒答和改造评分机制的价值。

摘要要点

从预训练中的二分类误差与后训练评估激励解释语言模型为何倾向于猜测, 并讨论允许拒答和改造评分机制的价值。本说明按“研究问题—核心机制—基础公式—实验阅读—局限与优化”的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层, 而是识别现有范式中最影响**质量、效率、可靠性或可部署性**的瓶颈。结合论文所讨论的问题, 可以将研究动机概括为以下几点:

- 二元评分基准 MMLU-Pro、GPQA, WildBench 会给 IDK 打 3-4 分, 但还是比“有幻觉的回答”(5-6 分) 低
- SWE-bench (软件测试) 补丁过测试得分, 否则分, 模型倾向选择“编代码”, 严肃场景高危险性
- 加个 IDK (I don't know) 选项, 就能减少幻觉?
- ChatGPT、DeepSeek、Llama 均答错
- DeepSeek-V3 给出 2、3、6、7 等答案
- 给模型加个‘我不知道’(IDK) 选项, 就能减少幻觉

理解重点

阅读这类论文时, 应把“问题是否真实存在”“方法是否直接解决该问题”“实验是否排除了其他解释”分开判断。仅凭更大的模型、更多数据或更长训练得到的提升, 不能自动视为结构创新带来的收益。

3 核心思想与整体流程

从预训练中的二分类误差与后训练评估激励解释语言模型为何倾向于猜测, 并讨论允许拒答和改造评分机制的价值。从信息流角度看, 其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- “二分类误差 → 生成错误” 催生幻觉

- 加个 IDK (I don't know) 选项, 就能减少幻觉?
- 模型幻觉现象测试: 生日, 字母计数, 论文标题, 多次输出错误答案
- 模型质量与错误观察: 以推理能力为代表的模型质量会影响错误率
- 人类反馈融合: 将人类对“不确定性表达”的偏好融入训练
- 模型校准数据引用: 预训练目标与模型错误有关联。
- 动态阈值调整: 根据任务风险动态调整置信度阈值

结构解析

- 幻觉率的量化关键发现; 模型幻觉现象测试: 生日, 字母计数, 论文标题, 多次输出错误答案; 模型校准数据引用: 预训练目标与模型错误有关联
- ; 基准测试机制分析: 二元评分会强化幻觉; 模型质量与错误观察: 以推理能力为代表的模型质量会影响错误率

上述内容以文字方式保留方法结构, 避免把整张幻灯片作为独立页面嵌入正文。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式, 并不替代原论文中的完整推导。

$$R = \Pr(\text{unsafe or private output} \mid x, a) \quad (1)$$

安全研究需要把风险定义为可测量事件: 给定输入 x 和攻击/推理策略 a , 模型产生有害、隐私或虚假输出的概率。实验设计必须同时报告攻击成功与正常能力保留。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分: 是输入表示、连接矩阵、条件变量、参数化方式、训练目标, 还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- 模型幻觉现象测试: 生日, 字母计数, 论文标题, 多次输出错误答案
- 模型质量与错误观察: 以推理能力为代表的模型质量会影响错误率
- 模型校准数据引用: 预训练目标与模型错误有关联。
- 基准测试机制分析: 二元评分会强化幻觉
- 二元评分基准 MMLU-Pro、GPQA, WildBench 会给 IDK 打 3-4 分, 但还是比“有幻觉的回答”(5-6 分) 低
- SWE-bench (软件测试) 补丁过测试得分, 否则分, 模型倾向选择“编代码”, 严肃场景高危险性
- ChatGPT、DeepSeek、Llama 均答错

结果解读

- 评估体系如何“奖励”幻觉；二元评分引发幻觉的必然：回答问题，猜比不说强；二元评分基准 MMLU-Pro、GPQA，WildBench 会给 IDK 打 3-4 分，

该部分以文字概括实验结论与比较条件，避免用整页截图代替分析。实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时，结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**：论文围绕一个可识别的核心瓶颈展开，方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**：即使不完整复现模型，其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**：实验通常同时展示主结果、效率比较、案例或消融，使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益，并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析；在一个数据集上的最优配置不一定能直接迁移。
- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性，而不仅是离线平均指标。
- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合，验证不同优化是否互补。

7 结论

总体而言，从预训练中的二分类误差与后训练评估激励解释语言模型为何倾向于猜测，并讨论允许拒答和改造评分机制的价值。。进一步需要注意：加个 IDK (I don't know) 选项, 就能减少幻觉?; 允许 AI “说不知道”，给予合理的激励, 才能走向“可靠”。