

1 论文基本信息

题目	Optical Generative Models
课件日期	2025-10-16
研究方向	光计算 / 生成模型
一句话概括	把生成过程的一部分映射到光学传播与调制器件中, 以光的并行传播降低数字生成模型的能耗和延迟。

摘要要点

把生成过程的一部分映射到光学传播与调制器件中, 以光的并行传播降低数字生成模型的能耗和延迟。本说明按“研究问题—核心机制—基础公式—实验阅读—局限与优化”的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层, 而是识别现有范式中最影响**质量、效率、可靠性或可部署性**的瓶颈。结合论文所讨论的问题, 可以将研究动机概括为以下几点:

- DDPM(高要求图像生成) 甚至需数百 GB 级显存支持
- DDPM 单张 256×256 图像计算能耗可达数百毫焦
- DDPM 模型生成一张图像需数百毫秒至秒级
- 三、生成任务与硬件架构的强绑定限制
- 传统数字生成模型的三大核心痛点
- 二、模型规模扩大带来的扩展瓶颈

理解重点

阅读这类论文时, 应把“问题是否真实存在”“方法是否直接解决该问题”“实验是否排除了其他解释”分开判断。仅凭更大的模型、更多数据或更长训练得到的提升, 不能自动视为结构创新带来的收益。

3 核心思想与整体流程

把生成过程的一部分映射到光学传播与调制器件中, 以光的并行传播降低数字生成模型的能耗和延迟。从信息流角度看, 其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- 与 DDPM 区别: 训练部分无异, 生成推理使用光学系统

- 静态光学种子生成: 随机噪声 $\rightarrow$ 相位图案的数字映射
- 联合训练: 数字编码器与光学解码器的协同优化
- 动态光学解码: 自由空间衍射的图像合成过程
- 关注推理部分, 就能把握核心 idea
- 光学生成模型核心创新- 联合训练
- 看这篇文章容易只关注训练的部分, 实际上推理的部分更重要

结构解析

- 光学生成模型核心创新; 关注推理部分, 就能把握核心 idea ; 静态光学种子生成: 随机噪声 $\rightarrow$ 相位图案的数字映射; 动态光学解码: 自由空间衍射的图像合成过程; 联合训练: 数字编码器与光学解码器的协同优化; 与 DDPM 区别: 训练部分无异, 生成推理使用光学系统

上述内容以文字方式保留方法结构, 避免把整张幻灯片作为独立页面嵌入正文。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式, 并不替代原论文中的完整推导。

$$U_z = \mathcal{F}^{-1}\{\mathcal{F}(U_0) H_z\} \quad (1)$$

光学系统利用傅里叶变换和传播传递函数 H_z 在物理空间中并行处理光场。可训练调制器相当于网络参数, 探测器读出生成结果。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分: 是输入表示、连接矩阵、条件变量、参数化方式、训练目标, 还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- 传统数字生成模型的三大核心痛点
 - 一、推理过程的高能耗与低速度
 - 二、模型规模扩大带来的扩展瓶颈
 - 三、生成任务与硬件架构的强绑定限制
- DDPM 单张 256×256 图像计算能耗可达数百毫焦
- DDPM 模型生成一张图像需数百毫秒至秒级
- DDPM(高要求图像生成) 甚至需数百 GB 级显存支持

结果解读

- 实验结果

下图用于直观呈现主要对比、消融、定性样例或效率结果。

实验结果

CV&NLP
RESEARCH




图 2: 代表性实验对比、消融结果或定性样例。

实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时，结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**：论文围绕一个可识别的核心瓶颈展开，方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**：即使不完整复现模型，其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**：实验通常同时展示主结果、效率比较、案例或消融，使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益，并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析；在一个数据集上的最优配置不一定能直接迁移。
- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性，而不仅是离线平均指标。
- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合，验证不同优化是否互补。

7 结论

总体而言，把生成过程的一部分映射到光学传播与调制器件中，以光的并行传播降低数字生成模型的能耗和延迟。。进一步需要注意：看这篇文章容易只关注训练的部分，实际上推理的部分更重要；关注“AI”之外的内容，比如物理世界基本规律。