

1 论文基本信息

题目	Back to Basics: Just Image Transformers
课件日期	2025-11-21
研究方向	扩散生成 / 纯图像 Transformer
一句话概括	重新审视生成模型是否必须依赖复杂压缩潜空间, 以纯图像 Transformer 在像素或简单表示上学习生成分布。

摘要要点

重新审视生成模型是否必须依赖复杂压缩潜空间, 以纯图像 Transformer 在像素或简单表示上学习生成分布。本说明按“研究问题—核心机制—基础公式—实验阅读—局限与优化”的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层, 而是识别现有范式中最影响**质量、效率、可靠性或可部署性**的瓶颈。结合论文所讨论的问题, 可以将研究动机概括为以下几点:

- 对比 $\nabla_{\mathbf{v}} \text{pred } \epsilon$ 揭传统痛点, 让读者能迅速 get 到核心 idea
- JiT 确立 “Diffusion + Transformer” 范式
- 可推广至蛋白质、分子等难设计 Tokenizer 领域
- JiT 无额外依赖, 原生数据高效生成
- “少即是多” 思路具 CV 领域价值
- 凸显 “直接预测干净数据” 的价值

理解重点

阅读这类论文时, 应把“问题是否真实存在”“方法是否直接解决该问题”“实验是否排除了其他解释”分开判断。仅凭更大的模型、更多数据或更长训练得到的提升, 不能自动视为结构创新带来的收益。

3 核心思想与整体流程

重新审视生成模型是否必须依赖复杂压缩潜空间, 以纯图像 Transformer 在像素或简单表示上学习生成分布。从信息流角度看, 其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- JiT - 极简架构设计 (大 patch Transformer)

- 大 patch 保留局部语义完整性, 减计算量, 分辨率不影响长度
- 无 Tokenizer、预训练等, 像素端到端训
- 图像划非重叠大 patch, 降序列长度
- 核心组件仅线性嵌入等, 无额外模块
- 对比 /v-pred ε 揭传统痛点, 让读者能迅速 get 到核心 idea
- JiT 确立 “Diffusion + Transformer” 范式

结构解析

- 极简架构设计 (大 patch Transformer); 图像划非重叠大 patch, 降序列长度; 256×256 用 16×16 patch (长 256); 512×512 用 32×32 patch (长 256); 核心组件仅线性嵌入等,

上述内容以文字方式保留方法结构, 避免把整张幻灯片作为独立页面嵌入正文。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式, 并不替代原论文中的完整推导。

$$x_t = \alpha_t x_0 + \sigma_t \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I) \quad (1)$$

扩散类方法把真实样本与噪声按时间混合, 模型再学习逆向去噪、速度场或条件流。不同论文的主要差异通常落在表示空间、网络骨干和训练目标上。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分: 是输入表示、连接矩阵、条件变量、参数化方式、训练目标, 还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- 多场景验证: 单分辨率生成、跨分辨率生成、高维大 patch 测试
- FID-50K (生成质量)、计算量 (Gflops)
- 训练数据与设置: ImageNet 数据集
- JiT-B/L/H/G 四种模型尺寸
- 参数规模 (M)、跨分辨率表现
- 对比 /v-pred ε 揭传统痛点, 让读者能迅速 get 到核心 idea
- JiT 确立 “Diffusion + Transformer” 范式

结果解读

- 实验验证; 训练数据与设置: ImageNet 数据集; (256×256/512×512/1024×1024); JiT-B/L/H/G 四种模型尺寸; 核心性能指标:; FID-50K (生成质量)、计算量 (Gflops); 参数规模 (M)、跨……

该部分以文字概括实验结论与比较条件，避免用整页截图代替分析。实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时，结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**：论文围绕一个可识别的核心瓶颈展开，方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**：即使不完整复现模型，其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**：实验通常同时展示主结果、效率比较、案例或消融，使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益，并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析；在一个数据集上的最优配置不一定能直接迁移。
- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性，而不仅是离线平均指标。
- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合，验证不同优化是否互补。

7 结论

总体而言，重新审视生成模型是否必须依赖复杂压缩潜空间，以纯图像 Transformer 在像素或简单表示上学习生成分布。。进一步需要注意：对比 $\nabla_v \text{-pred } \epsilon$ 揭传统痛点, 让读者能迅速 get 到核心 idea;JiT 确立 “Diffusion + Transformer” 范式。