

1 论文基本信息

题目	Anthropic 大模型机制可解释性研究
课件日期	2026-03-26
研究方向	机制可解释性 / 特征字典 / 回路
一句话概括	从神经元混叠出发, 用稀疏特征和跨层回路追踪模型内部概念, 进一步研究人格、推理和行为倾向的内部机制。

摘要要点

从神经元混叠出发, 用稀疏特征和跨层回路追踪模型内部概念, 进一步研究人格、推理和行为倾向的内部机制。本说明按“研究问题—核心机制—基础公式—实验阅读—局限与优化”的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层, 而是识别现有范式中最影响**质量、效率、可靠性或可部署性**的瓶颈。结合论文所讨论的问题, 可以将研究动机概括为以下几点:

- “” 在模型的中间层接特征分解器
- 拆分在神经元上叠在一起的特征
- 人类首次对 LLM 内部精准定位与干预
- LLM 可被别有用心的人利用
- Templeton, A., Conerly, T., Marcus, J., et al. (2024). *Scaling monosemanticity: Extracting interpretable features from Claude Sonnet*. Transformer Circuits Thread.
- Lu, C., Gallagher, J., Michala, J., Fish, K., & Lindsey, J. (2026). *The assistant axis: Situating and stabilizing the character of large language models* [ArXiv Preprint]. arXiv:2601.10387v1 [cs.CL].

理解重点

阅读这类论文时, 应把“问题是否真实存在”“方法是否直接解决该问题”“实验是否排除了其他解释”分开判断。仅凭更大的模型、更多数据或更长训练得到的提升, 不能自动视为结构创新带来的收益。

3 核心思想与整体流程

从神经元混叠出发, 用稀疏特征和跨层回路追踪模型内部概念, 进一步研究人格、推理和行为倾向的内部机制。从信息流角度看, 其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- “” 在模型的中间层接特征分解器
- 拆分在神经元上叠在一起的特征
- 人类首次对 LLM 内部精准定位与干预
- LLM 可被别有用心的人利用
- Templeton, A., Conerly, T., Marcus, J., et al. (2024). *Scaling monosemanticity: Extracting interpretable features from Claude Sonnet*. Transformer Circuits Thread.
- Lu, C., Gallagher, J., Michala, J., Fish, K., & Lindsey, J. (2026). *The assistant axis: Situating and stabilizing the character of large language models* [ArXiv Preprint]. arXiv:2601.10387v1 [cs.CL].
- Ronge, R., Maier, M., & Eberhardt, F. (2026). *When the coffee feature activates on coffins: An analysis of feature extraction and steering for mechanistic interpretability* [ArXiv Preprint]. arXiv:2601.03047v1 [cs.LG].

结构解析

- 参考文献 1. Elhage, N., Hume, T., Olsson, C., Schiefer, N., Henighan, T., Kravec,

下图补充展示模块连接、数据流或训练阶段之间的关系。

CV&NLP
RESEARCHER

1. Elhage, N., Hume, T., Olsson, C., Schiefer, N., Henighan, T., Kravec, S., Hatfield-Dodds, Z., Lasenby, R., Drain, D., Chen, C., Grosse, R., McCandlish, S., Kaplan, J., Amodei, D., Wattenberg, M., & Olah, C. (2022). *Toy models of superposition*. Transformer Circuits Thread. https://transformer-circuits.pub/2022/toy_model/index.html
2. Templeton, A., Conerly, T., Marcus, J., et al. (2024). *Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet*. Transformer Circuits Thread. <https://transformer-circuits.pub/2024/scaling-monosemanticity/index.html>
3. Ameisen, E., Lindsey, J., Pearce, A., Gurnee, W., Turner, N. L., Chen, B., Citro, C., Abrahams, D., Carter, S., Hosmer, B., Marcus, J., Sklar, I., Templeton, A., Bricken, T., McDougall, C., Cunningham, H., Henighan, T., Jermyn, A., Jones, A., Persic, A., Qi, Z., Thompson, T. B., Zimmerma S., Rivoire, K., Conerly, T., Olah, C., & Batson, J. (2025). *Circuit tracing: Revealing computational graphs in language models*. Transformer Circuits Publication. <https://transformer-circuits.pub/2025/attribution-graphs/methods.html>
4. Lindsey, J., Gurnee, W., Ameisen, E., Chen, B., Pearce, A., Turner, N. L., Citro, C., Abrahams, D., Carter, S., Hosmer, B., Marcus, J., Sklar, I., Templeton, A., Bricken, T., McDougall, C., Cunningham, H., Henighan, T., Jermyn, A., Jones, A., Persic, A., Qi, Z., Thompson, T. B., Zimmerma S., Rivoire, K., Conerly, T., Olah, C., & Batson, J. (2025). *On the biology of a large language model*. Anthropic. <https://transformer-circuits.pub/2025/attribution-graphs/biology.html>
5. Karvonen, A., Chua, J., Dumas, C., Fraser-Taliente, K., Kantamneni, S., Minder, J., Ong, E., Sen Sharma, A., Wen, D., Evans, O., & Marks, (2025). *Activation oracles: Training and evaluating LLMs as general-purpose activation explainers* [ArXiv Preprint]. arXiv:2512.15674. <https://arxiv.org/pdf/2512.15674>
6. Lu, C., Gallagher, J., Michala, J., Fish, K., & Lindsey, J. (2026). *The assistant axis: Situating and stabilizing the character of large language models* [ArXiv Preprint]. arXiv:2601.10387v1 [cs.CL]. <https://www.anthropic.com/research/assistant-axis>
7. Ronge, R., Maier, M., & Eberhardt, F. (2026). *When the coffee feature activates on coffins: An analysis of feature extraction and steering for mechanistic interpretability* [ArXiv Preprint]. arXiv:2601.03047v1 [cs.LG]. <https://arxiv.org/pdf/2601.03047v1>

图 2: 模型结构、数据流或主要训练阶段。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式，并不替代原论文中的完整推导。

$$\Delta y = F(h + \delta) - F(h) \quad (1)$$

机制可解释性强调因果验证：先定位内部表示 h ，再施加可控干预 δ ，观察输出变化 Δy 。仅有相关性可视化不足以证明某个特征真正参与计算。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分：是输入表示、连接矩阵、条件变量、参数化方式、训练目标，还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- “” 在模型的中间层接特征分解器
- 拆分在神经元上叠在一起的特征
- 人类首次对 LLM 内部精准定位与干预
- LLM 可被别有用心的人利用
- Templeton, A., Conerly, T., Marcus, J., et al. (2024). *Scaling monosemanticity: Extracting interpretable features from Claude Sonnet*. Transformer Circuits Thread.
- Lu, C., Gallagher, J., Michala, J., Fish, K., & Lindsey, J. (2026). *The assistant axis: Situating and stabilizing the character of large language models* [ArXiv Preprint]. arXiv:2601.10387v1 [cs.CL].
- Ronge, R., Maier, M., & Eberhardt, F. (2026). *When the coffee feature activates on coffins: An analysis of feature extraction and steering for mechanistic interpretability* [ArXiv Preprint]. arXiv:2601.03047v1 [cs.LG].

结果解读

- 预测北京房价；房间数量、犯罪率、学区质量； $\text{房价} = 0.5 \times \text{房间数} - 0.3 \times \text{犯罪率}$ ；房间 $\uparrow$ 则房价 $\uparrow$ ；犯罪率 $\uparrow$ 则房价 $\downarrow$

该部分以文字概括实验结论与比较条件，避免用整页截图代替分析。实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时，结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**：论文围绕一个可识别的核心瓶颈展开，方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**：即使不完整复现模型，其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**：实验通常同时展示主结果、效率比较、案例或消融，使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益，并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析；在一个数据集上的最优配置不一定能直接迁移。

- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性，而不仅是离线平均指标。
- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合，验证不同优化是否互补。

7 结论

总体而言，从神经元混叠出发，用稀疏特征和跨层回路追踪模型内部概念，进一步研究人格、推理和行为倾向的内部机制。。进一步需要注意：“” 在模型的中间层接特征分解器; 拆分在神经元上叠在一起的特征。