

1 论文基本信息

题目	Classical Chinese Jailbreaks(文言文越狱)
课件日期	2026-04-01
研究方向	大模型安全 / 越狱攻击
一句话概括	研究古典中文的高压缩、隐喻和低资源特性如何绕过安全检测, 并讨论跨语言安全评测与反越狱策略。

摘要要点

研究古典中文的高压缩、隐喻和低资源特性如何绕过安全检测, 并讨论跨语言安全评测与反越狱策略。本说明按“研究问题—核心机制—基础公式—实验阅读—局限与优化”的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层, 而是识别现有范式中最影响**质量、效率、可靠性或部署性**的瓶颈。结合论文所讨论的问题, 可以将研究动机概括为以下几点:

- 发现盲区: 古典中文语义压缩 + 修辞丰富 + 检测难
- 研究动机: 发现漏洞并加固防御

理解重点

阅读这类论文时, 应把“问题是否真实存在”“方法是否直接解决该问题”“实验是否排除了其他解释”分开判断。仅凭更大的模型、更多数据或更长训练得到的提升, 不能自动视为结构创新带来的收益。

3 核心思想与整体流程

研究古典中文的高压缩、隐喻和低资源特性如何绕过安全检测, 并讨论跨语言安全评测与反越狱策略。从信息流角度看, 其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- 角色设定、行为引导、实现机制、语义映射
- 表达形式、知识关联、场景构建、触发条件
- Andriushchenko et al. (2024). Jailbreaking leading safety-aligned LLMs with simple adaptive attacks. arXiv:2404.02151. (DAN 方法)
- Li et al. (2023). DeepInception: Hypnotize large language model to be jailbreaker. arXiv:2311.03191. (“写小说”流派越狱)

- Mehrotra et al. (2024). Tree of attacks: Jailbreaking black-box LLMs automatically. NeurIPS. (PAIR 方法)
- Chao et al. (2025). Jailbreaking black box large language models in twenty queries. IEEE SaTML. (TAP 方法)
- Zou et al. (2023). Universal and transferable adversarial attacks on aligned language models. arXiv:2307.15043. (AdvBench 基准/GCG 方法)

结构解析

- 参考文献；1. Andriushchenko et al. (2024). Jailbreaking leading safety-aligned LLMs with simple adaptive attacks. arXiv:2404.02151. (DA……

上述内容以文字方式保留方法结构，避免把整张幻灯片作为独立页面嵌入正文。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式，并不替代原论文中的完整推导。

$$R = \Pr(\text{unsafe or private output} \mid x, a) \quad (1)$$

安全研究需要把风险定义为可测量事件：给定输入 x 和攻击/推理策略 a ，模型产生有害、隐私或虚假输出的概率。实验设计必须同时报告攻击成功与正常能力保留。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分：是输入表示、连接矩阵、条件变量、参数化方式、训练目标，还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- LLM 的古典语言方面防护并没有那么强
- Andriushchenko et al. (2024). Jailbreaking leading safety-aligned LLMs with simple adaptive attacks. arXiv:2404.02151. (DAN 方法)
- Li et al. (2023). DeepInception: Hypnotize large language model to be jailbreaker. arXiv:2311.03191. (“写小说”流派越狱)
- Mehrotra et al. (2024). Tree of attacks: Jailbreaking black-box LLMs automatically. NeurIPS. (PAIR 方法)
- Chao et al. (2025). Jailbreaking black box large language models in twenty queries. IEEE SaTML. (TAP 方法)
- Zou et al. (2023). Universal and transferable adversarial attacks on aligned language models. arXiv:2307.15043. (AdvBench 基准/GCG 方法)
- Yu et al. (2023). GPTFuzzer: Red teaming large language models with auto-generated jailbreak prompts. arXiv:2309.10253

结果解读

- “” 大模型越狱的启示；LLM 的古典语言方面防护并没有那么强；不只是关注算法性能上提升；要多关注跨领域研究

该部分以文字概括实验结论与比较条件，避免用整页截图代替分析。实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时，结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**：论文围绕一个可识别的核心瓶颈展开，方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**：即使不完整复现模型，其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**：实验通常同时展示主结果、效率比较、案例或消融，使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益，并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析；在一个数据集上的最优配置不一定能直接迁移。
- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性，而不仅是离线平均指标。
- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合，验证不同优化是否互补。

7 结论

总体而言，研究古典中文的高压缩、隐喻和低资源特性如何绕过安全检测，并讨论跨语言安全评测与反越狱策略。。进一步需要注意：LLM 的古典语言方面防护并没有那么强；“” 六大模型防护机制集体破防。