

1 论文基本信息

题目	DSpark
课件日期	2026-06-29
研究方向	大模型推理系统 / 并行调度
一句话概括	从系统层面对训练和推理链路进行并行化、调度与内存优化, 以提高单用户生成速度和高并发有效吞吐。

摘要要点

从系统层面对训练和推理链路进行并行化、调度与内存优化, 以提高单用户生成速度和高并发有效吞吐。本说明按“研究问题—核心机制—基础公式—实验阅读—局限与优化”的顺序重新组织, 不保留原始材料的封面、目录和页码对应。

2 研究问题与动机

这项工作的出发点不是简单地替换某个网络层, 而是识别现有范式中最影响**质量、效率、可靠性或可部署性**的瓶颈。结合论文所讨论的问题, 可以将研究动机概括为以下几点:

- 精度高但速度慢, 抑或速度快但精度不足这一矛盾构成投机解码的经典困境 Lau 博士云组会
- 频繁出现搭配不当如「of problem」等不合理组合
- 各位置 token 独立预测位置间缺乏依赖关系
- 接受率呈断崖式下降即所谓的「后缀衰减」现象
- 并行草稿的关键问题: 后缀衰减
- 然而实际生产环境差异显著不同任务特征各异代码生成任务语法固定,8 个候选可全部接受开放对话任务不确定性高,4 个候选可能全部失败

理解重点

阅读这类论文时, 应把“问题是否真实存在”“方法是否直接解决该问题”“实验是否排除了其他解释”分开判断。仅凭更大的模型、更多数据或更长训练得到的提升, 不能自动视为结构创新带来的收益。

3 核心思想与整体流程

从系统层面对训练和推理链路进行并行化、调度与内存优化, 以提高单用户生成速度和高并发有效吞吐。从信息流角度看, 其基本流程可以整理为下图。




图 1: 核心信息流与处理阶段。

3.1 方法组成与信息流

- 公式 4 : 各位置最终概率分布 = 并行骨干基础输出 + 串行头偏移量经归一化处理后获得 Lau 博士云组会
- 设计思路: 取长补短 1 采用并行骨干确保生成速度 2 叠加轻量串行头补偿预测精度
- DSpark 的首要核心创新: 半自回归生成架构
- DSpark 采用全链路优化策略, 同时提升三个关键维度在速度、精度、调度三方面实现协同优化 Lau 博士云组会
- DSpark 是一套全链路的系统级加速方案整合了半自回归架构、置信度评分、硬件感知调度、在线校准四项关键技术
- 公式 1 : 单 token 实际延迟 = (草稿生成耗时 + 验证耗时) / 接受 token 数 τ
- DSpark 为行业提供了一个值得借鉴的工程实践范式 Lau 博士云组会

结构解析

- 是一套全链路的系统级加速方案整合了半自回归架构、置信度评分、硬件感知调度、在线校准四项关键技术
- 单用户速度提升 60
- 该方案已完成从论文研究到 DeepSeek-V4 生产的完整落地
- 单点技术红利收窄, 全链路系统优化成为未来方向

下图补充展示模块连接、数据流或训练阶段之间的关系。

CV&NLP
RESEARCHER

- **DSpark 的首要核心创新：半自回归生成架构**
- **设计思路：取长补短**
 - ① 采用并行骨干确保生成速度
 - ② 叠加轻量串行头补偿预测精度
- **公式 4：各位置最终概率分布**
= 并行骨干基础输出 + 串行头偏移量
经归一化处理后获得

图 2: 模型结构、数据流或主要训练阶段。

4 数学与机制理解

本节给出理解该工作的基础数学结构。公式用于解释方法所属范式，并不替代原论文中的完整推导。

$$\text{Throughput} = \frac{\text{generated tokens}}{\text{time}}, \quad \text{latency} = t_{\text{finish}} - t_{\text{request}} \quad (1)$$

系统工作必须同时考虑吞吐量、单请求时延、显存、并发公平性和实现复杂度。单一速度数字不足以完整评价真实部署收益。

从公式回到方法

应重点观察论文究竟改变了公式中的哪一部分：是输入表示、连接矩阵、条件变量、参数化方式、训练目标，还是求解与调度过程。真正的创新通常可以在这一层被准确定位。

5 实验结果应如何阅读

- 以 Qwen3-14B 为例的关键数据宏平均接受长度较 Eagle3 提升 30.0% 较 DFlash 提升 18.3%
- 在 Qwen3 (4B/8B/14B) 与 Gemma4-12B 上全面超越 Eagle3 与 DFlash 基线
- 覆盖 3 大领域、9 个标准数据集数学推理、代码生成、日常对话
- 在所有测试场景中均表现稳定 Lau 博士云组会
- 离线基准测试 · 多模型全面验证
- DeepSeek 将 DSpark 部署于 DeepSeek-V4 与现役 MTP-1 基线进行真实流量对比
- DSpark 平均接受长度较 Eagle3 提升 26%-31% 较 DFlash 提升 16%-18%

结果解读

- Figure 7 帕累托前沿结果
- DeepSeek 将部署于 DeepSeek-V4 与现役 MTP-1 基线进行真实流量对比
- 整条性能曲线位于基线外侧
- 实际意义在相同生成速度下，可承载更高总吞吐量在相同并发量下，用户获得更快响应

下图用于直观呈现主要对比、消融、定性样例或效率结果。

CV&NLP
RESEARCHER

Target	Drafter	Math			Code			Chat		
		GSM8K	MATH	AIME25	MBPP	HumanEval	LCB	MT-Bench	Alpaca	Arena-Hard
Qwen3-4B	Eagle3	5.14	4.62	3.92	3.69	4.16	3.77	2.39	2.26	2.55
	DFlash	5.40	4.85	4.15	4.40	4.74	4.18	3.07	2.96	2.83
	DSpark	6.11	5.70	4.89	5.13	5.38	4.86	3.64	3.54	3.29
Qwen3-8B	Eagle3	5.30	4.77	3.91	3.96	4.33	4.17	2.66	2.54	2.54
	DFlash	5.33	4.91	4.07	4.36	4.64	4.39	3.11	2.98	2.81
	DSpark	6.17	5.78	5.01	5.16	5.52	5.17	3.72	3.58	3.21
Qwen3-14B	Eagle3	5.24	4.60	3.71	3.81	4.14	4.01	2.62	2.47	2.48
	DFlash	5.41	4.84	3.98	4.44	4.59	4.33	3.10	2.94	2.72
	DSpark	6.21	5.74	4.94	5.26	5.43	5.02	3.70	3.58	3.13
Gemma4-12B	Eagle3	5.87	5.46	4.83	4.72	5.37	4.16	3.19	3.06	2.72
	DFlash	5.45	5.04	4.22	4.39	4.95	3.70	2.98	2.84	2.59
	DSpark	6.05	5.78	5.12	5.11	5.64	4.51	3.49	3.35	2.92

- Table 1 离线基准结果
- 覆盖 3 大领域、9 个标准数据集
数学推理、代码生成、日常对话
- 在 Qwen3 (4B/8B/14B) 与 Gemma4-12B 上
全面超越 Eagle3 与 DFlash 基线
- 以 Qwen3-14B 为例的关键数据
宏平均接受长度
较 Eagle3 提升 30.0%
较 DFlash 提升 18.3%
- 在所有测试场景中均表现稳定

图 3: 代表性实验对比、消融结果或定性样例。

实验部分不应只看单一最好数字。还需要核对模型规模、训练数据、训练步数、采样或解码预算、硬件条件以及是否使用额外蒸馏、检索或后处理。只有比较条件接近时，结果才能真正说明方法本身的优势。

6 优点、局限与可优化空间

6.1 主要优点

- **问题与方法对应明确**：论文围绕一个可识别的核心瓶颈展开，方法结构能够直接映射到该瓶颈。
- **可复用的设计思想**：即使不完整复现模型，其中的分解、稀疏化、递归、条件控制或系统优化思想也可迁移到相邻任务。
- **实验提供了多角度证据**：实验通常同时展示主结果、效率比较、案例或消融，使结论不完全依赖单一指标。

6.2 局限与进一步优化

- 需要进一步区分**结构收益**与更大算力、更多数据、不同训练技巧带来的收益，并在等参数、等计算预算下进行严格比较。
- 对超参数、输入分布和模型规模的敏感性仍应系统分析；在一个数据集上的最优配置不一定能直接迁移。
- 实际部署还要考虑显存峰值、并发、延迟抖动、失败案例和鲁棒性，而不仅是离线平均指标。
- 可尝试将该方法与蒸馏、量化、缓存复用、动态路由或更强的表示学习结合，验证不同优化是否互补。

7 结论

总体而言，从系统层面对训练和推理链路进行并行化、调度与内存优化，以提高单用户生成速度和高并发有效吞吐。。进一步需要注意：对大模型发展的启示单点技术红利正在逐步收窄真正的体验提升源于全链路的系统优化每个环节的精细打磨将累积为显著的体验差异 Lau 博士云组会;DSpark 是一套全链路的系统级加速方案整合了半自回归架构、置信度评分、硬件感知调度、在线校准四项关键技术。