

01_Fractal Generative Models

1 符号与维度

符号	维度	含义
$x_{1:N}$	$\{1, \dots, K\}^N$	展平后的离散图像序列。
$X^{(j)}$	--	递归层中的第 j 个块。
b, L	$\mathbb{N}$	分支数与递归深度。
p_θ	--	自回归条件分布。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 递归生成树的概率归一化

设根表示完整对象，深度 d 的每个节点 v 产生 b 个子节点 $c_1(v), \dots, c_b(v)$ 。条件生成分布

$$p_\theta(x_{c_1}, \dots, x_{c_b} \mid x_v) \quad (2.1)$$

对每个父状态都归一化。整棵有限树的联合分布

$$p_\theta(x_{\mathcal{T}}) = p(x_{\text{root}}) \prod_{v \in \mathcal{I}} p_\theta(x_{\text{ch}(v)} \mid x_v), \quad (2.2)$$

其中 $\mathcal{I}$ 是内部节点集合。

归一化可从叶到根证明。固定一个最深内部节点 v ，对其全部孩子求和/积分：

$$\int p_\theta(x_{\text{ch}(v)} \mid x_v) dx_{\text{ch}(v)} = 1. \quad (2.3)$$

逐个消去所有最深层条件因子，再向上重复，最终只剩 $\int p(x_{\text{root}}) dx_{\text{root}} = 1$ 。因此局部条件归一化保证全局联合归一化，不要求不同分支边缘独立；它们通过共同祖先相关。

3 叶子数、节点数与递归深度

满 b 叉树深度 D （根为深度 0）的叶子数

$$N_{\text{leaf}} = b^D. \quad (3.1)$$

总节点数是几何级数

$$N_{\text{total}} = \sum_{d=0}^D b^d = \frac{b^{D+1} - 1}{b - 1}. \quad (3.2)$$

内部节点数

$$N_{\text{int}} = \frac{b^D - 1}{b - 1}. \quad (3.3)$$

若每个内部节点调用同一生成模块一次，串行总调用量为 N_{int} ；同一深度的节点可并行，理想关键路径只有 D 次模块调用，但显存随并行宽度 b^d 增长。

若目标叶子数为 N ，所需深度

$$D = \lceil \log_b N \rceil. \quad (3.4)$$

增大分支因子降低关键路径，却增加单次父节点输出维度和同层并行宽度。

4 分层负对数似然的分解

由联合分解，单棵树负对数似然

$$-\log p_\theta(x_{\mathcal{T}}) = -\log p(x_{\text{root}}) - \sum_{v \in \mathcal{I}} \log p_\theta(x_{\text{ch}(v)} \mid x_v). \quad (4.1)$$

若根分布固定，训练只需最小化所有内部节点局部 NLL 之和。参数共享意味着总梯度累加：

$$\nabla_\theta \mathcal{L} = - \sum_{v \in \mathcal{I}} \nabla_\theta \log p_\theta(x_{\text{ch}(v)} \mid x_v). \quad (4.2)$$

深层节点数量指数增多，所以不加权时深层对梯度总量占主导。

若每层先平均再加权，

$$\mathcal{L} = \sum_{d=0}^{D-1} \lambda_d \frac{1}{b^d} \sum_{v: \text{depth}(v)=d} \ell_v, \quad (4.3)$$

则每层总权重为 λ_d ，不随节点数增长。若直接对所有节点平均，深度 d 的总权重比例为

$$\frac{b^d}{\sum_{j=0}^{D-1} b^j}. \quad (4.4)$$

两种归一化对应不同的统计目标。

5 随机抽取节点的无偏梯度

完整损失是

$$L = \sum_{v \in \mathcal{I}} w_v \ell_v. \quad (5.1)$$

若按概率 $q_v > 0$ 抽一个节点，估计

$$\hat{L} = \frac{w_v}{q_v} \ell_v \quad (5.2)$$

满足

$$\mathbb{E}_q \hat{L} = \sum_v q_v \frac{w_v}{q_v} \ell_v = L. \quad (5.3)$$

同理梯度无偏。其二阶矩

$$\mathbb{E} \|\hat{g}\|^2 = \sum_v \frac{w_v^2}{q_v} \|g_v\|^2. \quad (5.4)$$

在 $\sum_v q_v = 1$ 下用拉格朗日乘子最小化，得到理论最优

$$q_v^* \propto w_v \|g_v\|. \quad (5.5)$$

实际未知梯度范数，可用损失、深度或历史梯度作代理。

6 误差沿树传播

设父到子映射 $x_c = F_\theta(x_v, \epsilon_c)$ ，对父状态 Lipschitz：

$$\|F(x, \epsilon) - F(y, \epsilon)\| \leq L \|x - y\|. \quad (6.1)$$

若每一层还有局部模型误差 δ_d ，某条深度 D 路径的误差递推

$$e_{d+1} \leq L e_d + \delta_d. \quad (6.2)$$

展开得

$$e_D \leq L^D e_0 + \sum_{d=0}^{D-1} L^{D-1-d} \delta_d. \quad (6.3)$$

$L < 1$ 时早期误差衰减, $L > 1$ 时根部误差会影响大量后代并被放大。这说明分层监督不仅提供多尺度损失, 也可直接约束早期递归误差。

7 分支相关性

考虑两个叶子 a, b 的最近公共祖先位于深度 k 。若线性化递归

$$x_{d+1} = Ax_d + \epsilon_{d+1}, \quad \text{Cov}(\epsilon) = \Sigma, \quad (7.1)$$

且分叉后的噪声独立, 则共同祖先状态 x_k 传播到叶子的协方差为

$$\text{Cov}(x_a, x_b) = A^{D-k} \text{Cov}(x_k) (A^{D-k})^T. \quad (7.2)$$

分叉越晚, 共享随机历史越长, 叶子通常相关越强。树分解提供条件独立

$$x_a \perp x_b \mid x_{\text{LCA}}, \quad (7.3)$$

却不意味着边缘独立。

8 自回归因子化与块内因子化

一个父节点生成 b 个孩子, 可联合建模

$$p(x_{1:b} \mid x_v), \quad (8.1)$$

也可块内自回归

$$p(x_{1:b} \mid x_v) = \prod_{j=1}^b p(x_j \mid x_v, x_{<j}). \quad (8.2)$$

后者由概率链式法则不损失表达能力, 但块内关键路径增加到 b ; 若条件独立近似

$$p(x_{1:b} \mid x_v) \approx \prod_j p(x_j \mid x_v), \quad (8.3)$$

可完全并行, 却舍弃给定父表示后仍存在的兄弟相关性。

9 条件期望作为 L^2 正交投影

令随机向量 $Y \in L^2$, 观测 Z 生成子空间

$$\mathcal{H}_Z = \{f(Z) : \mathbb{E}\|f(Z)\|^2 < \infty\}. \quad (9.1)$$

条件期望 $m(Z) = \mathbb{E}[Y \mid Z]$ 满足任意 $h(Z) \in \mathcal{H}_Z$:

$$\mathbb{E}[(Y - m(Z))^T h(Z)] = 0. \quad (9.2)$$

因为

$$\mathbb{E}[(Y - m)^T h] = \mathbb{E}\{\mathbb{E}[(Y - m)^T h \mid Z]\} \quad (9.3)$$

$$= \mathbb{E}\{h^T \mathbb{E}[Y - m \mid Z]\} = 0. \quad (9.4)$$

于是 Pythagoras 恒等式

$$\mathbb{E}\|Y - f(Z)\|^2 = \mathbb{E}\|Y - m(Z)\|^2 + \mathbb{E}\|m(Z) - f(Z)\|^2. \quad (9.5)$$

多数回归、去噪、流匹配和局部目标的“最优预测器”都由这一投影结论得到。

全方差公式也是同一正交分解：

$$\text{Var}(Y) = \mathbb{E} \text{Var}(Y | Z) + \text{Var}(\mathbb{E}[Y | Z]). \quad (9.6)$$

第一项是观测 Z 后仍不可约的不确定性，第二项是不同 Z 条件均值的变化。

10 Jensen、对数和与变分界

对凹函数 $\log$,

$$\log \mathbb{E}X \geq \mathbb{E} \log X, \quad X > 0. \quad (10.1)$$

差距可以写成 KL。令未归一权重 $w(z) > 0$ 、提议分布 $q(z)$ ，配分函数 $Z = \mathbb{E}_q w(z)$ ，定义

$$p^*(z) = \frac{q(z)w(z)}{Z}. \quad (10.2)$$

则

$$\log Z - \mathbb{E}_q \log w = \mathbb{E}_q \log \frac{Z}{w(z)} \quad (10.3)$$

$$= \mathbb{E}_q \log \frac{q(z)}{p^*(z)} \quad (10.4)$$

$$= D_{\text{KL}}(q \| p^*) \geq 0. \quad (10.5)$$

因此 Jensen 下界何时紧不只取决于“方差小”，而是提议分布是否等于归一化后的目标分布。

log-sum-exp

$$\text{LSE}(x) = \log \sum_{i=1}^n e^{x_i} \quad (10.6)$$

满足

$$\max_i x_i \leq \text{LSE}(x) \leq \max_i x_i + \log n. \quad (10.7)$$

减去最大值 $m = \max_i x_i$ 后计算

$$\text{LSE}(x) = m + \log \sum_i e^{x_i - m} \quad (10.8)$$

可避免指数上溢且数学等价。

11 Hoeffding 不等式的矩母函数推导

设独立 $X_i \in [a_i, b_i]$ ， $S = \sum_i (X_i - \mathbb{E}X_i)$ 。对任意 $\lambda > 0$ ，Markov 不等式

$$\mathbb{P}(S \geq t) = \mathbb{P}(e^{\lambda S} \geq e^{\lambda t}) \leq e^{-\lambda t} \mathbb{E} e^{\lambda S}. \quad (11.1)$$

独立性给出矩母函数乘积。Hoeffding 引理

$$\mathbb{E} e^{\lambda(X_i - \mathbb{E}X_i)} \leq \exp\left(\frac{\lambda^2(b_i - a_i)^2}{8}\right). \quad (11.2)$$

故

$$\mathbb{P}(S \geq t) \leq \exp\left(-\lambda t + \frac{\lambda^2}{8} \sum_i (b_i - a_i)^2\right). \quad (11.3)$$

对 λ 最小化,

$$\lambda^* = \frac{4t}{\sum_i (b_i - a_i)^2}, \quad (11.4)$$

得到

$$\mathbb{P}(S \geq t) \leq \exp\left(-\frac{2t^2}{\sum_i (b_i - a_i)^2}\right). \quad (11.5)$$

对下尾应用于 $-S$, 再 union bound 得双侧界。

12 Bernstein 界利用方差信息

若独立零均值 X_i 满足 $|X_i| \leq M$, 总方差 $v = \sum_i \mathbb{E}X_i^2$, Bernstein 界

$$\mathbb{P}\left(\sum_i X_i \geq t\right) \leq \exp\left(-\frac{t^2}{2(v + Mt/3)}\right). \quad (12.1)$$

当 $t \ll v/M$ 时近似高斯尾 $e^{-t^2/(2v)}$; 当 t 很大时转为 $e^{-3t/(2M)}$ 。相比只使用取值区间的 Hoeffding, 方差远小于最坏范围时 Bernstein 更紧。

对 Bernoulli 均值 $\hat{p} = N^{-1} \sum_i X_i$, $v = Np(1-p)$,

$$\mathbb{P}(|\hat{p} - p| \geq \epsilon) \leq 2 \exp\left(-\frac{N\epsilon^2}{2[p(1-p) + \epsilon/3]}\right). \quad (12.2)$$

13 并合界与同时保证

事件 $E_1, \dots, E_M$ 不要求独立也有

$$\mathbb{P}\left(\bigcup_{j=1}^M E_j\right) \leq \sum_{j=1}^M \mathbb{P}(E_j). \quad (13.1)$$

若每个失败概率至多 δ/M , 则全部结论同时成立的概率至少 $1 - \delta$ 。将单点集中界扩展到有限候选集合通常产生 $\log M$ 项。例如

$$2Me^{-2N\epsilon^2} \leq \delta \quad (13.2)$$

等价于

$$\epsilon \geq \sqrt{\frac{\log(2M/\delta)}{2N}}. \quad (13.3)$$

若候选集合无限, 需要覆盖数、VC 维或 Rademacher 复杂度, 而不能直接把 $M = \infty$ 代入。

14 Delta 方法与非线性估计误差

设 $\sqrt{N}(\hat{\theta} - \theta) \Rightarrow \mathcal{N}(0, \Sigma)$, 光滑函数 g 的一阶展开

$$g(\hat{\theta}) = g(\theta) + \nabla g(\theta)^T (\hat{\theta} - \theta) + o_p(N^{-1/2}). \quad (14.1)$$

于是

$$\sqrt{N}[g(\hat{\theta}) - g(\theta)] \Rightarrow \mathcal{N}(0, \nabla g^T \Sigma \nabla g). \quad (14.2)$$

例如 $g(p) = \log p$, 方差近似

$$\text{Var}(\log \hat{p}) \approx \frac{\text{Var}(\hat{p})}{p^2}. \quad (14.3)$$

当 p 很小时误差被 $1/p^2$ 放大, 解释了稀有事件对数概率和概率比估计的不稳定。

二阶展开还给非线性偏差

$$\mathbb{E}g(\hat{\theta}) - g(\theta) \approx \frac{1}{2} \text{tr}(H_g(\theta) \text{Cov}(\hat{\theta})). \quad (14.4)$$

FID、比率、倒数和归一化优势等即使基础估计无偏, 非线性组合也可有有限样本偏差。

15 重要性采样与有效样本量

目标期望 $\mathbb{E}_p f(X)$ 用提议 q 采样, 权重 $w(x) = p(x)/q(x)$:

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N w(X_i) f(X_i), \quad X_i \sim q. \quad (15.1)$$

若 p 的归一化常数未知, 使用自归一估计

$$\tilde{\mu} = \frac{\sum_i w_i f_i}{\sum_i w_i}, \quad (15.2)$$

它一般有 $O(1/N)$ 偏差, 但常更实用。权重退化可用

$$N_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2} \quad (15.3)$$

衡量; 权重相等时为 N , 单个权重主导时接近 1。

比率裁剪 $\tilde{w} = \min(w, c)$ 降低方差, 但引入偏差

$$\mathbb{E}_q[(w - \tilde{w})f] = \mathbb{E}_q[(w - c)_+ f]. \quad (15.4)$$

若 $|f| \leq F$, 绝对偏差至多

$$F \mathbb{E}_q[(w - c)_+]. \quad (15.5)$$

16 校准与 Brier 分解

二元预测概率 $P \in [0, 1]$ 、标签 $Y \in \{0, 1\}$ 。条件真实频率 $m(P) = \mathbb{E}[Y | P]$ 。Brier 分数

$$\mathbb{E}(P - Y)^2 = \mathbb{E}(P - m(P))^2 + \mathbb{E}(m(P) - Y)^2, \quad (16.1)$$

交叉项因条件期望为零而消失。第一项是校准误差, 第二项是给定预测分组后的不可约噪声。若模型完美校准, $m(P) = P$, 第一项为零, 但单次预测仍可错误; 校准不是零错误率, 而是概率与长期频率一致。