

07_LoRI

1 符号与维度

符号	维度	含义
W_0	$\mathbb{R}^{m \times n}$	冻结预训练权重。
A, B	$\mathbb{R}^{r \times n}, \mathbb{R}^{m \times r}$	低秩下投影与上投影。
r	$\mathbb{N}$	适配器秩。
x, δ	$\mathbb{R}^n, \mathbb{R}^m$	输入和输出端反向梯度。
c	$\mathbb{R}$	低秩更新缩放系数。
M_t	$\{0, 1\}^{m \times r}$	任务 t 的稀疏掩码。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 低秩更新的完整矩阵微分

令冻结权重 $W_0 \in \mathbb{R}^{m \times n}$ ，低秩更新

$$W = W_0 + cBA, \quad B \in \mathbb{R}^{m \times r}, \quad A \in \mathbb{R}^{r \times n}, \quad c = \alpha/r. \quad (2.1)$$

对一个输入 $x \in \mathbb{R}^n$,

$$h = W_0 x + cB(Ax). \quad (2.2)$$

令 $y = Ax \in \mathbb{R}^r$ 、输出梯度 $g = \partial \mathcal{L} / \partial h \in \mathbb{R}^m$ 。微分为

$$dh = c dB y + c B dA x + c B A dx + W_0 dx. \quad (2.3)$$

由 $d\mathcal{L} = g^T dh$ 以及 $a^T dM b = \langle ab^T, dM \rangle_F$ ，逐项得到

$$\boxed{\nabla_B \mathcal{L} = c, g, y^T = c, g, x^T A^T,} \quad (2.4)$$

$$\boxed{\nabla_A \mathcal{L} = c, B^T g, x^T,} \quad (2.5)$$

$$\boxed{\nabla_x \mathcal{L} = W_0^T g + c A^T B^T g.} \quad (2.6)$$

若批输入按行堆成 $X \in \mathbb{R}^{b \times n}$ ，上游梯度为 $G \in \mathbb{R}^{b \times m}$ ，则

$$\nabla_B \mathcal{L} = c G^T X A^T, \quad (2.7)$$

$$\nabla_A \mathcal{L} = c B^T G^T X. \quad (2.8)$$

2.1 rank-1 专家分解

写 $B = [b_1, \dots, b_r]$ 、 A 的第 i 行为 a_i^T ，则

$$BA = \sum_{i=1}^r b_i a_i^T, \quad BA x = \sum_{i=1}^r b_i (a_i^T x). \quad (2.9)$$

每一项均为秩至多 1 的更新。对单样本，

$$\nabla_{b_i} \mathcal{L} = c (a_i^T x) g, \quad \nabla_{a_i} \mathcal{L} = c (b_i^T g) x. \quad (2.10)$$

于是列 b_i 的更新强度由标量路由量 $a_i^T x$ 控制；这也是把 rank 分量解释为隐式专家的数学依据。

3 初始化时两因子的非对称动力学

常见初始化为 $B_0 = 0$ 、 A_0 随机。此时

$$\Delta W_0 = cB_0A_0 = 0, \quad (3.1)$$

所以前向不改变基座。梯度却满足

$$\nabla_B \mathcal{L}|_0 = cG^T X A_0^T, \quad \nabla_A \mathcal{L}|_0 = cB_0^T G^T X = 0. \quad (3.2)$$

第一步梯度下降

$$B_1 = -\eta c G^T X A_0^T, \quad A_1 = A_0, \quad (3.3)$$

因此第二步开始 A 才获得非零梯度。若反过来令 $A_0 = 0$ 、 B_0 随机，则第一步只有 A 更新。两种初始化前向等价，但早期优化动力学不同。

还有尺度不识别性：任意 $s \neq 0$ 满足

$$BA = (sB)(s^{-1}A). \quad (3.4)$$

然而带独立权重衰减时

$$\|sB\|_F^2 + \|s^{-1}A\|_F^2 = s^2\|B\|_F^2 + s^{-2}\|A\|_F^2, \quad (3.5)$$

最优平衡尺度由求导得到

$$s^4 = \frac{\|A\|_F^2}{\|B\|_F^2}. \quad (3.6)$$

故因子正则化会隐式选择分解，即使乘积 BA 相同。

4 最佳秩约束近似

设目标全量更新的奇异值分解为

$$\Delta W^* = U \Sigma V^T = \sum_{i=1}^q \sigma_i u_i v_i^T, \quad \sigma_1 \geq \dots \geq \sigma_q \geq 0. \quad (4.1)$$

截断矩阵

$$\Delta W_r = \sum_{i=1}^r \sigma_i u_i v_i^T \quad (4.2)$$

满足 Eckart-Young-Mirsky 结论

$$\min_{\text{rank}(M) \leq r} \|\Delta W^* - M\|_F^2 = \sum_{i>r} \sigma_i^2. \quad (4.3)$$

一种直接证明如下。因 Frobenius 范数在正交变换下不变，令 $C = U^T M V$ ，则 $\text{rank}(C) \leq r$ 且

$$\|\Delta W^* - M\|_F^2 = \|\Sigma - C\|_F^2. \quad (4.4)$$

任意秩不超过 r 的 C 至多精确保留 r 个相互正交奇异方向；由奇异值的变分刻画或 Pythagoras 分解，剩余平方能量至少为 $\sum_{i>r} \sigma_i^2$ 。取 $C = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots)$ 达到该下界。

谱范数版本为

$$\min_{\text{rank}(M) \leq r} \|\Delta W^* - M\|_2 = \sigma_{r+1}. \quad (4.5)$$

这只是表达能力上界；训练能否找到截断 SVD 解还取决于非凸因子化、数据和优化器。

5 子空间限制与梯度投影

若 A 冻结, 只训练 B , 可达更新集合为

$$\mathcal{S}_A = \{BA : B \in \mathbb{R}^{m \times r}\}. \quad (5.1)$$

其中每一行都位于 A 的行空间。若 A 满行秩, 其行空间正交投影为

$$P_A = A^T(AA^T)^{-1}A. \quad (5.2)$$

给定任意目标更新 M , 最小二乘问题

$$\min_B \|M - BA\|_F^2 \quad (5.3)$$

的正规方程为

$$(BA - M)A^T = 0, \quad B^* = MA^T(AA^T)^{-1}. \quad (5.4)$$

故最佳可达更新

$$B^*A = MP_A, \quad \min_B \|M - BA\|_F^2 = \|M(I - P_A)\|_F^2. \quad (5.5)$$

这把“冻结随机下投影”的表达损失精确写成目标在随机行空间外的能量。

6 随机投影的尺度与集中

设 A_{ij} 独立、均值零、方差 $1/r$ 。对固定 $x \in \mathbb{R}^n$,

$$\mathbb{E}\|Ax\|_2^2 = \sum_{i=1}^r \mathbb{E} \left(\sum_j A_{ij} x_j \right)^2 \quad (6.1)$$

$$= \sum_i \sum_j \mathbb{E}[A_{ij}^2] x_j^2 = \|x\|_2^2. \quad (6.2)$$

若 $A_{ij} \sim \mathcal{N}(0, 1/r)$, 则

$$\frac{\|Ax\|_2^2}{\|x\|_2^2} \sim \frac{1}{r} \chi_r^2. \quad (6.3)$$

利用卡方尾界, 对 $0 < \varepsilon < 1$,

$$\mathbb{P}(|\|Ax\|_2^2 - \|x\|_2^2| \geq \varepsilon \|x\|_2^2) \leq 2 \exp\left(-\frac{r}{8} \varepsilon^2\right). \quad (6.4)$$

对有限集合 N 个向量做并合界, 若

$$r \geq \frac{8}{\varepsilon^2} \log \frac{2N}{\delta}, \quad (6.5)$$

则所有向量同时保持范数的概率至少为 $1 - \delta$ 。对点对差向量应用同一结论即得到距离保持。

稀疏随机投影若每个元素以概率 ρ 非零, 则为保持同样二阶矩, 非零幅值应按 $1/\sqrt{\rho r}$ 缩放:

$$A_{ij} = \begin{cases} +1/\sqrt{\rho r}, & \rho/2, \\ -1/\sqrt{\rho r}, & \rho/2, \\ 0, & 1 - \rho. \end{cases} \quad (6.6)$$

此时 $\mathbb{E}[A_{ij}^2] = 1/r$, 但四阶矩为 $\mathbb{E}[A_{ij}^4] = 1/(\rho r^2)$; ρ 越小, 尾部越重, 获得同样集中精度通常需要更大 r 。

7 任务更新的干扰量

两个任务的更新 $U_i = B_i A_i$ 、 $U_j = B_j A_j$ 的 Frobenius 内积为

$$\langle U_i, U_j \rangle_F = \text{tr}((B_i A_i)^T B_j A_j) \quad (7.1)$$

$$= \text{tr}(B_i^T B_j A_j A_i^T). \quad (7.2)$$

因此

$$|\langle U_i, U_j \rangle_F| \leq \|B_i^T B_j\|_F \|A_j A_i^T\|_F. \quad (7.3)$$

随机下投影近似正交只控制第二个因子；若 B_i, B_j 范数无界，绝对干扰仍可任意大。对加权合并 $U = \sum_i w_i U_i$,

$$\|U\|_F^2 = \sum_i w_i^2 \|U_i\|_F^2 + 2 \sum_{i < j} w_i w_j \langle U_i, U_j \rangle_F. \quad (7.4)$$

交叉项就是任务干扰对合并范数的精确贡献，而不是抽象的“方向冲突”。

8 参数量、训练内存与合并

全量矩阵参数量为 mn ，低秩因子参数量为

$$r(m+n), \quad (8.1)$$

压缩要求 $r < mn/(m+n)$ 。训练时只有可训练因子需要梯度和优化器状态；冻结基座仍需存储权重并参与前向、反向的输入梯度计算。

推理前可合并

$$W_{\text{merged}} = W_0 + cBA. \quad (8.2)$$

合并后对单个适配器不增加矩阵乘次数，但丢失了动态切换不同适配器的便利。若基座以低比特存储，通常必须先在计算精度中反量化再加 BA ；直接在整数码空间相加并不等价。

9 光滑损失的下降引理

若 L 的梯度是 β -Lipschitz:

$$\|\nabla L(x) - \nabla L(y)\| \leq \beta \|x - y\|, \quad (9.1)$$

则沿线段积分

$$L(y) - L(x) = \int_0^1 \nabla L(x + t(y-x))^T (y-x) dt \quad (9.2)$$

$$= \nabla L(x)^T (y-x) + R, \quad (9.3)$$

余项满足

$$|R| \leq \int_0^1 \beta t \|y-x\|^2 dt = \frac{\beta}{2} \|y-x\|^2. \quad (9.4)$$

故下降引理

$$L(y) \leq L(x) + \nabla L(x)^T (y-x) + \frac{\beta}{2} \|y-x\|^2. \quad (9.5)$$

取梯度步 $y = x - \eta \nabla L(x)$:

$$L(y) \leq L(x) - \eta \left(1 - \frac{\beta\eta}{2}\right) \|\nabla L(x)\|^2. \quad (9.6)$$

当 $0 < \eta < 2/\beta$ 时每个精确梯度步下降；深网中 β 未知且随位置变化，这仍解释了学习率过大造成不稳定的局部机制。

10 二阶近似与曲率方向

在 x 附近 Taylor 展开

$$L(x + \Delta) = L(x) + g^T \Delta + \frac{1}{2} \Delta^T H \Delta + O(\|\Delta\|^3). \quad (10.1)$$

若 $H = U \text{diag}(\lambda_i) U^T$, 在本征方向 u_i 上步长 a 的变化

$$\Delta L \approx a g_i + \frac{1}{2} \lambda_i a^2. \quad (10.2)$$

$\lambda_i > 0$ 为局部碗形, $\lambda_i < 0$ 是负曲率逃离鞍点方向。加阻尼的 Newton 步

$$\Delta = -(H + \lambda I)^{-1} g \quad (10.3)$$

在特征方向缩放为 $-g_i/(\lambda_i + \lambda)$, 避免接近零或负特征值造成巨大步长。

11 链式 Jacobian 与条件数

复合映射 $y = f_L \circ \dots \circ f_1(x)$ 的 Jacobian

$$J_{y \leftarrow x} = J_L J_{L-1} \dots J_1. \quad (11.1)$$

谱范数上界

$$\|J_{y \leftarrow x}\|_2 \leq \prod_{\ell=1}^L \|J_\ell\|_2. \quad (11.2)$$

若各层最小奇异值存在,

$$\sigma_{\min}(J_{y \leftarrow x}) \geq \prod_{\ell} \sigma_{\min}(J_\ell). \quad (11.3)$$

因此条件数至多乘法累积:

$$\kappa(J_{y \leftarrow x}) \leq \prod_{\ell} \kappa(J_\ell). \quad (11.4)$$

低维映射、递归模块和物理传播都面临同一问题: 表示存在不代表反向梯度数值良态。

12 随机梯度的偏差与方差

设样本梯度 $g(\theta; \xi)$ 满足

$$\mathbb{E}_\xi g(\theta; \xi) = \nabla L(\theta), \quad \mathbb{E} \|g - \nabla L\|^2 \leq \sigma^2. \quad (12.1)$$

独立批量 B 的平均

$$\bar{g}_B = \frac{1}{B} \sum_{i=1}^B g_i \quad (12.2)$$

满足

$$\mathbb{E} \bar{g}_B = \nabla L, \quad \mathbb{E} \|\bar{g}_B - \nabla L\|^2 \leq \frac{\sigma^2}{B}. \quad (12.3)$$

若样本相关, 协方差项出现:

$$\text{Var}(\bar{g}_B) = \frac{1}{B^2} \left[\sum_i \text{Var}(g_i) + \sum_{i \neq j} \text{Cov}(g_i, g_j) \right]. \quad (12.4)$$

扩大批量只有在交叉协方差不主导时才近似按 $1/B$ 降噪。

若使用有偏估计 $\mathbb{E} \hat{g} = \nabla L + b$, 均方误差分解

$$\mathbb{E} \|\hat{g} - \nabla L\|^2 = \|b\|^2 + \text{tr Cov}(\hat{g}). \quad (12.5)$$

直通估计、停止梯度目标和截断反传通常以可控偏差换低方差或低内存。

13 Adam 的尺度归一化

逐坐标 Adam 更新

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (13.1)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad (13.2)$$

$$\hat{m}_t = m_t / (1 - \beta_1^t), \quad (13.3)$$

$$\hat{v}_t = v_t / (1 - \beta_2^t), \quad (13.4)$$

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (13.5)$$

若梯度长期乘常数 $c > 0$, 忽略 ϵ 时 $\hat{m}$ 乘 c , $\sqrt{\hat{v}}$ 也乘 c , 更新近似不变。但瞬态、符号变化和 ϵ 会破坏精确尺度不变性。

AdamW 把权重衰减解耦:

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (13.6)$$

这不同于把 $\lambda\theta$ 加入梯度后再经过自适应分母; 后者会按坐标二阶矩缩放正则化。

14 范数约束与投影梯度

约束集合 $\mathcal{C}$ 上的投影梯度

$$\theta^+ = \Pi_{\mathcal{C}}(\theta - \eta g), \quad \Pi_{\mathcal{C}}(x) = \arg \min_{y \in \mathcal{C}} \|x - y\|^2. \quad (14.1)$$

对欧氏球 $\mathcal{C} = \{x : \|x\| \leq R\}$,

$$\Pi_{\mathcal{C}}(x) = \begin{cases} x, & \|x\| \leq R, \\ Rx/\|x\|, & \|x\| > R. \end{cases} \quad (14.2)$$

对流形约束, 局部一阶步先投影到切空间, 再用 retraction 回到流形; 仅把参数写成 $g(z)$ 相当于用参数化隐式满足约束, 但会引入 $J_g^T J_g$ 的坐标度量。

15 Lipschitz 误差的层间传播

真实模块 f_ℓ 、近似模块 $\hat{f}_\ell$ 满足

$$\|f_\ell(x) - \hat{f}_\ell(x)\| \leq \epsilon_\ell, \quad \|f_\ell(x) - f_\ell(y)\| \leq L_\ell \|x - y\|. \quad (15.1)$$

令真实、近似中间状态差 e_ℓ 。三角不等式给出

$$e_{\ell+1} = \|f_\ell(h_\ell) - \hat{f}_\ell(\hat{h}_\ell)\| \quad (15.2)$$

$$\leq L_\ell e_\ell + \epsilon_\ell. \quad (15.3)$$

递归展开

$$e_L \leq \left(\prod_{j=0}^{L-1} L_j \right) e_0 + \sum_{\ell=0}^{L-1} \left(\prod_{j=\ell+1}^{L-1} L_j \right) \epsilon_\ell. \quad (15.4)$$

早期层误差乘更多后续 Lipschitz 因子, 所以量化、低秩近似或局部训练的相同单层误差, 放在不同深度并不等价。

16 复杂度必须区分四个量

参数量、FLOPs、激活内存和通信量是不同指标。以线性层 $Y = XW$ 、 $X \in \mathbb{R}^{B \times n}$ 、 $W \in \mathbb{R}^{n \times m}$ 为例：

$$\text{参数量} = nm, \quad (16.1)$$

$$\text{前向乘加量} \asymp Bnm, \quad (16.2)$$

$$\text{主要激活量} = B(n + m), \quad (16.3)$$

$$\text{数据并行梯度通信} \asymp nm. \quad (16.4)$$

低秩因子可同时减少参数与乘法，但动态稀疏若实现仍做稠密 kernel，参数/FLOPs 公式不会自动转化为墙钟加速。冻结参数减少梯度和优化器状态，却不一定减少前向计算或输入梯度计算。

17 冻结随机投影与任务掩码

LoRI 对任务 t 使用

$$\Delta W_t = c(B_t \odot M_t)A, \quad (17.1)$$

其中 A 随机初始化后冻结， $M_t \in \{0, 1\}^{m \times r}$ 是任务稀疏掩码。若每个元素独立以概率 s 保留，则期望可训练参数为 smr ，相对 LoRA 的 $r(m + n)$ 进一步下降。

18 交叉任务干扰的内积

以 Frobenius 内积衡量两个任务更新的干扰：

$$\langle \Delta W_s, \Delta W_t \rangle_F = c^2 \text{tr} \left((B_s \odot M_s) A A^T (B_t \odot M_t)^T \right). \quad (18.1)$$

若随机投影近似满足 $AA^T \approx \sigma_A^2 I_r$ ，则

$$\langle \Delta W_s, \Delta W_t \rangle_F \approx c^2 \sigma_A^2 \langle B_s \odot M_s, B_t \odot M_t \rangle_F. \quad (18.2)$$

掩码支持不相交时右侧严格为零；随机稀疏掩码只有“期望重叠小”，并不保证每次合并都正交。

19 随机投影的尺度

若 $A_{ij} \sim \mathcal{N}(0, 1/n)$ ，固定 x 时

$$\mathbb{E} \|Ax\|_2^2 = \frac{r}{n} \|x\|_2^2. \quad (19.1)$$

使用 $\sqrt{n/r}A$ 才在期望上保持范数。冻结 A 的作用是固定共享子空间；它减少任务间自由度，也可能在 r 太小时丢失任务需要的方向。