

08_Building Vision Models upon Heat Conduction

1 符号与维度

符号	维度	含义
$u(x, y, t)$	$\mathbb{R}$	连续温度或特征场。
κ	$\mathbb{R}_{\geq 0}$	热扩散系数。
ω_x, ω_y	$\mathbb{R}$	二维空间频率。
U^t	$\mathbb{R}^{H \times W}$	离散视觉特征图。
H_t	$\mathbb{R}^{H \times W}$	频域热核。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 热方程的谱解

连续热方程

$$\partial_t u(x, t) = \kappa \Delta u(x, t), \quad \kappa > 0 \quad (2.1)$$

在矩形区域上配 Neumann 边界 $\partial_n u = 0$ 。先看一维 $x \in [0, L]$ ，分离变量 $u(x, t) = X(x)T(t)$ ：

$$X(x)T'(t) = \kappa X''(x)T(t). \quad (2.2)$$

两边除以 κXT 得常数 $-\lambda$ ，所以

$$X'' + \lambda X = 0, \quad T' + \kappa \lambda T = 0. \quad (2.3)$$

边界 $X'(0) = X'(L) = 0$ 给出本征函数和本征值

$$X_k(x) = \cos(k\pi x/L), \quad \lambda_k = (k\pi/L)^2, \quad k = 0, 1, \dots \quad (2.4)$$

时间解

$$T_k(t) = e^{-\kappa \lambda_k t} T_k(0). \quad (2.5)$$

故 Fourier-cosine 系数逐频率衰减：

$$\hat{u}_k(t) = e^{-\kappa(k\pi/L)^2 t} \hat{u}_k(0). \quad (2.6)$$

二维本征函数是两个余弦的乘积，

$$\hat{u}_{k\ell}(t) = e^{-\kappa[(k\pi/L_x)^2 + (\ell\pi/L_y)^2]t} \hat{u}_{k\ell}(0). \quad (2.7)$$

高频因指数中的平方频率而更快衰减，零频 $k = \ell = 0$ 保持不变。

3 离散 DCT 与 Neumann 边界

一维网格的反射边界可写为虚拟点 $u_{-1} = u_1$ 、 $u_N = u_{N-2}$ 。离散 Laplacian

$$(Lu)_j = u_{j-1} - 2u_j + u_{j+1} \quad (3.1)$$

由离散余弦基向量对角化。对无限/周期直觉，代入模式 $u_j = e^{i\omega j}$ ：

$$(Lu)_j = e^{i\omega j}(e^{-i\omega} - 2 + e^{i\omega}) \quad (3.2)$$

$$= -4 \sin^2(\omega/2) u_j. \quad (3.3)$$

反射边界选择实余弦模式，故 DCT 矩阵 C 满足

$$L = C^T \Lambda C, \quad \Lambda_{kk} = -4 \sin^2(\omega_k/2) \leq 0. \quad (3.4)$$

离散热半群为

$$e^{\kappa t L} = C^T \text{diag}(e^{\kappa t \lambda_k}) C. \quad (3.5)$$

二维可分离情形用 $C_y \otimes C_x$ 对角化，特征值相加。

4 显式迭代与稳定条件

显式 Euler 离散

$$u^{n+1} = u^n + \eta L u^n = (I + \eta L) u^n. \quad (4.1)$$

在特征模态 k 上放大因子为

$$g_k = 1 + \eta \lambda_k. \quad (4.2)$$

稳定要求 $|g_k| \leq 1$ 对所有 k 成立，即

$$-2 \leq \eta \lambda_k \leq 0. \quad (4.3)$$

若一维未除网格步长的 Laplacian 有 $\lambda_{\min} \geq -4$ ，充分条件为 $0 \leq \eta \leq 1/2$ ；二维五点格式最小特征值约 -8 ，充分条件变为 $\eta \leq 1/4$ 。直接使用指数谱门 $e^{\eta \lambda_k}$ 则对任意 $\eta \geq 0$ 都不放大模态。

5 能量与均值的单调性

Neumann 边界下积分分部：

$$\frac{d}{dt} \frac{1}{2} \|u(t)\|_{L^2}^2 = \int_{\Omega} u \partial_t u \, dx \quad (5.1)$$

$$= \kappa \int_{\Omega} u \Delta u \, dx \quad (5.2)$$

$$= -\kappa \int_{\Omega} \|\nabla u\|_2^2 \, dx + \kappa \int_{\partial\Omega} u \partial_n u \, dS \quad (5.3)$$

$$= -\kappa \|\nabla u\|_{L^2}^2 \leq 0. \quad (5.4)$$

总质量满足

$$\frac{d}{dt} \int_{\Omega} u \, dx = \kappa \int_{\Omega} \Delta u \, dx = \kappa \int_{\partial\Omega} \partial_n u \, dS = 0. \quad (5.5)$$

因此热扩散保留均值但降低非恒定部分能量。

离散对称半负定 L 也有

$$\frac{d}{dt} \frac{1}{2} \|u\|_2^2 = \kappa u^T L u \leq 0. \quad (5.6)$$

若学习频率门 g_k ，要保持非扩张，需约束 $|g_k| \leq 1$ ；任意可学习门可能放大高频，此时模块不再严格对应物理热方程。

6 频域门的梯度

设二维 DCT 后 $\hat{X} = CXC^T$, 输出

$$Y = C^T(G \odot \hat{X})C, \quad (6.1)$$

其中 C 正交、 G 是频率门。令上游梯度 $H = \partial\mathcal{L}/\partial Y$, 利用 Frobenius 内积的正交不变性,

$$d\mathcal{L} = \langle H, C^T(dG \odot \hat{X} + G \odot d\hat{X})C \rangle_F \quad (6.2)$$

$$= \langle CHC^T, dG \odot \hat{X} + G \odot d\hat{X} \rangle_F. \quad (6.3)$$

故

$$\nabla_G \mathcal{L} = (CHC^T) \odot \hat{X}, \quad (6.4)$$

以及

$$\nabla_X \mathcal{L} = C^T (G \odot (CHC^T)) C. \quad (6.5)$$

若 $G_{k\ell} = e^{-t\lambda_{k\ell}}$ 且 $\lambda_{k\ell} \geq 0$,

$$\frac{\partial G_{k\ell}}{\partial t} = -\lambda_{k\ell} G_{k\ell}, \quad (6.6)$$

所以大频率对扩散时间的梯度更敏感。

7 复杂度比较

直接空间卷积核大小 $K \times K$ 、通道 C 的深度卷积量为 $O(HWCK^2)$ 。二维快速 DCT 的量约为

$$O(CHW(\log H + \log W)), \quad (7.1)$$

再加逐频率门 $O(CHW)$ 。频域方法一次覆盖全局感受野；但小分辨率或小卷积核时，变换常数和内存搬运可能使理论复杂度优势无法兑现。

8 光滑损失的下降引理

若 L 的梯度是 β -Lipschitz:

$$\|\nabla L(x) - \nabla L(y)\| \leq \beta\|x - y\|, \quad (8.1)$$

则沿线段积分

$$L(y) - L(x) = \int_0^1 \nabla L(x + t(y-x))^T (y-x) dt \quad (8.2)$$

$$= \nabla L(x)^T (y-x) + R, \quad (8.3)$$

余项满足

$$|R| \leq \int_0^1 \beta t \|y-x\|^2 dt = \frac{\beta}{2} \|y-x\|^2. \quad (8.4)$$

故下降引理

$$L(y) \leq L(x) + \nabla L(x)^T (y-x) + \frac{\beta}{2} \|y-x\|^2. \quad (8.5)$$

取梯度步 $y = x - \eta \nabla L(x)$:

$$L(y) \leq L(x) - \eta \left(1 - \frac{\beta\eta}{2}\right) \|\nabla L(x)\|^2. \quad (8.6)$$

当 $0 < \eta < 2/\beta$ 时每个精确梯度步下降；深网中 β 未知且随位置变化，这仍解释了学习率过大造成不稳定的局部机制。

9 二阶近似与曲率方向

在 x 附近 Taylor 展开

$$L(x + \Delta) = L(x) + g^T \Delta + \frac{1}{2} \Delta^T H \Delta + O(\|\Delta\|^3). \quad (9.1)$$

若 $H = U \text{diag}(\lambda_i) U^T$, 在本征方向 u_i 上步长 a 的变化

$$\Delta L \approx a g_i + \frac{1}{2} \lambda_i a^2. \quad (9.2)$$

$\lambda_i > 0$ 为局部碗形, $\lambda_i < 0$ 是负曲率逃离鞍点方向。加阻尼的 Newton 步

$$\Delta = -(H + \lambda I)^{-1} g \quad (9.3)$$

在特征方向缩放为 $-g_i/(\lambda_i + \lambda)$, 避免接近零或负特征值造成巨大步长。

10 链式 Jacobian 与条件数

复合映射 $y = f_L \circ \dots \circ f_1(x)$ 的 Jacobian

$$J_{y \leftarrow x} = J_L J_{L-1} \dots J_1. \quad (10.1)$$

谱范数上界

$$\|J_{y \leftarrow x}\|_2 \leq \prod_{\ell=1}^L \|J_\ell\|_2. \quad (10.2)$$

若各层最小奇异值存在,

$$\sigma_{\min}(J_{y \leftarrow x}) \geq \prod_{\ell} \sigma_{\min}(J_\ell). \quad (10.3)$$

因此条件数至多乘法累积:

$$\kappa(J_{y \leftarrow x}) \leq \prod_{\ell} \kappa(J_\ell). \quad (10.4)$$

低维映射、递归模块和物理传播都面临同一问题: 表示存在不代表反向梯度数值良态。

11 随机梯度的偏差与方差

设样本梯度 $g(\theta; \xi)$ 满足

$$\mathbb{E}_\xi g(\theta; \xi) = \nabla L(\theta), \quad \mathbb{E} \|g - \nabla L\|^2 \leq \sigma^2. \quad (11.1)$$

独立批量 B 的平均

$$\bar{g}_B = \frac{1}{B} \sum_{i=1}^B g_i \quad (11.2)$$

满足

$$\mathbb{E} \bar{g}_B = \nabla L, \quad \mathbb{E} \|\bar{g}_B - \nabla L\|^2 \leq \frac{\sigma^2}{B}. \quad (11.3)$$

若样本相关, 协方差项出现:

$$\text{Var}(\bar{g}_B) = \frac{1}{B^2} \left[\sum_i \text{Var}(g_i) + \sum_{i \neq j} \text{Cov}(g_i, g_j) \right]. \quad (11.4)$$

扩大批量只有在交叉协方差不主导时才近似按 $1/B$ 降噪。

若使用有偏估计 $\mathbb{E} \hat{g} = \nabla L + b$, 均方误差分解

$$\mathbb{E} \|\hat{g} - \nabla L\|^2 = \|b\|^2 + \text{tr Cov}(\hat{g}). \quad (11.5)$$

直通估计、停止梯度目标和截断反传通常以可控偏差换低方差或低内存。

12 Adam 的尺度归一化

逐坐标 Adam 更新

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (12.1)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad (12.2)$$

$$\hat{m}_t = m_t / (1 - \beta_1^t), \quad (12.3)$$

$$\hat{v}_t = v_t / (1 - \beta_2^t), \quad (12.4)$$

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (12.5)$$

若梯度长期乘常数 $c > 0$, 忽略 ϵ 时 $\hat{m}$ 乘 c , $\sqrt{\hat{v}}$ 也乘 c , 更新近似不变。但瞬态、符号变化和 ϵ 会破坏精确尺度不变性。

AdamW 把权重衰减解耦:

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (12.6)$$

这不同于把 $\lambda\theta$ 加入梯度后再经过自适应分母; 后者会按坐标二阶矩缩放正则化。

13 范数约束与投影梯度

约束集合 $\mathcal{C}$ 上的投影梯度

$$\theta^+ = \Pi_{\mathcal{C}}(\theta - \eta g), \quad \Pi_{\mathcal{C}}(x) = \arg \min_{y \in \mathcal{C}} \|x - y\|^2. \quad (13.1)$$

对欧氏球 $\mathcal{C} = \{x : \|x\| \leq R\}$,

$$\Pi_{\mathcal{C}}(x) = \begin{cases} x, & \|x\| \leq R, \\ Rx/\|x\|, & \|x\| > R. \end{cases} \quad (13.2)$$

对流形约束, 局部一阶步先投影到切空间, 再用 retraction 回到流形; 仅把参数写成 $g(z)$ 相当于用参数化隐式满足约束, 但会引入 $J_g^T J_g$ 的坐标度量。

14 Lipschitz 误差的层间传播

真实模块 f_ℓ 、近似模块 $\hat{f}_\ell$ 满足

$$\|f_\ell(x) - \hat{f}_\ell(x)\| \leq \epsilon_\ell, \quad \|f_\ell(x) - f_\ell(y)\| \leq L_\ell \|x - y\|. \quad (14.1)$$

令真实、近似中间状态差 e_ℓ 。三角不等式给出

$$e_{\ell+1} = \|f_\ell(h_\ell) - \hat{f}_\ell(\hat{h}_\ell)\| \quad (14.2)$$

$$\leq L_\ell e_\ell + \epsilon_\ell. \quad (14.3)$$

递归展开

$$e_L \leq \left(\prod_{j=0}^{L-1} L_j \right) e_0 + \sum_{\ell=0}^{L-1} \left(\prod_{j=\ell+1}^{L-1} L_j \right) \epsilon_\ell. \quad (14.4)$$

早期层误差乘更多后续 Lipschitz 因子, 所以量化、低秩近似或局部训练的相同单层误差, 放在不同深度并不等价。

15 复杂度必须区分四个量

参数量、FLOPs、激活内存和通信量是不同指标。以线性层 $Y = XW$ 、 $X \in \mathbb{R}^{B \times n}$ 、 $W \in \mathbb{R}^{n \times m}$ 为例：

$$\text{参数量} = nm, \quad (15.1)$$

$$\text{前向乘加量} \asymp Bnm, \quad (15.2)$$

$$\text{主要激活量} = B(n + m), \quad (15.3)$$

$$\text{数据并行梯度通信} \asymp nm. \quad (15.4)$$

低秩因子可同时减少参数与乘法，但动态稀疏若实现仍做稠密 kernel，参数/FLOPs 公式不会自动转化为墙钟加速。冻结参数减少梯度和优化器状态，却不一定减少前向计算或输入梯度计算。