

12_MUDDFormer

1 符号与维度

符号	维度	含义
X	$\mathbb{R}^{T \times d}$	长度为 T 的隐藏状态序列。
Q, K, V	$\mathbb{R}^{T \times d_h}$	查询、键和值。
A	$\mathbb{R}^{T \times T}$	行归一化注意力矩阵。
M	$\mathbb{R}^{T \times T}$	因果或结构掩码。
H, d_h	$\mathbb{N}$	注意力头数与单头维度, $Hd_h = d$ 。
X_i	$\mathbb{R}^{T \times d}$	第 i 层隐藏状态。
a_i	$\mathbb{R}^{i+1}$	第 i 层的动态跨层权重。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 缩放点积注意力的逐项推导

设单头输入为 $X \in \mathbb{R}^{n \times d}$ ，投影矩阵为 $W_Q, W_K \in \mathbb{R}^{d \times d_k}$ 、 $W_V \in \mathbb{R}^{d \times d_v}$ 。于是

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V, \quad S = \frac{QK^T}{\sqrt{d_k}}, \quad P = \text{softmax}_{\text{row}}(S), \quad O = PV. \quad (2.1)$$

维度依次为 $Q, K \in \mathbb{R}^{n \times d_k}$ 、 $S, P \in \mathbb{R}^{n \times n}$ 、 $V, O \in \mathbb{R}^{n \times d_v}$ 。

2.1 为什么除以 $\sqrt{d_k}$

令某一对 query、key 的坐标独立、均值为零、方差为 σ^2 ，则

$$q^T k = \sum_{a=1}^{d_k} q_a k_a, \quad (2.2)$$

$$\mathbb{E}[q^T k] = \sum_a \mathbb{E}[q_a] \mathbb{E}[k_a] = 0, \quad (2.3)$$

$$\text{Var}(q^T k) = \sum_a \text{Var}(q_a k_a) = \sum_a \mathbb{E}[q_a^2] \mathbb{E}[k_a^2] = d_k \sigma^4. \quad (2.4)$$

因此未缩放 logit 的标准差为 $\sqrt{d_k} \sigma^2$ ；缩放后

$$\text{Var}\left(\frac{q^T k}{\sqrt{d_k}}\right) = \sigma^4. \quad (2.5)$$

这不是让注意力必然均匀，而是避免初始化时维度增大直接把 softmax 推入饱和区。

2.2 softmax Jacobian 的完整形式

对一行 $p_i = e^{s_i} / Z$ ， $Z = \sum_j e^{s_j}$ 。逐坐标求导得

$$\frac{\partial p_i}{\partial s_j} = \frac{\delta_{ij} e^{s_i} Z - e^{s_i} e^{s_j}}{Z^2} \quad (2.6)$$

$$= p_i (\delta_{ij} - p_j). \quad (2.7)$$

写成矩阵即

$$J_{\text{sm}}(p) = \text{diag}(p) - pp^T. \quad (2.8)$$

它是半正定矩阵，因为任意 z 满足

$$z^T J_{\text{sm}}(p) z = \sum_i p_i z_i^2 - \left(\sum_i p_i z_i \right)^2 \quad (2.9)$$

$$= \text{Var}_{i \sim p}(z_i) \geq 0. \quad (2.10)$$

又因 $J_{\text{sm}}(p)\mathbf{1} = 0$ ，给所有 logit 加同一常数不改变 softmax。

设损失对输出一行的梯度为 $g_o \in \mathbb{R}^{d_v}$ 。由 $o = \sum_j p_j v_j$ ，

$$\frac{\partial \mathcal{L}}{\partial p_j} = g_o^T v_j, \quad (2.11)$$

$$\frac{\partial \mathcal{L}}{\partial s_j} = \sum_i \frac{\partial \mathcal{L}}{\partial p_i} \frac{\partial p_i}{\partial s_j} \quad (2.12)$$

$$= p_j g_o^T (v_j - o). \quad (2.13)$$

所以一个 key 的梯度由它相对当前加权均值 o 的偏差决定；这给出了注意力各位置梯度耦合的精确来源。

2.3 对 Q, K, V 的矩阵梯度

记 $G_O = \partial \mathcal{L} / \partial O$ 。矩阵微分

$$dO = dP V + P dV \quad (2.14)$$

与 Frobenius 内积 $d\mathcal{L} = \langle G_O, dO \rangle_F$ 给出

$$G_V = P^T G_O, \quad G_P = G_O V^T. \quad (2.15)$$

对每行应用 softmax Jacobian，令

$$G_S = P \odot \left(G_P - ((G_P \odot P)\mathbf{1})\mathbf{1}^T \right), \quad (2.16)$$

其中括号中的列向量在行内广播。再由

$$dS = \frac{dQ K^T + Q dK^T}{\sqrt{d_k}} \quad (2.17)$$

得到

$$\boxed{G_Q = \frac{G_S K}{\sqrt{d_k}}, \quad G_K = \frac{G_S^T Q}{\sqrt{d_k}}, \quad G_V = P^T G_O.} \quad (2.18)$$

最后通过 $Q = XW_Q$ 等式继续链式求导：

$$G_{W_Q} = X^T G_Q, \quad G_X^{(Q)} = G_Q W_Q^T, \quad (2.19)$$

$$G_{W_K} = X^T G_K, \quad G_X^{(K)} = G_K W_K^T, \quad (2.20)$$

$$G_{W_V} = X^T G_V, \quad G_X^{(V)} = G_V W_V^T. \quad (2.21)$$

同一输入同时产生三条梯度路径，故 $G_X = G_X^{(Q)} + G_X^{(K)} + G_X^{(V)}$ 。

3 掩码、稀疏化与复杂度

令二值可见性矩阵 $M \in \{0, 1\}^{n \times n}$ 。严格掩码写成

$$\tilde{S}_{ij} = \begin{cases} S_{ij}, & M_{ij} = 1, \\ -\infty, & M_{ij} = 0, \end{cases} \quad \tilde{P}_{ij} = \frac{M_{ij} e^{S_{ij}}}{\sum_{\ell} M_{i\ell} e^{S_{i\ell}}}. \quad (3.1)$$

因此被掩码项的概率与梯度都严格为零。若第 i 行只保留 s_i 个 key，注意力乘法量为

$$\Theta \left(d_k \sum_i s_i + d_v \sum_i s_i \right). \quad (3.2)$$

稠密情形 $s_i = n$ 为 $\Theta(n^2(d_k + d_v))$ ；若 $s_i \leq s \ll n$ ，则为 $\Theta(ns(d_k + d_v))$ 。但只有稀疏索引和 kernel 真正跳过零块时，理论乘法量才会转化为实际加速。

3.1 稀疏截断的输出误差

对一行概率 p ，保留集合 S ，被删除概率质量 $\varepsilon = \sum_{j \notin S} p_j$ 。重新归一化后

$$\hat{p}_j = \begin{cases} p_j / (1 - \varepsilon), & j \in S, \\ 0, & j \notin S. \end{cases} \quad (3.3)$$

直接计算其 ℓ_1 距离：

$$\|p - \hat{p}\|_1 = \sum_{j \in S} p_j \frac{\varepsilon}{1 - \varepsilon} + \sum_{j \notin S} p_j \quad (3.4)$$

$$= \varepsilon + \varepsilon = 2\varepsilon. \quad (3.5)$$

若 $\|v_j\|_2 \leq V_{\max}$ ，则输出误差满足

$$\|o - \hat{o}\|_2 = \left\| \sum_j (p_j - \hat{p}_j) v_j \right\|_2 \leq 2\varepsilon V_{\max}. \quad (3.6)$$

这说明 top- k 的关键不是 k 本身，而是被丢弃的注意力质量。

3.2 KV 缓存的精确规模

自回归解码第 t 步只新增一个 key/value。若有 L 层、 h_{kv} 个 KV 头、每头维度 d_h 、每元素 b 字节，则缓存量为

$$\text{Mem}_{KV} = 2Lth_{kv}d_hb. \quad (3.7)$$

其中因子 2 来自 key 与 value。多查询或分组查询通过令 $h_{kv} < h_q$ 降低缓存；它改变的是存储与带宽，不改变 query 头的数量。

4 残差路径与归一化的稳定性

对 pre-norm 块

$$x_{\ell+1} = x_{\ell} + F_{\ell}(\text{LN}(x_{\ell})), \quad (4.1)$$

Jacobian 为

$$\frac{\partial x_{\ell+1}}{\partial x_{\ell}} = I + J_{F_{\ell}} J_{\text{LN}}. \quad (4.2)$$

跨 L 层梯度是这些矩阵的乘积。与没有残差时只乘 $J_{F_\ell} J_{\text{LN}}$ 相比，恒等项提供直接通路。若 $\|J_{F_\ell} J_{\text{LN}}\|_2 \leq \eta_\ell$ ，则

$$\left\| \prod_{\ell=1}^L (I + A_\ell) \right\|_2 \leq \prod_{\ell=1}^L (1 + \eta_\ell) \leq \exp\left(\sum_{\ell=1}^L \eta_\ell\right). \quad (4.3)$$

这给出稳定性的充分条件；它不是“残差必然防止爆炸”的无条件结论。

对向量 $x \in \mathbb{R}^d$ ，忽略可学习仿射项时

$$\mu = \frac{1}{d} \mathbf{1}^\top x, \quad \sigma^2 = \frac{1}{d} \|x - \mu \mathbf{1}\|_2^2, \quad y = \frac{x - \mu \mathbf{1}}{\sqrt{\sigma^2 + \epsilon}}. \quad (4.4)$$

令 $P_c = I - \frac{1}{d} \mathbf{1} \mathbf{1}^\top$ 、 $u = P_c x$ 、 $s = \sqrt{d^{-1} u^\top u + \epsilon}$ ，则逐步微分得

$$du = P_c dx, \quad (4.5)$$

$$ds = \frac{u^\top du}{ds}, \quad (4.6)$$

$$dy = \frac{1}{s} P_c dx - \frac{u u^\top P_c dx}{ds^3}, \quad (4.7)$$

故

$$J_{\text{LN}} = \frac{1}{s} P_c - \frac{u u^\top}{ds^3}. \quad (4.8)$$

该式显示归一化会消除全常数方向，并对样本方差方向施加额外投影。

5 多头分解与合并

第 a 个头输出 $O_a = P_a V_a \in \mathbb{R}^{n \times d_h}$ ，拼接后

$$Y = [O_1 \| \cdots \| O_h] W_O, \quad W_O \in \mathbb{R}^{hd_h \times d}. \quad (5.1)$$

因此多头不是把概率矩阵简单平均，而是在不同投影子空间中分别形成概率矩阵，再由 W_O 线性混合。参数量（忽略偏置）为

$$d(hd_k) + d(hd_k) + d(hd_v) + (hd_v)d. \quad (5.2)$$

常用 $hd_k = hd_v = d$ 时等于 $4d^2$ 。注意力矩阵的主内存项仍为 hn^2 ；Flash 类实现通过分块在线维护 softmax 的行最大值与归一化和，避免物化完整矩阵，但其数学输出仍与上述 softmax 等价。

6 自回归似然与 token 梯度

对序列 $x_{1:T}$ ，因果语言模型按概率链式法则分解

$$p_\theta(x_{1:T}) = \prod_{t=1}^T p_\theta(x_t | x_{<t}). \quad (6.1)$$

负对数似然

$$\mathcal{L}_{\text{NLL}} = - \sum_{t=1}^T \log p_\theta(x_t | x_{<t}). \quad (6.2)$$

若第 t 步 logits 为 $z_t \in \mathbb{R}^V$ ，概率 $p_{tj} = e^{z_{tj}} / \sum_k e^{z_{tk}}$ ，真实 token 索引 y_t ，则

$$\ell_t = -z_{t,y_t} + \log \sum_k e^{z_{tk}}, \quad (6.3)$$

逐 logit 梯度

$$\frac{\partial \ell_t}{\partial z_{tj}} = p_{tj} - \mathbf{1}\{j = y_t\}. \quad (6.4)$$

Hessian 正是 softmax Jacobian

$$\nabla_z^2 \ell_t = \text{diag}(p_t) - p_t p_t^T \succeq 0. \quad (6.5)$$

所以交叉熵关于 logits 凸，但关于深网参数并不凸。

对非 padding token 集合 $\mathcal{I}$ ，平均损失和困惑度

$$\bar{L} = \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \ell_t, \quad \text{PPL} = e^{\bar{L}}. \quad (6.6)$$

因此 PPL 是真实 token 概率倒数的几何平均：

$$\text{PPL} = \left(\prod_{t \in \mathcal{I}} \frac{1}{p_\theta(x_t | x_{<t})} \right)^{1/|\mathcal{I}|}. \quad (6.7)$$

不同 tokenizer 的 token 粒度不同，PPL 不能不经换算直接横向比较。

7 旋转位置编码的相对位置恒等式

对二维坐标对，定义旋转

$$R(m\omega) = \begin{bmatrix} \cos(m\omega) & -\sin(m\omega) \\ \sin(m\omega) & \cos(m\omega) \end{bmatrix}. \quad (7.1)$$

位置 m, n 的 query、key 分别为 $q_m = R(m\omega)q$ 、 $k_n = R(n\omega)k$ 。内积

$$q_m^T k_n = q^T R(m\omega)^T R(n\omega) k \quad (7.2)$$

$$= q^T R((n-m)\omega) k. \quad (7.3)$$

第二步用到 $R(a)^T = R(-a)$ 和 $R(a)R(b) = R(a+b)$ 。所以绝对位置旋转后的内积只依赖相对距离 $n-m$ 。

在 d_h 维中对相邻坐标对使用频率

$$\omega_j = \theta^{-2j/d_h}, \quad j = 0, \dots, d_h/2 - 1. \quad (7.4)$$

低 j 频率高、分辨近距离，高 j 频率低、覆盖远距离。若推理长度远超训练长度，相位 $m\omega_j$ 的外推和周期混叠会改变注意力几何；位置插值本质上是重新缩放这些相位。

8 RMSNorm 的 Jacobian

忽略可学习增益，RMSNorm

$$y = \frac{x}{s}, \quad s = \sqrt{\frac{1}{d} x^T x + \epsilon}. \quad (8.1)$$

微分

$$ds = \frac{x^T dx}{ds}, \quad (8.2)$$

因此

$$dy = \frac{1}{s} dx - \frac{x}{s^2} ds \quad (8.3)$$

$$= \left(\frac{1}{s} I - \frac{xx^T}{ds^3} \right) dx. \quad (8.4)$$

故

$$J_{\text{RMS}} = \frac{1}{s} I - \frac{xx^T}{ds^3}. \quad (8.5)$$

与 LayerNorm 相比，它没有去均值投影 $I - d^{-1}\mathbf{1}\mathbf{1}^T$ ，因此不消除常数方向。加上逐坐标增益 g 后，Jacobain 左乘 $\text{diag}(g)$ 。

谱上，对任意 $v \perp x$ ， $Jv = v/s$ ；沿 x 方向

$$Jx = \left(\frac{1}{s} - \frac{\|x\|^2}{ds^3} \right) x = \frac{\epsilon}{s^3} x. \quad (8.6)$$

当 ϵ 很小，径向尺度方向被强烈压制，而切向方向按 $1/s$ 缩放。

9 SwiGLU 前馈层的逐项梯度

SwiGLU 可写

$$a = xW_a, \quad b = xW_b, \quad h = \text{swish}(a) \odot b, \quad y = hW_o, \quad (9.1)$$

其中

$$\text{swish}(a) = a\sigma(a). \quad (9.2)$$

其导数

$$\frac{d}{da}[a\sigma(a)] = \sigma(a) + a\sigma(a)(1 - \sigma(a)). \quad (9.3)$$

令 $g_h = \partial\mathcal{L}/\partial h$ ，则

$$g_a = g_h \odot b \odot [\sigma(a) + a\sigma(a)(1 - \sigma(a))], \quad (9.4)$$

$$g_b = g_h \odot \text{swish}(a), \quad (9.5)$$

$$\nabla_{W_a}\mathcal{L} = x^T g_a, \quad \nabla_{W_b}\mathcal{L} = x^T g_b, \quad (9.6)$$

$$\nabla_x\mathcal{L} = g_a W_a^T + g_b W_b^T. \quad (9.7)$$

门分支 b 同时调制激活和 a 分支梯度，故两个投影不是可独立解释的普通 MLP。

10 MoE 路由与负载

对 token x_i ，router logits $r_i = W_r x_i$ ，概率

$$p_{ie} = \frac{e^{r_{ie}}}{\sum_{j=1}^E e^{r_{ij}}}. \quad (10.1)$$

若 top- k 专家集合 S_i ，归一化门

$$\tilde{p}_{ie} = \frac{p_{ie}\mathbf{1}\{e \in S_i\}}{\sum_{j \in S_i} p_{ij}}, \quad y_i = \sum_{e \in S_i} \tilde{p}_{ie} F_e(x_i). \quad (10.2)$$

固定集合 S_i 内可正常求导；集合边界的 arg-top- k 不连续，几乎处处把未选专家梯度置零。

令软重要性

$$P_e = \frac{1}{N} \sum_i p_{ie}, \quad (10.3)$$

硬负载

$$F_e = \frac{1}{N} \sum_i \mathbf{1}\{e \in S_i\}/k. \quad (10.4)$$

常见平衡项

$$L_{\text{bal}} = E \sum_e P_e F_e \quad (10.5)$$

在均匀 $P_e = F_e = 1/E$ 时等于 1。把硬 F_e 停止梯度后，router 梯度只通过 P_e ，会降低当前过载专家的概率；它是训练启发式，不等同于严格容量约束。

若每专家容量为

$$C_e = \left\lceil \frac{Nk}{E} c_{\text{cap}} \right\rceil, \quad (10.6)$$

超过容量的 token 必须丢弃或转送。即使平均负载均匀，局部批次方差仍可能溢出。

11 低秩 KV 潜变量的吸收

设 key/value 由共享潜变量

$$c_t = W_c x_t \in \mathbb{R}^{d_c}, \quad k_t = W_k c_t, \quad v_t = W_v c_t. \quad (11.1)$$

注意力 logit

$$q_s^T k_t = q_s^T W_k c_t = (W_k^T q_s)^T c_t. \quad (11.2)$$

因此解码时可把 W_k 吸收到 query 投影，缓存 c_t 而非完整 k_t 。若 value 聚合

$$o_s = \sum_t p_{st} W_v c_t = W_v \left(\sum_t p_{st} c_t \right), \quad (11.3)$$

W_v 可放到加权求和之后。缓存从每 token 的 $d_k + d_v$ 降为 d_c ，前提是位置编码等操作不破坏这些线性交换关系；对只作用在部分 key 维度的 RoPE，需把旋转部分另行缓存或重构。

12 多 token 预测的联合似然

若同一隐藏状态 h_t 用 K 个头预测 $x_{t+1}, \dots, x_{t+K}$,

$$\mathcal{L}_t = \sum_{k=1}^K \lambda_k [-\log p_{\theta,k}(x_{t+k} | h_t)]. \quad (12.1)$$

共享骨干梯度

$$\nabla_{h_t} \mathcal{L}_t = \sum_{k=1}^K \lambda_k g_{t,k}. \quad (12.2)$$

其平方范数精确展开

$$\left\| \sum_k \lambda_k g_{t,k} \right\|^2 = \sum_k \lambda_k^2 \|g_{t,k}\|^2 + 2 \sum_{j < k} \lambda_j \lambda_k g_{t,j}^T g_{t,k}. \quad (12.3)$$

交叉内积为负时存在任务冲突；辅助头退火相当于训练后期逐渐去掉这些交叉项，使最终目标回到下一 token 似然。

13 跨层稠密聚合

设第 i 层可访问 $X_0, \dots, X_i$ ，动态权重 $a_i \in \mathbb{R}^{i+1}$ 经 softmax 归一化，

$$\tilde{X}_i = \sum_{j=0}^i a_{ij} X_j, \quad a_{ij} \geq 0, \quad \sum_j a_{ij} = 1. \quad (13.1)$$

这使每个 token 的跨层聚合是凸组合。若权重 logits 为 s_i ，则

$$\frac{\partial \tilde{X}_i}{\partial s_{ik}} = a_{ik} (X_k - \tilde{X}_i), \quad (13.2)$$

所以某层状态只有在偏离当前加权均值时才产生较大门控梯度。

14 与注意力的对应

若把深度索引看成长度 $i + 1$ 的序列，权重可写成

$$a_i = \text{softmax}(q_i K_i^T), \quad \tilde{X}_i = a_i V_i. \quad (14.1)$$

普通 token 注意力沿空间维混合；MUDDFormer 的动态稠密连接沿深度维混合。两者矩阵形式相同，但键值的索引语义不同，复杂度分别依赖 T^2 与 L^2 。