

17_Mixture-of-Recursions Learning Dynamic Recursive Depths for Adaptive Token-Level Computation

1 符号与维度

符号	维度	含义
$h_i^{(k)}$	$\mathbb{R}^d$	token i 在第 k 次递归后的状态。
K_i	$\{1, \dots, K_{\max}\}$	token 的动态递归深度。
$s_i^{(k)}$	$[0, 1]$	继续执行下一次递归的概率。
F_θ	--	多次共享参数的递归块。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 共享递归块的状态与梯度

设同一参数化块被递归调用 T 次：

$$h_{t+1} = F_\theta(h_t, x), \quad t = 0, \dots, T-1. \quad (2.1)$$

令末端损失 $\mathcal{L}(h_T)$ 。对状态的反向递推

$$g_t = \frac{\partial \mathcal{L}}{\partial h_t} = J_{h_t} F_\theta(h_t, x)^T g_{t+1}. \quad (2.2)$$

因此

$$g_t = \left(\prod_{j=t}^{T-1} J_{h_j} F_\theta^T \right) g_T, \quad (2.3)$$

其中乘积按时间反序作用。共享参数在每次调用都贡献梯度：

$$\nabla_\theta \mathcal{L} = \sum_{t=0}^{T-1} J_\theta F_\theta(h_t, x)^T g_{t+1}. \quad (2.4)$$

参数量不随 T 增长，但激活存储和计算量通常线性增长；共享不等于免费。

若 $\|J_{h_t} F\|_2 \leq \rho$ ，则

$$\|g_t\|_2 \leq \rho^{T-t} \|g_T\|_2. \quad (2.5)$$

$\rho < 1$ 导致长程梯度衰减， $\rho > 1$ 可能爆炸。残差形式 $F(h) = h + G(h)$ 的 Jacobian 为 $I + J_G$ ，给出直接通路但仍需控制谱范数。

3 动态深度的期望计算量

令 token i 的递归深度为离散变量 $D_i \in \{1, \dots, T\}$ ，概率 $p_{it} = \mathbb{P}(D_i = t)$ 。期望深度

$$\mathbb{E}[D_i] = \sum_{t=1}^T t p_{it}. \quad (3.1)$$

也可用生存概率写成

$$\mathbb{E}[D_i] = \sum_{t=1}^T \mathbb{P}(D_i \geq t). \quad (3.2)$$

证明为

$$\sum_{t=1}^T \mathbb{P}(D_i \geq t) = \sum_{t=1}^T \sum_{d=t}^T p_{id} \quad (3.3)$$

$$= \sum_{d=1}^T \sum_{t=1}^d p_{id} = \sum_d d p_{id}. \quad (3.4)$$

若每次递归单 token 代价为 c_i , 批次期望计算

$$\mathbb{E}[C] = \sum_i c_i \mathbb{E}[D_i]. \quad (3.5)$$

预算正则可写

$$\mathcal{L}_{\text{budget}} = \lambda \left(\frac{1}{n} \sum_i \mathbb{E}[D_i] - D_{\text{target}} \right)^2. \quad (3.6)$$

其对路由 logit 的梯度会把所有 token 耦合, 因为批平均出现在同一平方项中。

4 离散路由的梯度估计

若 $D \sim p_\phi(D | x)$, 期望损失

$$J(\phi) = \sum_D p_\phi(D | x) \mathcal{L}_D \quad (4.1)$$

的 score-function 梯度

$$\nabla_\phi J = \sum_D p_\phi(D) \mathcal{L}_D \nabla_\phi \log p_\phi(D) \quad (4.2)$$

$$= \mathbb{E}[(\mathcal{L}_D - b(x)) \nabla_\phi \log p_\phi(D)], \quad (4.3)$$

其中基线不改变期望, 因为 $\mathbb{E} \nabla \log p = \nabla \sum_D p(D) = 0$ 。该估计无偏但方差可能高。

Gumbel-Softmax 松弛令

$$y_t = \frac{\exp((\ell_t + g_t)/\tau)}{\sum_j \exp((\ell_j + g_j)/\tau)}, \quad g_t = -\log[-\log u_t], \quad u_t \sim U(0, 1). \quad (4.4)$$

$\tau \rightarrow 0$ 时趋向 one-hot, 但 Jacobian 含 $1/\tau$, 梯度可能尖锐。直通版本前向取 $\text{onehot}(\arg \max y)$ 、反向用软 y 的梯度, 因此是有偏估计。

5 同步统计量的矩阵表达

设神经元内部时间序列 $z_i(1), \dots, z_i(T)$, 去均值向量

$$\tilde{z}_i = z_i - \bar{z}_i \mathbf{1}, \quad \bar{z}_i = \frac{1}{T} \sum_t z_i(t). \quad (5.1)$$

归一化相关

$$S_{ij} = \frac{\tilde{z}_i^T \tilde{z}_j}{\sqrt{\|\tilde{z}_i\|_2^2 + \epsilon} \sqrt{\|\tilde{z}_j\|_2^2 + \epsilon}} \quad (5.2)$$

形成同步矩阵 S 。若把标准化后的行堆成 $Z \in \mathbb{R}^{m \times T}$ ，则

$$S = ZZ^T. \quad (5.3)$$

所以 S 半正定、 $\text{rank}(S) \leq T$ 。对任意 a ，

$$a^T S a = \|Z^T a\|_2^2 \geq 0. \quad (5.4)$$

这类二阶表征包含神经元两两时间关系，计算和存储却为 $O(m^2 T)$ 与 $O(m^2)$ 。

6 指数衰减同步的在线递推

对乘积统计定义

$$C_t = \lambda C_{t-1} + (1 - \lambda) z_t z_t^T, \quad 0 \leq \lambda < 1. \quad (6.1)$$

递归展开

$$C_t = \lambda^t C_0 + (1 - \lambda) \sum_{k=1}^t \lambda^{t-k} z_k z_k^T. \quad (6.2)$$

历史样本相隔 h 步的权重为 $(1 - \lambda)\lambda^h$ ，半衰期

$$h_{1/2} = \frac{\log(1/2)}{\log \lambda}. \quad (6.3)$$

若 λ 接近 1， $\log \lambda \approx -(1 - \lambda)$ ，故 $h_{1/2} \approx \log 2 / (1 - \lambda)$ 。

若对每一步都保留递归图，梯度穿过

$$\frac{\partial C_t}{\partial C_{t-k}} = \lambda^k I, \quad (6.4)$$

长程梯度指数衰减。若在线统计使用停止梯度，则它作为状态提供历史信息，却不承担跨全部时间的反向传播。

7 固定点与隐式微分

当递归收敛到固定点 $h^* = F_\theta(h^*, x)$ ，对参数微分：

$$dh^* = J_h F dh^* + J_\theta F d\theta. \quad (7.1)$$

若 $I - J_h F$ 可逆，

$$\frac{\partial h^*}{\partial \theta} = (I - J_h F)^{-1} J_\theta F. \quad (7.2)$$

当谱半径 $\rho(J_h F) < 1$ ，逆矩阵有 Neumann 级数

$$(I - J_h F)^{-1} = \sum_{k=0}^{\infty} (J_h F)^k, \quad (7.3)$$

与无限展开的反向路径一致。动态有限深度模型通常不达到固定点，但此式说明稳定递归和可求导性的共同谱条件。

8 自回归似然与 token 梯度

对序列 $x_{1:T}$ ，因果语言模型按概率链式法则分解

$$p_{\theta}(x_{1:T}) = \prod_{t=1}^T p_{\theta}(x_t | x_{<t}). \quad (8.1)$$

负对数似然

$$\mathcal{L}_{\text{NLL}} = - \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t}). \quad (8.2)$$

若第 t 步 logits 为 $z_t \in \mathbb{R}^V$ ，概率 $p_{tj} = e^{z_{tj}} / \sum_k e^{z_{tk}}$ ，真实 token 索引 y_t ，则

$$\ell_t = -z_{t,y_t} + \log \sum_k e^{z_{tk}}, \quad (8.3)$$

逐 logit 梯度

$$\frac{\partial \ell_t}{\partial z_{tj}} = p_{tj} - \mathbf{1}\{j = y_t\}. \quad (8.4)$$

Hessian 正是 softmax Jacobian

$$\nabla_z^2 \ell_t = \text{diag}(p_t) - p_t p_t^T \succeq 0. \quad (8.5)$$

所以交叉熵关于 logits 凸，但关于深网参数并不凸。

对非 padding token 集合 $\mathcal{I}$ ，平均损失和困惑度

$$\bar{L} = \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \ell_t, \quad \text{PPL} = e^{\bar{L}}. \quad (8.6)$$

因此 PPL 是真实 token 概率倒数的几何平均：

$$\text{PPL} = \left(\prod_{t \in \mathcal{I}} \frac{1}{p_{\theta}(x_t | x_{<t})} \right)^{1/|\mathcal{I}|}. \quad (8.7)$$

不同 tokenizer 的 token 粒度不同，PPL 不能不经换算直接横向比较。

9 旋转位置编码的相对位置恒等式

对二维坐标对，定义旋转

$$R(m\omega) = \begin{bmatrix} \cos(m\omega) & -\sin(m\omega) \\ \sin(m\omega) & \cos(m\omega) \end{bmatrix}. \quad (9.1)$$

位置 m, n 的 query、key 分别为 $q_m = R(m\omega)q$ 、 $k_n = R(n\omega)k$ 。内积

$$q_m^T k_n = q^T R(m\omega)^T R(n\omega) k \quad (9.2)$$

$$= q^T R((n-m)\omega) k. \quad (9.3)$$

第二步用到 $R(a)^T = R(-a)$ 和 $R(a)R(b) = R(a+b)$ 。所以绝对位置旋转后的内积只依赖相对距离 $n-m$ 。

在 d_h 维中对相邻坐标对使用频率

$$\omega_j = \theta^{-2j/d_h}, \quad j = 0, \dots, d_h/2 - 1. \quad (9.4)$$

低 j 频率高、分辨近距离，高 j 频率低、覆盖远距离。若推理长度远超训练长度，相位 $m\omega_j$ 的外推和周期混叠会改变注意力几何；位置插值本质上是重新缩放这些相位。

10 RMSNorm 的 Jacobian

忽略可学习增益, RMSNorm

$$y = \frac{x}{s}, \quad s = \sqrt{\frac{1}{d}x^T x + \epsilon}. \quad (10.1)$$

微分

$$ds = \frac{x^T dx}{ds}, \quad (10.2)$$

因此

$$dy = \frac{1}{s}dx - \frac{x}{s^2}ds \quad (10.3)$$

$$= \left(\frac{1}{s}I - \frac{xx^T}{ds^3} \right) dx. \quad (10.4)$$

故

$$J_{\text{RMS}} = \frac{1}{s}I - \frac{xx^T}{ds^3}. \quad (10.5)$$

与 LayerNorm 相比, 它没有去均值投影 $I - d^{-1}\mathbf{1}\mathbf{1}^T$, 因此不消除常数方向。加上逐坐标增益 g 后, Jacobian 左乘 $\text{diag}(g)$ 。

谱上, 对任意 $v \perp x$, $Jv = v/s$; 沿 x 方向

$$Jx = \left(\frac{1}{s} - \frac{\|x\|^2}{ds^3} \right) x = \frac{\epsilon}{s^3}x. \quad (10.6)$$

当 ϵ 很小, 径向尺度方向被强烈压制, 而切向方向按 $1/s$ 缩放。

11 SwiGLU 前馈层的逐项梯度

SwiGLU 可写

$$a = xW_a, \quad b = xW_b, \quad h = \text{swish}(a) \odot b, \quad y = hW_o, \quad (11.1)$$

其中

$$\text{swish}(a) = a\sigma(a). \quad (11.2)$$

其导数

$$\frac{d}{da}[a\sigma(a)] = \sigma(a) + a\sigma(a)(1 - \sigma(a)). \quad (11.3)$$

令 $g_h = \partial\mathcal{L}/\partial h$, 则

$$g_a = g_h \odot b \odot [\sigma(a) + a\sigma(a)(1 - \sigma(a))], \quad (11.4)$$

$$g_b = g_h \odot \text{swish}(a), \quad (11.5)$$

$$\nabla_{W_a}\mathcal{L} = x^T g_a, \quad \nabla_{W_b}\mathcal{L} = x^T g_b, \quad (11.6)$$

$$\nabla_x\mathcal{L} = g_a W_a^T + g_b W_b^T. \quad (11.7)$$

门分支 b 同时调制激活和 a 分支梯度, 故两个投影不是可独立解释的普通 MLP。

12 MoE 路由与负载

对 token x_i , router logits $r_i = W_r x_i$, 概率

$$p_{ie} = \frac{e^{r_{ie}}}{\sum_{j=1}^E e^{r_{ij}}}. \quad (12.1)$$

若 top- k 专家集合 S_i , 归一化门

$$\tilde{p}_{ie} = \frac{p_{ie} \mathbf{1}\{e \in S_i\}}{\sum_{j \in S_i} p_{ij}}, \quad y_i = \sum_{e \in S_i} \tilde{p}_{ie} F_e(x_i). \quad (12.2)$$

固定集合 S_i 内可正常求导；集合边界的 arg-top- k 不连续，几乎处处把未选专家梯度置零。

令软重要性

$$P_e = \frac{1}{N} \sum_i p_{ie}, \quad (12.3)$$

硬负载

$$F_e = \frac{1}{N} \sum_i \mathbf{1}\{e \in S_i\}/k. \quad (12.4)$$

常见平衡项

$$L_{\text{bal}} = E \sum_e P_e F_e \quad (12.5)$$

在均匀 $P_e = F_e = 1/E$ 时等于 1。把硬 F_e 停止梯度后，router 梯度只通过 P_e ，会降低当前过载专家的概率；它是训练启发式，不等同于严格容量约束。

若每专家容量为

$$C_e = \left\lceil \frac{Nk}{E} c_{\text{cap}} \right\rceil, \quad (12.6)$$

超过容量的 token 必须丢弃或转送。即使平均负载均匀，局部批次方差仍可能溢出。

13 低秩 KV 潜变量的吸收

设 key/value 由共享潜变量

$$c_t = W_c x_t \in \mathbb{R}^{d_c}, \quad k_t = W_k c_t, \quad v_t = W_v c_t. \quad (13.1)$$

注意力 logit

$$q_s^T k_t = q_s^T W_k c_t = (W_k^T q_s)^T c_t. \quad (13.2)$$

因此解码时可把 W_k 吸收到 query 投影，缓存 c_t 而非完整 k_t 。若 value 聚合

$$o_s = \sum_t p_{st} W_v c_t = W_v \left(\sum_t p_{st} c_t \right), \quad (13.3)$$

W_v 可放到加权和之后。缓存从每 token 的 $d_k + d_v$ 降为 d_c ，前提是位置编码等操作不破坏这些线性交换关系；对只作用在部分 key 维度的 RoPE，需把旋转部分另行缓存或重构。

14 多 token 预测的联合似然

若同一隐藏状态 h_t 用 K 个头预测 $x_{t+1}, \dots, x_{t+K}$,

$$\mathcal{L}_t = \sum_{k=1}^K \lambda_k [-\log p_{\theta,k}(x_{t+k} | h_t)]. \quad (14.1)$$

共享骨干梯度

$$\nabla_{h_t} \mathcal{L}_t = \sum_{k=1}^K \lambda_k g_{t,k}. \quad (14.2)$$

其平方范数精确展开

$$\left\| \sum_k \lambda_k g_{t,k} \right\|^2 = \sum_k \lambda_k^2 \|g_{t,k}\|^2 + 2 \sum_{j < k} \lambda_j \lambda_k g_{t,j}^T g_{t,k}. \quad (14.3)$$

交叉内积为负时存在任务冲突；辅助头退火相当于训练后期逐渐去掉这些交叉项，使最终目标回到下一 token 似然。