

25_DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning

1 符号与维度

符号	维度	含义
q, o	--	提示与完整回答。
$\pi_\theta, \pi_{\text{old}}, \pi_{\text{ref}}$	--	当前、行为与参考策略。
r_j, A_j	$\mathbb{R}$	第 j 个回答的奖励与组相对优势。
$\rho_{j,t}$	$\mathbb{R}_{>0}$	token 概率比。
ϵ, β	$\mathbb{R}_{>0}$	裁剪半径与 KL 权重。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 折扣占用分布与策略梯度定理

轨迹概率为

$$p_\theta(\tau) = p(s_0) \prod_{t=0}^{T-1} \pi_\theta(a_t | s_t) p(s_{t+1} | s_t, a_t). \quad (2.1)$$

环境转移不依赖 θ ，故对数导数为

$$\nabla_\theta \log p_\theta(\tau) = \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t). \quad (2.2)$$

令回报 $R(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t$ ，使用 $\nabla p = p \nabla \log p$ ：

$$\nabla_\theta J(\theta) = \nabla_\theta \int p_\theta(\tau) R(\tau) d\tau \quad (2.3)$$

$$= \mathbb{E}_{\tau \sim p_\theta} \left[R(\tau) \sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) \right]. \quad (2.4)$$

时刻 t 的 score 对此前已经发生的奖励没有因果影响。对 $k < t$ ，

$$\mathbb{E}[r_k \nabla \log \pi(a_t | s_t)] = \mathbb{E}[r_k \mathbb{E}[\nabla \log \pi(a_t | s_t) | s_t]] \quad (2.5)$$

$$= \mathbb{E} \left[r_k \sum_a \pi(a | s_t) \nabla \log \pi(a | s_t) \right] \quad (2.6)$$

$$= \mathbb{E} \left[r_k \sum_a \nabla \pi(a | s_t) \right] = 0. \quad (2.7)$$

所以可用从 t 开始的 return-to-go G_t ：

$$\boxed{\nabla J = \mathbb{E} \sum_t \nabla \log \pi_\theta(a_t | s_t) G_t.} \quad (2.8)$$

定义归一化折扣占用分布

$$d_\gamma^\pi(s) = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \mathbb{P}_\pi(s_t = s). \quad (2.9)$$

则无限时域形式为

$$\nabla J(\theta) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_{\gamma}^{\pi}, a \sim \pi} [Q^{\pi}(s, a) \nabla \log \pi_{\theta}(a | s)]. \quad (2.10)$$

3 基线不改变期望但降低方差

任意只依赖状态的 $b(s)$ 满足

$$\mathbb{E}_{a \sim \pi} [b(s) \nabla \log \pi(a | s)] = b(s) \sum_a \pi(a | s) \frac{\nabla \pi(a | s)}{\pi(a | s)} \quad (3.1)$$

$$= b(s) \nabla \sum_a \pi(a | s) = 0. \quad (3.2)$$

因此用优势 $A^{\pi} = Q^{\pi} - V^{\pi}$ 替代 Q^{π} 不引入偏差。

对固定状态，令 $z(a) = \nabla \log \pi(a | s)$ 。最小化

$$\mathbb{E} \|z(a)(Q(s, a) - b)\|_2^2 \quad (3.3)$$

对 b 求导，得到方差最优标量基线

$$b^*(s) = \frac{\mathbb{E} [\|z(a)\|_2^2 Q(s, a) | s]}{\mathbb{E} [\|z(a)\|_2^2 | s]}. \quad (3.4)$$

它一般不恰好等于 $V(s)$ ； $V(s)$ 是易学习且通常有效的近似。

4 TD 误差与广义优势估计

定义

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t). \quad (4.1)$$

k 步优势估计为

$$\hat{A}_t^{(k)} = \sum_{l=0}^{k-1} \gamma^l r_{t+l} + \gamma^k V(s_{t+k}) - V(s_t) \quad (4.2)$$

$$= \sum_{l=0}^{k-1} \gamma^l \delta_{t+l}, \quad (4.3)$$

第二行通过望远镜消去中间 V 项。GAE 对不同 k 做几何加权：

$$\hat{A}_t^{\text{GAE}} = (1 - \lambda) \sum_{k=1}^{\infty} \lambda^{k-1} \hat{A}_t^{(k)} \quad (4.4)$$

$$= \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}. \quad (4.5)$$

推导第二行时，固定 l 的 δ_{t+l} 出现在所有 $k \geq l+1$ 中，其系数为

$$(1 - \lambda) \sum_{k=l+1}^{\infty} \lambda^{k-1} = \lambda^l. \quad (4.6)$$

$\lambda = 0$ 接近一步 TD，方差低而依赖 critic 偏差； $\lambda = 1$ 接近 Monte Carlo，偏差小而方差大。

5 重要性比率与裁剪目标的分段分析

旧策略采样、评估新策略时, token 或动作比率为

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\text{old}}(a_t | s_t)}. \quad (5.1)$$

在旧策略分布下,

$$\mathbb{E}_{a \sim \pi_{\text{old}}}[r_t f(a)] = \sum_a \pi_\theta(a | s_t) f(a) = \mathbb{E}_{a \sim \pi_\theta}[f(a)]. \quad (5.2)$$

PPO 代理项为

$$\ell(r, A) = \min\{rA, \text{clip}(r, 1 - \epsilon, 1 + \epsilon)A\}. \quad (5.3)$$

必须按 A 符号分析。若 $A > 0$,

$$\ell(r, A) = A \min(r, 1 + \epsilon), \quad (5.4)$$

超过上界后梯度为零; 若 $A < 0$, 乘负数反转大小关系,

$$\ell(r, A) = A \max(r, 1 - \epsilon), \quad (5.5)$$

低于下界后梯度为零。它只截断会进一步改善代理目标的方向, 不是把所有比率都投影进区间。

比率梯度为

$$\nabla r_t = r_t \nabla \log \pi_\theta(a_t | s_t), \quad (5.6)$$

所以未裁剪区的梯度等于

$$\nabla(r_t A_t) = r_t A_t \nabla \log \pi_\theta(a_t | s_t). \quad (5.7)$$

裁剪制造分段常数区, 只是限制单次更新的激励; 它不严格保证全状态 KL 小于某阈值。

6 组相对优势的统计性质

对同一问题采样 G 个奖励 $R_1, \dots, R_G$, 定义

$$\bar{R} = \frac{1}{G} \sum_{j=1}^G R_j, \quad s_G^2 = \frac{1}{G} \sum_{j=1}^G (R_j - \bar{R})^2, \quad \hat{A}_i = \frac{R_i - \bar{R}}{s_G + \epsilon}. \quad (6.1)$$

当 $\epsilon = 0$ 时, 组内恒有

$$\sum_i \hat{A}_i = 0, \quad \frac{1}{G} \sum_i \hat{A}_i^2 = 1. \quad (6.2)$$

若只中心化,

$$R_i - \bar{R} = \left(1 - \frac{1}{G}\right) R_i - \frac{1}{G} \sum_{j \neq i} R_j. \quad (6.3)$$

假设奖励独立同分布、方差 σ_R^2 , 则

$$\text{Var}(R_i - \bar{R}) = \left(1 - \frac{1}{G}\right)^2 \sigma_R^2 + (G-1) \frac{1}{G^2} \sigma_R^2 \quad (6.4)$$

$$= \left(1 - \frac{1}{G}\right) \sigma_R^2. \quad (6.5)$$

同时 R_i 参与自身基线, 因而优势与基线相关。若使用 leave-one-out 基线

$$\bar{R}_{-i} = \frac{1}{G-1} \sum_{j \neq i} R_j, \quad (6.6)$$

则 R_i 与 $\bar{R}_{-i}$ 在条件独立假设下独立, 但方差变为

$$\text{Var}(R_i - \bar{R}_{-i}) = \sigma_R^2 \left(1 + \frac{1}{G-1}\right). \quad (6.7)$$

前者方差较小, 后者减少自耦合; 二者并非完全等价。

7 序列概率与 token 级目标

语言模型序列 $y = (y_1, \dots, y_T)$ 的概率分解为

$$\pi_\theta(y | x) = \prod_{t=1}^T \pi_\theta(y_t | x, y_{<t}), \quad (7.1)$$

故序列比率

$$r_{\text{seq}} = \frac{\pi_\theta(y | x)}{\pi_{\text{old}}(y | x)} = \prod_{t=1}^T r_t, \quad \log r_{\text{seq}} = \sum_{t=1}^T \log r_t. \quad (7.2)$$

长序列中乘积易产生高方差。token 级裁剪对每个 r_t 分别限制，数值更稳定，但它不是对 r_{seq} 的同一个裁剪目标。若所有 token 共用序列奖励优势 A ，常见目标为

$$\frac{1}{T} \sum_{t=1}^T \min\{r_t A, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A\}. \quad (7.3)$$

长度归一化改变不同长度样本的总梯度权重，应与任务奖励设计一起解释。

8 参考策略 KL 的两种估计

正向 KL 为

$$D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) = \mathbb{E}_{a \sim \pi_\theta} \left[\log \frac{\pi_\theta(a | s)}{\pi_{\text{ref}}(a | s)} \right]. \quad (8.1)$$

单样本对数比可以为负，虽其期望非负。令 $r = \pi_{\text{ref}} / \pi_\theta$ ，函数

$$k(r) = r - 1 - \log r \quad (8.2)$$

满足 $k(r) \geq 0$ ，因为 $\log r \leq r - 1$ 。而

$$\mathbb{E}_{a \sim \pi_\theta} [k(r)] = \sum_a \pi_\theta(a) \left(\frac{\pi_{\text{ref}}(a)}{\pi_\theta(a)} - 1 - \log \frac{\pi_{\text{ref}}(a)}{\pi_\theta(a)} \right) \quad (8.3)$$

$$= 0 + D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}). \quad (8.4)$$

因此 $r - 1 - \log r$ 是逐样本非负且期望正确的估计；前提是两策略的支撑相容。

9 Bellman 期望方程与优势恒等式

对策略 π ，定义

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s \right], \quad (9.1)$$

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s, a_0 = a \right]. \quad (9.2)$$

分离首步奖励：

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} V^\pi(s'), \quad (9.3)$$

$$V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot | s)} Q^\pi(s, a). \quad (9.4)$$

优势

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s) \quad (9.5)$$

在策略动作分布下均值为零：

$$\mathbb{E}_{a \sim \pi} A^\pi(s, a) = 0. \quad (9.6)$$

这不表示每个动作优势小，只表示正负改进机会按当前策略加权抵消。

10 性能差异引理

令新旧策略为 π', π 。沿 π' 轨迹,

$$\mathbb{E}_{\pi'} \sum_{t=0}^{\infty} \gamma^t A^{\pi}(s_t, a_t) = \mathbb{E}_{\pi'} \sum_t \gamma^t [r_t + \gamma V^{\pi}(s_{t+1}) - V^{\pi}(s_t)] \quad (10.1)$$

$$= J(\pi') - \mathbb{E} V^{\pi}(s_0), \quad (10.2)$$

其中价值项望远镜消去, 且有界价值使末项 $\gamma^{T+1} V(s_{T+1}) \rightarrow 0$ 。若初始分布相同, $\mathbb{E} V^{\pi}(s_0) = J(\pi)$, 故

$$J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_{\pi'}, a \sim \pi'} A^{\pi}(s, a). \quad (10.3)$$

策略优化代理常把难采样的 $d_{\pi'}$ 替换为旧占用分布 d_{π} ; 信赖域或比率裁剪的目标是限制这一步替换造成的误差。

11 KL 信赖域的二阶局部形式

对小参数变化 $\Delta\theta$,

$$D_{\text{KL}}(\pi_{\theta} \| \pi_{\theta+\Delta}) = \frac{1}{2} \Delta^T F(\theta) \Delta + O(\|\Delta\|^3), \quad (11.1)$$

其中 Fisher 信息

$$F(\theta) = \mathbb{E}_{s,a} [\nabla \log \pi_{\theta}(a | s) \nabla \log \pi_{\theta}(a | s)^T]. \quad (11.2)$$

一阶目标改进 $g^T \Delta$, 约束 $\frac{1}{2} \Delta^T F \Delta \leq \delta$ 。拉格朗日法:

$$\mathcal{J} = g^T \Delta - \lambda \left(\frac{1}{2} \Delta^T F \Delta - \delta \right). \quad (11.3)$$

驻点

$$g - \lambda F \Delta = 0 \Rightarrow \Delta = \lambda^{-1} F^{-1} g. \quad (11.4)$$

代回约束得到

$$\Delta = \sqrt{\frac{2\delta}{g^T F^{-1} g}} F^{-1} g. \quad (11.5)$$

自然梯度 $F^{-1}g$ 是概率分布几何下最陡方向; PPO 裁剪是更易实现但不严格等价的近似。

12 离策略序列比率的方差

轨迹前 T 步重要性比率

$$W_T = \prod_{t=0}^{T-1} \frac{\pi(a_t | s_t)}{\mu(a_t | s_t)}. \quad (12.1)$$

在行为策略 μ 下若支撑相容, $\mathbb{E}_{\mu} W_T = 1$ 。对数比率是和

$$\log W_T = \sum_t \ell_t, \quad \ell_t = \log \pi(a_t | s_t) - \log \mu(a_t | s_t). \quad (12.2)$$

若粗略假设 ℓ_t 独立、均值 m 、方差 v , 则 W_T 近似 log-normal,

$$\frac{\text{Var}(W_T)}{(\mathbb{E} W_T)^2} \approx e^{Tv} - 1. \quad (12.3)$$

方差随长度指数增长, 这解释了 token/step 级截断、V-trace 或短视野校正的必要性。

截断 $\bar{w}_t = \min(c, w_t)$ 产生偏差, 但单步权重有界, 能控制乘积和梯度爆炸。偏差精确来自尾部

$$\mathbb{E}_{\mu} [(w_t - c)_+ f_t]. \quad (12.4)$$

13 熵正则的策略梯度

状态熵

$$\mathcal{H}(\pi_\theta) = - \sum_a \pi_\theta(a) \log \pi_\theta(a). \quad (13.1)$$

求导

$$\nabla \mathcal{H} = - \sum_a \nabla \pi(a) [1 + \log \pi(a)] \quad (13.2)$$

$$= -\mathbb{E}_{a \sim \pi} [(1 + \log \pi(a)) \nabla \log \pi(a)]. \quad (13.3)$$

因 $\mathbb{E} \nabla \log \pi = 0$ ，常数 1 可去掉：

$$\nabla \mathcal{H} = -\mathbb{E}[\log \pi(a) \nabla \log \pi(a)]. \quad (13.4)$$

加入 $+\alpha \mathcal{H}$ 会提高低概率动作的相对激励，防止策略过早坍缩；但在可验证答案任务中，过强熵也会降低正确答案集中度。

14 奖励平移、缩放与归一化

若所有奖励加常数 c ，无限折扣回报

$$G'_t = G_t + \frac{c}{1 - \gamma}. \quad (14.1)$$

精确优势不变，因为 Q, V 同时加 $c/(1 - \gamma)$ 。用采样回报而无正确基线时，常数会增加梯度方差但期望 score 项仍抵消。

奖励乘正数 a 时，优势和策略梯度乘 a ，等价于改变有效学习率；PPO 的裁剪边界不随 a 变，所以裁剪区域不变但目标梯度尺度变。组内标准化

$$\hat{A}_i = \frac{R_i - \bar{R}}{s_R + \epsilon} \quad (14.2)$$

同时消除平移并近似消除尺度，但 s_R 很小时会放大噪声，故需要 ϵ 或跳过全同奖励组。

15 KL 正则与奖励塑形

目标

$$J(\pi) = \mathbb{E}_\pi[R] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}}) \quad (15.1)$$

可写为每步塑形奖励

$$r'_t = r_t - \beta [\log \pi(a_t | s_t) - \log \pi_{\text{ref}}(a_t | s_t)]. \quad (15.2)$$

固定状态、给定动作价值 $Q(a)$ 时，最优非参数策略由拉格朗日法得到

$$\pi^*(a) = \frac{\pi_{\text{ref}}(a) e^{Q(a)/\beta}}{\sum_b \pi_{\text{ref}}(b) e^{Q(b)/\beta}}. \quad (15.3)$$

$\beta \rightarrow 0$ 时集中到高价值动作， $\beta \rightarrow \infty$ 时回到参考策略。参考策略为零概率的动作在正向 KL 约束下永远不可选，故支撑选择很重要。

16 拒答动作与错误成本

设回答正确收益 u_c 、错误收益 u_e 、拒答收益 u_a ，模型置信度 $p = \mathbb{P}(\text{correct} \mid s)$ 。回答期望效用

$$U_{\text{ans}}(p) = pu_c + (1 - p)u_e, \quad (16.1)$$

拒答效用 $U_{\text{abstain}} = u_a$ 。当

$$p \geq \frac{u_a - u_e}{u_c - u_e} \quad (16.2)$$

时回答更优（假设 $u_c > u_e$ ）。因此最优置信阈值由错误和拒答的相对成本决定，不是固定的 $1/2$ 。RL 后训练若隐含奖励给拒答过低分，就会系统性鼓励猜测。

17 有限 horizon 的回报界

若 $|r_t| \leq R_{\max}$ ，无限折扣回报有界

$$|G_t| \leq \sum_{k=0}^{\infty} \gamma^k R_{\max} = \frac{R_{\max}}{1 - \gamma}. \quad (17.1)$$

截断到 H 步的尾部误差

$$\left| G_t - \sum_{k=0}^{H-1} \gamma^k r_{t+k} \right| \leq \frac{\gamma^H R_{\max}}{1 - \gamma}. \quad (17.2)$$

要使其不超过 ϵ ，充分条件

$$H \geq \frac{\log[\epsilon(1 - \gamma)/R_{\max}]}{\log \gamma}, \quad (17.3)$$

注意 $\log \gamma < 0$ ，除法会反转不等号，右端为正。