

26_Why Language Models Hallucinate

1 符号与维度

符号	维度	含义
$p, \hat{p}$	--	真实事实分布与模型分布。
E, V	2^X	错误集合与有效回答集合。
err, h	$[0, 1]$	分类错误率与生成幻觉率。
K, k	$\mathbb{N}$	阈值分母与每提示有效答案数上界。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 主归约定理的完整集合证明

对提示 $c \sim \mu$ ，有效回答集合 V_c 、错误集合 E_c 。令

$$K = \min_c |E_c|, \quad k = \max_c |V_c|, \quad (2.1)$$

并定义阈值集合

$$A = \{(c, r) : \hat{p}(r | c) > 1/K\}, \quad (2.2)$$

$$B = \{(c, r) : \hat{p}(r | c) \leq 1/K\}. \quad (2.3)$$

训练分布只支持有效回答， $p(V) = 1$ 。联合分布写成 $p(c, r) = \mu(c)p(r | c)$ 、 $\hat{p}(c, r) = \mu(c)\hat{p}(r | c)$ 。

IIV 分类分布以概率 $1/2$ 从 p 采有效样本，以概率 $1/2$ 先采 $c \sim \mu$ 、再从 E_c 均匀采错误回答。分类器在 A 判正、在 B 判负。因此

$$\text{err}_{\text{iiv}} = D(A \setminus V) + D(B \cap V). \quad (2.4)$$

生成错误率分解为

$$\text{err} = \hat{p}(A \setminus V) + \hat{p}(B \setminus V). \quad (2.5)$$

先处理阈值以上的假阳性。对 $(c, r) \in A \setminus V$,

$$D(c, r) = \frac{\mu(c)}{2|E_c|} \leq \frac{\mu(c)}{2K}, \quad (2.6)$$

而

$$\hat{p}(c, r) = \mu(c)\hat{p}(r | c) > \frac{\mu(c)}{K}. \quad (2.7)$$

逐项相加得到

$$\hat{p}(A \setminus V) \geq 2D(A \setminus V). \quad (2.8)$$

再处理阈值以下的假阴性。因训练分布只在 V 上，

$$2D(B \cap V) = p(B \cap V) = p(B). \quad (2.9)$$

每个提示至多有 k 个有效回答落入 B ，每个条件概率至多 $1/K$ ，所以

$$\hat{p}(B \cap V) = \sum_c \mu(c) \sum_{r \in B \cap V_c} \hat{p}(r | c) \quad (2.10)$$

$$\leq \sum_c \mu(c) \frac{k}{K} = \frac{k}{K}. \quad (2.11)$$

令校准偏差

$$\delta = |\hat{p}(A) - p(A)| = |\hat{p}(B) - p(B)|. \quad (2.12)$$

于是

$$2D(B \cap V) - \hat{p}(B \setminus V) = p(B) - [\hat{p}(B) - \hat{p}(B \cap V)] \quad (2.13)$$

$$\leq \delta + \hat{p}(B \cap V) \quad (2.14)$$

$$\leq \delta + \frac{k}{K}. \quad (2.15)$$

移项并与阈值以上部分相加，得到论文主定理

$$\boxed{\text{err} \geq 2 \text{err}_{\text{iiv}} - \frac{k}{K} - \delta.} \quad (2.16)$$

常数 2 来自 IIV 分布把一半质量分配给错误样本，不是经验拟合常数。

3 校准项等于概率重标定方向导数

令 $a = \hat{p}(A)$ 。对 A 内概率乘 $s > 0$ 并归一化：

$$\hat{p}_s(x) = \begin{cases} \frac{s\hat{p}(x)}{Z(s)}, & x \in A, \\ \frac{\hat{p}(x)}{Z(s)}, & x \notin A, \end{cases} \quad Z(s) = sa + (1 - a). \quad (3.1)$$

交叉熵

$$L(s) = -\mathbb{E}_{x \sim p} \log \hat{p}_s(x) \quad (3.2)$$

$$= -\mathbb{E}_p \log \hat{p}(x) - p(A) \log s + \log Z(s). \quad (3.3)$$

求导

$$L'(s) = -\frac{p(A)}{s} + \frac{a}{sa + 1 - a}. \quad (3.4)$$

在 $s = 1$,

$$\boxed{L'(1) = \hat{p}(A) - p(A).} \quad (3.5)$$

故 $\delta = |L'(1)|$ 。若模型类能实现这一简单重标定且交叉熵达到局部最优，该方向导数应接近零；这解释了为什么预训练自然倾向小 δ 。

二阶导数

$$L''(1) = p(A) - a^2. \quad (3.6)$$

当 $p(A) \approx a$ 时约为 $a(1 - a) \geq 0$ ，重标定方向局部凸。

4 正向 KL 对未观测错误区的约束

交叉熵恒等式

$$\mathbb{E}_p[-\log \hat{p}] = H(p) + D_{\text{KL}}(p \parallel \hat{p}) \quad (4.1)$$

中，若 $p(x) = 0$ ，该点不直接出现在求和

$$D_{\text{KL}}(p \parallel \hat{p}) = \sum_{x: p(x) > 0} p(x) \log \frac{p(x)}{\hat{p}(x)}. \quad (4.2)$$

但概率总和仍把区域耦合：给错误区质量 ε 后，有效区总质量仅 $1 - \varepsilon$ 。若在有效区保持相对比例 $\hat{p}(x) = (1 - \varepsilon)p(x)$ ，则

$$D_{\text{KL}}(p \parallel \hat{p}) = \sum_x p(x) \log \frac{1}{1 - \varepsilon} = -\log(1 - \varepsilon). \quad (4.3)$$

小 ε 时

$$-\log(1 - \varepsilon) = \varepsilon + \frac{\varepsilon^2}{2} + O(\varepsilon^3). \quad (4.4)$$

所以错误质量并非完全免费，但有限样本只观测有效区的一小部分，模型可在大量未见字符串之间重新分配质量而训练损失近似不变。

5 Good-Turing 缺失质量与 singleton rate

对离散分布 ν 抽 N 个样本。令类别 x 的样本计数 N_x ，缺失质量

$$M = \sum_x \nu_x \mathbf{1}\{N_x = 0\}, \quad (5.1)$$

singleton 比率

$$GT = \frac{1}{N} \sum_x \mathbf{1}\{N_x = 1\}. \quad (5.2)$$

其期望分别为

$$\mathbb{E}M = \sum_x \nu_x (1 - \nu_x)^N, \quad (5.3)$$

$$\mathbb{E}GT = \frac{1}{N} \sum_x \mathbb{P}(N_x = 1) \quad (5.4)$$

$$= \sum_x \nu_x (1 - \nu_x)^{N-1}. \quad (5.5)$$

所以

$$\mathbb{E}GT - \mathbb{E}M = \sum_x \nu_x^2 (1 - \nu_x)^{N-1} \geq 0. \quad (5.6)$$

且对 $u \in [0, 1]$ ，函数 $u(1 - u)^{N-1}$ 的最大值不超过 $1/N$ ，因此

$$\mathbb{E}GT - \mathbb{E}M = \sum_x \nu_x [\nu_x (1 - \nu_x)^{N-1}] \quad (5.7)$$

$$\leq \frac{1}{N} \sum_x \nu_x = \frac{1}{N}. \quad (5.8)$$

这证明 singleton 比率的期望只比缺失质量高至多 $1/N$ 。

改变一个训练样本时，singleton 个数至多改变 2，所以 GT 的 bounded difference 常数为 $2/N$ 。McDiarmid 给出

$$\mathbb{P}(|GT - \mathbb{E}GT| \geq \epsilon) \leq 2 \exp\left(-\frac{N\epsilon^2}{2}\right). \quad (5.9)$$

结合缺失质量自身的集中界与上述期望偏差，就得到 $|M - GT| = O(\sqrt{\log(1/\gamma)/N})$ 的高概率结论。

6 带拒答样本的 singleton 修正

论文把所有 IDK 回答折叠成同一类别。设折叠后的标准 Good-Turing 量为 GT ，忽略 IDK 后的 singleton rate 为 sr 。折叠操作至多让 IDK 类额外成为一个 singleton，因此

$$GT - sr \in \{0, 1/N\}. \quad (6.1)$$

令 φ 是 IDK 总概率。IDK 未在 N 个样本中出现的概率

$$(1 - \varphi)^N \leq e^{-N\varphi}. \quad (6.2)$$

若

$$\varphi \geq N^{-1} \log(5/\gamma), \quad (6.3)$$

该概率至多 $\gamma/5$ 。若不等式反向成立，则忽略 IDK 对缺失质量的改变量本身至多

$$N^{-1} \log(5/\gamma). \quad (6.4)$$

两种情况合并并用 union bound，得到带拒答版本仍为

$$|MM - sr| = O\left(\sqrt{\frac{\log(1/\gamma)}{N}}\right). \quad (6.5)$$

7 Arbitrary Facts 下界的组合

对训练中未回答的提示集合 U ，算法输出与随机指定的正确答案 a_c 独立。在 IIV 的正负对称构造中，对每个未见提示，任一固定分类器平均至少产生 $1/2$ 的局部分类误差。若未见提示质量为 MM ，加权 Hoeffding 给出高概率下界

$$2 \text{err}_{\text{iiv}} \geq MM - O\left(\sqrt{\frac{\log(N/\gamma)}{N}}\right). \quad (7.1)$$

再用 $MM \approx sr$ 与主归约定理 $k = 2$ ，得到

$$\text{err} \geq sr - \frac{2}{\min_c |E_c|} - O\left(\sqrt{\frac{\log(N/\gamma)}{N}}\right) - \delta. \quad (7.2)$$

论文在 99% 概率下把常数显式化为

$$\text{err} \geq sr - \frac{2}{\min_c |E_c|} - \frac{35 + 6 \log N}{\sqrt{N}} - \delta. \quad (7.3)$$

各减项分别对应有有限错误选项数、统计集中误差和阈值校准误差；不能把它们都解释为同一种“模型能力不足”。

8 条件期望作为 L^2 正交投影

令随机向量 $Y \in L^2$ ，观测 Z 生成子空间

$$\mathcal{H}_Z = \{f(Z) : \mathbb{E}\|f(Z)\|^2 < \infty\}. \quad (8.1)$$

条件期望 $m(Z) = \mathbb{E}[Y | Z]$ 满足任意 $h(Z) \in \mathcal{H}_Z$ ：

$$\mathbb{E}[(Y - m(Z))^T h(Z)] = 0. \quad (8.2)$$

因为

$$\mathbb{E}[(Y - m)^T h] = \mathbb{E}\{\mathbb{E}[(Y - m)^T h | Z]\} \quad (8.3)$$

$$= \mathbb{E}\{h^T \mathbb{E}[Y - m | Z]\} = 0. \quad (8.4)$$

于是 Pythagoras 恒等式

$$\mathbb{E}\|Y - f(Z)\|^2 = \mathbb{E}\|Y - m(Z)\|^2 + \mathbb{E}\|m(Z) - f(Z)\|^2. \quad (8.5)$$

多数回归、去噪、流匹配和局部目标的“最优预测器”都由这一投影结论得到。

全方差公式也是同一正交分解：

$$\text{Var}(Y) = \mathbb{E} \text{Var}(Y | Z) + \text{Var}(\mathbb{E}[Y | Z]). \quad (8.6)$$

第一项是观测 Z 后仍不可约的不确定性，第二项是不同 Z 条件均值的变化。

9 Jensen、对数和与变分界

对凹函数 $\log$,

$$\log \mathbb{E}X \geq \mathbb{E} \log X, \quad X > 0. \quad (9.1)$$

差距可以写成 KL。令未归一权重 $w(z) > 0$ 、提议分布 $q(z)$ ，配分函数 $Z = \mathbb{E}_q w(z)$ ，定义

$$p^*(z) = \frac{q(z)w(z)}{Z}. \quad (9.2)$$

则

$$\log Z - \mathbb{E}_q \log w = \mathbb{E}_q \log \frac{Z}{w(z)} \quad (9.3)$$

$$= \mathbb{E}_q \log \frac{q(z)}{p^*(z)} \quad (9.4)$$

$$= D_{\text{KL}}(q \| p^*) \geq 0. \quad (9.5)$$

因此 Jensen 下界何时紧不只取决于“方差小”，而是提议分布是否等于归一化后的目标分布。

log-sum-exp

$$\text{LSE}(x) = \log \sum_{i=1}^n e^{x_i} \quad (9.6)$$

满足

$$\max_i x_i \leq \text{LSE}(x) \leq \max_i x_i + \log n. \quad (9.7)$$

减去最大值 $m = \max_i x_i$ 后计算

$$\text{LSE}(x) = m + \log \sum_i e^{x_i - m} \quad (9.8)$$

可避免指数上溢且数学等价。

10 Hoeffding 不等式的矩母函数推导

设独立 $X_i \in [a_i, b_i]$ ， $S = \sum_i (X_i - \mathbb{E}X_i)$ 。对任意 $\lambda > 0$ ，Markov 不等式

$$\mathbb{P}(S \geq t) = \mathbb{P}(e^{\lambda S} \geq e^{\lambda t}) \leq e^{-\lambda t} \mathbb{E} e^{\lambda S}. \quad (10.1)$$

独立性给出矩母函数乘积。Hoeffding 引理

$$\mathbb{E} e^{\lambda(X_i - \mathbb{E}X_i)} \leq \exp\left(\frac{\lambda^2(b_i - a_i)^2}{8}\right). \quad (10.2)$$

故

$$\mathbb{P}(S \geq t) \leq \exp\left(-\lambda t + \frac{\lambda^2}{8} \sum_i (b_i - a_i)^2\right). \quad (10.3)$$

对 λ 最小化，

$$\lambda^* = \frac{4t}{\sum_i (b_i - a_i)^2}, \quad (10.4)$$

得到

$$\mathbb{P}(S \geq t) \leq \exp\left(-\frac{2t^2}{\sum_i (b_i - a_i)^2}\right). \quad (10.5)$$

对下尾应用于 $-S$ ，再 union bound 得双侧界。

11 Bernstein 界利用方差信息

若独立零均值 X_i 满足 $|X_i| \leq M$, 总方差 $v = \sum_i \mathbb{E}X_i^2$, Bernstein 界

$$\mathbb{P}\left(\sum_i X_i \geq t\right) \leq \exp\left(-\frac{t^2}{2(v + Mt/3)}\right). \quad (11.1)$$

当 $t \ll v/M$ 时近似高斯尾 $e^{-t^2/(2v)}$; 当 t 很大时转为 $e^{-3t/(2M)}$ 。相比只使用取值区间的 Hoeffding, 方差远小于最坏范围时 Bernstein 更紧。

对 Bernoulli 均值 $\hat{p} = N^{-1} \sum_i X_i$, $v = Np(1-p)$,

$$\mathbb{P}(|\hat{p} - p| \geq \epsilon) \leq 2 \exp\left(-\frac{N\epsilon^2}{2[p(1-p) + \epsilon/3]}\right). \quad (11.2)$$

12 并合界与同时保证

事件 $E_1, \dots, E_M$ 不要求独立也有

$$\mathbb{P}\left(\bigcup_{j=1}^M E_j\right) \leq \sum_{j=1}^M \mathbb{P}(E_j). \quad (12.1)$$

若每个失败概率至多 δ/M , 则全部结论同时成立的概率至少 $1 - \delta$ 。将单点集中界扩展到有限候选集合通常产生 $\log M$ 项。例如

$$2Me^{-2N\epsilon^2} \leq \delta \quad (12.2)$$

等价于

$$\epsilon \geq \sqrt{\frac{\log(2M/\delta)}{2N}}. \quad (12.3)$$

若候选集合无限, 需要覆盖数、VC 维或 Rademacher 复杂度, 而不能直接把 $M = \infty$ 代入。

13 Delta 方法与非线性估计误差

设 $\sqrt{N}(\hat{\theta} - \theta) \Rightarrow \mathcal{N}(0, \Sigma)$, 光滑函数 g 的一阶展开

$$g(\hat{\theta}) = g(\theta) + \nabla g(\theta)^T (\hat{\theta} - \theta) + o_p(N^{-1/2}). \quad (13.1)$$

于是

$$\sqrt{N}[g(\hat{\theta}) - g(\theta)] \Rightarrow \mathcal{N}(0, \nabla g^T \Sigma \nabla g). \quad (13.2)$$

例如 $g(p) = \log p$, 方差近似

$$\text{Var}(\log \hat{p}) \approx \frac{\text{Var}(\hat{p})}{p^2}. \quad (13.3)$$

当 p 很小时误差被 $1/p^2$ 放大, 解释了稀有事件对数概率和概率比估计的不稳定。

二阶展开还给非线性偏差

$$\mathbb{E}g(\hat{\theta}) - g(\theta) \approx \frac{1}{2} \text{tr}(H_g(\theta) \text{Cov}(\hat{\theta})). \quad (13.4)$$

FID、比率、倒数和归一化优势等即使基础估计无偏, 非线性组合也可有有限样本偏差。

14 重要性采样与有效样本量

目标期望 $\mathbb{E}_p f(X)$ 用提议 q 采样, 权重 $w(x) = p(x)/q(x)$:

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N w(X_i) f(X_i), \quad X_i \sim q. \quad (14.1)$$

若 p 的归一化常数未知, 使用自归一估计

$$\tilde{\mu} = \frac{\sum_i w_i f_i}{\sum_i w_i}, \quad (14.2)$$

它一般有 $O(1/N)$ 偏差, 但常更实用。权重退化可用

$$N_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2} \quad (14.3)$$

衡量; 权重相等时为 N , 单个权重主导时接近 1。

比率裁剪 $\tilde{w} = \min(w, c)$ 降低方差, 但引入偏差

$$\mathbb{E}_q[(w - \tilde{w})f] = \mathbb{E}_q[(w - c)_+ f]. \quad (14.4)$$

若 $|f| \leq F$, 绝对偏差至多

$$F \mathbb{E}_q[(w - c)_+]. \quad (14.5)$$

15 校准与 Brier 分解

二元预测概率 $P \in [0, 1]$ 、标签 $Y \in \{0, 1\}$ 。条件真实频率 $m(P) = \mathbb{E}[Y | P]$ 。Brier 分数

$$\mathbb{E}(P - Y)^2 = \mathbb{E}(P - m(P))^2 + \mathbb{E}(m(P) - Y)^2, \quad (15.1)$$

交叉项因条件期望为零而消失。第一项是校准误差, 第二项是给定预测分组后的不可约噪声。若模型完美校准, $m(P) = P$, 第一项为零, 但单次预测仍可错误; 校准不是零错误率, 而是概率与长期频率一致。