

29_FlyLoRA

1 符号与维度

符号	维度	含义
W_0	$\mathbb{R}^{m \times n}$	冻结的预训练权重。
x	$\mathbb{R}^n$	单个输入 token 的列向量。
A	$\mathbb{R}^{r \times n}$	下投影；FlyLoRA 中稀疏、随机初始化并冻结。
B	$\mathbb{R}^{m \times r}$	上投影；FlyLoRA 中唯一通过梯度训练的适配器矩阵。
$a_i = A[i, :]$	$\mathbb{R}^{1 \times n}$	A 的第 i 行。
$b_i = B[:, i]$	$\mathbb{R}^{m \times 1}$	B 的第 i 列。
$y = Ax$	$\mathbb{R}^r$	稀疏投影后的 rank-wise 激活。
Λ	$\mathbb{R}^{r \times r}$	top- k 二值对角掩码。
α/r	$\mathbb{R}$	LoRA 缩放系数，以下简记为 $c = \alpha/r$ 。
p	$\{1, \dots, n-1\}$	每行非零位置数；稀疏率 $q = \rho = p/n$ 。
k	$\{1, \dots, r\}$	每个样本激活的 rank-1 专家数。
δ	$\mathbb{R}^m$	输出端反向传播向量 $\partial \mathcal{L} / \partial h$ 。

所有向量默认是列向量； $\|\cdot\|_2$ 对向量表示欧氏范数、对矩阵表示谱范数， $\|\cdot\|_F$ 表示 Frobenius 范数。

2 从 LoRA 到 rank-wise 专家

2.1 LoRA 的基本分解

LoRA 用秩不超过 r 的矩阵模拟全量更新：

$$W' = W_0 + \Delta W, \quad \Delta W = cBA, \quad c = \frac{\alpha}{r}. \quad (2.1)$$

维度逐项检查为

$$(m \times r)(r \times n) = m \times n, \quad (m \times n)(n \times 1) = m \times 1. \quad (2.2)$$

因此前向传播是

$$f_{\text{LoRA}}(x) = W'x = W_0x + cBAx. \quad (2.3)$$

由于

$$B = [b_1, \dots, b_r], \quad A = \begin{bmatrix} a_1 \\ \vdots \\ a_r \end{bmatrix}, \quad (2.4)$$

矩阵乘积可按中间指标展开。对任意 $\mu \in \{1, \dots, m\}$ 、 $\nu \in \{1, \dots, n\}$,

$$(BA)_{\mu\nu} = \sum_{i=1}^r B_{\mu i} A_{i\nu} \quad (2.5)$$

$$= \sum_{i=1}^r (b_i)_\mu (a_i)_\nu = \left(\sum_{i=1}^r b_i a_i \right)_{\mu\nu}. \quad (2.6)$$

故有精确恒等式

$$BA = \sum_{i=1}^r b_i a_i, \quad BAx = \sum_{i=1}^r b_i (a_i x). \quad (2.7)$$

其中 $b_i a_i \in \mathbb{R}^{m \times n}$ 的秩至多为 1，而 $a_i x \in \mathbb{R}$ 是标量。于是每个中间维度都可以看成一个 rank-1 专家：

$$E_i(x) = b_i(a_i x) \in \mathbb{R}^m. \quad (2.8)$$

2.2 SVD 类比的准确含义

若对某个固定更新矩阵做奇异值分解,

$$\Delta W = U \Sigma V^T = \sum_{i=1}^s \sigma_i u_i v_i^T, \quad \sigma_1 \geq \dots \geq \sigma_s \geq 0, \quad (2.9)$$

则 Eckart-Young-Mirsky 定理给出

$$\min_{\text{rank}(M) \leq k} \|\Delta W - M\|_F^2 = \sum_{i=k+1}^s \sigma_i^2, \quad (2.10)$$

最优解为 $\sum_{i=1}^k \sigma_i u_i v_i^T$ 。FlyLoRA 借用的是“保留较重要 rank-1 分量”的直觉, 但必须注意: 一般的 $b_i a_i$ 并不是 ΔW 的奇异分量, $|a_i x|$ 也不是奇异值。因此, Eckart-Young-Mirsky 定理 **不能直接证明** 按 $|a_i x|$ 选 top- k 就是 $B A x$ 的最优近似。

对单个专家, 贡献范数有精确分解

$$\|b_i a_i x\|_2 = \|b_i(a_i x)\|_2 = |a_i x| \|b_i\|_2. \quad (2.11)$$

因此按 $|a_i x|$ 排序等同于按真实贡献范数排序, 当且仅当各列 $\|b_i\|_2$ 相同; 若

$$0 < \beta_{\min} \leq \|b_i\|_2 \leq \beta_{\max}, \quad (2.12)$$

则有

$$\beta_{\min} |a_i x| \leq \|b_i a_i x\|_2 \leq \beta_{\max} |a_i x|. \quad (2.13)$$

这说明代理分数的失真至多受列范数比 $\beta_{\max}/\beta_{\min}$ 控制。

令 $z = Ax$, S 是 $|z_i|$ 最大的 k 个坐标, 截断误差为

$$e_S = B(I - \Lambda_S)z = \sum_{i \notin S} b_i z_i. \quad (2.14)$$

总能得到

$$\|e_S\|_2 \leq \sum_{i \notin S} \|b_i\|_2 |z_i| \quad (2.15)$$

$$\leq \beta_{\max} \sum_{i \notin S} |z_i| \quad (2.16)$$

$$\leq \beta_{\max} \sqrt{r-k} \|z_{S^c}\|_2. \quad (2.17)$$

若进一步有 $B^T B = \beta^2 I_r$, 则

$$\|e_S\|_2^2 = z^T (I - \Lambda_S) B^T B (I - \Lambda_S) z = \beta^2 \sum_{i \notin S} |z_i|^2, \quad (2.18)$$

此时保留最大的 $|z_i|$ 才是所有坐标子集中的严格最优解。

3 FlyLoRA 前向传播、路由和反向传播

3.1 稀疏投影与两种 top- k 解释

FlyLoRA 固定 A , 每行恰好保留 p 个位置, 并在这些位置采样

$$A_{ij} \mid (j \in S_i) \sim \mathcal{N}\left(0, \frac{1}{r^2}\right), \quad |S_i| = p. \quad (3.1)$$

令 $y = Ax$ 。论文叙述和式 (7) 强调按幅值选择, 即

$$\mathcal{S}_k^{\text{mag}}(y) = \{|y_i| \text{ 最大的 } k \text{ 个指标}\}. \quad (3.2)$$

但原文式 (10) 加入负载均衡偏置后写成对 $(Ax + d)_i$ 本身逐次取最大值, 没有绝对值。对应集合为

$$\mathcal{S}_k^{\text{raw}}(x, d) = \{(Ax + d)_i \text{ 最大的 } k \text{ 个指标}\}. \quad (3.3)$$

两者并不等价。下文凡涉及“贡献幅值”均采用式 (3.2); 只涉及二值掩码和梯度稀疏性时, 两种规则都适用。

对选中集合 S 定义

$$\lambda_i = \mathbf{1}\{i \in S\}, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_r), \quad y' = \Lambda y. \quad (3.4)$$

于是严格且维度一致的前向式为

$$h = f_{\text{FlyLoRA}}(x) = W_0 x + c B \Lambda A x \quad (3.5)$$

$$= W_0 x + c \sum_{i=1}^r \lambda_i b_i (a_i x). \quad (3.6)$$

原文式 (8) 把分段条件写在 $[By']_i$ 上, 但 $By' \in \mathbb{R}^m$, 其指标属于输出维度而不是专家维度; 维度一致的分段定义应写成

$$y'_i = \begin{cases} y_i, & i \in S, \\ 0, & i \notin S. \end{cases} \quad (3.7)$$

3.2 无损负载均衡偏置

原文对偏置 $d \in \mathbb{R}^r$ 做非梯度更新:

$$d_i \leftarrow d_i + u \text{ sign}(\bar{c}_i - c_i). \quad (3.8)$$

若专家 i 的实际计数 c_i 小于目标计数 $\bar{c}_i$, 则 d_i 增加, 使其以后更容易进入 top- k ; 反之则降低。 d 不进入专家输出的数值, 只改变离散选择集合, 所以这种机制不向任务损失增加额外可训练参数。

3.3 单样本梯度的逐元素推导

固定本次前向得到的掩码 Λ , 定义

$$u = \Lambda A x \in \mathbb{R}^r, \quad h = W_0 x + c B u, \quad \delta = \frac{\partial \mathcal{L}}{\partial h} \in \mathbb{R}^m. \quad (3.9)$$

对 $B_{\mu i}$,

$$h_\nu = (W_0 x)_\nu + c \sum_{j=1}^r B_{\nu j} u_j, \quad (3.10)$$

$$\frac{\partial h_\nu}{\partial B_{\mu i}} = c \mathbf{1}\{\nu = \mu\} u_i, \quad (3.11)$$

$$\frac{\partial \mathcal{L}}{\partial B_{\mu i}} = \sum_{\nu=1}^m \frac{\partial \mathcal{L}}{\partial h_\nu} \frac{\partial h_\nu}{\partial B_{\mu i}} = c \delta_\mu u_i. \quad (3.12)$$

把所有元素重新组成矩阵, 得到

$$\boxed{\frac{\partial \mathcal{L}}{\partial B} = c \delta u^T = c \delta (Ax)^T \Lambda.} \quad (3.13)$$

第 i 列梯度为

$$g_i := \frac{\partial \mathcal{L}}{\partial b_i} = c \lambda_i (a_i x) \delta. \quad (3.14)$$

若定义不加 top- k 时的稠密梯度

$$g_i^{(0)} = c(a_i x) \delta, \quad (3.15)$$

则 $g_i = \lambda_i g_i^{(0)}$ 。这就是附录式 (14)

$$\frac{\partial \mathcal{L}}{\partial \widetilde{B}} = \frac{\partial \mathcal{L}}{\partial B} \Lambda \quad (3.16)$$

的逐列含义。

对批量 $\{x_s\}_{s=1}^N$ ，令相应量为 δ_s, Λ_s ，则

$$\frac{\partial \mathcal{L}_{\text{batch}}}{\partial B} = c \sum_{s=1}^N \delta_s (A x_s)^T \Lambda_s. \quad (3.17)$$

因为 A 冻结，算法不对离散 top- k 求导； d 由式 (3.8) 更新。

4 稀疏随机投影

4.1 两个不同的随机矩阵模型

主文采用“每行恰好 p 个非零元”的模型 (3.1)。附录 A.1 为了便于分析，实际改用逐元素独立的替代模型

$$A_{ij} = \frac{\xi_{ij} G_{ij}}{r}, \quad \xi_{ij} \sim \text{Bernoulli}(q), \quad G_{ij} \sim \mathcal{N}(0, 1), \quad q = \frac{p}{n}, \quad (4.1)$$

并假设所有 ξ_{ij}, G_{ij} 相互独立。两种模型的单个元素边缘分布相同，但前者同一行的支持位置互相依赖；所以从替代模型得到的定理不能不加说明地等同于原始模型定理。

令

$$z = x - y, \quad \sigma^2 = \mathbb{E}[A_{ij}^2] = \frac{q}{r^2} = \frac{p}{nr^2}. \quad (4.2)$$

因为各行独立且零均值，

$$\mathbb{E} \|Az\|_2^2 = \sum_{u=1}^r \mathbb{E} \left(\sum_{j=1}^n A_{uj} z_j \right)^2 \quad (4.3)$$

$$= \sum_{u=1}^r \sum_{j=1}^n \mathbb{E}[A_{uj}^2] z_j^2 \quad (4.4)$$

$$= r \sigma^2 \|z\|_2^2. \quad (4.5)$$

所以无偏归一化必须是

$$D_A(z) = \frac{1}{r \sigma^2} \|Az\|_2^2 = \frac{nr}{p} \|Az\|_2^2, \quad \mathbb{E} D_A(z) = \|z\|_2^2. \quad (4.6)$$

4.2 原论文声称的概率界

论文定理 3.1/A.2 声称：对任意 $\epsilon > 0$,

$$\begin{aligned} \mathbb{P} \left((1 - \epsilon) \|z\|_2^2 \leq D_A(z) \leq (1 + \epsilon) \|z\|_2^2 \right) \\ \geq 1 - \exp \left[-(\epsilon^2 - \epsilon^3) \frac{r}{4} \right] - \exp \left[-\frac{(\epsilon^2 - \epsilon^3) r}{2(3p/n + 1)} \right]. \end{aligned} \quad (4.7)$$

其意图是分别控制上尾和下尾，再用

$$\mathbb{P}(L \cap U) = 1 - \mathbb{P}(L^c \cup U^c) \geq 1 - \mathbb{P}(L^c) - \mathbb{P}(U^c) \quad (4.8)$$

合并两项。

4.3 附录所引用矩定理的两个尾界

为了看清常数如何进入结论，把论文附录引用的定理 A.1 改写到目前符号。设随机矩阵 $H \in \mathbb{R}^{r \times n}$ 的元素独立、关于零对称，且

$$\mathbb{E}[H_{ij}^2] = \sigma^2 > 0, \quad C = \mathbb{E}[H_{ij}^4] < \infty. \quad (4.9)$$

对固定的非零 $z \in \mathbb{R}^n$ ，其下尾界写为

$$\mathbb{P}\left(\frac{1}{r}\|Hz\|_2^2 \leq \sigma^2(1-\epsilon)\|z\|_2^2\right) \leq \exp\left[-\frac{(\epsilon^2 - \epsilon^3)r}{2(C/\sigma^4 + 1)}\right]. \quad (4.10)$$

若还存在与阶数无关的 $L > 0$ ，使得对所有整数 $s \geq 1$ ，

$$\mathbb{E}[H_{ij}^{2s}] \leq \sigma^{2s} \frac{(2s)!}{2^s s!} L^{2s}, \quad (4.11)$$

则引用定理给出的上尾界是

$$\mathbb{P}\left(\frac{1}{r}\|Hz\|_2^2 \geq \sigma^2(1+\epsilon)L^2\|z\|_2^2\right) \leq \exp\left[-(\epsilon^2 - \epsilon^3)\frac{r}{4}\right]. \quad (4.12)$$

注意上尾阈值含有 L^2 。若 $L = 1$ ，上下尾都围绕期望尺度 $\sigma^2\|z\|_2^2$ ；若 $L > 1$ ，式 (4.12) 只控制更远处的尾部。后面将看到，稀疏 Bernoulli-Gaussian 元素需要 $L \geq q^{-1/2}$ ，这正是原证明无法直接得到对称 $1 \pm \epsilon$ 界的关键。

4.4 偶数阶矩的完整计算

对任意整数 $s \geq 1$ ，由 $\xi^{2s} = \xi$ 和独立性，

$$\mathbb{E}[A_{ij}^{2s}] = \mathbb{E}[\xi_{ij}^{2s}] \mathbb{E}\left[\left(\frac{G_{ij}}{r}\right)^{2s}\right] \quad (4.13)$$

$$= q \frac{\mathbb{E}[G^{2s}]}{r^{2s}}. \quad (4.14)$$

标准高斯偶数阶矩为

$$\mathbb{E}[G^{2s}] = (2s-1)!! \quad (4.15)$$

$$= (2s-1)(2s-3)\cdots 3 \cdot 1 \quad (4.16)$$

$$= \frac{(2s)!}{2^s s!}. \quad (4.17)$$

因此

$$\boxed{\mathbb{E}[A_{ij}^{2s}] = q \frac{(2s)!}{2^s s!} \frac{1}{r^{2s}}}. \quad (4.18)$$

特别地，

$$C := \mathbb{E}[A_{ij}^4] = \frac{3q}{r^4} = \frac{3p}{nr^4}. \quad (4.19)$$

4.5 原证明不能直接闭合的四个位置

1. 随机模型发生了替换。“每行恰好 p 个”不等于逐元素独立 Bernoulli(p/n)；后者每行非零数是随机变量。
2. 高斯矩的幂次。若方差为 $1/r^2$ ，则

$$\mathbb{E}[(G/r)^{2s}] = (2s-1)!! (1/r^2)^s, \quad (4.20)$$

而不是 $(2s-1)!! (1/r^2)^{2s}$ 。

3. 四阶矩比值。由 (4.2)、(4.19),

$$\frac{C}{\sigma^4} = \frac{3q/r^4}{q^2/r^4} = \frac{3}{q} = \frac{3n}{p}, \quad (4.21)$$

不是 $3p/n$ 。因此直接代入附录定理 A.1 的下尾常数, 会得到 $2(3n/p + 1)$, 而不是式 (4.7) 中的 $2(3p/n + 1)$ 。

4. 统一矩常数 L 。附录引用的上尾条件要求

$$\mathbb{E}[A_{ij}^{2s}] \leq \sigma^{2s} \frac{(2s)!}{2^s s!} L^{2s} \quad (\forall s \geq 1). \quad (4.22)$$

代入 (4.18) 和 $\sigma^{2s} = q^s/r^{2s}$, 等价于

$$q \leq q^s L^{2s} \iff L \geq q^{-\frac{s-1}{2s}}. \quad (4.23)$$

对所有 s 统一成立的简单选择是

$$L = q^{-1/2} = \sqrt{\frac{n}{p}}. \quad (4.24)$$

但该引用定理的上尾阈值会包含 $L^2 = n/p$, 因而不能推出围绕 $1 + \epsilon$ 的对称界。

所以, 式 (4.7) 应理解为论文的目标性结论; 按照附录当前写出的代数, 尚不能把它视作已经严格证明的 Johnson–Lindenstrauss 型指数界。

4.6 一条可完全验证的修正界

下面仍在逐元素独立模型 (4.1) 下, 推导一条常数透明、无需引用外部定理的界。令第 u 行投影为

$$S_u = \sum_{j=1}^n A_{uj} z_j, \quad \|Az\|_2^2 = \sum_{u=1}^r S_u^2. \quad (4.25)$$

对独立、零均值、同方差的随机变量展开四次方, 只保留“同一指标出现四次”和“两个指标各出现两次”的项:

$$\mathbb{E}[S_u^4] = \sum_{j=1}^n C z_j^4 + 6 \sum_{j < \ell} \sigma^4 z_j^2 z_\ell^2 \quad (4.26)$$

$$= 3\sigma^4 \left(\sum_{j=1}^n z_j^2 \right)^2 + (C - 3\sigma^4) \sum_{j=1}^n z_j^4. \quad (4.27)$$

又因为 $\mathbb{E}[S_u^2] = \sigma^2 \|z\|_2^2$,

$$\text{Var}(S_u^2) = \mathbb{E}[S_u^4] - (\mathbb{E}[S_u^2])^2 \quad (4.28)$$

$$= 2\sigma^4 \|z\|_2^4 + (C - 3\sigma^4) \|z\|_4^4. \quad (4.29)$$

各行独立, 故

$$\text{Var}(\|Az\|_2^2) = r [2\sigma^4 \|z\|_2^4 + (C - 3\sigma^4) \|z\|_4^4]. \quad (4.30)$$

定义集中度参数

$$\kappa(z) = \frac{\|z\|_4^4}{\|z\|_2^4}, \quad \frac{1}{n} \leq \kappa(z) \leq 1. \quad (4.31)$$

对归一化距离 $R_A(z) = D_A(z)/\|z\|_2^2$, 由 (4.21) 得

$$\text{Var}(R_A(z)) = \frac{2}{r} + \frac{1}{r} \left(\frac{C}{\sigma^4} - 3 \right) \kappa(z) \quad (4.32)$$

$$= \frac{1}{r} \left[2 + \frac{3(1-q)}{q} \kappa(z) \right]. \quad (4.33)$$

应用切比雪夫不等式, 得到严格有效的双侧界

$$\mathbb{P} \left(\left| \frac{D_A(z)}{\|z\|_2^2} - 1 \right| \geq \epsilon \right) \leq \frac{2 + 3(1-q)\kappa(z)/q}{r\epsilon^2}. \quad (4.34)$$

式 (4.34) 是可直接验证的多项式尾界, 不是论文声称的指数尾界。

5 top- k 如何降低列间梯度协方差

5.1 均匀无放回激活的精确概率

附录假设每个样本从 r 列中均匀、无放回地选出恰好 k 列。于是对任意 $i \neq j$,

$$q_1 := \mathbb{P}(\lambda_i = 1) = \frac{\binom{r-1}{k-1}}{\binom{r}{k}} = \frac{k}{r}, \quad (5.1)$$

而共同激活概率为

$$q_2 := \mathbb{P}(\lambda_i = 1, \lambda_j = 1) \quad (5.2)$$

$$= \frac{\binom{r-2}{k-2}}{\binom{r}{k}} = \frac{k(k-1)}{r(r-1)}. \quad (5.3)$$

近似式

$$q_2 \approx \frac{k^2}{r^2} \quad (5.4)$$

只在忽略减一项时成立；精确比值为

$$\frac{q_2}{k^2/r^2} = \frac{r(k-1)}{k(r-1)}. \quad (5.5)$$

当 $k = 1$ 时, $q_2 = 0$, 而 $k^2/r^2 = 1/r^2$, 所以“几乎为零”可加强为“在该随机掩码模型下严格为零”。

5.2 零均值与独立假设下的精确证明

令 $g_i^{(0)}, g_j^{(0)} \in \mathbb{R}^m$ 为不加掩码的随机梯度列, 令

$$\tilde{g}_i = \lambda_i g_i^{(0)}, \quad \tilde{g}_j = \lambda_j g_j^{(0)}. \quad (5.6)$$

使用两个关键假设:

$$(\lambda_i, \lambda_j) \text{ 与 } (g_i^{(0)}, g_j^{(0)}) \text{ 独立}, \quad \mathbb{E}[g_i^{(0)}] = \mathbb{E}[g_j^{(0)}] = 0. \quad (5.7)$$

定义标量型列间协方差

$$\Sigma_{ij} = \mathbb{E}[(g_i^{(0)})^T g_j^{(0)}] - \mathbb{E}[g_i^{(0)}]^T \mathbb{E}[g_j^{(0)}]. \quad (5.8)$$

在零均值下, $\Sigma_{ij} = \mathbb{E}[(g_i^{(0)})^T g_j^{(0)}]$ 。于是

$$\tilde{\Sigma}_{ij} = \mathbb{E}[\tilde{g}_i^T \tilde{g}_j] \quad (5.9)$$

$$= \mathbb{E}[\lambda_i \lambda_j (g_i^{(0)})^T g_j^{(0)}] \quad (5.10)$$

$$= \mathbb{E}[\lambda_i \lambda_j] \mathbb{E}[(g_i^{(0)})^T g_j^{(0)}] \quad (5.11)$$

$$= q_2 \Sigma_{ij}. \quad (5.12)$$

故精确结论是

$$\boxed{\tilde{\Sigma}_{ij} = \frac{k(k-1)}{r(r-1)} \Sigma_{ij}, \quad i \neq j.} \quad (5.13)$$

论文定理 3.3 的 k^2/r^2 是式 (5.13) 的渐近近似。

对角项不同:

$$\tilde{\Sigma}_{ii} = \mathbb{E}[\lambda_i^2 \|g_i^{(0)}\|_2^2] \quad (5.14)$$

$$= \mathbb{E}[\lambda_i] \mathbb{E}[\|g_i^{(0)}\|_2^2] \quad (5.15)$$

$$= \frac{k}{r} \Sigma_{ii}. \quad (5.16)$$

所以非对角协方差按约 $(k/r)^2$ 缩小, 而方差只按 k/r 缩小。若进一步用相关系数归一化,

$$\widetilde{\text{Corr}}_{ij} = \frac{q_2}{q_1} \text{Corr}_{ij} = \frac{k-1}{r-1} \text{Corr}_{ij}. \quad (5.17)$$

这比只看协方差更直接地解释论文热力图中非对角相关性的变浅。

5.3 非零均值时多出的项

令 $\mu_i = \mathbb{E}[g_i^{(0)}]$ 、 $\mu_j = \mathbb{E}[g_j^{(0)}]$ ，仍假设掩码与梯度独立。则

$$\tilde{\Sigma}_{ij} = q_2 \mathbb{E}[(g_i^{(0)})^T g_j^{(0)}] - q_1^2 \mu_i^T \mu_j \quad (5.18)$$

$$= q_2 \Sigma_{ij} + (q_2 - q_1^2) \mu_i^T \mu_j. \quad (5.19)$$

固定选 k 个坐标属于无放回抽样，故

$$q_2 - q_1^2 = -\frac{k(r-k)}{r^2(r-1)} \leq 0. \quad (5.20)$$

因此若不作零均值假设，不能只乘一个 q_2 。

5.4 适用条件

真实掩码与梯度都依赖 Ax ，因此二者并不严格独立。式 (5.13) 严格对应均匀随机掩码代理模型；真实 top- k 的缩放因子取决于掩码和梯度的联合分布。

6 跨任务随机子空间近似正交

6.1 交叉 Gram 矩阵的均值

取两个任务独立初始化的随机投影

$$A_i, A_j \in \mathbb{R}^{r \times n}, \quad i \neq j, \quad (6.1)$$

每个元素零均值、方差 $\sigma^2 = p/(nr^2)$ 。定义行空间交叉 Gram 矩阵

$$M_{ij} = A_i A_j^T \in \mathbb{R}^{r \times r}. \quad (6.2)$$

第 (u, v) 个元素为

$$(M_{ij})_{uv} = \sum_{\ell=1}^n (A_i)_{u\ell} (A_j)_{v\ell}. \quad (6.3)$$

两个任务的矩阵独立，故

$$\mathbb{E}[(M_{ij})_{uv}] = \sum_{\ell=1}^n \mathbb{E}[(A_i)_{u\ell}] \mathbb{E}[(A_j)_{v\ell}] \quad (6.4)$$

$$= 0, \quad (6.5)$$

从而

$$\boxed{\mathbb{E}[A_i A_j^T] = 0_{r \times r}.} \quad (6.6)$$

这是“均值正交”，不是说每次随机初始化后都精确正交。

6.2 单个元素的方差

令 $X_\ell = (A_i)_{u\ell}$ 、 $Y_\ell = (A_j)_{v\ell}$ 。不同任务独立且零均值，交叉坐标项的期望为零，因此

$$\text{Var}((M_{ij})_{uv}) = \mathbb{E} \left(\sum_{\ell=1}^n X_\ell Y_\ell \right)^2 \quad (6.7)$$

$$= \sum_{\ell=1}^n \mathbb{E}[X_\ell^2] \mathbb{E}[Y_\ell^2] \quad (6.8)$$

$$= n \sigma^4 \quad (6.9)$$

$$= n \left(\frac{p}{nr^2} \right)^2 = \frac{p^2}{nr^4}. \quad (6.10)$$

于是切比雪夫不等式给出

$$\mathbb{P}(|(M_{ij})_{uv}| \geq \epsilon) \leq \frac{p^2}{nr^4\epsilon^2}. \quad (6.11)$$

6.3 从元素界到矩阵范数界

若 $\|M_{ij}\|_F \geq \epsilon r$, 则 r^2 个元素中至少有一个的绝对值不小于 ϵ ; 否则所有元素均小于 ϵ , Frobenius 范数就小于 $\sqrt{r^2\epsilon^2} = \epsilon r$ 。因此由并合界

$$\mathbb{P}(\|M_{ij}\|_F \geq \epsilon r) \leq \sum_{u=1}^r \sum_{v=1}^r \mathbb{P}(|(M_{ij})_{uv}| \geq \epsilon) \quad (6.12)$$

$$\leq r^2 \frac{p^2}{nr^4\epsilon^2} = \frac{p^2}{nr^2\epsilon^2}. \quad (6.13)$$

再由 $\|M\|_2 \leq \|M\|_F$, 得到论文定理 3.4 的有效但较松界

$$\mathbb{P}(\|A_i A_j^T\|_2 \geq \epsilon r) \leq \frac{p^2}{nr^2\epsilon^2}. \quad (6.14)$$

还可以直接计算

$$\mathbb{E}\|M_{ij}\|_F^2 = \sum_{u,v} \mathbb{E}[(M_{ij})_{uv}^2] \quad (6.15)$$

$$= r^2 \frac{p^2}{nr^4} = \frac{p^2}{nr^2}. \quad (6.16)$$

对 $\|M_{ij}\|_F^2$ 使用 Markov 不等式, 甚至得到更强的同阈值界

$$\mathbb{P}(\|M_{ij}\|_F \geq \epsilon r) \leq \frac{p^2}{nr^4\epsilon^2}. \quad (6.17)$$

式 (6.14) 仍然成立, 只是没有利用所有元素平方和的期望。

6.4 如何传递到 LoRA 更新矩阵

令两个任务的更新为

$$U_i = B_i A_i, \quad U_j = B_j A_j. \quad (6.18)$$

其 Frobenius 内积逐步变形为

$$\langle U_j, U_i \rangle_F = \text{tr}(U_j^T U_i) \quad (6.19)$$

$$= \text{tr}(A_j^T B_j^T B_i A_i) \quad (6.20)$$

$$= \text{tr}(B_j^T B_i A_i A_j^T). \quad (6.21)$$

最后一步用到了迹的循环不变性: 只要乘积维度合法, $\text{tr}(XYZ) = \text{tr}(ZXY)$ 。

令 $C_{ji} = B_j^T B_i$, $M_{ij} = A_i A_j^T$ 。Frobenius Cauchy-Schwarz 不等式给出

$$|\langle U_j, U_i \rangle_F| = |\text{tr}(C_{ji} M_{ij})| \leq \|C_{ji}\|_F \|M_{ij}\|_F. \quad (6.22)$$

进一步,

$$\|B_j^T B_i\|_F \leq \|B_j\|_2 \|B_i\|_F, \quad (6.23)$$

所以只有在 $A_i A_j^T$ 小且 B_i, B_j 的范数受到控制时, 才能定量地说更新近似正交。原文“对任意学得的 $B_i A_i, B_j A_j$ 都有内积约为零”需要隐含这一范数条件; 若任意放大 B , 绝对内积也可被任意放大。

6.5 模型合并范数的精确展开

对 t 个任务，令

$$\Delta W_{\text{merge}} = \sum_{i=1}^t w_i U_i, \quad W' = W_0 + \Delta W_{\text{merge}}. \quad (6.24)$$

由双线性展开，

$$\|\Delta W_{\text{merge}}\|_{\text{F}}^2 = \left\langle \sum_i w_i U_i, \sum_j w_j U_j \right\rangle_{\text{F}} \quad (6.25)$$

$$= \sum_{i=1}^t w_i^2 \|U_i\|_{\text{F}}^2 + 2 \sum_{1 \leq i < j \leq t} w_i w_j \langle U_i, U_j \rangle_{\text{F}} \quad (6.26)$$

$$= \sum_{i=1}^t w_i^2 \|U_i\|_{\text{F}}^2 + \sum_{i \neq j} w_i w_j \langle U_i, U_j \rangle_{\text{F}}. \quad (6.27)$$

若所有交叉内积相对较小，则

$$\|\Delta W_{\text{merge}}\|_{\text{F}}^2 \approx \sum_{i=1}^t w_i^2 \|U_i\|_{\text{F}}^2. \quad (6.28)$$

近似误差可以显式控制：

$$\left| \|\Delta W_{\text{merge}}\|_{\text{F}}^2 - \sum_i w_i^2 \|U_i\|_{\text{F}}^2 \right| \quad (6.29)$$

$$\leq 2 \sum_{i < j} |w_i w_j| \|B_j^{\text{T}} B_i\|_{\text{F}} \|A_i A_j^{\text{T}}\|_{\text{F}}. \quad (6.30)$$