

34_Toy Models of Superposition

1 符号与维度

符号	维度	含义
$x, \hat{x}$	$\mathbb{R}^n$	稀疏输入特征与重建。
W	$\mathbb{R}^{m \times n}$	$m < n$ 的线性瓶颈。
w_i	$\mathbb{R}^m$	第 i 个特征的表示方向。
I_i	$\mathbb{R}_{>0}$	特征重要度。
$G = W^T W$	$\mathbb{R}^{n \times n}$	表示方向 Gram 矩阵。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 线性自编码器中的干扰展开

设 n 个理想特征 $x \in \mathbb{R}^n$ 被压入 $m < n$ 维，列向量 $w_i \in \mathbb{R}^m$ 组成 $W = [w_1, \dots, w_n]$ 。绑权重线性重建

$$\hat{x} = W^T W x. \quad (2.1)$$

第 i 个坐标

$$\hat{x}_i = w_i^T \sum_j w_j x_j = \|w_i\|_2^2 x_i + \sum_{j \neq i} (w_i^T w_j) x_j. \quad (2.2)$$

第一项是自信号，第二项是其他特征通过 Gram 非对角元产生的干扰。

令重要性权重 $I_i \geq 0$ ，平方损失

$$\mathcal{L} = \mathbb{E} \sum_i I_i (x_i - \hat{x}_i)^2. \quad (2.3)$$

假设各特征独立、均值零、方差 v_j ，交叉项期望消失，得到

$$\mathbb{E}(x_i - \hat{x}_i)^2 = (1 - \|w_i\|^2)^2 v_i + \sum_{j \neq i} (w_i^T w_j)^2 v_j. \quad (2.4)$$

所以

$$\mathcal{L} = \sum_i I_i (1 - \|w_i\|^2)^2 v_i + \sum_i \sum_{j \neq i} I_i (w_i^T w_j)^2 v_j. \quad (2.5)$$

正交表示消除干扰但最多容纳 m 个非零方向；超位置用小而非零的内积容纳更多特征。

3 稀疏性为何降低期望干扰

若

$$x_j = \begin{cases} 0, & \text{概率 } S_j, \\ \xi_j, & \text{概率 } 1 - S_j, \end{cases} \quad (3.1)$$

且 $\mathbb{E}\xi_j = 0$ 、 $\mathbb{E}\xi_j^2 = v_j$ ，则

$$v_j = \mathbb{E}x_j^2 = (1 - S_j)v_j. \quad (3.2)$$

干扰项变为

$$\sum_{j \neq i} (w_i^T w_j)^2 (1 - S_j) \nu_j. \quad (3.3)$$

当特征很少同时激活，方向非正交造成的平均代价按激活概率下降；这给“稀疏特征可以超位置”一个定量解释。

若特征均值不为零， $\mathbb{E}[x_j x_k]$ 的交叉项不再消失，损失还包含

$$\sum_{j \neq k} (w_i^T w_j)(w_i^T w_k) \mathbb{E}[x_j x_k]. \quad (3.4)$$

因此独立零均值假设是上述简化式的重要前提。

4 Gram 矩阵与 Welch 下界

假设 n 个方向单位化， $\|w_i\| = 1$ 。Gram 矩阵 $G = W^T W \in \mathbb{R}^{n \times n}$ ，秩至多 m ，迹

$$\text{tr } G = \sum_i \|w_i\|^2 = n. \quad (4.1)$$

设 G 的非零特征值为 $\lambda_1, \dots, \lambda_m$ 。由 Cauchy-Schwarz,

$$\|G\|_F^2 = \sum_{k=1}^m \lambda_k^2 \geq \frac{1}{m} \left(\sum_k \lambda_k \right)^2 = \frac{n^2}{m}. \quad (4.2)$$

另一方面

$$\|G\|_F^2 = \sum_i G_{ii}^2 + \sum_{i \neq j} G_{ij}^2 = n + \sum_{i \neq j} (w_i^T w_j)^2. \quad (4.3)$$

故

$$\boxed{\frac{1}{n(n-1)} \sum_{i \neq j} (w_i^T w_j)^2 \geq \frac{n-m}{m(n-1)}}. \quad (4.4)$$

于是最大相干性也满足

$$\max_{i \neq j} |w_i^T w_j| \geq \sqrt{\frac{n-m}{m(n-1)}}. \quad (4.5)$$

这说明 $n > m$ 时不可能让全部方向严格正交，最优只能均匀分配干扰。

5 ReLU 输出与负干扰的非对称性

带偏置的模型

$$\hat{x} = \text{ReLU}(W^T W x + b) \quad (5.1)$$

在第 i 坐标预激活

$$a_i = \|w_i\|^2 x_i + \sum_{j \neq i} (w_i^T w_j) x_j + b_i. \quad (5.2)$$

梯度门为

$$\frac{\partial \hat{x}_i}{\partial a_i} = \mathbf{1}\{a_i > 0\} \quad (5.3)$$

（零点取任一子梯度）。如果真实特征非负，适当负偏置可让小的纯干扰预激活被截为零，而强自信号仍越过阈值。这使正负内积的代价不再对称，几何最优可形成多边形、反向对等相位。

6 单特征表示、超位置与忽略的比较

考虑一个重要性 I 、激活概率 $p = 1 - S$ 的特征。若完全忽略，输出恒为零，代价

$$L_{\text{ignore}} = I\mathbb{E}x^2 = Ip\nu. \quad (6.1)$$

若独占单位方向且解码无偏，理想代价接近零。若加入超位置，它获得自信信号但产生/承受干扰，粗略代价可写

$$L_{\text{super}} \approx I(1 - \|w_i\|^2)^2 p\nu + Ip \sum_{j \neq i} p_j \nu_j (w_i^T w_j)^2. \quad (6.2)$$

随着 I 或 p 增加，忽略代价线性上升，模型更愿分配专属维度；当 p 很小，干扰又被联合激活概率削弱，超位置更划算。不同方案损失曲线交叉时，全局最优结构会突然切换，形成观察到的相变。

7 多义神经元与可解释性的区别

隐藏坐标 $h = Wx$ 的第 k 个神经元

$$h_k = \sum_i W_{ki} x_i \quad (7.1)$$

通常同时响应多个特征；但表示方向是列 w_i ，不必与坐标轴对齐。若 $R \in \mathbb{R}^{m \times m}$ 正交，替换

$$W \leftarrow RW \quad (7.2)$$

不会改变 Gram 矩阵

$$(RW)^T(RW) = W^T W, \quad (7.3)$$

因而重建函数不变，却会完全旋转神经元坐标。可辨识的是特征方向间的几何关系，不是某个隐藏坐标的绝对语义。

8 压缩感知类比的边界

若 x 是 k -稀疏，随机测量 $h = Wx$ 在满足受限等距性质时可由非线性优化恢复。RIP 要求所有 k -稀疏向量满足

$$(1 - \delta)\|x\|_2^2 \leq \|Wx\|_2^2 \leq (1 + \delta)\|x\|_2^2. \quad (8.1)$$

随机矩阵通常需 $m = O(k \log(n/k)/\delta^2)$ 。玩具模型解码器 $\text{ReLU}(W^T h + b)$ 并不是通用 ℓ_1 恢复算法，因此“超位置类似压缩感知”是几何动机，不能直接继承精确恢复定理。

9 低秩更新的完整矩阵微分

令冻结权重 $W_0 \in \mathbb{R}^{m \times n}$ ，低秩更新

$$W = W_0 + cBA, \quad B \in \mathbb{R}^{m \times r}, \quad A \in \mathbb{R}^{r \times n}, \quad c = \alpha/r. \quad (9.1)$$

对一个输入 $x \in \mathbb{R}^n$,

$$h = W_0 x + cB(Ax). \quad (9.2)$$

令 $y = Ax \in \mathbb{R}^r$ 、输出梯度 $g = \partial \mathcal{L} / \partial h \in \mathbb{R}^m$ 。微分为

$$dh = c dB y + c B dA x + c B A dx + W_0 dx. \quad (9.3)$$

由 $d\mathcal{L} = g^T dh$ 以及 $a^T dM b = \langle ab^T, dM \rangle_F$ ，逐项得到

$$\boxed{\nabla_B \mathcal{L} = c, g, y^T = c, g, x^T A^T,} \quad (9.4)$$

$$\boxed{\nabla_A \mathcal{L} = c, B^T g, x^T,} \quad (9.5)$$

$$\boxed{\nabla_x \mathcal{L} = W_0^T g + c A^T B^T g.} \quad (9.6)$$

若批输入按行堆成 $X \in \mathbb{R}^{b \times n}$, 上游梯度为 $G \in \mathbb{R}^{b \times m}$, 则

$$\nabla_B \mathcal{L} = cG^T X A^T, \quad (9.7)$$

$$\nabla_A \mathcal{L} = cB^T G^T X. \quad (9.8)$$

9.1 rank-1 专家分解

写 $B = [b_1, \dots, b_r]$ 、 A 的第 i 行为 a_i^T , 则

$$BA = \sum_{i=1}^r b_i a_i^T, \quad BAx = \sum_{i=1}^r b_i (a_i^T x). \quad (9.9)$$

每一项均为秩至多 1 的更新。对单样本,

$$\nabla_{b_i} \mathcal{L} = c(a_i^T x)g, \quad \nabla_{a_i} \mathcal{L} = c(b_i^T g)x. \quad (9.10)$$

于是列 b_i 的更新强度由标量路由量 $a_i^T x$ 控制; 这也是把 rank 分量解释为隐式专家的数学依据。

10 初始化时两因子的非对称动力学

常见初始化为 $B_0 = 0$ 、 A_0 随机。此时

$$\Delta W_0 = cB_0 A_0 = 0, \quad (10.1)$$

所以前向不改变基座。梯度却满足

$$\nabla_B \mathcal{L}|_0 = cG^T X A_0^T, \quad \nabla_A \mathcal{L}|_0 = cB_0^T G^T X = 0. \quad (10.2)$$

第一步梯度下降

$$B_1 = -\eta cG^T X A_0^T, \quad A_1 = A_0, \quad (10.3)$$

因此第二步开始 A 才获得非零梯度。若反过来令 $A_0 = 0$ 、 B_0 随机, 则第一步只有 A 更新。两种初始化前向等价, 但早期优化动力学不同。

还有尺度不识别性: 任意 $s \neq 0$ 满足

$$BA = (sB)(s^{-1}A). \quad (10.4)$$

然而带独立权重衰减时

$$\|sB\|_F^2 + \|s^{-1}A\|_F^2 = s^2\|B\|_F^2 + s^{-2}\|A\|_F^2, \quad (10.5)$$

最优平衡尺度由求导得到

$$s^4 = \frac{\|A\|_F^2}{\|B\|_F^2}. \quad (10.6)$$

故因子正则化会隐式选择分解, 即使乘积 BA 相同。

11 最佳秩约束近似

设目标全量更新的奇异值分解为

$$\Delta W^* = U \Sigma V^T = \sum_{i=1}^q \sigma_i u_i v_i^T, \quad \sigma_1 \geq \dots \geq \sigma_q \geq 0. \quad (11.1)$$

截断矩阵

$$\Delta W_r = \sum_{i=1}^r \sigma_i u_i v_i^T \quad (11.2)$$

满足 Eckart–Young–Mirsky 结论

$$\min_{\text{rank}(M) \leq r} \|\Delta W^* - M\|_F^2 = \sum_{i>r} \sigma_i^2. \quad (11.3)$$

一种直接证明如下。因 Frobenius 范数在正交变换下不变，令 $C = U^T M V$ ，则 $\text{rank}(C) \leq r$ 且

$$\|\Delta W^* - M\|_F^2 = \|\Sigma - C\|_F^2. \quad (11.4)$$

任意秩不超过 r 的 C 至多精确保留 r 个相互正交奇异方向；由奇异值的变分刻画或 Pythagoras 分解，剩余平方能量至少为 $\sum_{i>r} \sigma_i^2$ 。取 $C = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots)$ 达到该下界。

谱范数版本为

$$\min_{\text{rank}(M) \leq r} \|\Delta W^* - M\|_2 = \sigma_{r+1}. \quad (11.5)$$

这只是表达能力上界；训练能否找到截断 SVD 解还取决于非凸因子化、数据和优化器。

12 子空间限制与梯度投影

若 A 冻结，只训练 B ，可达更新集合为

$$\mathcal{S}_A = \{BA : B \in \mathbb{R}^{m \times r}\}. \quad (12.1)$$

其中每一行都位于 A 的行空间。若 A 满行秩，其行空间正交投影为

$$P_A = A^T (A A^T)^{-1} A. \quad (12.2)$$

给定任意目标更新 M ，最小二乘问题

$$\min_B \|M - BA\|_F^2 \quad (12.3)$$

的正规方程为

$$(BA - M)A^T = 0, \quad B^* = M A^T (A A^T)^{-1}. \quad (12.4)$$

故最佳可达更新

$$B^* A = M P_A, \quad \min_B \|M - BA\|_F^2 = \|M(I - P_A)\|_F^2. \quad (12.5)$$

这把“冻结随机下投影”的表达损失精确写成目标在随机行空间外的能量。

13 随机投影的尺度与集中

设 A_{ij} 独立、均值零、方差 $1/r$ 。对固定 $x \in \mathbb{R}^n$,

$$\mathbb{E} \|Ax\|_2^2 = \sum_{i=1}^r \mathbb{E} \left(\sum_j A_{ij} x_j \right)^2 \quad (13.1)$$

$$= \sum_i \sum_j \mathbb{E} [A_{ij}^2] x_j^2 = \|x\|_2^2. \quad (13.2)$$

若 $A_{ij} \sim \mathcal{N}(0, 1/r)$ ，则

$$\frac{\|Ax\|_2^2}{\|x\|_2^2} \sim \frac{1}{r} \chi_r^2. \quad (13.3)$$

利用卡方尾界，对 $0 < \varepsilon < 1$,

$$\mathbb{P} \left(\left| \|Ax\|_2^2 - \|x\|_2^2 \right| \geq \varepsilon \|x\|_2^2 \right) \leq 2 \exp \left(-\frac{r}{8} \varepsilon^2 \right). \quad (13.4)$$

对有限集合 N 个向量做并合界，若

$$r \geq \frac{8}{\varepsilon^2} \log \frac{2N}{\delta}, \quad (13.5)$$

则所有向量同时保持范数的概率至少为 $1 - \delta$ 。对点对差向量应用同一结论即得到距离保持。

稀疏随机投影若每个元素以概率 ρ 非零，则为保持同样二阶矩，非零幅值应按 $1/\sqrt{\rho r}$ 缩放：

$$A_{ij} = \begin{cases} +1/\sqrt{\rho r}, & \rho/2, \\ -1/\sqrt{\rho r}, & \rho/2, \\ 0, & 1 - \rho. \end{cases} \quad (13.6)$$

此时 $\mathbb{E}[A_{ij}^2] = 1/r$ ，但四阶矩为 $\mathbb{E}[A_{ij}^4] = 1/(\rho r^2)$ ； ρ 越小，尾部越重，获得同样集中精度通常需要更大 r 。

14 任务更新的干扰量

两个任务的更新 $U_i = B_i A_i$ 、 $U_j = B_j A_j$ 的 Frobenius 内积为

$$\langle U_i, U_j \rangle_F = \text{tr}((B_i A_i)^T B_j A_j) \quad (14.1)$$

$$= \text{tr}(B_i^T B_j A_j A_i^T). \quad (14.2)$$

因此

$$|\langle U_i, U_j \rangle_F| \leq \|B_i^T B_j\|_F \|A_j A_i^T\|_F. \quad (14.3)$$

随机下投影近似正交只控制第二个因子；若 B_i, B_j 范数无界，绝对干扰仍可任意大。对加权合并 $U = \sum_i w_i U_i$,

$$\|U\|_F^2 = \sum_i w_i^2 \|U_i\|_F^2 + 2 \sum_{i < j} w_i w_j \langle U_i, U_j \rangle_F. \quad (14.4)$$

交叉项就是任务干扰对合并范数的精确贡献，而不是抽象的“方向冲突”。

15 参数量、训练内存与合并

全量矩阵参数量为 mn ，低秩因子参数量为

$$r(m + n), \quad (15.1)$$

压缩要求 $r < mn/(m + n)$ 。训练时只有可训练因子需要梯度和优化器状态；冻结基座仍需存储权重并参与前向、反向的输入梯度计算。

推理前可合并

$$W_{\text{merged}} = W_0 + cBA. \quad (15.2)$$

合并后对单个适配器不增加矩阵乘次数，但丢失了动态切换不同适配器的便利。若基座以低比特存储，通常必须先计算精度中反量化再加 BA ；直接在整数码空间相加并不等价。

16 条件期望作为 L^2 正交投影

令随机向量 $Y \in L^2$ ，观测 Z 生成子空间

$$\mathcal{H}_Z = \{f(Z) : \mathbb{E}\|f(Z)\|^2 < \infty\}. \quad (16.1)$$

条件期望 $m(Z) = \mathbb{E}[Y | Z]$ 满足任意 $h(Z) \in \mathcal{H}_Z$ ：

$$\mathbb{E}[(Y - m(Z))^T h(Z)] = 0. \quad (16.2)$$

因为

$$\mathbb{E}[(Y - m)^T h] = \mathbb{E}\{\mathbb{E}[(Y - m)^T h \mid Z]\} \quad (16.3)$$

$$= \mathbb{E}\{h^T \mathbb{E}[Y - m \mid Z]\} = 0. \quad (16.4)$$

于是 Pythagoras 恒等式

$$\mathbb{E}\|Y - f(Z)\|^2 = \mathbb{E}\|Y - m(Z)\|^2 + \mathbb{E}\|m(Z) - f(Z)\|^2. \quad (16.5)$$

多数回归、去噪、流匹配和局部目标的“最优预测器”都由这一投影结论得到。

全方差公式也是同一正交分解：

$$\text{Var}(Y) = \mathbb{E} \text{Var}(Y \mid Z) + \text{Var}(\mathbb{E}[Y \mid Z]). \quad (16.6)$$

第一项是观测 Z 后仍不可约的不确定性，第二项是不同 Z 条件均值的变化。

17 Jensen、对数和与变分界

对凹函数 $\log$,

$$\log \mathbb{E}X \geq \mathbb{E} \log X, \quad X > 0. \quad (17.1)$$

差距可以写成 KL。令未归一权重 $w(z) > 0$ 、提议分布 $q(z)$ ，配分函数 $Z = \mathbb{E}_q w(z)$ ，定义

$$p^*(z) = \frac{q(z)w(z)}{Z}. \quad (17.2)$$

则

$$\log Z - \mathbb{E}_q \log w = \mathbb{E}_q \log \frac{Z}{w(z)} \quad (17.3)$$

$$= \mathbb{E}_q \log \frac{q(z)}{p^*(z)} \quad (17.4)$$

$$= D_{\text{KL}}(q \| p^*) \geq 0. \quad (17.5)$$

因此 Jensen 下界何时紧不只取决于“方差小”，而是提议分布是否等于归一化后的目标分布。

log-sum-exp

$$\text{LSE}(x) = \log \sum_{i=1}^n e^{x_i} \quad (17.6)$$

满足

$$\max_i x_i \leq \text{LSE}(x) \leq \max_i x_i + \log n. \quad (17.7)$$

减去最大值 $m = \max_i x_i$ 后计算

$$\text{LSE}(x) = m + \log \sum_i e^{x_i - m} \quad (17.8)$$

可避免指数上溢且数学等价。

18 Hoeffding 不等式的矩母函数推导

设独立 $X_i \in [a_i, b_i]$ ， $S = \sum_i (X_i - \mathbb{E}X_i)$ 。对任意 $\lambda > 0$ ，Markov 不等式

$$\mathbb{P}(S \geq t) = \mathbb{P}(e^{\lambda S} \geq e^{\lambda t}) \leq e^{-\lambda t} \mathbb{E} e^{\lambda S}. \quad (18.1)$$

独立性给出矩母函数乘积。Hoeffding 引理

$$\mathbb{E} e^{\lambda(X_i - \mathbb{E}X_i)} \leq \exp\left(\frac{\lambda^2(b_i - a_i)^2}{8}\right). \quad (18.2)$$

故

$$\mathbb{P}(S \geq t) \leq \exp \left(-\lambda t + \frac{\lambda^2}{8} \sum_i (b_i - a_i)^2 \right). \quad (18.3)$$

对 λ 最小化,

$$\lambda^* = \frac{4t}{\sum_i (b_i - a_i)^2}, \quad (18.4)$$

得到

$$\mathbb{P}(S \geq t) \leq \exp \left(-\frac{2t^2}{\sum_i (b_i - a_i)^2} \right). \quad (18.5)$$

对下尾应用于 $-S$, 再 union bound 得双侧界。

19 Bernstein 界利用方差信息

若独立零均值 X_i 满足 $|X_i| \leq M$, 总方差 $v = \sum_i \mathbb{E}X_i^2$, Bernstein 界

$$\mathbb{P} \left(\sum_i X_i \geq t \right) \leq \exp \left(-\frac{t^2}{2(v + Mt/3)} \right). \quad (19.1)$$

当 $t \ll v/M$ 时近似高斯尾 $e^{-t^2/(2v)}$; 当 t 很大时转为 $e^{-3t/(2M)}$ 。相比只使用取值区间的 Hoeffding, 方差远小于最坏范围时 Bernstein 更紧。

对 Bernoulli 均值 $\hat{p} = N^{-1} \sum_i X_i$, $v = Np(1-p)$,

$$\mathbb{P}(|\hat{p} - p| \geq \epsilon) \leq 2 \exp \left(-\frac{N\epsilon^2}{2[p(1-p) + \epsilon/3]} \right). \quad (19.2)$$

20 并合界与同时保证

事件 $E_1, \dots, E_M$ 不要求独立也有

$$\mathbb{P} \left(\bigcup_{j=1}^M E_j \right) \leq \sum_{j=1}^M \mathbb{P}(E_j). \quad (20.1)$$

若每个失败概率至多 δ/M , 则全部结论同时成立的概率至少 $1 - \delta$ 。将单点集中界扩展到有限候选集合通常产生 $\log M$ 项。例如

$$2Me^{-2N\epsilon^2} \leq \delta \quad (20.2)$$

等价于

$$\epsilon \geq \sqrt{\frac{\log(2M/\delta)}{2N}}. \quad (20.3)$$

若候选集合无限, 需要覆盖数、VC 维或 Rademacher 复杂度, 而不能直接把 $M = \infty$ 代入。

21 Delta 方法与非线性估计误差

设 $\sqrt{N}(\hat{\theta} - \theta) \Rightarrow \mathcal{N}(0, \Sigma)$, 光滑函数 g 的一阶展开

$$g(\hat{\theta}) = g(\theta) + \nabla g(\theta)^T (\hat{\theta} - \theta) + o_p(N^{-1/2}). \quad (21.1)$$

于是

$$\sqrt{N}[g(\hat{\theta}) - g(\theta)] \Rightarrow \mathcal{N}(0, \nabla g^T \Sigma \nabla g). \quad (21.2)$$

例如 $g(p) = \log p$, 方差近似

$$\text{Var}(\log \hat{p}) \approx \frac{\text{Var}(\hat{p})}{p^2}. \quad (21.3)$$

当 p 很小时误差被 $1/p^2$ 放大, 解释了稀有事件对数概率和概率比估计的不稳定。

二阶展开还给非线性偏差

$$\mathbb{E}g(\hat{\theta}) - g(\theta) \approx \frac{1}{2} \text{tr}(H_g(\theta) \text{Cov}(\hat{\theta})). \quad (21.4)$$

FID、比率、倒数和归一化优势等即使基础估计无偏, 非线性组合也可有有限样本偏差。

22 重要性采样与有效样本量

目标期望 $\mathbb{E}_p f(X)$ 用提议 q 采样, 权重 $w(x) = p(x)/q(x)$:

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N w(X_i) f(X_i), \quad X_i \sim q. \quad (22.1)$$

若 p 的归一化常数未知, 使用自归一估计

$$\tilde{\mu} = \frac{\sum_i w_i f_i}{\sum_i w_i}, \quad (22.2)$$

它一般有 $O(1/N)$ 偏差, 但常更实用。权重退化可用

$$N_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2} \quad (22.3)$$

衡量; 权重相等时为 N , 单个权重主导时接近 1。

比率裁剪 $\tilde{w} = \min(w, c)$ 降低方差, 但引入偏差

$$\mathbb{E}_q[(w - \tilde{w})f] = \mathbb{E}_q[(w - c)_+ f]. \quad (22.4)$$

若 $|f| \leq F$, 绝对偏差至多

$$F \mathbb{E}_q[(w - c)_+]. \quad (22.5)$$

23 校准与 Brier 分解

二元预测概率 $P \in [0, 1]$ 、标签 $Y \in \{0, 1\}$ 。条件真实频率 $m(P) = \mathbb{E}[Y | P]$ 。Brier 分数

$$\mathbb{E}(P - Y)^2 = \mathbb{E}(P - m(P))^2 + \mathbb{E}(m(P) - Y)^2, \quad (23.1)$$

交叉项因条件期望为零而消失。第一项是校准误差, 第二项是给定预测分组后的不可约噪声。若模型完美校准, $m(P) = P$, 第一项为零, 但单次预测仍可错误; 校准不是零错误率, 而是概率与长期频率一致。