

38_DeepSeek LLM

1 符号与维度

符号	维度	含义
N, D, C	$\mathbb{R}_{>0}$	参数量、训练 token 数与计算预算。
$L(N, D)$	$\mathbb{R}$	验证损失缩放模型。
α, β	$\mathbb{R}_{>0}$	参数与数据幂律指数。
n_L, d, V	$\mathbb{N}$	层数、隐藏宽度与词表大小。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 可分离幂律与计算约束下的最优分配

设验证损失模型

$$L(N, D) = L_\infty + AN^{-\alpha} + BD^{-\beta}, \quad A, B, \alpha, \beta > 0, \quad (2.1)$$

其中 N 是模型规模代理量、 D 是训练 token 数。训练计算近似

$$C = \kappa ND. \quad (2.2)$$

固定 C 时 $D = C/(\kappa N)$ ，代入可约为一元函数

$$\tilde{L}(N) = L_\infty + AN^{-\alpha} + B \left(\frac{\kappa N}{C} \right)^\beta. \quad (2.3)$$

一阶条件

$$-\alpha AN^{-\alpha-1} + \beta B \left(\frac{\kappa}{C} \right)^\beta N^{\beta-1} = 0. \quad (2.4)$$

整理得

$$N^{\alpha+\beta} = \frac{\alpha A}{\beta B} \left(\frac{C}{\kappa} \right)^\beta. \quad (2.5)$$

因此

$$N^*(C) = \left(\frac{\alpha A}{\beta B} \right)^{1/(\alpha+\beta)} \left(\frac{C}{\kappa} \right)^{\beta/(\alpha+\beta)}, \quad (2.6)$$

$$D^*(C) = \left(\frac{\beta B}{\alpha A} \right)^{1/(\alpha+\beta)} \left(\frac{C}{\kappa} \right)^{\alpha/(\alpha+\beta)}. \quad (2.7)$$

两个最优指数相加为 1，保证 $N^*D^* \propto C$ 。

在最优点，一阶条件还给出两项的比例

$$\alpha A(N^*)^{-\alpha} = \beta B(D^*)^{-\beta}. \quad (2.8)$$

不是两项数值相等，而是乘上各自幂指数后相等。

3 最优损失随计算的幂指数

将 N^*, D^* 代入, 两项都按

$$C^{-\frac{\alpha\beta}{\alpha+\beta}} \quad (3.1)$$

衰减。因此

$$L^*(C) = L_\infty + KC^{-\gamma}, \quad \gamma = \frac{\alpha\beta}{\alpha+\beta}, \quad (3.2)$$

常数 K 由 $A, B, \alpha, \beta, \kappa$ 决定。若任一资源的幂指数很小, 它将成为调和式组合中的瓶颈。

边际计算收益

$$\frac{dL^*}{dC} = -\gamma KC^{-\gamma-1} \quad (3.3)$$

随规模快速减小; 幂律外推给的是平均趋势, 不保证单次训练的确定回报。

4 对数线性拟合与不可忽略的 L_∞

若只拟合单项 $y = Ax^{-\alpha}$, 取对数得到

$$\log y = \log A - \alpha \log x, \quad (4.1)$$

可以线性回归。但实际有不可约项

$$L(x) = L_\infty + Ax^{-\alpha}, \quad (4.2)$$

则

$$\log L \neq \log A - \alpha \log x. \quad (4.3)$$

只有对 $L - L_\infty$ 取对数才线性, 而 L_∞ 本身未知, 需要非线性联合拟合。

若误设 $\tilde{L}_\infty = L_\infty + \delta$, 变换量变为

$$\log(L - \tilde{L}_\infty) = \log(Ax^{-\alpha} - \delta). \quad (4.4)$$

在大规模、幂律项较小时, 对 δ 极敏感; 这解释了外推指数和渐近损失之间的强相关。

5 参数估计的不确定性传播

令拟合参数 $\psi = (\log A, \log B, \alpha, \beta, L_\infty)$, 最小二乘目标

$$S(\psi) = \sum_i w_i [L_i - L(N_i, D_i; \psi)]^2. \quad (5.1)$$

在最优点 $\hat{\psi}$ 附近二阶近似

$$S(\psi) \approx S(\hat{\psi}) + \frac{1}{2}(\psi - \hat{\psi})^T H(\psi - \hat{\psi}). \quad (5.2)$$

若残差近似高斯, 参数协方差可估为

$$\text{Cov}(\hat{\psi}) \approx \hat{\sigma}^2 H^{-1}. \quad (5.3)$$

对由参数导出的最优规模 $g(\psi) = \log N^*(C)$, delta 方法给出

$$\text{Var}(g(\hat{\psi})) \approx \nabla_\psi g^T \text{Cov}(\hat{\psi}) \nabla_\psi g. \quad (5.4)$$

因此只报告单条最优曲线会隐藏幂指数拟合误差经外推放大的区间。

6 模型规模代理量的选择

稠密 Transformer 每 token 前向 FLOPs 常近似与参数量成正比，训练再乘常数，于是 $C \approx \kappa ND$ 。MoE 中总参数 N_{total} 与每 token 激活参数 N_{active} 不同：

$$C \approx \kappa N_{\text{active}} D, \quad (6.1)$$

而容量和存储更接近 N_{total} 。若把总参数直接代入稠密计算公式，会高估训练计算。

假设每层有 E 个专家、每 token 激活 k 个，专家参数总量 N_e ，则粗略

$$N_{\text{active}} = N_{\text{shared}} + \frac{k}{E} N_e, \quad N_{\text{total}} = N_{\text{shared}} + N_e. \quad (6.2)$$

路由不均衡还会让实际设备时间由最拥挤专家决定，因此 FLOPs 相同也不保证墙钟时间相同。

7 两阶段或多阶段训练的计算核算

若不同阶段模型规模、序列长度或激活稀疏度不同，总计算应相加

$$C_{\text{total}} = \sum_{j=1}^J \kappa_j N_{\text{active},j} D_j. \quad (7.1)$$

把全部 token 简单相加再乘最终模型规模只有在各阶段 $\kappa_j N_j$ 相同才成立。这对继续预训练、长上下文阶段和多 token 预测辅助头尤其重要。

8 自回归似然与 token 梯度

对序列 $x_{1:T}$ ，因果语言模型按概率链式法则分解

$$p_{\theta}(x_{1:T}) = \prod_{t=1}^T p_{\theta}(x_t | x_{<t}). \quad (8.1)$$

负对数似然

$$\mathcal{L}_{\text{NLL}} = - \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t}). \quad (8.2)$$

若第 t 步 logits 为 $z_t \in \mathbb{R}^V$ ，概率 $p_{tj} = e^{z_{tj}} / \sum_k e^{z_{tk}}$ ，真实 token 索引 y_t ，则

$$\ell_t = -z_{t,y_t} + \log \sum_k e^{z_{tk}}, \quad (8.3)$$

逐 logit 梯度

$$\frac{\partial \ell_t}{\partial z_{tj}} = p_{tj} - \mathbf{1}\{j = y_t\}. \quad (8.4)$$

Hessian 正是 softmax Jacobian

$$\nabla_z^2 \ell_t = \text{diag}(p_t) - p_t p_t^T \succeq 0. \quad (8.5)$$

所以交叉熵关于 logits 凸，但关于深网参数并不凸。

对非 padding token 集合 $\mathcal{I}$ ，平均损失和困惑度

$$\bar{L} = \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \ell_t, \quad \text{PPL} = e^{\bar{L}}. \quad (8.6)$$

因此 PPL 是真实 token 概率倒数的几何平均：

$$\text{PPL} = \left(\prod_{t \in \mathcal{I}} \frac{1}{p_{\theta}(x_t | x_{<t})} \right)^{1/|\mathcal{I}|}. \quad (8.7)$$

不同 tokenizer 的 token 粒度不同，PPL 不能不经换算直接横向比较。

9 旋转位置编码的相对位置恒等式

对二维坐标对，定义旋转

$$R(m\omega) = \begin{bmatrix} \cos(m\omega) & -\sin(m\omega) \\ \sin(m\omega) & \cos(m\omega) \end{bmatrix}. \quad (9.1)$$

位置 m, n 的 query、key 分别为 $q_m = R(m\omega)q$ 、 $k_n = R(n\omega)k$ 。内积

$$q_m^T k_n = q^T R(m\omega)^T R(n\omega) k \quad (9.2)$$

$$= q^T R((n-m)\omega) k. \quad (9.3)$$

第二步用到 $R(a)^T = R(-a)$ 和 $R(a)R(b) = R(a+b)$ 。所以绝对位置旋转后的内积只依赖相对距离 $n-m$ 。

在 d_h 维中对相邻坐标对使用频率

$$\omega_j = \theta^{-2j/d_h}, \quad j = 0, \dots, d_h/2 - 1. \quad (9.4)$$

低 j 频率高、分辨近距离，高 j 频率低、覆盖远距离。若推理长度远超训练长度，相位 $m\omega_j$ 的外推和周期混叠会改变注意力几何；位置插值本质上是重新缩放这些相位。

10 RMSNorm 的 Jacobian

忽略可学习增益，RMSNorm

$$y = \frac{x}{s}, \quad s = \sqrt{\frac{1}{d}x^T x + \epsilon}. \quad (10.1)$$

微分

$$ds = \frac{x^T dx}{ds}, \quad (10.2)$$

因此

$$dy = \frac{1}{s} dx - \frac{x}{s^2} ds \quad (10.3)$$

$$= \left(\frac{1}{s} I - \frac{xx^T}{ds^3} \right) dx. \quad (10.4)$$

故

$$J_{\text{RMS}} = \frac{1}{s} I - \frac{xx^T}{ds^3}. \quad (10.5)$$

与 LayerNorm 相比，它没有去均值投影 $I - d^{-1}\mathbf{1}\mathbf{1}^T$ ，因此不消除常数方向。加上逐坐标增益 g 后，Jacobian 左乘 $\text{diag}(g)$ 。

谱上，对任意 $v \perp x$ ， $Jv = v/s$ ；沿 x 方向

$$Jx = \left(\frac{1}{s} - \frac{\|x\|^2}{ds^3} \right) x = \frac{\epsilon}{s^3} x. \quad (10.6)$$

当 ϵ 很小，径向尺度方向被强烈压制，而切向方向按 $1/s$ 缩放。

11 SwiGLU 前馈层的逐项梯度

SwiGLU 可写

$$a = xW_a, \quad b = xW_b, \quad h = \text{swish}(a) \odot b, \quad y = hW_o, \quad (11.1)$$

其中

$$\text{swish}(a) = a\sigma(a). \quad (11.2)$$

其导数

$$\frac{d}{da}[a\sigma(a)] = \sigma(a) + a\sigma(a)(1 - \sigma(a)). \quad (11.3)$$

令 $g_h = \partial\mathcal{L}/\partial h$, 则

$$g_a = g_h \odot b \odot [\sigma(a) + a\sigma(a)(1 - \sigma(a))], \quad (11.4)$$

$$g_b = g_h \odot \text{swish}(a), \quad (11.5)$$

$$\nabla_{W_a}\mathcal{L} = x^T g_a, \quad \nabla_{W_b}\mathcal{L} = x^T g_b, \quad (11.6)$$

$$\nabla_x\mathcal{L} = g_a W_a^T + g_b W_b^T. \quad (11.7)$$

门分支 b 同时调制激活和 a 分支梯度, 故两个投影不是可独立解释的普通 MLP。

12 MoE 路由与负载

对 token x_i , router logits $r_i = W_r x_i$, 概率

$$p_{ie} = \frac{e^{r_{ie}}}{\sum_{j=1}^E e^{r_{ij}}}. \quad (12.1)$$

若 top- k 专家集合 S_i , 归一化门

$$\tilde{p}_{ie} = \frac{p_{ie} \mathbf{1}\{e \in S_i\}}{\sum_{j \in S_i} p_{ij}}, \quad y_i = \sum_{e \in S_i} \tilde{p}_{ie} F_e(x_i). \quad (12.2)$$

固定集合 S_i 内可正常求导; 集合边界的 arg-top- k 不连续, 几乎处处把未选专家梯度置零。

令软重要性

$$P_e = \frac{1}{N} \sum_i p_{ie}, \quad (12.3)$$

硬负载

$$F_e = \frac{1}{N} \sum_i \mathbf{1}\{e \in S_i\}/k. \quad (12.4)$$

常见平衡项

$$L_{\text{bal}} = E \sum_e P_e F_e \quad (12.5)$$

在均匀 $P_e = F_e = 1/E$ 时等于 1。把硬 F_e 停止梯度后, router 梯度只通过 P_e , 会降低当前过载专家的概率; 它是训练启发式, 不等同于严格容量约束。

若每专家容量为

$$C_e = \left\lceil \frac{Nk}{E} c_{\text{cap}} \right\rceil, \quad (12.6)$$

超过容量的 token 必须丢弃或转送。即使平均负载均匀, 局部批次方差仍可能溢出。

13 低秩 KV 潜变量的吸收

设 key/value 由共享潜变量

$$c_t = W_c x_t \in \mathbb{R}^{d_c}, \quad k_t = W_k c_t, \quad v_t = W_v c_t. \quad (13.1)$$

注意力 logit

$$q_s^T k_t = q_s^T W_k c_t = (W_k^T q_s)^T c_t. \quad (13.2)$$

因此解码时可把 W_k 吸收到 query 投影，缓存 c_t 而非完整 k_t 。若 value 聚合

$$o_s = \sum_t p_{st} W_v c_t = W_v \left(\sum_t p_{st} c_t \right), \quad (13.3)$$

W_v 可放到加权和之后。缓存从每 token 的 $d_k + d_v$ 降为 d_c ，前提是位置编码等操作不破坏这些线性交换关系；对只作用在部分 key 维度的 RoPE，需把旋转部分另行缓存或重构。

14 多 token 预测的联合似然

若同一隐藏状态 h_t 用 K 个头预测 $x_{t+1}, \dots, x_{t+K}$,

$$\mathcal{L}_t = \sum_{k=1}^K \lambda_k [-\log p_{\theta,k}(x_{t+k} | h_t)]. \quad (14.1)$$

共享骨干梯度

$$\nabla_{h_t} \mathcal{L}_t = \sum_{k=1}^K \lambda_k g_{t,k}. \quad (14.2)$$

其平方范数精确展开

$$\left\| \sum_k \lambda_k g_{t,k} \right\|^2 = \sum_k \lambda_k^2 \|g_{t,k}\|^2 + 2 \sum_{j < k} \lambda_j \lambda_k g_{t,j}^T g_{t,k}. \quad (14.3)$$

交叉内积为负时存在任务冲突；辅助头退火相当于训练后期逐渐去掉这些交叉项，使最终目标回到下一 token 似然。