

44_Mapping Networks

1 符号与维度

符号	维度	含义
θ	$\mathbb{R}^P$	目标网络完整参数。
z	$\mathbb{R}^d$	低维潜参数, $d \ll P$ 。
g_ψ	$\mathbb{R}^d \rightarrow \mathbb{R}^P$	映射网络。
$\mathcal{M}$	—	假设中的低维参数流形。
L_θ, L_ℓ	$\mathbb{R}_{>0}$	模型和损失的 Lipschitz 常数。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 局部坐标图与映射定理的严格构造

设 $\mathcal{M} \subset \mathbb{R}^P$ 是 d^* 维 C^2 嵌入流形, $\theta^* \in \mathcal{M}$ 。按定义, 存在开集 $U \subset \mathbb{R}^{d^*}$ 、 $0 \in U$ 和局部坐标图

$$\phi: U \rightarrow V \subset \mathcal{M}, \quad \phi(0) = \theta^*, \quad \text{rank } J_\phi(u) = d^*. \quad (2.1)$$

若任务损失在 $B(\theta^*, r)$ 内满足

$$|L(\theta_1) - L(\theta_2)| \leq L_\ell L_\theta \|\theta_1 - \theta_2\|_2, \quad (2.2)$$

给定 $0 < \epsilon \leq L_\ell L_\theta r$, 令

$$\delta = \frac{\epsilon}{L_\ell L_\theta} \leq r. \quad (2.3)$$

由 ϕ 在 0 连续, 存在 $\eta > 0$ 使

$$\|u\| < \eta \Rightarrow \|\phi(u) - \theta^*\| < \delta. \quad (2.4)$$

于是任取该邻域内 z^* ,

$$|L(\phi(z^*)) - L(\theta^*)| \leq L_\ell L_\theta \|\phi(z^*) - \theta^*\| < \epsilon. \quad (2.5)$$

论文希望得到定义在整个 $\mathbb{R}^{d^*}$ 上的 C^2 映射。严格做法是先选 $U_1 \Subset U_2 \Subset U$, $0 \in U_1$, 再取光滑 cutoff $\psi \in C_c^\infty(U_2)$ 且 $\psi = 1$ 于 U_1 。定义

$$g(u) = \begin{cases} \theta^* + \psi(u)[\phi(u) - \theta^*], & u \in U_2, \\ \theta^*, & u \notin U_2. \end{cases} \quad (2.6)$$

因为 ψ 在 U_2 边界附近恒为零, 两段及其任意阶导数平滑拼接, $g \in C^2(\mathbb{R}^{d^*}, \mathbb{R}^P)$ 。这避免直接在 U 外书写未定义的 $\phi(u)$ 。

注意取 $z^* = 0$ 就有

$$g(0) = \phi(0) = \theta^*, \quad (2.7)$$

损失误差严格为零。因此这个存在性定理本身来自“已知最优点位于流形并以它为坐标图中心”, 并没有证明某个预先随机固定的网络能找到或表示该坐标图。

3 复合 Lipschitz 常数的来源

若对所有输入 x ,

$$\|f_{\theta_1}(x) - f_{\theta_2}(x)\| \leq L_\theta \|\theta_1 - \theta_2\|, \quad (3.1)$$

且逐样本损失对预测满足

$$|\ell(y_1, y) - \ell(y_2, y)| \leq L_\ell \|y_1 - y_2\|, \quad (3.2)$$

则期望任务损失 $L(\theta) = \mathbb{E}_{x,y} \ell(f_\theta(x), y)$ 满足

$$|L(\theta_1) - L(\theta_2)| \leq \mathbb{E} |\ell(f_{\theta_1}(x), y) - \ell(f_{\theta_2}(x), y)| \quad (3.3)$$

$$\leq L_\ell \mathbb{E} \|f_{\theta_1}(x) - f_{\theta_2}(x)\| \quad (3.4)$$

$$\leq L_\ell L_\theta \|\theta_1 - \theta_2\|. \quad (3.5)$$

若交叉熵的预测概率可趋近零，它在概率坐标中没有全局有限 Lipschitz 常数；需要把 logits 或概率限制在紧集，故论文的结论是局部而非全局。

4 潜变量梯度是切空间拉回

令 $\theta = g_\psi(z)$ ，任务梯度 $q = \nabla_\theta L \in \mathbb{R}^P$ 。链式法则

$$\boxed{\nabla_z L(g(z)) = J_g(z)^T q.} \quad (4.1)$$

潜空间一步 $z^+ = z - \eta J_g^T q$ 在参数空间的一阶变化

$$\Delta \theta \approx J_g(z)(z^+ - z) = -\eta J_g J_g^T q. \quad (4.2)$$

若 $J_g = U \Sigma V^T$ ，则

$$J_g J_g^T = U \Sigma^2 U^T. \quad (4.3)$$

所以更新只在切空间 $\text{col}(J_g)$ 内，并按奇异值平方预条件。它通常不是欧氏正交投影；正交投影为

$$P_T = J_g (J_g^T J_g)^{-1} J_g^T \quad (4.4)$$

(满列秩时)。若希望参数空间沿 $-P_T q$ ，潜更新应使用自然梯度

$$\Delta z = -\eta (J_g^T J_g)^{-1} J_g^T q. \quad (4.5)$$

奇异值界给出

$$\sigma_{\min} \|P_T q\| \leq \|J_g^T q\| \leq \sigma_{\max} \|P_T q\|. \quad (4.6)$$

小 $\sigma_{\min}$ 造成某些切向方向学习极慢，条件数 $\kappa(J_g) = \sigma_{\max}/\sigma_{\min}$ 是低维优化是否良态的关键。

5 局部可解性的逆函数推导

设初点 z_0 、 $\theta_0 = g(z_0)$ ，残差 $r = \theta^* - \theta_0$ 。Taylor 展开

$$g(z_0 + \Delta z) = \theta_0 + J \Delta z + R(\Delta z), \quad \|R(\Delta z)\| \leq \frac{M}{2} \|\Delta z\|^2, \quad (5.1)$$

其中 $J = J_g(z_0)$ ， M 控制二阶导数。若 r 位于 $\text{col}(J)$ ，且 J 满列秩，可取

$$\Delta z = J^\dagger r, \quad \|\Delta z\| \leq \frac{\|r\|}{\sigma_{\min}(J)}. \quad (5.2)$$

线性项精确抵消残差，剩余

$$\|g(z_0 + \Delta z) - \theta^*\| \leq \frac{M}{2\sigma_{\min}(J)^2} \|r\|^2. \quad (5.3)$$

这给出论文 $O(\|r\|^2)$ 声称所需的明确条件。

若 r 含法向分量 $r_\perp = (I - P_T)r \neq 0$ ，任何一阶潜更新都无法消除它：

$$\min_{\Delta z} \|J\Delta z - r\| = \|r_\perp\|. \quad (5.4)$$

因此仅假设 $\|r\|$ 小并不足以保证二次剩余；还需目标位于局部映射像，或法向残差本身为二阶小量。

6 加性权重调制的导数

映射网络权重由潜变量调制

$$\omega(z) = \omega_0 + Bz, \quad g(z) = g_{\omega(z)}(z). \quad (6.1)$$

因为 z 同时作为网络输入和权重来源，全导数是

$$\boxed{\frac{dg}{dz} = \frac{\partial g_{\omega}(z)}{\partial z} + \frac{\partial g_{\omega}(z)}{\partial \omega} B.} \quad (6.2)$$

只计算第一项会漏掉调制路径。对逐元素规则 $\omega_{ij} \leftarrow \omega_{ij} + \alpha z_i$ ，矩阵 B 是稀疏复制算子；同一 z_i 调制多个权重，因此其梯度累加这些连接的贡献。

加性调制仍是一个特定参数化。要声称它满足映射定理，必须证明其像包含定理构造的局部坐标图，或至少以所需精度逼近；仅有 C^2 光滑性并不保证像经过任意 θ^* 。

7 稳定、平滑和对齐正则的精确含义

稳定损失

$$L_{\text{stab}} = \mathbb{E}_{\epsilon \sim \mathcal{N}(0, \sigma^2 I)} \|F(z + \epsilon) - F(z)\|_2^2 \quad (7.1)$$

在小 σ 下 Taylor 展开

$$F(z + \epsilon) - F(z) = J_F(z)\epsilon + O(\|\epsilon\|^2). \quad (7.2)$$

故

$$L_{\text{stab}} = \mathbb{E} \epsilon^T J_F^T J_F \epsilon + O(\sigma^3) \quad (7.3)$$

$$= \text{tr}(J_F^T J_F \mathbb{E} \epsilon \epsilon^T) + O(\sigma^3) \quad (7.4)$$

$$= \sigma^2 \|J_F(z)\|_F^2 + O(\sigma^3). \quad (7.5)$$

它小噪声极限等价于 Jacobian 正则。

论文平滑项

$$L_{\text{smooth}} = \|J_{M_\phi}(z)\|_F^2 \quad (7.6)$$

只惩罚一阶导数幅值，并不单独“保证 C^2 ”。若网络激活本身不是 C^2 （例如 ReLU），函数仍可能只分段光滑；要控制曲率还需 Hessian 项

$$\|\nabla_z^2 M_\phi(z)\|_F^2. \quad (7.7)$$

余弦对齐

$$L_{\text{align}} = 1 - \frac{z^T w}{\|z\| \|w\|} \quad (7.8)$$

对 z 的梯度

$$\nabla_z L_{\text{align}} = -\frac{1}{\|z\| \|w\|} \left(w - \frac{z^T w}{\|z\|^2} z \right), \quad (7.9)$$

它只改变方向且在 $z = 0$ 奇异，实际实现需范数下界。

8 全局拓扑限制

单一坐标图只能覆盖与 $\mathbb{R}^d$ 开集微分同胚的局部区域。若最优参数集合是圆环、球面或多个不连通分支，不存在一张无奇点、单射的欧氏全局坐标图覆盖全部集合。连续 $g: \mathbb{R}^d \rightarrow \mathbb{R}^P$ 可以覆盖或穿过这些区域，但可能非单射，且不同潜点映射到同一参数。因此流形假设支持局部降维，不自动推出单个潜向量参数化整个训练轨迹的全局可学习性。

9 光滑损失的下降引理

若 L 的梯度是 β -Lipschitz:

$$\|\nabla L(x) - \nabla L(y)\| \leq \beta \|x - y\|, \quad (9.1)$$

则沿线段积分

$$L(y) - L(x) = \int_0^1 \nabla L(x + t(y-x))^T (y-x) dt \quad (9.2)$$

$$= \nabla L(x)^T (y-x) + R, \quad (9.3)$$

余项满足

$$|R| \leq \int_0^1 \beta t \|y-x\|^2 dt = \frac{\beta}{2} \|y-x\|^2. \quad (9.4)$$

故下降引理

$$L(y) \leq L(x) + \nabla L(x)^T (y-x) + \frac{\beta}{2} \|y-x\|^2. \quad (9.5)$$

取梯度步 $y = x - \eta \nabla L(x)$:

$$L(y) \leq L(x) - \eta \left(1 - \frac{\beta\eta}{2}\right) \|\nabla L(x)\|^2. \quad (9.6)$$

当 $0 < \eta < 2/\beta$ 时每个精确梯度步下降；深网中 β 未知且随位置变化，这仍解释了学习率过大造成不稳定的局部机制。

10 二阶近似与曲率方向

在 x 附近 Taylor 展开

$$L(x + \Delta) = L(x) + g^T \Delta + \frac{1}{2} \Delta^T H \Delta + O(\|\Delta\|^3). \quad (10.1)$$

若 $H = U \text{diag}(\lambda_i) U^T$ ，在本征方向 u_i 上步长 a 的变化

$$\Delta L \approx a g_i + \frac{1}{2} \lambda_i a^2. \quad (10.2)$$

$\lambda_i > 0$ 为局部碗形， $\lambda_i < 0$ 是负曲率逃离鞍点方向。加阻尼的 Newton 步

$$\Delta = -(H + \lambda I)^{-1} g \quad (10.3)$$

在特征方向缩放为 $-g_i/(\lambda_i + \lambda)$ ，避免接近零或负特征值造成巨大步长。

11 链式 Jacobian 与条件数

复合映射 $y = f_L \circ \dots \circ f_1(x)$ 的 Jacobian

$$J_{y \leftarrow x} = J_L J_{L-1} \dots J_1. \quad (11.1)$$

谱范数上界

$$\|J_{y \leftarrow x}\|_2 \leq \prod_{\ell=1}^L \|J_\ell\|_2. \quad (11.2)$$

若各层最小奇异值存在,

$$\sigma_{\min}(J_{y \leftarrow x}) \geq \prod_{\ell} \sigma_{\min}(J_\ell). \quad (11.3)$$

因此条件数至多乘法累积:

$$\kappa(J_{y \leftarrow x}) \leq \prod_{\ell} \kappa(J_\ell). \quad (11.4)$$

低维映射、递归模块和物理传播都面临同一问题: 表示存在不代表反向梯度数值良态。

12 随机梯度的偏差与方差

设样本梯度 $g(\theta; \xi)$ 满足

$$\mathbb{E}_\xi g(\theta; \xi) = \nabla L(\theta), \quad \mathbb{E}\|g - \nabla L\|^2 \leq \sigma^2. \quad (12.1)$$

独立批量 B 的平均

$$\bar{g}_B = \frac{1}{B} \sum_{i=1}^B g_i \quad (12.2)$$

满足

$$\mathbb{E} \bar{g}_B = \nabla L, \quad \mathbb{E}\|\bar{g}_B - \nabla L\|^2 \leq \frac{\sigma^2}{B}. \quad (12.3)$$

若样本相关, 协方差项出现:

$$\text{Var}(\bar{g}_B) = \frac{1}{B^2} \left[\sum_i \text{Var}(g_i) + \sum_{i \neq j} \text{Cov}(g_i, g_j) \right]. \quad (12.4)$$

扩大批量只有在交叉协方差不主导时才近似按 $1/B$ 降噪。

若使用有偏估计 $\mathbb{E} \hat{g} = \nabla L + b$, 均方误差分解

$$\mathbb{E}\|\hat{g} - \nabla L\|^2 = \|b\|^2 + \text{tr Cov}(\hat{g}). \quad (12.5)$$

直通估计、停止梯度目标和截断反传通常以可控偏差换低方差或低内存。

13 Adam 的尺度归一化

逐坐标 Adam 更新

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (13.1)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad (13.2)$$

$$\hat{m}_t = m_t / (1 - \beta_1^t), \quad (13.3)$$

$$\hat{v}_t = v_t / (1 - \beta_2^t), \quad (13.4)$$

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (13.5)$$

若梯度长期乘常数 $c > 0$, 忽略 ϵ 时 $\hat{m}$ 乘 c 、 $\sqrt{\hat{v}}$ 也乘 c , 更新近似不变。但瞬态、符号变化和 ϵ 会破坏精确尺度不变性。

AdamW 把权重衰减解耦:

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (13.6)$$

这不同于把 $\lambda\theta$ 加入梯度后再经过自适应分母; 后者会按坐标二阶矩缩放正则化。

14 范数约束与投影梯度

约束集合 $\mathcal{C}$ 上的投影梯度

$$\theta^+ = \Pi_{\mathcal{C}}(\theta - \eta g), \quad \Pi_{\mathcal{C}}(x) = \arg \min_{y \in \mathcal{C}} \|x - y\|^2. \quad (14.1)$$

对欧氏球 $\mathcal{C} = \{x : \|x\| \leq R\}$,

$$\Pi_{\mathcal{C}}(x) = \begin{cases} x, & \|x\| \leq R, \\ Rx/\|x\|, & \|x\| > R. \end{cases} \quad (14.2)$$

对流形约束，局部一阶步先投影到切空间，再用 retraction 回到流形；仅把参数写成 $g(z)$ 相当于用参数化隐式满足约束，但会引入 $J_g^T J_g$ 的坐标度量。

15 Lipschitz 误差的层间传播

真实模块 f_ℓ 、近似模块 $\hat{f}_\ell$ 满足

$$\|f_\ell(x) - \hat{f}_\ell(x)\| \leq \epsilon_\ell, \quad \|f_\ell(x) - f_\ell(y)\| \leq L_\ell \|x - y\|. \quad (15.1)$$

令真实、近似中间状态差 e_ℓ 。三角不等式给出

$$e_{\ell+1} = \|f_\ell(h_\ell) - \hat{f}_\ell(\hat{h}_\ell)\| \quad (15.2)$$

$$\leq L_\ell e_\ell + \epsilon_\ell. \quad (15.3)$$

递归展开

$$e_L \leq \left(\prod_{j=0}^{L-1} L_j \right) e_0 + \sum_{\ell=0}^{L-1} \left(\prod_{j=\ell+1}^{L-1} L_j \right) \epsilon_\ell. \quad (15.4)$$

早期层误差乘更多后续 Lipschitz 因子，所以量化、低秩近似或局部训练的相同单层误差，放在不同深度并不等价。

16 复杂度必须区分四个量

参数量、FLOPs、激活内存和通信量是不同指标。以线性层 $Y = XW$ 、 $X \in \mathbb{R}^{B \times n}$ 、 $W \in \mathbb{R}^{n \times m}$ 为例：

$$\text{参数量} = nm, \quad (16.1)$$

$$\text{前向乘加量} \asymp Bnm, \quad (16.2)$$

$$\text{主要激活量} = B(n + m), \quad (16.3)$$

$$\text{数据并行梯度通信} \asymp nm. \quad (16.4)$$

低秩因子可同时减少参数与乘法，但动态稀疏若实现仍做稠密 kernel，参数/FLOPs 公式不会自动转化为墙钟加速。冻结参数减少梯度和优化器状态，却不一定减少前向计算或输入梯度计算。