

45_DSpark

1 符号与维度

符号	维度	含义
p, q	Δ^{V-1}	目标模型与草稿模型的 token 分布。
c_k, S_k	$[0, 1]$	第 k 位接受率与前缀生存概率。
K, L	$\mathbb{N}$	验证块长度与实际接受长度。
$R(K, B)$	$\mathbb{R}_{>0}$	批大小 B 下的验证吞吐 profile。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 前缀接受长度的概率恒等式

草稿模型一次提出 K 个 token，令 A_j 表示第 j 个 token 在此前均被接受条件下也被接受。连续接受前缀长度 $L \in \{0, 1, \dots, K\}$ 满足

$$\{L \geq \ell\} = A_1 \cap \dots \cap A_\ell. \quad (2.1)$$

任意非负整数变量的尾和公式

$$\mathbb{E}L = \sum_{\ell=1}^K \mathbb{P}(L \geq \ell) \quad (2.2)$$

可由

$$\mathbb{E}L = \sum_{l=0}^K l \mathbb{P}(L = l) = \sum_{l=0}^K \sum_{\ell=1}^l \mathbb{P}(L = l) \quad (2.3)$$

$$= \sum_{\ell=1}^K \sum_{l=\ell}^K \mathbb{P}(L = l) = \sum_{\ell=1}^K \mathbb{P}(L \geq \ell) \quad (2.4)$$

得到。若每个条件接受概率同为 a ，则

$$\mathbb{P}(L \geq \ell) = a^\ell, \quad \mathbb{E}L = \sum_{\ell=1}^K a^\ell = \frac{a(1 - a^K)}{1 - a}. \quad (2.5)$$

$a \rightarrow 1$ 时极限为 K ， a 较小时增加 K 收益很快饱和。

3 精确 speculative sampling 的接受率

目标模型分布 $p(x)$ 、草稿分布 $q(x)$ 。候选 $x \sim q$ 的接受概率

$$\alpha(x) = \min\left(1, \frac{p(x)}{q(x)}\right). \quad (3.1)$$

总接受率

$$A = \sum_x q(x) \min\left(1, \frac{p(x)}{q(x)}\right) \quad (3.2)$$

$$= \sum_x \min(p(x), q(x)). \quad (3.3)$$

利用

$$\min(p, q) = \frac{1}{2}(p + q - |p - q|), \quad (3.4)$$

得到

$$A = 1 - \text{TV}(p, q), \quad \text{TV}(p, q) = \frac{1}{2} \sum_x |p(x) - q(x)|. \quad (3.5)$$

由 Pinsker 不等式

$$\text{TV}(p, q) \leq \sqrt{\frac{1}{2} D_{\text{KL}}(p \| q)}, \quad (3.6)$$

因此较小 KL 给出较高接受率的下界，但 KL 的方向和支撑条件必须匹配。

拒绝时从残差分布

$$r(x) = \frac{[p(x) - q(x)]_+}{\sum_y [p(y) - q(y)]_+} \quad (3.7)$$

采样。候选被接受后贡献概率 $\min(p, q)$ ；拒绝概率为 $1 - A = \sum [p - q]_+$ ，乘残差 r 贡献 $[p - q]_+$ 。总输出概率

$$\min(p(x), q(x)) + [p(x) - q(x)]_+ = p(x), \quad (3.8)$$

证明校正后的单步分布与目标模型完全一致。

4 验证并行与每轮产出

目标模型一次前向并行验证 K 个草稿 token，并通常在首次拒绝处再从目标/残差采一个 token。若每轮输出 token 数近似 $Y = L + 1$ ，则

$$\mathbb{E}Y = 1 + \sum_{\ell=1}^K \mathbb{P}(L \geq \ell). \quad (4.1)$$

若条件接受率恒为 a ，

$$\mathbb{E}Y = 1 + \frac{a(1 - a^K)}{1 - a}. \quad (4.2)$$

设草稿生成 K token 时间 $T_d(K)$ ，目标验证时间 $T_v(K)$ ，其他开销 T_o ，吞吐率

$$\text{TPS}(K) = \frac{\mathbb{E}Y(K)}{T_d(K) + T_v(K) + T_o}. \quad (4.3)$$

最优 K 不一定最大：分子随 K 饱和，分母仍增长。

与目标逐 token 时间 T_p 比，理论加速

$$S(K) = \frac{T_p \mathbb{E}Y(K)}{T_d(K) + T_v(K) + T_o}. \quad (4.4)$$

即使接受率高，若草稿模型太慢或验证 kernel 未能并行利用硬件，也可能 $S \leq 1$ 。

5 位置相关接受概率

实际条件接受率依赖位置，记

$$a_j = \mathbb{P}(A_j \mid A_1, \dots, A_{j-1}). \quad (5.1)$$

链式法则给出

$$\mathbb{P}(L \geq \ell) = \prod_{j=1}^{\ell} a_j, \quad (5.2)$$

所以

$$\mathbb{E}L = \sum_{\ell=1}^K \prod_{j=1}^{\ell} a_j. \quad (5.3)$$

早期 a_j 的改善会乘法影响所有更长前缀，比同等幅度改善末端接受率更重要。对 a_j 的偏导

$$\frac{\partial \mathbb{E}L}{\partial a_j} = \sum_{\ell=j}^K \prod_{\substack{h=1 \\ h \neq j}}^{\ell} a_h. \quad (5.4)$$

6 草稿训练损失与接受率的关系

以目标分布为软标签训练草稿，token 级交叉熵

$$\mathcal{L}_{\text{KD}} = -\mathbb{E}_c \sum_x p(x | c) \log q_{\phi}(x | c) \quad (6.1)$$

分解为

$$\mathcal{L}_{\text{KD}} = H(p) + D_{\text{KL}}(p \| q_{\phi}). \quad (6.2)$$

目标熵 $H(p)$ 与 ϕ 无关，所以最小化蒸馏交叉熵等价于最小化正向 KL。结合 Pinsker,

$$A(c) = 1 - \text{TV}(p, q_{\phi}) \geq 1 - \sqrt{\frac{1}{2} D_{\text{KL}}(p \| q_{\phi})}. \quad (6.3)$$

这提供训练损失与单步接受率的保守联系。

若只用目标模型 $\arg\max$ 的硬标签，优化的是

$$-\log q_{\phi}(x^* | c), \quad x^* = \arg \max_x p(x | c), \quad (6.4)$$

它不约束其余概率质量，可能有很高 top-1 一致率却有较大总变差，影响采样式接受率。

7 多 token 预测头的联合梯度

若共享骨干表示 h_t 同时预测未来 K 个 token，损失

$$\mathcal{L} = \sum_{k=1}^K \lambda_k [-\log p_{\theta,k}(y_{t+k} | h_t)]. \quad (7.1)$$

骨干梯度为

$$\nabla_{h_t} \mathcal{L} = \sum_{k=1}^K \lambda_k \nabla_{h_t} \mathcal{L}_k. \quad (7.2)$$

若不同未来步梯度冲突，内积

$$\langle \nabla \mathcal{L}_j, \nabla \mathcal{L}_k \rangle < 0 \quad (7.3)$$

会降低合成梯度对各单任务的下降量；权重 λ_k 需要在更长预测能力与当前 token 建模之间折衷。

8 自回归似然与 token 梯度

对序列 $x_{1:T}$ ，因果语言模型按概率链式法则分解

$$p_{\theta}(x_{1:T}) = \prod_{t=1}^T p_{\theta}(x_t | x_{<t}). \quad (8.1)$$

负对数似然

$$\mathcal{L}_{\text{NLL}} = - \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t}). \quad (8.2)$$

若第 t 步 logits 为 $z_t \in \mathbb{R}^V$ ，概率 $p_{tj} = e^{z_{tj}} / \sum_k e^{z_{tk}}$ ，真实 token 索引 y_t ，则

$$\ell_t = -z_{t,y_t} + \log \sum_k e^{z_{tk}}, \quad (8.3)$$

逐 logit 梯度

$$\frac{\partial \ell_t}{\partial z_{tj}} = p_{tj} - \mathbf{1}\{j = y_t\}. \quad (8.4)$$

Hessian 正是 softmax Jacobian

$$\nabla_z^2 \ell_t = \text{diag}(p_t) - p_t p_t^T \succeq 0. \quad (8.5)$$

所以交叉熵关于 logits 凸，但关于深网参数并不凸。

对非 padding token 集合 $\mathcal{I}$ ，平均损失和困惑度

$$\bar{L} = \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \ell_t, \quad \text{PPL} = e^{\bar{L}}. \quad (8.6)$$

因此 PPL 是真实 token 概率倒数的几何平均：

$$\text{PPL} = \left(\prod_{t \in \mathcal{I}} \frac{1}{p_{\theta}(x_t | x_{<t})} \right)^{1/|\mathcal{I}|}. \quad (8.7)$$

不同 tokenizer 的 token 粒度不同，PPL 不能不经换算直接横向比较。

9 旋转位置编码的相对位置恒等式

对二维坐标对，定义旋转

$$R(m\omega) = \begin{bmatrix} \cos(m\omega) & -\sin(m\omega) \\ \sin(m\omega) & \cos(m\omega) \end{bmatrix}. \quad (9.1)$$

位置 m, n 的 query、key 分别为 $q_m = R(m\omega)q$ 、 $k_n = R(n\omega)k$ 。内积

$$q_m^T k_n = q^T R(m\omega)^T R(n\omega) k \quad (9.2)$$

$$= q^T R((n-m)\omega) k. \quad (9.3)$$

第二步用到 $R(a)^T = R(-a)$ 和 $R(a)R(b) = R(a+b)$ 。所以绝对位置旋转后的内积只依赖相对距离 $n-m$ 。

在 d_h 维中对相邻坐标对使用频率

$$\omega_j = \theta^{-2j/d_h}, \quad j = 0, \dots, d_h/2 - 1. \quad (9.4)$$

低 j 频率高、分辨近距离，高 j 频率低、覆盖远距离。若推理长度远超训练长度，相位 $m\omega_j$ 的外推和周期混叠会改变注意力几何；位置插值本质上是重新缩放这些相位。

10 RMSNorm 的 Jacobian

忽略可学习增益, RMSNorm

$$y = \frac{x}{s}, \quad s = \sqrt{\frac{1}{d}x^T x + \epsilon}. \quad (10.1)$$

微分

$$ds = \frac{x^T dx}{ds}, \quad (10.2)$$

因此

$$dy = \frac{1}{s}dx - \frac{x}{s^2}ds \quad (10.3)$$

$$= \left(\frac{1}{s}I - \frac{xx^T}{ds^3} \right) dx. \quad (10.4)$$

故

$$J_{\text{RMS}} = \frac{1}{s}I - \frac{xx^T}{ds^3}. \quad (10.5)$$

与 LayerNorm 相比, 它没有去均值投影 $I - d^{-1}\mathbf{1}\mathbf{1}^T$, 因此不消除常数方向。加上逐坐标增益 g 后, Jacobian 左乘 $\text{diag}(g)$ 。

谱上, 对任意 $v \perp x$, $Jv = v/s$; 沿 x 方向

$$Jx = \left(\frac{1}{s} - \frac{\|x\|^2}{ds^3} \right) x = \frac{\epsilon}{s^3}x. \quad (10.6)$$

当 ϵ 很小, 径向尺度方向被强烈压制, 而切向方向按 $1/s$ 缩放。

11 SwiGLU 前馈层的逐项梯度

SwiGLU 可写

$$a = xW_a, \quad b = xW_b, \quad h = \text{swish}(a) \odot b, \quad y = hW_o, \quad (11.1)$$

其中

$$\text{swish}(a) = a\sigma(a). \quad (11.2)$$

其导数

$$\frac{d}{da}[a\sigma(a)] = \sigma(a) + a\sigma(a)(1 - \sigma(a)). \quad (11.3)$$

令 $g_h = \partial\mathcal{L}/\partial h$, 则

$$g_a = g_h \odot b \odot [\sigma(a) + a\sigma(a)(1 - \sigma(a))], \quad (11.4)$$

$$g_b = g_h \odot \text{swish}(a), \quad (11.5)$$

$$\nabla_{W_a}\mathcal{L} = x^T g_a, \quad \nabla_{W_b}\mathcal{L} = x^T g_b, \quad (11.6)$$

$$\nabla_x\mathcal{L} = g_a W_a^T + g_b W_b^T. \quad (11.7)$$

门分支 b 同时调制激活和 a 分支梯度, 故两个投影不是可独立解释的普通 MLP。

12 MoE 路由与负载

对 token x_i , router logits $r_i = W_r x_i$, 概率

$$p_{ie} = \frac{e^{r_{ie}}}{\sum_{j=1}^E e^{r_{ij}}}. \quad (12.1)$$

若 top- k 专家集合 S_i , 归一化门

$$\tilde{p}_{ie} = \frac{p_{ie} \mathbf{1}\{e \in S_i\}}{\sum_{j \in S_i} p_{ij}}, \quad y_i = \sum_{e \in S_i} \tilde{p}_{ie} F_e(x_i). \quad (12.2)$$

固定集合 S_i 内可正常求导；集合边界的 arg-top- k 不连续，几乎处处把未选专家梯度置零。

令软重要性

$$P_e = \frac{1}{N} \sum_i p_{ie}, \quad (12.3)$$

硬负载

$$F_e = \frac{1}{N} \sum_i \mathbf{1}\{e \in S_i\}/k. \quad (12.4)$$

常见平衡项

$$L_{\text{bal}} = E \sum_e P_e F_e \quad (12.5)$$

在均匀 $P_e = F_e = 1/E$ 时等于 1。把硬 F_e 停止梯度后，router 梯度只通过 P_e ，会降低当前过载专家的概率；它是训练启发式，不等同于严格容量约束。

若每专家容量为

$$C_e = \left\lceil \frac{Nk}{E} c_{\text{cap}} \right\rceil, \quad (12.6)$$

超过容量的 token 必须丢弃或转送。即使平均负载均匀，局部批次方差仍可能溢出。

13 低秩 KV 潜变量的吸收

设 key/value 由共享潜变量

$$c_t = W_c x_t \in \mathbb{R}^{d_c}, \quad k_t = W_k c_t, \quad v_t = W_v c_t. \quad (13.1)$$

注意力 logit

$$q_s^T k_t = q_s^T W_k c_t = (W_k^T q_s)^T c_t. \quad (13.2)$$

因此解码时可把 W_k 吸收到 query 投影，缓存 c_t 而非完整 k_t 。若 value 聚合

$$o_s = \sum_t p_{st} W_v c_t = W_v \left(\sum_t p_{st} c_t \right), \quad (13.3)$$

W_v 可放到加权和之后。缓存从每 token 的 $d_k + d_v$ 降为 d_c ，前提是位置编码等操作不破坏这些线性交换关系；对只作用在部分 key 维度的 RoPE，需把旋转部分另行缓存或重构。

14 多 token 预测的联合似然

若同一隐藏状态 h_t 用 K 个头预测 $x_{t+1}, \dots, x_{t+K}$,

$$\mathcal{L}_t = \sum_{k=1}^K \lambda_k [-\log p_{\theta,k}(x_{t+k} | h_t)]. \quad (14.1)$$

共享骨干梯度

$$\nabla_{h_t} \mathcal{L}_t = \sum_{k=1}^K \lambda_k g_{t,k}. \quad (14.2)$$

其平方范数精确展开

$$\left\| \sum_k \lambda_k g_{t,k} \right\|^2 = \sum_k \lambda_k^2 \|g_{t,k}\|^2 + 2 \sum_{j < k} \lambda_j \lambda_k g_{t,j}^T g_{t,k}. \quad (14.3)$$

交叉内积为负时存在任务冲突；辅助头退火相当于训练后期逐渐去掉这些交叉项，使最终目标回到下一 token 似然。