

03_Flow to the Mode 数学过程详解

LFQ 二值量化、Rectified Flow、一步重建与可微采样损失

本文只处理真正需要推导的部分

本文聚焦编码器量化、流匹配目标、一步重建恒等式、感知损失、熵/承诺正则、多步采样复合与非均匀时间网格。全文按“公式从哪里来-每个符号是什么-中间步骤为何成立-维度和复杂度如何核对-论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1	编码器、二值量化与解码器的变量关系	3
1.1	量化不可导与直通估计	3
2	Rectified Flow 路径与速度目标	3
3	Flow Matching 损失的逐项解释	4
4	一步重建公式为什么是 $x_t + td_\theta$	4
5	感知损失与像素损失的梯度差异	5
6	量化承诺损失与熵正则	5
7	Stage 1A 总损失与不同项的尺度	5
8	多步 Euler 采样与可微采样损失	6
9	非均匀时间网格的推导	6
10	码率与重建质量的数学关系	6
11	容易混淆的符号与结论	7
12	二值量化与 Straight-Through Estimator 的精确梯度	7
13	码率、熵与互信息	7

14 Flow Matching 最优向量场是条件期望	8
15 一步重建公式的符号核对	8
16 Euler 多步采样的局部与全局误差	9
17 非均匀时间网格的密度解释	9
18 感知损失梯度经过特征 Jacobian	9
19 量化承诺损失的作用	10
20 模式寻求与条件均值模糊	10
21 Flow Matching 最优解的 L^2 投影证明	11
22 直线路径、反向 ODE 与一步重建的符号核验	11
23 二值量化与 Straight-Through Estimator 的偏差	12
24 熵正则的逐位梯度与码本塌缩	12
25 可微多步采样链的 Jacobian 连乘	13
26 Euler 采样误差的局部与全局界	13
27 非均匀时间网格的密度推导	13
28 率失真拉格朗日视角	14
29 一个一维条件均值导致模糊的例子	14

1 编码器、二值量化与解码器的变量关系

给定图像 $x \in \mathbb{R}^{H \times W \times 3}$ ，编码器先输出连续隐变量

$$\hat{c} = e_\phi(x, c_0), \quad c_0 = 0. \quad (1.1)$$

论文随后使用 lookup-free quantization，将每个分量二值化：

$$c = q(\hat{c}) = 2\mathbf{1}[\hat{c} \geq 0] - 1. \quad (1.2)$$

因此 $c_j \in \{-1, +1\}$ 。若隐变量共有 m 个二值位，理论码本容量为

$$|\mathcal{C}| = 2^m, \quad (1.3)$$

但实现中不需要显式存储 2^m 个向量，这正是 LFQ 与普通向量量化的重要区别。

1.1 量化不可导与直通估计

阶跃函数几乎处处导数为零，直接反向传播会得到

$$\frac{\partial q(\hat{c})}{\partial \hat{c}} = 0 \quad \text{a.e.} \quad (1.4)$$

训练通常用 straight-through estimator：前向仍取 $q(\hat{c})$ ，反向近似

$$\frac{\partial c}{\partial \hat{c}} \approx I. \quad (1.5)$$

可写成计算图技巧

$$c = \hat{c} + \text{sg}(q(\hat{c}) - \hat{c}), \quad (1.6)$$

因为 sg 分支不传梯度，于是前向值等于 $q(\hat{c})$ ，反向梯度却等于恒等映射。

2 Rectified Flow 路径与速度目标

论文定义噪声 $z \sim \mathcal{N}(0, I)$ 、数据 x 与时间 $t \sim U[0, 1]$ ，插值路径为

$$x_t = tz + (1 - t)x. \quad (2.1)$$

对时间求导：

$$\frac{dx_t}{dt} = z - x. \quad (2.2)$$

若解码器 $d_\theta(x_t, c, t)$ 预测从噪声方向到数据方向的速度，论文采用相反符号目标

$$v^* = x - z. \quad (2.3)$$

这是因为采样时从 $t = 1$ 向 $t = 0$ 积分，时间步长 $\Delta t < 0$ ；若网络输出 $x - z$ ，更新

$$x_{t+\Delta t} = x_t - \Delta s d_\theta(x_t, c, t), \quad \Delta s > 0, \quad (2.4)$$

会沿数据方向移动。理解公式时必须同时检查“时间方向”和“速度符号”，不能只看 x_t 的导数。

3 Flow Matching 损失的逐项解释

论文的核心回归损失为

$$\mathcal{L}_{\text{flow}} = \mathbb{E}_{x,z,t} \|x - z - d_{\theta}(x_t, q(e_{\phi}(x)), t)\|_2^2. \quad (3.1)$$

令误差

$$r_{\theta} = x - z - d_{\theta}(x_t, c, t), \quad (3.2)$$

则

$$\mathcal{L}_{\text{flow}} = \mathbb{E} r_{\theta}^{\top} r_{\theta}. \quad (3.3)$$

对网络输出 d_{θ} 的梯度为

$$\frac{\partial \mathcal{L}_{\text{flow}}}{\partial d_{\theta}} = -2\mathbb{E} r_{\theta} = 2\mathbb{E} [d_{\theta} - (x - z)]. \quad (3.4)$$

在均方误差下，最优函数满足条件期望性质：

$$d_{\theta^*}(x_t, c, t) = \mathbb{E}[x - z \mid x_t, c, t]. \quad (3.5)$$

因此网络一般学到的是所有可能 (x, z) 对的平均速度，而不是某一个样本对的唯一速度。

4 一步重建公式为什么是 $x_t + td_{\theta}$

从路径

$$x_t = tz + (1 - t)x \quad (4.1)$$

出发，若速度预测完全正确 $d_{\theta} = x - z$ ，则

$$x_t + td_{\theta} = tz + (1 - t)x + t(x - z) \quad (4.2)$$

$$= tz + (1 - t)x + tx - tz \quad (4.3)$$

$$= x. \quad (4.4)$$

所以一步干净图像估计为

$$\hat{x}_0 = x_t + td_{\theta}(x_t, c, t). \quad (4.5)$$

论文的感知损失正是作用于这个一步预测：

$$\mathcal{L}_{\text{perc}} = \mathbb{E} d_{\text{perc}}(x, x_t + td_{\theta}(x_t, c, t)). \quad (4.6)$$

它并不是直接约束速度向量，而是约束速度积分后得到的图像语义与纹理。

5 感知损失与像素损失的梯度差异

若 $d_{\text{perc}}(x, \hat{x}) = \|\psi(x) - \psi(\hat{x})\|_2^2$ ，其中 ψ 是冻结特征网络，则

$$\frac{\partial \mathcal{L}_{\text{perc}}}{\partial \hat{x}} = 2J_{\psi}(\hat{x})^{\top} [\psi(\hat{x}) - \psi(x)]. \quad (5.1)$$

再由 $\hat{x} = x_t + td_{\theta}$,

$$\frac{\partial \mathcal{L}_{\text{perc}}}{\partial d_{\theta}} = t \frac{\partial \mathcal{L}_{\text{perc}}}{\partial \hat{x}}. \quad (5.2)$$

因此高噪声时刻 t 较大，感知损失对速度的梯度更强；在 $t \approx 0$ 时，一步重建本来已接近 x ，梯度自然减弱。

6 量化承诺损失与熵正则

承诺损失常写为

$$\mathcal{L}_{\text{commit}} = \mathbb{E} \|\hat{c} - \text{sg}(q(\hat{c}))\|_2^2. \quad (6.1)$$

对 $\hat{c}$ 求导：

$$\frac{\partial \mathcal{L}_{\text{commit}}}{\partial \hat{c}} = 2(\hat{c} - q(\hat{c})), \quad (6.2)$$

它把连续编码推向 ± 1 ，减少量化前后偏差。

若第 j 位取 $+1$ 的经验概率为 p_j ，二元熵为

$$H_j = -p_j \log p_j - (1 - p_j) \log(1 - p_j). \quad (6.3)$$

熵在 $p_j = 1/2$ 时最大，在 $p_j \in \{0, 1\}$ 时为零。最大化边际熵可避免某些位长期恒定；同时若只最大化每位熵而不控制样本条件熵，可能产生随机而无语义的编码，因此 LFQ 的熵项通常包含“码本利用率”和“单样本确定性”的平衡。

7 Stage 1A 总损失与不同项的尺度

论文第一阶段总目标为

$$\mathcal{L}_{1A} = \mathcal{L}_{\text{flow}} + \lambda_{\text{perc}} \mathcal{L}_{\text{perc}} + \lambda_{\text{commit}} \mathcal{L}_{\text{commit}} + \lambda_{\text{ent}} \mathcal{L}_{\text{ent}}. \quad (7.1)$$

四项单位并不相同：flow 是像素空间速度平方，perceptual 是特征距离，commit 是隐变量距离，entropy 是无量纲信息量。权重 λ 不只是“重要性系数”，还承担数值尺度归一化作用。判断某项是否主导训练，应该比较

$$\lambda_i \|\nabla_{\theta} \mathcal{L}_i\|, \quad (7.2)$$

而不是只比较 λ_i 的数值。

8 多步 Euler 采样与可微采样损失

定义一步更新

$$d_{t_i}(x_{t_i}) = x_{t_i} + (t_i - t_{i+1})d_{\theta}(x_{t_i}, c, t_i), \quad (8.1)$$

其中采样方向满足 $t_{i+1} < t_i$ 。 n 步结果是函数复合

$$\hat{x} = d_{t_n} \circ d_{t_{n-1}} \circ \cdots \circ d_{t_1}(z). \quad (8.2)$$

Stage 1B 的采样损失可写为

$$\mathcal{L}_{\text{sample}} = \mathbb{E} d_{\text{perc}}(x, \hat{x}). \quad (8.3)$$

它把训练目标从“每个时刻速度局部正确”推进到“有限步数积分后的最终图像正确”。梯度需要穿过全部 Euler 步：

$$\frac{\partial \mathcal{L}_{\text{sample}}}{\partial \theta} = \frac{\partial \mathcal{L}}{\partial \hat{x}} \prod_{i=n}^1 \frac{\partial x_{t_{i+1}}}{\partial x_{t_i}} \sum_{j=1}^n \frac{\partial x_{t_{j+1}}}{\partial \theta}. \quad (8.4)$$

这比单步 flow matching 更耗显存，也更直接针对实际采样误差。

9 非均匀时间网格的推导

论文使用

$$t_i = \left(\frac{i}{n}\right)^{\rho}, \quad i = 0, 1, \dots, n. \quad (9.1)$$

相邻步长为

$$\Delta t_i = \left(\frac{i+1}{n}\right)^{\rho} - \left(\frac{i}{n}\right)^{\rho}. \quad (9.2)$$

当 $\rho > 1$ 时，导数

$$\frac{dt}{ds} = \rho s^{\rho-1} \quad (9.3)$$

随 $s = i/n$ 增大，因此靠近 $t = 1$ 的步长更大，靠近 $t = 0$ 的步长更密。若采样从 1 走向 0，这意味着更多计算分配到低噪声精修区。极限 $\rho \rightarrow \infty$ 时，大多数 t_i 接近零而最后一步接近一，时间网格高度不均匀。

10 码率与重建质量的数学关系

若图像有 $H \times W$ 像素，编码包含 M 个二值位，则理想固定长度码率

$$\text{bpp} = \frac{M}{HW}. \quad (10.1)$$

若使用熵编码，平均码长下界由熵给出：

$$R \geq \frac{H(C)}{HW}. \quad (10.2)$$

模式匹配 tokenizer 的目标不是逐像素重建最优，而是使条件分布 $p(x | c)$ 的主模态能够被解码器稳定命中。于是经典 rate-distortion 中的 distortion 被感知距离替代，优化更接近

$$\min_{e,d} R(c) + \beta \mathbb{E} d_{\text{perc}}(x, \hat{x}(c)). \quad (10.3)$$

11 容易混淆的符号与结论

必须同时检查的四件事

(1) $x_t = tz + (1-t)x$ 的时间方向与网络目标 $x - z$ 符号相反，原因是采样从 $t = 1$ 向 0；(2) 一步预测 $x_t + td_\theta$ 只有在该符号约定下成立；(3) LFQ 的 2^m 是潜在组合数，不等于训练中实际使用了全部码字；(4) 感知损失改善视觉质量并不保证逐像素似然或 PSNR 同步提高。

12 二值量化与 Straight-Through Estimator 的精确梯度

编码器输出 $h \in \mathbb{R}^m$ ，二值量化

$$q(h)_i = \text{sign}(h_i) \in \{-1, +1\}. \quad (12.1)$$

真实导数几乎处处为零：

$$\frac{\partial q_i}{\partial h_i} = 0 \quad \text{a.e.} \quad (12.2)$$

STE 用恒等映射替代反向导数。实现可写成

$$c = h + \text{sg}(q(h) - h). \quad (12.3)$$

前向时 $c = q(h)$ ；反向时

$$\frac{\partial c}{\partial h} = I + 0 \cdot \left(\frac{\partial q}{\partial h} - I \right) = I. \quad (12.4)$$

所以 STE 优化的不是原离散目标的真实梯度，而是一个代理梯度。若使用截断 STE

$$\frac{\partial c_i}{\partial h_i} \approx \mathbf{1}(|h_i| \leq 1), \quad (12.5)$$

可抑制远离阈值区域的有效大梯度。

13 码率、熵与互信息

长度为 m 的独立二值码理论上需要 m bit。若第 i 位取 $+1$ 的概率为 p_i ，最优无损熵码平均码长下界

$$R \geq H(C) = \sum_{i=1}^m h_2(p_i), \quad (13.1)$$

其中

$$h_2(p) = -p \log_2 p - (1-p) \log_2 (1-p). \quad (13.2)$$

当 $p_i = 1/2$ 时每位熵为 1；当 $p_i \rightarrow 0$ 或 1 时熵趋于 0，但该位几乎不携带样本区分信息。若编码器是确定函数 $C = E(X)$ ，则

$$I(X; C) = H(C) - H(C | X) = H(C). \quad (13.3)$$

因此压缩率与可保留信息之间存在直接上界。

14 Flow Matching 最优向量场是条件期望

给定插值

$$x_t = (1-t)x_0 + tx_1, \quad (14.1)$$

真实条件速度

$$u_t(x_0, x_1) = x_1 - x_0. \quad (14.2)$$

训练目标

$$\mathcal{L}(v) = \mathbb{E} \|v(x_t, t) - u_t\|^2. \quad (14.3)$$

对固定 (x_t, t) ，令随机变量 $U = u_t$ 。平方损失分解为

$$\mathbb{E}[\|v - U\|^2 | x_t, t] = \|v - \mathbb{E}[U | x_t, t]\|^2 \quad (14.4)$$

$$+ \mathbb{E} \|U - \mathbb{E}[U | x_t, t]\|^2. \quad (14.5)$$

第二项与 v 无关，所以最优场

$$\boxed{v^*(x, t) = \mathbb{E}[x_1 - x_0 | x_t = x, t].} \quad (14.6)$$

这解释了网络为何能从混合状态恢复一个确定速度：它学习所有可能配对速度的条件均值。

15 一步重建公式的符号核对

若论文把路径写成

$$x_t = (1-t)x + tz, \quad (15.1)$$

则速度

$$\dot{x}_t = z - x. \quad (15.2)$$

从时刻 t 沿反方向积分到 0：

$$x_0 = x_t - \int_0^t \dot{x}_s ds. \quad (15.3)$$

若用常速度近似 $d_\theta \approx x - z = -\dot{x}$ ，则

$$\boxed{\hat{x}_0 = x_t + td_\theta(x_t, c, t).} \quad (15.4)$$

正号来自网络预测的是去噪方向 $x - z$ ，而非前向速度 $z - x$ 。若网络定义相反，公式符号也必须反转。

16 Euler 多步采样的局部与全局误差

反向 ODE 为

$$\dot{x} = f_\theta(x, t). \quad (16.1)$$

Euler 更新

$$x_{i+1} = x_i + h_i f_\theta(x_i, t_i). \quad (16.2)$$

Taylor 展开精确解

$$x(t_i + h_i) = x(t_i) + h_i f(x_i, t_i) + \frac{h_i^2}{2} \ddot{x}(\xi_i) \quad (16.3)$$

给出局部误差 $O(h_i^2)$ 。若 f 对 x 的 Lipschitz 常数为 L ，离散 Grönwall 不等式给出

$$\|e_n\| \leq e^{LT} \left(\|e_0\| + C \sum_i h_i^2 \right). \quad (16.4)$$

均匀步长 $h = T/n$ 时全局误差为 $O(h) = O(1/n)$ 。非均匀网格的误差由 $\sum_i h_i^2$ 决定，而不只由步数决定。

17 非均匀时间网格的密度解释

论文使用

$$t_i = \left(\frac{i}{n} \right)^\rho. \quad (17.1)$$

令连续索引 $s = i/n$ ，则

$$\frac{dt}{ds} = \rho s^{\rho-1}. \quad (17.2)$$

当 $\rho > 1$ ，靠近 $t = 0$ 时导数小，网格更密；靠近 $t = 1$ 时步长更大。相邻步长近似

$$h_i \approx \frac{\rho}{n} \left(\frac{i}{n} \right)^{\rho-1}. \quad (17.3)$$

若去噪场在低噪声端曲率更大，这种分配可减少主导误差；若高噪声端更难，则应选择相反的时间变换。

18 感知损失梯度经过特征 Jacobian

设冻结感知网络为 ϕ ，损失

$$\mathcal{L}_{\text{perc}} = \|\phi(\hat{x}) - \phi(x)\|_2^2. \quad (18.1)$$

梯度

$$\nabla_{\hat{x}} \mathcal{L}_{\text{perc}} = 2J_\phi(\hat{x})^\top [\phi(\hat{x}) - \phi(x)]. \quad (18.2)$$

像素 MSE 的梯度方向是 $\hat{x} - x$ ；感知损失则先把特征误差通过 $J_\phi^\top$ 映回像素空间，所以它会优先修正感知网络敏感的结构，而可能忽略像素级高频偏差。

19 量化承诺损失的作用

承诺项

$$\mathcal{L}_{\text{commit}} = \|h - \text{sg}(q(h))\|^2 \quad (19.1)$$

对编码器输出的梯度

$$\nabla_h \mathcal{L}_{\text{commit}} = 2(h - q(h)). \quad (19.2)$$

它把连续表示拉向离散顶点，减少训练时连续 h 与推理时离散码之间的分布差。若权重过大， h 很早饱和在 ± 1 ，STE 可用梯度区域缩小；若过小，量化误差

$$\mathbb{E} \|h - q(h)\|^2 \quad (19.3)$$

会主导重建失败。

20 模式寻求与条件均值模糊

平方误差下最优预测是条件均值。若给定码 c 的真实图像分布有两个模式 $x^{(1)}, x^{(2)}$ ，概率各 $1/2$ ，则 MSE 最优解

$$\hat{x}^* = \frac{x^{(1)} + x^{(2)}}{2} \quad (20.1)$$

可能落在两个自然图像模式之间，产生模糊。Flow 解码器通过引入随机起点 z 和动力学

$$\dot{x} = v_\theta(x, c, t) \quad (20.2)$$

表示完整条件分布，而非只输出均值；这就是“mode-seeking tokenization”区别于确定性回归解码的数学基础。

21 Flow Matching 最优解的 L^2 投影证明

论文用可采样的条件速度监督网络。设随机变量为 (X, Z, T) ，条件目标速度为 V ，网络只能观察 (Z, T, C) 。考虑

$$\mathcal{L}(f) = \mathbb{E}\|f(Z, T, C) - V\|_2^2. \quad (21.1)$$

令

$$m(Z, T, C) = \mathbb{E}[V \mid Z, T, C]. \quad (21.2)$$

把误差拆成

$$f - V = (f - m) + (m - V). \quad (21.3)$$

平方并取期望：

$$\mathcal{L}(f) = \mathbb{E}\|f - m\|_2^2 + \mathbb{E}\|m - V\|_2^2 + 2\mathbb{E}\langle f - m, m - V \rangle. \quad (21.4)$$

最后一项为零，因为

$$\mathbb{E}[\langle f - m, m - V \rangle] = \mathbb{E}\left[\mathbb{E}[\langle f - m, m - V \rangle \mid Z, T, C]\right] \quad (21.5)$$

$$= \mathbb{E}\left[\langle f - m, \mathbb{E}[m - V \mid Z, T, C] \rangle\right] = 0. \quad (21.6)$$

所以

$$\mathcal{L}(f) = \mathbb{E}\|f - m\|_2^2 + \text{与 } f \text{ 无关的常数}, \quad (21.7)$$

唯一的 Bayes 最优解为

$$\boxed{f^*(z, t, c) = \mathbb{E}[V \mid Z = z, T = t, C = c]}. \quad (21.8)$$

这解释了为何用成对样本构造的速度监督，最终学到的是边缘概率流的条件平均速度。

22 直线路径、反向 ODE 与一步重建的符号核

论文定义

$$x_t = tz + (1 - t)x, \quad (22.1)$$

其中 $t = 0$ 为真实图像， $t = 1$ 为噪声。对 t 求导：

$$\dot{x}_t = z - x. \quad (22.2)$$

若网络 $d_\theta(x_t, c, t)$ 预测 $z - x$ ，则从当前 t 向 0 做一步 Euler：

$$\hat{x}_0 = x_t + (0 - t)d_\theta(x_t, c, t) \quad (22.3)$$

$$= x_t - td_\theta(x_t, c, t). \quad (22.4)$$

若论文的 d_θ 定义为相反方向 $x - z$ ，则公式变为 $x_t + td_\theta$ 。因此阅读时必须同时检查“路径方向”和“速度符号”，不能只记忆一步重建公式。精确速度下，若 $d = x - z$ ，

$$x_t + t(x - z) = tz + (1 - t)x + tx - tz = x. \quad (22.5)$$

23 二值量化与 Straight-Through Estimator 的偏差

编码器输出 $\hat{c} \in \mathbb{R}^d$ ，二值量化为

$$c = q(\hat{c}) = 2\mathbf{1}[\hat{c} \geq 0] - 1. \quad (23.1)$$

真实导数几乎处处为零：

$$\frac{\partial q}{\partial \hat{c}} = 0 \quad \text{a.e.} \quad (23.2)$$

若直接反向传播，编码器无法收到重建损失梯度。STE 在反向时人为设定

$$\frac{\partial q}{\partial \hat{c}} \approx I \quad (23.3)$$

或带截断的

$$\frac{\partial q_i}{\partial \hat{c}_i} \approx \mathbf{1}(|\hat{c}_i| \leq 1). \quad (23.4)$$

于是编码器梯度近似为

$$\nabla_{\hat{c}} \mathcal{L} \approx \nabla_c \mathcal{L}. \quad (23.5)$$

该估计不是某个光滑量化函数的真实梯度，因此一般有偏。它能工作依赖于：前向使用真实离散码，反向使用能够推动 $\hat{c}$ 跨越阈值的代理方向。

24 熵正则的逐位梯度与码本塌缩

设第 j 位取 +1 的经验概率为 p_j ，二元熵为

$$H(p_j) = -p_j \log p_j - (1 - p_j) \log(1 - p_j). \quad (24.1)$$

其导数

$$\frac{dH}{dp_j} = \log \frac{1 - p_j}{p_j}. \quad (24.2)$$

当 $p_j \rightarrow 0$ 时导数趋于 $+\infty$ ，当 $p_j \rightarrow 1$ 时趋于 $-\infty$ ，最大值位于 $p_j = 1/2$ 。因此最大化逐位熵会推动每一位均衡使用。

但仅最大化边缘熵不能保证不同位独立。若所有位完全相同，仍可能有每位 $p_j = 1/2$ ，而联合码只有两个状态。联合熵满足

$$H(C_1, \dots, C_d) \leq \sum_{j=1}^d H(C_j), \quad (24.3)$$

等号只在各位独立时成立。因此更严格的防塌缩目标需要同时抑制总相关性

$$\text{TC}(C) = \sum_j H(C_j) - H(C_1, \dots, C_d). \quad (24.4)$$

25 可微多步采样链的 Jacobian 连乘

设离散采样步为

$$x_{i+1} = x_i + \Delta t_i d_\theta(x_i, c, t_i). \quad (25.1)$$

最终感知损失 $\ell(x_n, x)$ 对参数的梯度满足

$$\frac{\partial \ell}{\partial \theta} = \frac{\partial \ell}{\partial x_n} \frac{\partial x_n}{\partial \theta}. \quad (25.2)$$

递推

$$\frac{\partial x_{i+1}}{\partial \theta} = (I + \Delta t_i J_x d_i) \frac{\partial x_i}{\partial \theta} + \Delta t_i J_\theta d_i. \quad (25.3)$$

展开后

$$\frac{\partial x_n}{\partial \theta} = \sum_{k=0}^{n-1} \left[\prod_{j=k+1}^{n-1} (I + \Delta t_j J_x d_j) \right] \Delta t_k J_\theta d_k. \quad (25.4)$$

这说明采样损失会把后续所有步的状态 Jacobian 乘到早期步梯度上；步数越多，显存和数值稳定压力越大。

26 Euler 采样误差的局部与全局界

对 ODE $\dot{x} = f(x, t)$ ，假设 f 对 x 是 L -Lipschitz，且真解二阶可导。一步 Euler 的局部截断误差为

$$\tau_i = x(t_{i+1}) - x(t_i) - h_i f(x(t_i), t_i) = O(h_i^2). \quad (26.1)$$

数值误差 $e_i = \hat{x}_i - x(t_i)$ 满足

$$\|e_{i+1}\| \leq (1 + Lh_i)\|e_i\| + Ch_i^2. \quad (26.2)$$

若均匀步长 $h = T/n$ ，离散 Gronwall 不等式给出

$$\max_i \|e_i\| = O(h) = O(n^{-1}). \quad (26.3)$$

若网络速度还有误差 $\|d_\theta - f\| \leq \varepsilon$ ，则额外项为 $h_i \varepsilon$ ，累计后约为 $T\varepsilon e^{LT}$ 。因此增加步数只能减少离散化误差，不能消除模型误差。

27 非均匀时间网格的密度推导

令连续变量 $s \in [0, 1]$ 均匀离散，时间映射为 $t = \phi(s)$ 。第 i 步宽度近似

$$\Delta t_i \approx \phi'(s_i) \Delta s. \quad (27.1)$$

某个时间区间内的点密度与 ϕ' 成反比：

$$\rho_t(t) \propto \frac{1}{\phi'(\phi^{-1}(t))}. \quad (27.2)$$

若希望在靠近数据端 $t = 0$ 放置更多步，应选择那里较小的 ϕ' 。论文的幂次调度可写成

$$t_i = \left(\frac{i}{n}\right)^\rho, \quad (27.3)$$

当 $\rho > 1$ 时， t 接近 0 的间隔更小；当 $\rho < 1$ 时，点更集中在 $t = 1$ 附近。

28 率失真拉格朗日视角

离散码率约为

$$R \approx H(C), \quad (28.1)$$

重建失真可取像素或感知距离

$$D = \mathbb{E}[d(X, \hat{X})]. \quad (28.2)$$

经典率失真优化写成

$$\min_{\theta} D + \beta R. \quad (28.3)$$

论文中的流匹配、感知损失、承诺损失和熵正则可以理解为该目标的可训练替代：流匹配控制生成动力学，感知项定义失真，熵项控制码利用率。不同损失权重并非纯经验常数，而是在隐式选择率失真曲线上的工作点。

29 一个一维条件均值导致模糊的例子

假设同一个离散码 c 对应两种等概率图像标量 $X \in \{-1, +1\}$ 。若解码器用平方误差直接回归，Bayes 最优输出为

$$\hat{x}^*(c) = \mathbb{E}[X | c] = 0, \quad (29.1)$$

它并不属于真实的两个模式。若使用能表达条件分布的生成解码器，则目标是学习

$$p(x | c) = \frac{1}{2}\delta_{-1}(x) + \frac{1}{2}\delta_{+1}(x), \quad (29.2)$$

采样会落在某个模式而不是均值。这就是“mode-seeking”相对于纯重建回归的数学动机。