

# 04\_NoProp 数学过程详解

ELBO、高斯条件分布、SNR 权重与局部独立训练的完整推导

## 本文只处理真正需要推导的部分

本文重点还原论文附录 A.1–A.4：从证据下界到高斯 KL，再到 SNR 差分加权的逐层平方误差，并解释连续时间和 Flow Matching 版本。全文按“公式从哪里来–每个符号是什么–中间步骤为何成立–维度和复杂度如何核对–论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

## 目录

|    |                                      |   |
|----|--------------------------------------|---|
| 1  | NoProp 的概率模型：把网络深度改写成潜变量链            | 3 |
| 2  | ELBO 从哪里来：逐步恢复论文公式                   | 3 |
| 3  | 固定 OU 扩散后验的边缘分布                      | 3 |
| 4  | 条件高斯均值 $a_t u_y + b_t z_{t-1}$ 的推导思想 | 4 |
| 5  | 网络转移与残差结构                            | 4 |
| 6  | 高斯 KL 如何化为逐层平方误差                     | 5 |
| 7  | NoProp 离散目标的完整形式                     | 5 |
| 8  | 为什么每个块可以独立训练                         | 5 |
| 9  | 连续时间极限                               | 6 |
| 10 | Flow Matching 版本                     | 6 |
| 11 | 输出分类器与标签嵌入重构                         | 7 |
| 12 | NoProp 结论的严格边界                       | 7 |
| 13 | ELBO 的逐步 Jensen 推导                   | 7 |
| 14 | Markov 分解如何产生逐层 KL                   | 8 |

|                             |    |
|-----------------------------|----|
| 15 OU 边缘分布的 SDE 解           | 8  |
| 16 高斯条件后验的配方法               | 8  |
| 17 等协方差高斯 KL 的完整化简          | 9  |
| 18 局部目标为何不需要跨层反向传播          | 9  |
| 19 连续时间 Flow Matching 目标    | 10 |
| 20 内存复杂度对比                  | 10 |
| 21 输出分类器与标签嵌入几何             | 10 |
| 22 从联合分布到 ELBO 的逐行推导        | 12 |
| 23 反向 Markov 分解如何产生逐层 KL    | 12 |
| 24 线性高斯 OU 边缘分布的递推证明        | 12 |
| 25 两个高斯相乘得到条件后验的配方法         | 13 |
| 26 等协方差高斯 KL 为什么变成平方误差      | 13 |
| 27 局部梯度为何不包含其他块参数           | 14 |
| 28 一个 $T = 2$ 的完整标量例子       | 14 |
| 29 连续时间极限：离散 OU 到 SDE       | 15 |
| 30 Flow Matching 版本的条件路径与速度 | 15 |
| 31 内存复杂度的严格比较               | 16 |

## 1 NoProp 的概率模型：把网络深度改写成潜变量链

论文令类别标签  $y \in \{1, \dots, m\}$  对应嵌入  $u_y \in \mathbb{R}^d$ 。深度方向的隐状态记为  $z_0, z_1, \dots, z_T$ 。生成方向（论文称 forward process）为

$$p(z_{0:T}, y \mid x) = p(z_0) \prod_{t=1}^T p_\theta(z_t \mid z_{t-1}, x) p_{\theta_{\text{out}}}(y \mid z_T). \quad (1.1)$$

辅助后验方向为

$$q(z_{0:T} \mid y, x) = q(z_T \mid y) \prod_{t=T}^1 q(z_{t-1} \mid z_t, y). \quad (1.2)$$

这里  $q$  只依赖标签嵌入并被固定成可解析高斯扩散； $p_\theta$  由每一层独立网络块拟合。NoProp 的“无全局前向/反向传播”来自：每个  $t$  的训练样本  $z_{t-1}$  可以直接从  $q(z_{t-1} \mid y)$  采样，而不必先运行前面所有块。

## 2 ELBO 从哪里来：逐步恢复论文公式

从边缘似然

$$p(y \mid x) = \int p(z_{0:T}, y \mid x) \mathrm{d}z_{0:T} \quad (2.1)$$

出发，乘除任意后验  $q(z_{0:T} \mid y, x)$ ：

$$\log p(y \mid x) = \log \int q(z_{0:T} \mid y, x) \frac{p(z_{0:T}, y \mid x)}{q(z_{0:T} \mid y, x)} \mathrm{d}z_{0:T}. \quad (2.2)$$

由于  $\log$  为凹函数，Jensen 不等式给出

$$\boxed{\log p(y \mid x) \geq \mathbb{E}_q [\log p(z_{0:T}, y \mid x) - \log q(z_{0:T} \mid y, x)]}. \quad (2.3)$$

把两个链式分解代入并重排，可得

$$\text{ELBO} = \mathbb{E}_{q(z_T \mid y)} \log p_{\theta_{\text{out}}}(y \mid z_T) - D_{\text{KL}}(q(z_0 \mid y) \parallel p(z_0)) \quad (2.4)$$

$$- \sum_{t=1}^T \mathbb{E}_{q(z_{t-1} \mid y)} D_{\text{KL}}(q(z_t \mid z_{t-1}, y) \parallel p_\theta(z_t \mid z_{t-1}, x)). \quad (2.5)$$

因此最小化负 ELBO 会产生三个部分：输出交叉熵、初始分布 KL、每层条件高斯 KL。

## 3 固定 OU 扩散后验的边缘分布

论文使用方差保持的离散 Ornstein–Uhlenbeck 过程。设单步系数  $\alpha_t \in (0, 1)$ ，累乘

$$\bar{\alpha}_t = \prod_{s=t+1}^T \alpha_s \quad (3.1)$$

(索引方向按论文由  $z_T$  向  $z_0$  的后验链约定)。边缘分布写成

$$q(z_t | y) = \mathcal{N}(z_t; \sqrt{\bar{\alpha}_t} u_y, (1 - \bar{\alpha}_t) I). \quad (3.2)$$

所以可直接重参数化采样

$$z_t = \sqrt{\bar{\alpha}_t} u_y + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I). \quad (3.3)$$

均值保留标签信号，方差注入噪声。信噪比为

$$\text{SNR}(t) = \frac{\bar{\alpha}_t}{1 - \bar{\alpha}_t}. \quad (3.4)$$

## 4 条件高斯均值 $a_t u_y + b_t z_{t-1}$ 的推导思想

联合变量  $(z_{t-1}, z_t)$  在给定  $y$  时为高斯，因此条件分布仍为高斯：

$$q(z_t | z_{t-1}, y) = \mathcal{N}(z_t; \mu_t(z_{t-1}, u_y), c_t I). \quad (4.1)$$

高斯条件均值公式

$$\mathbb{E}[z_t | z_{t-1}, y] = \mu_t^{(0)} + \Sigma_{t,t-1} \Sigma_{t-1,t-1}^{-1} (z_{t-1} - \mu_{t-1}^{(0)}) \quad (4.2)$$

说明条件均值必为  $z_{t-1}$  与  $u_y$  的线性组合，因此可写成

$$\mu_t(z_{t-1}, u_y) = a_t u_y + b_t z_{t-1}. \quad (4.3)$$

论文给出的系数为

$$a_t = \frac{\sqrt{\bar{\alpha}_t}(1 - \alpha_{t-1})}{1 - \bar{\alpha}_{t-1}}, \quad (4.4)$$

$$b_t = \frac{\sqrt{\alpha_{t-1}}(1 - \bar{\alpha}_t)}{1 - \bar{\alpha}_{t-1}}, \quad (4.5)$$

$$c_t = \frac{(1 - \bar{\alpha}_t)(1 - \alpha_{t-1})}{1 - \bar{\alpha}_{t-1}}. \quad (4.6)$$

这些系数并非可学习参数，而是由噪声日程唯一决定。

## 5 网络转移与残差结构

模型把真实标签嵌入  $u_y$  替换成网络预测  $\hat{u}_{\theta_t}(z_{t-1}, x)$ ：

$$p_{\theta}(z_t | z_{t-1}, x) = \mathcal{N}(z_t; a_t \hat{u}_{\theta_t}(z_{t-1}, x) + b_t z_{t-1}, c_t I). \quad (5.1)$$

重参数化后

$$z_t = a_t \hat{u}_{\theta_t}(z_{t-1}, x) + b_t z_{t-1} + \sqrt{c_t} \epsilon_t. \quad (5.2)$$

$b_t z_{t-1}$  是显式跳连， $a_t \hat{u}_{\theta_t}$  是当前块对标签原型的估计，噪声项保证与扩散后验方差一致。

## 6 高斯 KL 如何化为逐层平方误差

两个协方差完全相同的高斯

$$q = \mathcal{N}(\mu_q, c_t I), \quad p = \mathcal{N}(\mu_p, c_t I) \quad (6.1)$$

满足

$$D_{\text{KL}}(q||p) = \frac{1}{2c_t} \|\mu_q - \mu_p\|_2^2. \quad (6.2)$$

本论文中

$$\mu_q = a_t u_y + b_t z_{t-1}, \quad (6.3)$$

$$\mu_p = a_t \hat{u}_{\theta_t}(z_{t-1}, x) + b_t z_{t-1}. \quad (6.4)$$

跳连项相消：

$$\mu_q - \mu_p = a_t (u_y - \hat{u}_{\theta_t}). \quad (6.5)$$

于是

$$D_{\text{KL}}(q||p) = \frac{a_t^2}{2c_t} \|\hat{u}_{\theta_t} - u_y\|_2^2. \quad (6.6)$$

代入  $a_t, c_t$  并化简：

$$\frac{a_t^2}{2c_t} = \frac{1}{2} \frac{\bar{\alpha}_t(1 - \alpha_{t-1})}{(1 - \bar{\alpha}_t)(1 - \bar{\alpha}_{t-1})} \quad (6.7)$$

$$= \frac{1}{2} \left[ \frac{\bar{\alpha}_t}{1 - \bar{\alpha}_t} - \frac{\bar{\alpha}_{t-1}}{1 - \bar{\alpha}_{t-1}} \right] \quad (6.8)$$

$$= \frac{1}{2} [\text{SNR}(t) - \text{SNR}(t-1)]. \quad (6.9)$$

所以每层 KL 正好变成 SNR 增量加权的原型回归损失。

## 7 NoProp 离散目标的完整形式

取负 ELBO，并用均匀采样  $t \sim U\{1, \dots, T\}$  对求和做无偏估计，得到

$$\mathcal{L}_{\text{NoProp}} = \mathbb{E}_{q(z_T|y)} [-\log \hat{p}_{\theta_{\text{out}}}(y | z_T)] + D_{\text{KL}}(q(z_0 | y) || p(z_0)) \quad (7.1)$$

$$+ \frac{\eta T}{2} \mathbb{E}_{t, z_{t-1}} [(\text{SNR}(t) - \text{SNR}(t-1)) \|\hat{u}_{\theta_t}(z_{t-1}, x) - u_y\|_2^2]. \quad (7.2)$$

若实现中遍历所有  $t$ ，则不需要  $T$  的 Monte Carlo 补偿；若随机抽一个  $t$  估计总和，则必须乘  $T$  才严格无偏。论文公式将常数吸收到超参数  $\eta$  中。

## 8 为什么每个块可以独立训练

第  $t$  块的局部损失为

$$\ell_t(\theta_t) = w_t \|\hat{u}_{\theta_t}(z_{t-1}, x) - u_y\|_2^2, \quad w_t = \text{SNR}(t) - \text{SNR}(t-1). \quad (8.1)$$

训练输入  $z_{t-1}$  直接从已知  $q(z_{t-1} | y)$  采样，所以

$$\nabla_{\theta_t} \ell_t = 2w_t J_{\theta_t} \hat{u}_{\theta_t}^\top (\hat{u}_{\theta_t} - u_y) \quad (8.2)$$

不包含  $\theta_1, \dots, \theta_{t-1}$  的导数。标准反向传播则需要

$$\frac{\partial \mathcal{L}}{\partial \theta_t} = \frac{\partial \mathcal{L}}{\partial z_T} \prod_{s=t+1}^T \frac{\partial z_s}{\partial z_{s-1}} \frac{\partial z_t}{\partial \theta_t}. \quad (8.3)$$

NoProp 用固定后验提供局部监督，避免了这个长 Jacobian 乘积，但代价是优化目标变成变分下界而非直接端到端分类损失。

## 9 连续时间极限

令时间间隔  $\tau = 1/T$ 。离散权重可写成差商

$$\frac{\text{SNR}(t + \tau) - \text{SNR}(t)}{\tau}. \quad (9.1)$$

当  $T \rightarrow \infty$ 、 $\tau \rightarrow 0$  时

$$\frac{\text{SNR}(t + \tau) - \text{SNR}(t)}{\tau} \rightarrow \text{SNR}'(t). \quad (9.2)$$

连续目标为

$$\mathcal{L}_{\text{CT}} = \mathbb{E}[-\log \hat{p}(y | z_1)] + D_{\text{KL}}(q(z_0 | y) \| p(z_0)) \quad (9.3)$$

$$+ \frac{\eta}{2} \mathbb{E}_{t \sim U[0,1]} [\text{SNR}'(t) \|\hat{u}_{\theta}(z_t, x, t) - u_y\|_2^2]. \quad (9.4)$$

离散版本每个时刻一个块；连续版本用同一网络并把  $t$  作为输入。

## 10 Flow Matching 版本

取  $z_0 \sim \mathcal{N}(0, I)$ 、 $z_1 = u_y$ ，定义高斯路径

$$p_t(z_t | z_0, z_1, x) = \mathcal{N}(z_t; tz_1 + (1-t)z_0, \sigma^2 I). \quad (10.1)$$

均值轨迹的导数为

$$\frac{d}{dt} [tz_1 + (1-t)z_0] = z_1 - z_0. \quad (10.2)$$

故条件向量场是常量  $z_1 - z_0$ ，训练目标

$$\mathcal{L}_{\text{FM}} = \mathbb{E} \|v_{\theta}(z_t, x, t) - (u_y - z_0)\|_2^2. \quad (10.3)$$

与离散 NoProp 相同，它也允许随机抽取时间训练，不需要把整条 ODE 路径展开后反向传播。

## 11 输出分类器与标签嵌入重构

最后输出 logits  $f_{\theta_{\text{out}}}(z_T) \in \mathbb{R}^m$ , 概率

$$\hat{p}(y | z_T) = \frac{\exp f_y(z_T)}{\sum_{j=1}^m \exp f_j(z_T)}. \quad (11.1)$$

若将概率重新映射回嵌入空间,

$$\tilde{y} = \text{softmax}(f(z_T))W_{\text{Embed}}, \quad (11.2)$$

则  $\tilde{y}$  是所有类别原型的凸组合。平方重构

$$\|\tilde{y} - u_y\|_2^2 \quad (11.3)$$

不仅惩罚分类错误, 还利用类别嵌入之间的几何距离; 若原型不正交, 两个错误类别的惩罚可以不同。

## 12 NoProp 结论的严格边界

**“不需要前向传播” 不等于推理不前向**

训练第  $t$  块时不需要先运行  $1, \dots, t-1$  块, 也不需要把最终损失反传穿过全部深度; 但推理时仍需按  $z_0 \rightarrow z_1 \rightarrow \dots \rightarrow z_T$  运行网络链。局部目标来自固定后验与 ELBO, 因此其最优解是否达到端到端训练性能取决于后验设计、标签嵌入容量和各局局部块的拟合误差。

## 13 ELBO 的逐步 Jensen 推导

观测标签为  $y$ , 潜变量链为  $z_{0:T}$ 。边缘似然

$$p_{\theta}(y | x) = \int p_{\theta}(y, z_{0:T} | x) \mathrm{d}z_{0:T}. \quad (13.1)$$

插入任意变分分布  $q(z_{0:T} | y)$ :

$$\log p_{\theta}(y | x) = \log \mathbb{E}_q \left[ \frac{p_{\theta}(y, z_{0:T} | x)}{q(z_{0:T} | y)} \right] \quad (13.2)$$

$$\geq \mathbb{E}_q \log \frac{p_{\theta}(y, z_{0:T} | x)}{q(z_{0:T} | y)} = \mathcal{E}(\theta), \quad (13.3)$$

不等号来自  $\log$  的凹性。两者差值恰好是

$$\log p_{\theta}(y | x) - \mathcal{E} = D_{\text{KL}}(q(z_{0:T} | y) \| p_{\theta}(z_{0:T} | y, x)) \geq 0. \quad (13.4)$$

因此最大化 ELBO 等价于让模型后验逼近固定的标签扩散后验。

## 14 Markov 分解如何产生逐层 KL

若

$$q(z_{0:T} | y) = q(z_0 | y) \prod_{t=1}^T q(z_t | z_{t-1}, y) \quad (14.1)$$

且生成模型

$$p_\theta(y, z_{0:T} | x) = p(y | z_T) p(z_0) \prod_{t=1}^T p_{\theta_t}(z_t | z_{t-1}, x), \quad (14.2)$$

则对数比值拆成各因子的对数之和。取期望后

$$\mathcal{E} = \mathbb{E}_q \log p(y | z_T) - D_{\text{KL}}(q(z_0 | y) \| p(z_0)) \quad (14.3)$$

$$- \sum_{t=1}^T \mathbb{E}_{q(z_{t-1}|y)} D_{\text{KL}}(q(z_t | z_{t-1}, y) \| p_{\theta_t}(z_t | z_{t-1}, x)). \quad (14.4)$$

每个  $\theta_t$  只出现在第  $t$  个 KL 中，这是可局部训练的概率根源。

## 15 OU 边缘分布的 SDE 解

连续 OU 过程

$$dz_t = -\frac{1}{2}\beta(t)z_t dt + \sqrt{\beta(t)}dW_t, \quad z_0 = u_y \quad (15.1)$$

的积分因子为

$$a(t) = \exp\left(-\frac{1}{2} \int_0^t \beta(s) ds\right). \quad (15.2)$$

解为

$$z_t = a(t)u_y + a(t) \int_0^t \frac{\sqrt{\beta(s)}}{a(s)} dW_s. \quad (15.3)$$

随机积分是零均值高斯，方差

$$a(t)^2 \int_0^t \frac{\beta(s)}{a(s)^2} ds = a(t)^2 [a(t)^{-2} - 1] \quad (15.4)$$

$$= 1 - a(t)^2. \quad (15.5)$$

故

$$q(z_t | y) = \mathcal{N}(a(t)u_y, (1 - a(t)^2)I). \quad (15.6)$$

离散记号中  $a(t)^2$  对应  $\bar{\alpha}_{t_0}$

## 16 高斯条件后验的配方法

设

$$q(z_{t-1} | y) = \mathcal{N}(m_{t-1}, s_{t-1}^2 I), \quad (16.1)$$



转移

$$q(z_t | z_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} z_{t-1}, (1 - \alpha_t)I). \quad (16.2)$$

Bayes 后验的负对数中与  $z_{t-1}$  有关的项为

$$\frac{\|z_{t-1} - m_{t-1}\|^2}{2s_{t-1}^2} + \frac{\|z_t - \sqrt{\alpha_t} z_{t-1}\|^2}{2(1 - \alpha_t)}. \quad (16.3)$$

展开并收集二次项，精度矩阵

$$\Lambda = \frac{1}{s_{t-1}^2} I + \frac{\alpha_t}{1 - \alpha_t} I. \quad (16.4)$$

均值为

$$\mu = \Lambda^{-1} \left( \frac{m_{t-1}}{s_{t-1}^2} + \frac{\sqrt{\alpha_t}}{1 - \alpha_t} z_t \right). \quad (16.5)$$

代入  $m_{t-1} = \sqrt{\bar{\alpha}_{t-1}} u_y$  与  $s_{t-1}^2 = 1 - \bar{\alpha}_{t-1}$ ，即可整理成论文的

$$\mu_t = a_t u_y + b_t z_t, \quad (16.6)$$

并得到闭式方差  $c_t I$ 。

## 17 等协方差高斯 KL 的完整化简

一般高斯 KL 为

$$D_{\text{KL}}(\mathcal{N}(\mu_q, \Sigma_q) \| \mathcal{N}(\mu_p, \Sigma_p)) = \frac{1}{2} [\text{Tr}(\Sigma_p^{-1} \Sigma_q) + (\mu_p - \mu_q)^\top \Sigma_p^{-1} (\mu_p - \mu_q)] \quad (17.1)$$

$$-d + \log \frac{\det \Sigma_p}{\det \Sigma_q} \Big]. \quad (17.2)$$

当  $\Sigma_q = \Sigma_p = c_t I$  时，迹项为  $d$ ，对数行列式为 0，与  $-d$  抵消，只剩

$$D_{\text{KL}} = \frac{1}{2c_t} \|\mu_q - \mu_p\|^2. \quad (17.3)$$

若两均值只在标签嵌入预测上不同

$$\mu_q - \mu_p = a_t(u_y - \hat{u}_{\theta_t}), \quad (17.4)$$

则

$$D_{\text{KL}} = \frac{a_t^2}{2c_t} \|u_y - \hat{u}_{\theta_t}\|^2. \quad (17.5)$$

这说明论文逐层 MSE 不是随意设计，而是精确高斯 KL。

## 18 局部目标为何不需要跨层反向传播

第  $t$  层损失

$$\mathcal{L}_t(\theta_t) = \mathbb{E}_{y,x,z_{t-1}} w_t \|u_y - f_{\theta_t}(z_{t-1}, x)\|^2. \quad (18.1)$$

采样  $z_{t-1}$  来自固定  $q$ ，不依赖任何前层参数。因此

$$\frac{\partial z_{t-1}}{\partial \theta_s} = 0, \quad s < t. \quad (18.2)$$

于是

$$\nabla_{\theta_s} \mathcal{L}_t = 0 \quad (s \neq t), \quad (18.3)$$

每个块可独立优化。与 backprop 的差别不是链式法则被“近似”，而是概率构造主动切断了参数依赖图。

## 19 连续时间 Flow Matching 目标

在连续时间中，标签条件路径  $q_t(z | y)$  满足连续性方程

$$\partial_t q_t + \nabla \cdot (q_t u_t^y) = 0. \quad (19.1)$$

模型场  $v_\theta(z, t, x)$  用条件平方损失学习

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{t,y,z_t} \|v_\theta(z_t, t, x) - u_t^y(z_t)\|^2. \quad (19.2)$$

对固定  $(z, t, x)$ ，最优模型同样是条件期望

$$v^*(z, t, x) = \mathbb{E}[u_t^y(z) | z_t = z, x]. \quad (19.3)$$

因此离散高斯 KL 版与连续 FM 版都在学习“由输入  $x$  预测标签扩散方向”，只是一者通过转移密度，一者通过速度场表达。

## 20 内存复杂度对比

普通  $T$  层网络反向传播需保存各层激活，内存近似

$$M_{\text{BP}} = O(TBd), \quad (20.1)$$

其中  $B$  为 batch， $d$  为激活宽度。NoProp 单独训练某块时只需该块输入与局部中间量

$$M_{\text{NP}} = O(Bd) + M_{\text{block}}. \quad (20.2)$$

但总计算并不自动减少：若每个块都需要单独采样和更新，总训练 FLOPs 仍与  $T$  近似线性。其主要收益是并行性、局部优化和激活内存，而不是“免费训练”。

## 21 输出分类器与标签嵌入几何

若最终表示  $z_T$  与类别嵌入  $u_c$  用距离分类

$$p(y = c | z_T) = \frac{\exp(-\|z_T - u_c\|^2 / \tau)}{\sum_j \exp(-\|z_T - u_j\|^2 / \tau)}, \quad (21.1)$$

展开平方距离

$$-\|z - u_c\|^2 = 2z^\top u_c - \|u_c\|^2 - \|z\|^2. \quad (21.2)$$

对所有类别公共的  $-\|z\|^2$  在 softmax 中抵消，故等价于带类别偏置的线性分类器

$$\text{logit}_c = \frac{2}{\tau} z^\top u_c - \frac{1}{\tau} \|u_c\|^2. \quad (21.3)$$

## 22 从联合分布到 ELBO 的逐行推导

设潜变量链为  $z_{0:T}$ ，观测标签为  $y$ ，输入  $x$  作为条件。模型联合分布

$$p_{\theta}(y, z_{0:T} | x) = p(z_0) \prod_{t=1}^T p_{\theta}(z_t | z_{t-1}, x) p_{\theta}(y | z_T). \quad (22.1)$$

引入任意后验近似  $q(z_{0:T} | x, y)$ ，有

$$\log p_{\theta}(y | x) = \log \int q(z_{0:T} | x, y) \frac{p_{\theta}(y, z_{0:T} | x)}{q(z_{0:T} | x, y)} \mathrm{d}z_{0:T} \quad (22.2)$$

$$= \log \mathbb{E}_q \left[ \frac{p_{\theta}(y, z_{0:T} | x)}{q(z_{0:T} | x, y)} \right]. \quad (22.3)$$

由  $\log$  的凹性与 Jensen 不等式,

$$\log p_{\theta}(y | x) \geq \mathbb{E}_q [\log p_{\theta}(y, z_{0:T} | x) - \log q(z_{0:T} | x, y)]. \quad (22.4)$$

右侧即 ELBO。差距恰好为

$$\log p_{\theta}(y | x) - \text{ELBO} = D_{\text{KL}}(q(z_{0:T} | x, y) \| p_{\theta}(z_{0:T} | x, y)) \geq 0. \quad (22.5)$$

所以最大化 ELBO 等价于同时提高数据似然并使近似后验接近真实后验。

## 23 反向 Markov 分解如何产生逐层 KL

论文选择反向扩散后验

$$q(z_{0:T} | y) = q(z_T | y) \prod_{t=1}^T q(z_{t-1} | z_t, y). \quad (23.1)$$

把它与前向模型相除并取对数：

$$\log \frac{q(z_{0:T} | y)}{p_{\theta}(y, z_{0:T} | x)} = \log \frac{q(z_T | y)}{p_{\theta}(y | z_T)} + \sum_{t=1}^T \log \frac{q(z_{t-1} | z_t, y)}{p_{\theta}(z_t | z_{t-1}, x)} - \log p(z_0). \quad (23.2)$$

为了得到标准扩散式逐步 KL，需要利用 Bayes 关系把  $q(z_{t-1} | z_t, y)$  与前向条件写到同一方向。整理后每一层都出现一个只涉及该层转移参数的 KL 或平方误差项。这是 NoProp 能局部训练的概率根源，而不是简单地“截断反向传播”。

## 24 线性高斯 OU 边缘分布的递推证明

考虑

$$z_t = \alpha_t z_{t-1} + \sqrt{1 - \alpha_t^2} \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, I). \quad (24.1)$$

假设

$$z_{t-1} \mid y \sim \mathcal{N}(\bar{\alpha}_{t-1}u_y, (1 - \bar{\alpha}_{t-1}^2)I), \quad (24.2)$$

其中  $\bar{\alpha}_t = \prod_{s=1}^t \alpha_{s0}$  线性高斯变换给出均值

$$\mathbb{E}[z_t \mid y] = \alpha_t \bar{\alpha}_{t-1} u_y = \bar{\alpha}_t u_y, \quad (24.3)$$

方差

$$\text{Var}(z_t \mid y) = \alpha_t^2(1 - \bar{\alpha}_{t-1}^2)I + (1 - \alpha_t^2)I \quad (24.4)$$

$$= (1 - \alpha_t^2 \bar{\alpha}_{t-1}^2)I = (1 - \bar{\alpha}_t^2)I. \quad (24.5)$$

由数学归纳法,

$$\boxed{z_t \mid y \sim \mathcal{N}(\bar{\alpha}_t u_y, (1 - \bar{\alpha}_t^2)I)}. \quad (24.6)$$

## 25 两个高斯相乘得到条件后验的配方法

标量情形先看清结构。若

$$q(z_t \mid z_{t-1}) = \mathcal{N}(az_{t-1}, \sigma^2), \quad q(z_{t-1} \mid y) = \mathcal{N}(m, s^2), \quad (25.1)$$

则

$$\log q(z_{t-1} \mid z_t, y) = -\frac{(z_t - az_{t-1})^2}{2\sigma^2} - \frac{(z_{t-1} - m)^2}{2s^2} + \text{const.} \quad (25.2)$$

收集  $z_{t-1}^2$  和一次项:

$$-\frac{1}{2} \left( \frac{a^2}{\sigma^2} + \frac{1}{s^2} \right) z_{t-1}^2 + \left( \frac{az_t}{\sigma^2} + \frac{m}{s^2} \right) z_{t-1}. \quad (25.3)$$

因此后验方差与均值为

$$\tilde{s}^2 = \left( \frac{a^2}{\sigma^2} + \frac{1}{s^2} \right)^{-1}, \quad \tilde{m} = \tilde{s}^2 \left( \frac{az_t}{\sigma^2} + \frac{m}{s^2} \right). \quad (25.4)$$

多维各向同性情形逐维相同。论文中的系数  $a_t, b_t, c_t$  正是把该后验均值写成

$$\tilde{m}_t = a_t u_y + b_t z_t \quad (25.5)$$

后的闭式系数。

## 26 等协方差高斯 KL 为什么变成平方误差

对

$$q = \mathcal{N}(\mu_q, \Sigma), \quad p = \mathcal{N}(\mu_p, \Sigma), \quad (26.1)$$

一般高斯 KL 为

$$D_{\text{KL}}(q \parallel p) = \frac{1}{2} \left[ \text{Tr}(\Sigma^{-1}\Sigma) + (\mu_p - \mu_q)^\top \Sigma^{-1}(\mu_p - \mu_q) - d + \log \frac{\det \Sigma}{\det \Sigma} \right]. \quad (26.2)$$

迹项等于  $d$ ，行列式项为零，于是

$$D_{\text{KL}}(q||p) = \frac{1}{2} \|\mu_p - \mu_q\|_{\Sigma^{-1}}^2. \quad (26.3)$$

若  $\Sigma = c_t I$ ，则

$$D_{\text{KL}}(q||p) = \frac{1}{2c_t} \|\mu_p - \mu_q\|_2^2. \quad (26.4)$$

当两者均值只在  $u_y$  与网络预测  $\hat{u}_{\theta_t}$  上不同，便得到加权局部回归损失

$$\mathcal{L}_t = \lambda_t \|\hat{u}_{\theta_t}(z_{t-1}, x) - u_y\|_2^2. \quad (26.5)$$

## 27 局部梯度为何不包含其他块参数

设第  $t$  块损失为

$$\mathcal{L}_t(\theta_t) = \mathbb{E}_{z_{t-1} \sim q} \|u_{\theta_t}(z_{t-1}, x) - u_y\|^2. \quad (27.1)$$

关键是  $z_{t-1}$  来自固定的教师后验  $q$ ，不是由前面可训练块生成。于是对  $s \neq t$ ，

$$\frac{\partial \mathcal{L}_t}{\partial \theta_s} = 0. \quad (27.2)$$

对本块

$$\nabla_{\theta_t} \mathcal{L}_t = 2\mathbb{E} J_{\theta_t} u_{\theta_t}^\top (u_{\theta_t} - u_y). \quad (27.3)$$

如果改成把模型自己的  $z_{t-1}(\theta_{<t})$  喂给第  $t$  块，则链式法则产生

$$\frac{\partial \mathcal{L}_t}{\partial \theta_s} = \frac{\partial \mathcal{L}_t}{\partial z_{t-1}} \frac{\partial z_{t-1}}{\partial \theta_s}, \quad (27.4)$$

局部独立性立即消失。因此 NoProp 的核心是固定噪声教师分布，而非仅仅调用 stop-gradient。

## 28 一个 $T = 2$ 的完整标量例子

令标签嵌入  $u_y = 2$ ， $\alpha_1 = \alpha_2 = 0.8$ 。则

$$\bar{\alpha}_1 = 0.8, \quad \bar{\alpha}_2 = 0.64. \quad (28.1)$$

边缘分布为

$$z_1 | y \sim \mathcal{N}(1.6, 1 - 0.8^2), \quad (28.2)$$

$$z_2 | y \sim \mathcal{N}(1.28, 1 - 0.64^2). \quad (28.3)$$

训练第一块时直接采  $z_0$  或对应教师变量，回归目标始终是 2；训练第二块时独立采  $z_1$ ，仍回归 2。两个优化问题

$$\min_{\theta_1} \mathbb{E}(u_{\theta_1}(z_0, x) - 2)^2, \quad \min_{\theta_2} \mathbb{E}(u_{\theta_2}(z_1, x) - 2)^2 \quad (28.4)$$

可以并行求梯度。推理时才把第一块输出生成的状态传给第二块，因此训练分布与推理分布可能存在偏移，这是局部训练换来的主要代价。

## 29 连续时间极限：离散 OU 到 SDE

令步长  $\Delta t$  很小，取

$$\alpha_t = 1 - \frac{1}{2}\beta(t)\Delta t + o(\Delta t). \quad (29.1)$$

噪声尺度

$$\sqrt{1 - \alpha_t^2} = \sqrt{1 - (1 - \beta(t)\Delta t + o(\Delta t))} \quad (29.2)$$

$$= \sqrt{\beta(t)\Delta t} + o(\sqrt{\Delta t}). \quad (29.3)$$

离散更新

$$z_{t+\Delta t} - z_t = -\frac{1}{2}\beta(t)z_t\Delta t + \sqrt{\beta(t)}\sqrt{\Delta t}\epsilon \quad (29.4)$$

在极限下成为方差保持 SDE

$$dz_t = -\frac{1}{2}\beta(t)z_t dt + \sqrt{\beta(t)}dW_t. \quad (29.5)$$

其均值衰减因子为

$$\bar{\alpha}(t) = \exp \left[ -\frac{1}{2} \int_0^t \beta(s) ds \right]. \quad (29.6)$$

## 30 Flow Matching 版本的条件路径与速度

若取桥接路径

$$z_t = (1 - t)z_0 + tu_y + \sigma\epsilon, \quad (30.1)$$

对  $t$  求导得到条件速度

$$v^*(z_t | z_0, u_y) = u_y - z_0. \quad (30.2)$$

平方损失的最优向量场为条件期望

$$v_\theta^*(z, t, x) = \mathbb{E}[u_y - z_0 | z_t = z, x]. \quad (30.3)$$

由估计终点

$$\tilde{u}_y = z_t + (1 - t)v_\theta(z_t, t, x), \quad (30.4)$$

可以直接接分类器。若  $v_\theta$  精确，代入路径有

$$z_t + (1 - t)(u_y - z_0) = tu_y + (1 - t)z_0 + (1 - t)u_y - (1 - t)z_0 = u_y \quad (30.5)$$

(忽略固定桥噪声时)，说明该终点估计公式的系数来自直线运动几何。

## 31 内存复杂度的严格比较

标准端到端反向传播需要保存所有层激活。若每层激活大小为  $A_t$ ，峰值激活内存近似

$$M_{\text{BP}} = \Theta \left( \sum_{t=1}^T A_t \right). \quad (31.1)$$

NoProp 每次只训练一个块或并行独立块，不需要保留跨块计算图，单设备顺序训练时

$$M_{\text{NP}} = \Theta \left( \max_t A_t \right). \quad (31.2)$$

但总前向计算仍包含所有块，且为每层构造教师噪声样本和局部优化器状态。若所有块同时放在多设备上并行训练，总系统内存未必更小，只是单设备的反向图深度被消除。