

07_LoRI 数学过程详解

LoRA with Reduced Interference：从低秩分解、稀疏掩码到适配器近似正交性的完整推导

阅读说明

本文针对论文 *LoRI: Reducing Cross-Task Interference in Multi-Task Low-Rank Adaptation* 的数学部分进行逐式拆解。正文不仅复现论文公式 (1) – (15)，还补充矩阵维度检查、梯度推导、参数量计算、掩码重叠概率、Taylor 展开、Hoeffding 不等式证明细节，以及论文中若干需要谨慎理解的假设。所有“补充推导”都会明确标注，不把推论误写成论文已证明的结论。

目录

1 论文数学主线：LoRI 到底解决什么问题	4
2 预备知识：后文频繁出现的数学对象	4
2.1 矩阵形状与批量输入	4
2.2 低秩矩阵与秩上界	5
2.3 Frobenius 内积与范数	5
2.4 逐元素掩码	5
3 公式 (1)：从全量线性层到 LoRA 低秩增量	5
3.1 逐步检查维度	6
3.2 为什么这叫“先投影、再展开”	6
3.3 标准 LoRA 的参数量	6
3.4 标准 LoRA 的梯度	7
3.5 初始化为何令初始增量为零	7
4 冻结随机投影 A_t ：LoRI 的第一个限制	7
4.1 随机列向量的期望长度	8
4.2 冻结 A_t 后的优化变量	8
4.3 LoRI-D 的参数量	8
5 公式 (2)：全局分位数稀疏掩码	8
5.1 指示函数是什么意思	9

5.2	为什么采用“全局”阈值而不是每层固定保留相同比例	9
5.3	校准后为什么要把 B_t 重置为零	9
5.4	掩码梯度更新	10
5.5	LoRI-S 的参数量与“减少 95%”	10
6	LoRI 完整算法的逐步解释	10
6.1	步骤一：初始化所有层和投影	11
6.2	步骤二：在校准集上训练稠密 B_t	11
6.3	步骤三：跨模型计算全局阈值并生成掩码	11
6.4	步骤四：清零 B_t	11
6.5	步骤五：在完整任务数据上进行掩码训练	11
7	公式 (3)：如何定义任务间干扰	11
8	公式 (4) 与附录证明：不同任务适配器为何近似正交	12
8.1	第一步：吸收掩码记号	12
8.2	第二步：分析 X 的单个元素	12
8.3	第三步：Hoeffding 不等式	13
8.4	第四步：并集界控制全部 r^2 个元素	13
8.5	第五步：从逐元素界得到 Frobenius 范数界	14
8.6	第六步：回到适配器内积	14
9	公式 (5) – (6)：拼接合并为什么没有交叉项	15
9.1	合并后的秩	16
10	公式 (7)：用 Taylor 展开解释干扰损失	16
10.1	二阶项告诉我们什么	17
11	公式 (8)：线性合并为何产生交叉项	17
12	稀疏掩码与持续学习：为什么预计重叠约为 1%	18
12.1	为何稀疏能缓解灾难性遗忘	18
12.2	为什么不强制完全不重叠	18
13	参数、显存与计算量的系统比较	19

14 一个从输入到合并的完整数值化示例	19
15 论文数学部分的优点、边界与可优化方向	20
15.1 数学设计的优点	20
15.2 需要谨慎理解的地方	20
15.3 可进一步研究的数学方向	20
16 公式总表	21
结论	21

1 论文数学主线：LoRI 到底解决什么问题

LoRI 建立在标准 LoRA 的低秩更新上，但做了两个限制：

1. 将低秩投影矩阵 A_t 冻结为随机矩阵，只训练 B_t ；
2. 使用任务特定的二值掩码 M_t ，只允许 B_t 中少量位置更新。

对任务 t ，LoRI 的权重增量写成

$$\Delta_t = A_t(B_t \odot M_t). \quad (1.1)$$

这里 $\odot$ 表示逐元素乘法。整个方法的数学逻辑可概括为

$$\boxed{\text{随机低维子空间 } A_t + \text{稀疏可训练坐标 } B_t \odot M_t \implies \text{参数少、任务间干扰小}}. \quad (1.2)$$




图 1: LoRI 的核心计算图。灰色模块被冻结，绿色模块中只有掩码为 1 的位置可训练。

2 预备知识：后文频繁出现的数学对象

2.1 矩阵形状与批量输入

设某个线性层的预训练权重为

$$W_0 \in \mathbb{R}^{d_{\text{in}} \times d_{\text{out}}}. \quad (2.1)$$

若一条输入向量采用行向量记法，则

$$x \in \mathbb{R}^{1 \times d_{\text{in}}}, \quad xW_0 \in \mathbb{R}^{1 \times d_{\text{out}}}. \quad (2.2)$$

若批量大小为 b ，则

$$X \in \mathbb{R}^{b \times d_{\text{in}}}, \quad XW_0 \in \mathbb{R}^{b \times d_{\text{out}}}. \quad (2.3)$$

论文使用行向量右乘权重的约定。部分代码库使用列向量写成 W_0x ，二者只是记号转置，原理相同。

2.2 低秩矩阵与秩上界

LoRA 将一个大矩阵增量分解为

$$\Delta_t = A_t B_t, \quad A_t \in \mathbb{R}^{d_{\text{in}} \times r}, \quad B_t \in \mathbb{R}^{r \times d_{\text{out}}}, \quad (2.4)$$

其中

$$r \ll \min\{d_{\text{in}}, d_{\text{out}}\}. \quad (2.5)$$

根据矩阵秩的基本性质,

$$\text{rank}(A_t B_t) \leq \min\{\text{rank}(A_t), \text{rank}(B_t)\} \leq r. \quad (2.6)$$

所以 $A_t B_t$ 虽然与 W_0 形状相同, 但只能位于秩不超过 r 的低维集合中。

2.3 Frobenius 内积与范数

对同形状矩阵 $P, Q \in \mathbb{R}^{m \times n}$, Frobenius 内积定义为

$$\langle P, Q \rangle_F = \sum_{i=1}^m \sum_{j=1}^n P_{ij} Q_{ij} = \text{Tr}(P^\top Q). \quad (2.7)$$

对应范数为

$$\|P\|_F = \sqrt{\langle P, P \rangle_F}. \quad (2.8)$$

若

$$\langle P, Q \rangle_F = 0, \quad (2.9)$$

则称 P, Q 在参数空间中正交。LoRI 所说的“适配器近似正交”，就是不同任务的 Δ_s, Δ_t 的 Frobenius 内积接近零。

2.4 逐元素掩码

二值掩码

$$M_t \in \{0, 1\}^{r \times d_{\text{out}}} \quad (2.10)$$

作用于 B_t :

$$(B_t \odot M_t)_{ij} = (B_t)_{ij} (M_t)_{ij}. \quad (2.11)$$

当 $(M_t)_{ij} = 0$ 时, 该坐标被永久压成零; 当 $(M_t)_{ij} = 1$ 时, 该坐标允许学习。

3 公式 (1): 从全量线性层到 LoRA 低秩增量

论文公式 (1) 为

$$h = xW_0 + x\Delta_t = xW_0 + xA_t B_t. \quad (1)$$

3.1 逐步检查维度

各项形状如下：

$$x : 1 \times d_{\text{in}}, \quad (3.1)$$

$$W_0 : d_{\text{in}} \times d_{\text{out}}, \quad (3.2)$$

$$A_t : d_{\text{in}} \times r, \quad (3.3)$$

$$B_t : r \times d_{\text{out}}. \quad (3.4)$$

于是

$$xA_t \in \mathbb{R}^{1 \times r}, \quad (3.5)$$

$$xA_t B_t \in \mathbb{R}^{1 \times d_{\text{out}}}, \quad (3.6)$$

$$xW_0 + xA_t B_t \in \mathbb{R}^{1 \times d_{\text{out}}}. \quad (3.7)$$

两条分支形状一致，因此可以相加。

3.2 为什么这叫“先投影、再展开”

第一步

$$z = xA_t \in \mathbb{R}^{1 \times r} \quad (3.8)$$

把 d_{in} 维输入压入 r 维子空间；第二步

$$zB_t \in \mathbb{R}^{1 \times d_{\text{out}}} \quad (3.9)$$

再将低维坐标展开到输出维度。因此可把 A_t 理解成投影基，把 B_t 理解成对低维基的组合系数。

3.3 标准 LoRA 的参数量

忽略偏置时，标准 LoRA 的新增可训练参数为

$$P_{\text{LoRA}} = d_{\text{in}}r + rd_{\text{out}} = r(d_{\text{in}} + d_{\text{out}}). \quad (3.10)$$

而全量更新一个矩阵需要

$$P_{\text{FFT}} = d_{\text{in}}d_{\text{out}}. \quad (3.11)$$

当 r 很小时，LoRA 的参数比例为

$$\frac{P_{\text{LoRA}}}{P_{\text{FFT}}} = \frac{r(d_{\text{in}} + d_{\text{out}})}{d_{\text{in}}d_{\text{out}}}. \quad (3.12)$$

若 $d_{\text{in}} = d_{\text{out}} = d$ ，则

$$\frac{P_{\text{LoRA}}}{P_{\text{FFT}}} = \frac{2r}{d}. \quad (3.13)$$

例如 $d = 4096, r = 32$ 时，该比例约为

$$\frac{64}{4096} = 1.5625\%. \quad (3.14)$$

3.4 标准 LoRA 的梯度

设上游梯度为

$$G = \frac{\partial \mathcal{L}}{\partial h} \in \mathbb{R}^{b \times d_{\text{out}}}, \quad (3.15)$$

批量输入为 $X \in \mathbb{R}^{b \times d_{\text{in}}}$, LoRA 分支输出为

$$H_{\Delta} = X A_t B_t. \quad (3.16)$$

由矩阵微分可得

$$\frac{\partial \mathcal{L}}{\partial B_t} = (X A_t)^{\top} G = A_t^{\top} X^{\top} G, \quad (3.17)$$

$$\frac{\partial \mathcal{L}}{\partial A_t} = X^{\top} G B_t^{\top}. \quad (3.18)$$

标准 LoRA 同时保存这两组梯度, 并为两组参数维护优化器状态。

3.5 初始化为何令初始增量为零

标准做法是随机初始化 A_t , 令

$$B_t = 0. \quad (3.19)$$

则训练开始时

$$\Delta_t = A_t B_t = 0, \quad h = x W_0. \quad (3.20)$$

所以模型初始行为与预训练模型完全一致, 不会在第一步就突然改变输出。

一个常被忽略的梯度现象

当 $B_t = 0$ 时, 由式 (3.18) 可见, 第一步中 $\partial \mathcal{L} / \partial A_t = X^{\top} G B_t^{\top} = 0$, 而 $\partial \mathcal{L} / \partial B_t = A_t^{\top} X^{\top} G$ 通常非零。因此训练最开始主要由 B_t 先动起来, 之后 A_t 才获得非零梯度。LoRI 直接冻结 A_t , 相当于把这种非对称性贯彻到底。

4 冻结随机投影 A_t : LoRI 的第一个限制

LoRI 不再训练 A_t , 而是将其固定为随机投影。论文采用 Kaiming Uniform 初始化:

$$(A_t)_{ij} \sim \mathcal{U} \left(-\sqrt{\frac{3}{d_{\text{in}}}}, \sqrt{\frac{3}{d_{\text{in}}}} \right). \quad (4.1)$$

设

$$a = \sqrt{\frac{3}{d_{\text{in}}}}, \quad (4.2)$$

则均值与方差为

$$\mathbb{E}[(A_t)_{ij}] = 0, \quad (4.3)$$

$$\text{Var}[(A_t)_{ij}] = \frac{a^2}{3} = \frac{1}{d_{\text{in}}}. \quad (4.4)$$

4.1 随机列向量的期望长度

令 a_k 为 A_t 的第 k 列, 则

$$\mathbb{E} \|a_k\|_2^2 = \sum_{i=1}^{d_{\text{in}}} \mathbb{E}[(A_t)_{ik}^2] = d_{\text{in}} \cdot \frac{1}{d_{\text{in}}} = 1. \quad (4.5)$$

不同列 a_k, a_l 的期望内积为

$$\mathbb{E}[a_k^\top a_l] = 0, \quad k \neq l. \quad (4.6)$$

因此

$$\mathbb{E}[A_t^\top A_t] = I_r. \quad (4.7)$$

这说明随机 A_t 在期望意义上提供了一组近似归一、近似互相正交的低维基。

4.2 冻结 A_t 后的优化变量

LoRI-D (稠密版本) 只训练 B_t :

$$B_t^{(q+1)} = B_t^{(q)} - \eta_t \frac{\partial \mathcal{L}_t}{\partial B_t}. \quad (4.8)$$

而

$$A_t^{(q+1)} = A_t^{(q)} = A_t^{(0)}. \quad (4.9)$$

冻结后, 无需为 A_t 保存梯度与 Adam 的一阶、二阶动量。

4.3 LoRI-D 的参数量

LoRI-D 的可训练参数只有

$$P_{\text{LoRI-D}} = r d_{\text{out}}. \quad (4.10)$$

相对标准 LoRA 的比例为

$$\frac{P_{\text{LoRI-D}}}{P_{\text{LoRA}}} = \frac{d_{\text{out}}}{d_{\text{in}} + d_{\text{out}}}. \quad (4.11)$$

若输入输出维度相同, 则正好为

$$\frac{1}{2}. \quad (4.12)$$

即仅冻结 A_t 就减少约一半可训练参数。

5 公式 (2): 全局分位数稀疏掩码

论文在校准阶段先临时训练稠密 B_t , 然后把所有层、所有投影中的 $|B_t|$ 汇总, 计算全局阈值

$$\tau_t = \text{Quantile}_s \left(\bigcup_{l,m} |B_t^{(l,m)}| \right), \quad (5.1)$$

再生成掩码

$$M_t^{(l,m)} = \mathbb{I} \left(\left| B_t^{(l,m)} \right| \geq \tau_t \right). \quad (2)$$

其中 $s \in [0, 1)$ 是稀疏率。若 $s = 0.9$ ，则阈值取绝对值集合的 90% 分位点，只保留最大的约 10% 坐标。

5.1 指示函数是什么意思

逐元素指示函数定义为

$$\mathbb{I}(|b| \geq \tau) = \begin{cases} 1, & |b| \geq \tau, \\ 0, & |b| < \tau. \end{cases} \quad (5.2)$$

因此

$$B_t \odot M_t \quad (5.3)$$

只留下大幅值位置。

一个简单的分位数例子

假设校准后所有 B 元素的绝对值汇总为

$$\{0.01, 0.02, 0.03, 0.04, 0.08, 0.10, 0.30, 0.60, 0.90, 1.20\}.$$

若设稀疏率 $s = 0.8$ ，目标是保留最大的 20%，即大约两个元素。阈值可落在 0.90 附近，于是掩码仅保留 0.90 与 1.20 对应位置。实际实现需处理并列值与分位数插值，因此保留数可能有极小偏差。

5.2 为什么采用“全局”阈值而不是每层固定保留相同比例

若每层都强制保留 10%，就默认所有层同等重要。全局阈值则允许某些重要层保留更多坐标，某些不重要层保留更少坐标。数学上，全局掩码近似解决下面的预算分配问题：

$$\max_{M \in \{0,1\}^P} \sum_{j=1}^P |b_j| M_j, \quad \text{s.t.} \quad \sum_{j=1}^P M_j \leq (1-s)P. \quad (5.4)$$

对该问题，最优选择就是保留 $|b_j|$ 最大的若干项。

5.3 校准后为什么要把 B_t 重置为零

校准阶段的目的是不是直接得到最终权重，而是估计“哪些坐标重要”。得到 M_t 后，论文将

$$B_t \leftarrow 0 \quad (5.5)$$

再在完整任务数据上正式训练。这样最终训练从同一个零增量起点开始，避免校准数据对最终参数造成额外偏置，同时保留坐标选择结果。

5.4 掩码梯度更新

正式适配阶段的更新为

$$B_t^{(q+1)} = B_t^{(q)} - \eta_t (\nabla_{B_t} \mathcal{L}_t \odot M_t). \quad (5.6)$$

对任意坐标 (i, j) :

$$(B_t^{(q+1)})_{ij} = (B_t^{(q)})_{ij} - \eta_t \frac{\partial \mathcal{L}_t}{\partial (B_t)_{ij}} (M_t)_{ij}. \quad (5.7)$$

若 $(M_t)_{ij} = 0$, 则该位置每一步都不变; 由于初始值为零, 它始终保持零。

5.5 LoRI-S 的参数量与“减少 95%”

设掩码密度为

$$p = 1 - s. \quad (5.8)$$

LoRI-S 的可训练坐标数约为

$$P_{\text{LoRI-S}} = p r d_{\text{out}} = (1 - s) r d_{\text{out}}. \quad (5.9)$$

相对标准 LoRA:

$$\rho = \frac{P_{\text{LoRI-S}}}{P_{\text{LoRA}}} = \frac{(1 - s) d_{\text{out}}}{d_{\text{in}} + d_{\text{out}}}. \quad (5.10)$$

若 $d_{\text{in}} = d_{\text{out}}$ 且 $s = 0.9$, 则

$$\rho = \frac{0.1}{2} = 0.05. \quad (5.11)$$

所以 LoRI-S 只使用 LoRA 的约 5% 可训练参数, 即减少约 95%。

以 $d = 4096, r = 32$ 为例

标准 LoRA:

$$P_{\text{LoRA}} = 32(4096 + 4096) = 262144.$$

LoRI-D:

$$P_{\text{LoRI-D}} = 32 \times 4096 = 131072.$$

LoRI-S (90% 稀疏):

$$P_{\text{LoRI-S}} = 0.1 \times 131072 \approx 13107.$$

相对标准 LoRA 仅约 5%。

6 LoRI 完整算法的逐步解释

对每个任务 t , 算法可以分为五步。

6.1 步骤一：初始化所有层和投影

对层 $l = 1, \dots, L$ 、投影类型 $m = 1, \dots, M$:

$$A_t^{(l,m)} \sim \mathcal{U}\left(-\sqrt{\frac{3}{d_{\text{in}}}}, \sqrt{\frac{3}{d_{\text{in}}}}\right), \quad (6.1)$$

$$B_t^{(l,m)} = 0. \quad (6.2)$$

A_t 随后冻结。

6.2 步骤二：在校准集上训练稠密 B_t

对校准数据 $(x, y) \sim \mathcal{D}_t^C$ ，执行

$$B_t^{(l,m)} \leftarrow B_t^{(l,m)} - \eta_t \nabla_{B_t^{(l,m)}} \mathcal{L}_t(f(x, y)). \quad (6.3)$$

此时暂时不加掩码，目的是让幅值反映累计的重要性。

6.3 步骤三：跨模型计算全局阈值并生成掩码

把所有 $|B_t^{(l,m)}|$ 展平拼接，求 s 分位数 τ_t ，然后由式 (2) 生成 $M_t^{(l,m)}$ 。

6.4 步骤四：清零 B_t

$$B_t^{(l,m)} \leftarrow 0. \quad (6.4)$$

6.5 步骤五：在完整任务数据上进行掩码训练

对 $(x, y) \sim \mathcal{D}_t$ ，执行式 (5.6)。

算法本质

校准阶段回答“哪里可以学”，正式阶段回答“这些位置具体学成什么值”。掩码是离散结构变量， B_t 是连续参数变量。

7 公式 (3)：如何定义任务间干扰

对于任务 t ，单独使用其适配器时的模型为

$$W_t = W_0 + \alpha_t \Delta_t. \quad (7.1)$$

合并多个适配器后得到 W_{merge} 。论文定义额外损失

$$I_t = \mathcal{L}_t(W_{\text{merge}}) - \mathcal{L}_t(W_0 + \alpha_t \Delta_t). \quad (3)$$

若

$$I_t > 0, \quad (7.2)$$

说明合并后任务 t 的损失上升，发生负干扰；若

$$I_t < 0, \quad (7.3)$$

则其他任务更新反而对任务 t 有帮助，可视为正迁移。

8 公式 (4) 与附录证明：不同任务适配器为何近似正交

论文的性质 1 声称：若 A_s, A_t 是独立 Kaiming 随机矩阵，且 $r \ll d_{\text{in}}$ ，则

$$\langle \Delta_s, \Delta_t \rangle_F \xrightarrow[d_{\text{in}} \rightarrow \infty]{\mathbb{P}} 0, \quad s \neq t. \quad (4)$$

下面完整展开附录 C 的证明。

8.1 第一步：吸收掩码记号

令

$$\tilde{B}_s = B_s \odot M_s, \quad \tilde{B}_t = B_t \odot M_t. \quad (8.1)$$

于是

$$\Delta_s = A_s \tilde{B}_s, \quad \Delta_t = A_t \tilde{B}_t. \quad (8.2)$$

Frobenius 内积为

$$\langle \Delta_s, \Delta_t \rangle_F = \text{Tr}(\Delta_s^\top \Delta_t) \quad (8.3)$$

$$= \text{Tr}(\tilde{B}_s^\top A_s^\top A_t \tilde{B}_t). \quad (9)$$

定义

$$X = A_s^\top A_t \in \mathbb{R}^{r \times r}. \quad (8.4)$$

只要证明 X 以概率收敛到零矩阵，再利用范数不等式即可。

8.2 第二步：分析 X 的单个元素

设 a_k^s 是 A_s 的第 k 列， a_l^t 是 A_t 的第 l 列，则

$$X_{kl} = (a_k^s)^\top a_l^t = \sum_{i=1}^{d_{\text{in}}} (A_s)_{ik} (A_t)_{il}. \quad (8.5)$$

令

$$Z_i = (A_s)_{ik}(A_t)_{il}. \quad (8.6)$$

由于不同任务的 A_s, A_t 独立, 且每个元素均值为零,

$$\mathbb{E}[Z_i] = \mathbb{E}[(A_s)_{ik}]\mathbb{E}[(A_t)_{il}] = 0. \quad (8.7)$$

又因为每个元素绝对值不超过

$$\sqrt{\frac{3}{d_{\text{in}}}}, \quad (8.8)$$

所以

$$|Z_i| \leq \frac{3}{d_{\text{in}}}. \quad (8.9)$$

即

$$Z_i \in \left[-\frac{3}{d_{\text{in}}}, \frac{3}{d_{\text{in}}}\right]. \quad (8.10)$$

8.3 第三步: Hoeffding 不等式

对独立有界零均值变量 $Z_i \in [a_i, b_i]$, Hoeffding 不等式给出

$$\mathbb{P}\left(\left|\sum_i Z_i\right| \geq u\right) \leq 2 \exp\left(-\frac{2u^2}{\sum_i (b_i - a_i)^2}\right). \quad (8.11)$$

本题中

$$b_i - a_i = \frac{6}{d_{\text{in}}}, \quad (8.12)$$

因此

$$\sum_{i=1}^{d_{\text{in}}} (b_i - a_i)^2 = d_{\text{in}} \left(\frac{6}{d_{\text{in}}}\right)^2 = \frac{36}{d_{\text{in}}}. \quad (8.13)$$

代入得到

$$\mathbb{P}(|X_{kl}| \geq u) \leq 2 \exp\left(-\frac{u^2 d_{\text{in}}}{18}\right). \quad (10)$$

这说明任意一个交叉内积元素都随 d_{in} 增大而集中到零附近。

8.4 第四步: 并集界控制全部 r^2 个元素

矩阵 X 有 r^2 个元素。由并集界

$$\mathbb{P}\left(\max_{k,l} |X_{kl}| \geq u\right) \leq \sum_{k,l} \mathbb{P}(|X_{kl}| \geq u) \quad (8.14)$$

$$\leq 2r^2 \exp\left(-\frac{u^2 d_{\text{in}}}{18}\right). \quad (11)$$

令右边等于失败概率 δ :

$$\delta = 2r^2 \exp\left(-\frac{u^2 d_{\text{in}}}{18}\right). \quad (8.15)$$

两边取对数：

$$\log \frac{2r^2}{\delta} = \frac{u^2 d_{\text{in}}}{18}, \quad (8.16)$$

$$u = \sqrt{\frac{18 \log(2r^2/\delta)}{d_{\text{in}}}}. \quad (12)$$

因此以至少 $1 - \delta$ 的概率，所有元素同时满足

$$|X_{kl}| \leq u. \quad (8.17)$$

8.5 第五步：从逐元素界得到 Frobenius 范数界

$$\|X\|_F^2 = \sum_{k=1}^r \sum_{l=1}^r |X_{kl}|^2 \quad (8.18)$$

$$\leq r^2 \max_{k,l} |X_{kl}|^2 \quad (8.19)$$

$$\leq r^2 u^2. \quad (13)$$

所以

$$\|X\|_F \leq ru \quad (8.20)$$

$$= r \sqrt{\frac{18 \log(2r^2/\delta)}{d_{\text{in}}}} \quad (8.21)$$

$$= O\left(r \sqrt{\frac{\log r}{d_{\text{in}}}}\right). \quad (14)$$

当 r 固定而 $d_{\text{in}} \rightarrow \infty$ 时，该上界趋于零。

8.6 第六步：回到适配器内积

由式 (9)、Frobenius Cauchy–Schwarz 不等式与次乘性：

$$|\langle \Delta_s, \Delta_t \rangle_F| = |\text{Tr}(\tilde{B}_s^\top X \tilde{B}_t)| \quad (8.22)$$

$$= \left| \left\langle \tilde{B}_s, X \tilde{B}_t \right\rangle_F \right| \quad (8.23)$$

$$\leq \|\tilde{B}_s\|_F \|X \tilde{B}_t\|_F \quad (8.24)$$

$$\leq \|\tilde{B}_s\|_F \|X\|_F \|\tilde{B}_t\|_F. \quad (15)$$

若 $\|\tilde{B}_s\|_F$ 与 $\|\tilde{B}_t\|_F$ 有限，且 $\|X\|_F \rightarrow 0$ ，则

$$\langle \Delta_s, \Delta_t \rangle_F \rightarrow 0 \quad (8.25)$$

依概率成立，证明完成。

比论文表述更精确的增长条件

论文用 “ $r \ll d_{\text{in}}$ ” 概括条件。由式 (14) 可见，若 r 也随 d_{in} 增长，更精确的充分条件是

$$\frac{r^2 \log r}{d_{\text{in}}} \rightarrow 0.$$

仅有 $r/d_{\text{in}} \rightarrow 0$ 并不自动保证上界趋零。例如 $r = d_{\text{in}}^{0.75}$ 时，虽然 $r/d_{\text{in}} \rightarrow 0$ ，但 r^2/d_{in} 反而发散。实际 LoRA 中 r 通常固定为 8、16、32、64，因此论文条件在工程设置下通常满足。

9 公式 (5) – (6)：拼接合并为什么没有交叉项

对 T 个任务，论文定义

$$A' = [\alpha_1 A_1 \ \alpha_2 A_2 \ \cdots \ \alpha_T A_T] \in \mathbb{R}^{d_{\text{in}} \times Tr}, \quad (9.1)$$

以及竖直拼接

$$B' = \begin{bmatrix} B_1 \odot M_1 \\ B_2 \odot M_2 \\ \vdots \\ B_T \odot M_T \end{bmatrix} \in \mathbb{R}^{Tr \times d_{\text{out}}}. \quad (5)$$

矩阵乘法的块结构给出

$$A'B' = [\alpha_1 A_1 \ \cdots \ \alpha_T A_T] \begin{bmatrix} \tilde{B}_1 \\ \vdots \\ \tilde{B}_T \end{bmatrix} \quad (9.2)$$

$$= \alpha_1 A_1 \tilde{B}_1 + \cdots + \alpha_T A_T \tilde{B}_T \quad (9.3)$$

$$= \sum_{t=1}^T \alpha_t \Delta_t. \quad (9.4)$$

所以

$$W_{\text{merge}} = W_0 + A'B' = W_0 + \sum_{t=1}^T \alpha_t \Delta_t. \quad (6)$$

关键点

拼接不是把 A 与 B 分别相加，而是扩大内部秩维度，将每个 A_t 与自己的 B_t 保持块配对。因此乘积中只有 $A_t \tilde{B}_t$ ，不会出现 $A_s \tilde{B}_t$ ($s \neq t$) 的交叉组合。

9.1 合并后的秩

每个 Δ_t 的秩不超过 r ，因此

$$\text{rank} \left(\sum_{t=1}^T \alpha_t \Delta_t \right) \leq \sum_{t=1}^T \text{rank}(\Delta_t) \leq Tr. \quad (9.5)$$

拼接合并相当于将有效秩从 r 提高到至多 Tr 。

10 公式 (7)：用 Taylor 展开解释干扰损失

令任务 t 的单任务点为

$$W_t = W_0 + \alpha_t \Delta_t, \quad (10.1)$$

其余任务带来的扰动为

$$E_t = \sum_{s \neq t} \alpha_s \Delta_s. \quad (10.2)$$

于是

$$W_{\text{merge}} = W_t + E_t. \quad (10.3)$$

对 $\mathcal{L}_t(W_t + E_t)$ 在 W_t 处做一阶 Taylor 展开：

$$\mathcal{L}_t(W_t + E_t) \approx \mathcal{L}_t(W_t) + \langle \nabla \mathcal{L}_t(W_t), E_t \rangle_F. \quad (10.4)$$

所以

$$I_t = \mathcal{L}_t(W_t + E_t) - \mathcal{L}_t(W_t) \quad (10.5)$$

$$\approx \left\langle \nabla \mathcal{L}_t(W_t), \sum_{s \neq t} \alpha_s \Delta_s \right\rangle_F \quad (10.6)$$

$$= \sum_{s \neq t} \alpha_s \langle \nabla \mathcal{L}_t(W_t), \Delta_s \rangle_F. \quad (10.7)$$

论文进一步采用“梯度方向与任务增量对齐”的启发式假设

$$\nabla \mathcal{L}_t(W_t) \propto \Delta_t, \quad (10.8)$$

于是

$$I_t \propto \sum_{s \neq t} \alpha_s \langle \Delta_t, \Delta_s \rangle_F. \quad (7)$$

若不同适配器近似正交，则每个内积都接近零，因而 I_t 较小。

10.1 二阶项告诉我们什么

更完整的 Taylor 展开为

$$I_t \approx \langle \nabla \mathcal{L}_t(W_t), E_t \rangle_F + \frac{1}{2} \text{vec}(E_t)^\top H_t(W_t) \text{vec}(E_t), \quad (10.9)$$

其中 H_t 是 Hessian。即使一阶项因正交性很小，二阶曲率项也可能不小。因此论文式 (7) 提供的是合理直觉，而不是严格保证“合并损失必然为零”的定理。

梯度对齐假设的张力

若 W_t 真的是任务 t 的精确局部最优点，则通常 $\nabla \mathcal{L}_t(W_t) \approx 0$ ，这时“梯度与 Δ_t 成比例”虽然形式上可成立，但无法提供方向信息。更合理的理解是：在近似解或训练轨迹附近，任务敏感方向与已学习更新 Δ_t 存在相关性。论文明确将此部分称为 *theoretical sketch*，应按启发式解释，而非完整定理。

11 公式 (8)：线性合并为何产生交叉项

所谓线性合并先分别求和：

$$\bar{A} = \sum_{s=1}^T \alpha_s A_s, \quad \bar{B} = \sum_{t=1}^T \alpha_t \tilde{B}_t. \quad (11.1)$$

然后相乘：

$$\begin{aligned} \bar{A}\bar{B} &= \left(\sum_{s=1}^T \alpha_s A_s \right) \left(\sum_{t=1}^T \alpha_t \tilde{B}_t \right) \\ &= \sum_{s=1}^T \sum_{t=1}^T \alpha_s \alpha_t A_s \tilde{B}_t. \end{aligned} \quad (11.2)$$

(8)

把双重求和拆开：

$$\bar{A}\bar{B} = \underbrace{\sum_{t=1}^T \alpha_t^2 A_t \tilde{B}_t}_{\text{同任务主项}} + \underbrace{\sum_{s \neq t} \alpha_s \alpha_t A_s \tilde{B}_t}_{\text{交叉项}}. \quad (11.3)$$

交叉项 $A_s \tilde{B}_t$ 将任务 s 的随机基与任务 t 的组合系数错误配对，未必对应任何训练过的方向，因此容易产生干扰。

两个任务时的展开

当 $T = 2$ 时，

$$\begin{aligned} (\alpha_1 A_1 + \alpha_2 A_2)(\alpha_1 \tilde{B}_1 + \alpha_2 \tilde{B}_2) &= \alpha_1^2 A_1 \tilde{B}_1 + \alpha_2^2 A_2 \tilde{B}_2 \\ &\quad + \alpha_1 \alpha_2 A_1 \tilde{B}_2 + \alpha_1 \alpha_2 A_2 \tilde{B}_1. \end{aligned}$$

后两项就是拼接合并中完全不存在的交叉项。

12 稀疏掩码与持续学习：为什么预计重叠约为 1%

设每个任务掩码的密度为

$$p = 1 - s. \quad (12.1)$$

若两个任务的掩码位置近似独立，则任意一个坐标同时被两个任务选中的概率为

$$\mathbb{P}(M_s = 1, M_t = 1) = \mathbb{P}(M_s = 1)\mathbb{P}(M_t = 1) = p^2. \quad (12.2)$$

当 $s = 0.9$ 时， $p = 0.1$ ，所以

$$p^2 = 0.01 = 1\%. \quad (12.3)$$

这就是论文所说的理论期望重叠。

“1% 重叠”有两种分母

论文的 1% 是相对于全部坐标数的交集比例。如果改成“交集占单个任务已激活坐标的比例”，则为

$$\frac{p^2}{p} = p = 10\%.$$

两种说法分母不同，不能混淆。

12.1 为何稀疏能缓解灾难性遗忘

在安全任务后继续训练新任务时，若新任务仅更新 $M_t = 1$ 的少量位置，而安全任务主要依赖 $M_{\text{safety}} = 1$ 的另一组位置，则大多数参数坐标互不覆盖：

$$M_t \odot M_{\text{safety}} \approx 0. \quad (12.4)$$

这是一种参数隔离。新任务梯度难以覆盖安全任务使用的坐标，从而降低遗忘风险。

12.2 为什么不强制完全不重叠

完全不重叠会把可用参数空间进一步缩小，并且可能禁止两个任务共享真正有用的公共坐标。少量自然重叠可允许正迁移。因此 LoRI 依赖高稀疏率使交集自然较小，而不硬性设置

$$M_t \cap M_{\text{safety}} = \emptyset. \quad (12.5)$$

13 参数、显存与计算量的系统比较

表 1: 单个权重矩阵上的可训练参数量比较。

方法	可训练对象	参数量
全量微调	W_0	$d_{\text{in}}d_{\text{out}}$
LoRA	A_t, B_t	$r(d_{\text{in}} + d_{\text{out}})$
LoRI-D	B_t	rd_{out}
LoRI-S	$B_t \odot M_t$	$(1 - s)rd_{\text{out}}$

若使用 AdamW, 每个可训练标量通常至少需要: 参数值、梯度、一阶动量、二阶动量。忽略精度混合与主副本差异, 训练状态量大致与可训练参数数目成正比。因此冻结 A_t 与稀疏化 B_t 不仅减少参数文件, 也减少梯度与优化器状态。

训练稀疏与实际算力

论文实现通过梯度掩码限制可训练坐标。若底层仍以稠密矩阵乘法计算 $A_t(B_t \odot M_t)$, 理论参数稀疏不一定按相同比例减少前向 FLOPs。它最直接减少的是可训练参数、梯度和优化状态; 要获得真正稀疏算子加速, 还需要硬件和算子库对结构化或非结构化稀疏提供支持。

14 一个从输入到合并的完整数值化示例

设

$$d_{\text{in}} = d_{\text{out}} = 4, \quad r = 2. \quad (14.1)$$

两个任务适配器为

$$\Delta_1 = A_1(B_1 \odot M_1), \quad \Delta_2 = A_2(B_2 \odot M_2). \quad (14.2)$$

若

$$M_1 = \begin{bmatrix} 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{bmatrix}, \quad M_2 = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}, \quad (14.3)$$

则两个任务在 B 坐标上没有重叠。拼接合并为

$$A' = [\alpha_1 A_1 \quad \alpha_2 A_2], \quad B' = \begin{bmatrix} B_1 \odot M_1 \\ B_2 \odot M_2 \end{bmatrix}. \quad (14.4)$$

其乘积严格等于

$$A'B' = \alpha_1 \Delta_1 + \alpha_2 \Delta_2. \quad (14.5)$$

而分别求和再相乘会额外产生

$$A_1(B_2 \odot M_2), \quad A_2(B_1 \odot M_1), \quad (14.6)$$

这两个从未训练过的组合。

15 论文数学部分的优点、边界与可优化方向

15.1 数学设计的优点

1. 低秩分解、随机投影和稀疏掩码三者的维度关系清晰；
2. 拼接合并的块矩阵推导严格说明了为何不产生交叉项；
3. 附录使用 Hoeffding 不等式、并集界与 Frobenius 范数给出可验证的近似正交性证明；
4. 参数量减少比例可以直接由维度与稀疏率计算，而非仅靠实验陈述。

15.2 需要谨慎理解的地方

1. 近似正交性证明控制的是随机 $A_s^\top A_t$ ，最终还需要训练后的 $\tilde{B}_s, \tilde{B}_t$ 范数不随维度爆炸；
2. 式 (7) 的干扰分析依赖局部线性与梯度对齐，是启发式而非严格上界；
3. 一阶正交不能消除 Hessian 二阶交互；
4. 掩码由校准训练的幅值确定，幅值是否总能代表最终任务重要性并无普遍定理；
5. 非结构化稀疏主要带来参数和优化器状态节省，不必然带来同等比例的计算加速。

15.3 可进一步研究的数学方向

1. 用 Hessian 加权内积

$$\langle \Delta_s, \Delta_t \rangle_{H_t} = \text{vec}(\Delta_s)^\top H_t \text{vec}(\Delta_t)$$

替代普通 Frobenius 内积，更直接刻画损失曲率下的干扰；

2. 将全局 Top- k 掩码写成带预算的双层优化，联合学习掩码与参数；
3. 对 $\|\tilde{B}_t\|_F$ 加显式正则，强化近似正交证明中的有界假设；
4. 对多个任务同时推导总干扰的高概率上界，而不仅是两两内积；
5. 研究结构化块稀疏，使参数稀疏能够转化为真实硬件加速。

16 公式总表

编号	公式	含义
(1)	$h = xW_0 + xA_tB_t$	标准 LoRA 的低秩增量
(2)	$M_t = \mathbb{I}(B_t \geq \tau_t)$	全局分位数掩码
(3)	$I_t = \mathcal{L}_t(W_{\text{merge}}) - \mathcal{L}_t(W_0 + \alpha_t \Delta_t)$	合并干扰损失
(4)	$\langle \Delta_s, \Delta_t \rangle_F \rightarrow 0$	不同任务适配器近似正交
(5)	A' 横向拼接, B' 纵向拼接	保持任务块配对
(6)	$W_{\text{merge}} = W_0 + \sum_t \alpha_t \Delta_t$	拼接合并结果
(7)	$I_t \propto \sum_{s \neq t} \alpha_s \langle \Delta_t, \Delta_s \rangle_F$	一阶干扰近似
(8)	$(\sum_s \alpha_s A_s)(\sum_t \alpha_t \tilde{B}_t)$	线性合并产生双重求和
(9)–(15)	Hoeffding、并集界、范数界	性质 1 的高概率证明

结论

LoRI 的数学核心不是单纯“把 LoRA 再剪枝”，而是利用三个层次的约束：

$$\boxed{\text{低秩约束} + \text{随机子空间隔离} + \text{稀疏坐标隔离}}. \quad (16.1)$$

低秩限制单任务更新规模；独立随机 A_t 使不同任务子空间在高维中近似正交；稀疏 M_t 进一步减少参数重叠。拼接合并保持每个任务的 A_t 与 B_t 正确配对，避免线性合并中的交叉项。附录证明为“随机投影带来近似正交”提供了高概率依据，但从正交到真实损失无干扰仍依赖局部线性、梯度对齐、有限范数与较小二阶项等条件。