

08_Building Vision Models upon Heat Conduction 数学过程详解

从二维热方程到 Heat Conduction Operator：连续模型、频域解、DCT 离散化与复杂度推导

阅读说明

本文针对论文 *Building Vision Models upon Heat Conduction* 的数学部分进行逐式拆解。正文详细推导论文公式 (1) – (11)，补充 Fourier 导数性质、常微分方程求解、Gaussian 热核、Neumann 边界与余弦基、二维 DCT 的矩阵形式、复杂度 $O(N^{3/2})$ 的来源、频率自适应热扩散率、HCO 的梯度与稳定性，以及“物理热传导”和“学习型频域滤波”之间的边界。为避免把解释性推论误当作论文原结论，补充推导与批判性说明均会明确标注。

目录

1 数学主线：把视觉特征传播写成热扩散	4
2 预备知识：热方程中的每个符号	4
2.1 温度场与空间区域	4
2.2 Laplacian 算子	5
2.3 热扩散率	5
3 论文公式 (1)：二维热方程	5
3.1 为什么这是“扩散”而不是任意滤波	5
4 论文公式 (2) – (5)：将偏微分方程变成频域常微分方程	6
4.1 二维 Fourier 变换约定	6
4.2 对热方程两侧做 Fourier 变换：公式 (2)	6
4.3 左侧变换：公式 (3)	6
4.4 右侧变换：公式 (4) 的完整分部积分推导	7
4.5 得到频域 ODE：公式 (5)	7
5 论文公式 (6)：频域热方程的完整求解	7
5.1 频率响应如何解释	8
5.2 极限情况	8

6 论文公式 (7): 回到空间域与 Gaussian 热核	9
6.1 热核为什么是 Gaussian	9
6.2 扩散尺度	9
7 从标量温度到多通道视觉特征: 论文公式 (8)	10
7.1 逐通道与跨通道建模的区别	10
8 为什么 Neumann 边界自然对应 DCT	10
8.1 边界条件	10
8.2 余弦函数满足零法向导数	11
9 论文公式 (9): HCO 的离散实现	11
9.1 离散 Laplacian 的更精确特征值	11
10 论文公式 (10): 二维 DCT 与 IDCT 逐项解释	12
10.1 为什么二维 DCT 可分离	12
11 论文公式 (11): DCT 的矩阵乘法实现	12
11.1 维度核对	13
12 为什么复杂度是 $O(N^{3/2})$	13
13 自适应热扩散率与 Frequency Value Embeddings	14
13.1 为什么固定 k 不够	14
13.2 FVE 的数学角色	14
13.3 固定 t 的可辨识性原因	15
13.4 对参数的梯度	15
14 自适应频率滤波与经典热方程的关系	15
15 HCO Layer 的完整计算链	16
15.1 门控的意义	16
15.2 残差连接的梯度通道	17
16 HCO 为什么具有全局感受野	17
16.1 与注意力矩阵的对比	17

17 稳定性、能量与可逆性分析	18
17.1 频域能量不增条件	18
17.2 若 $k < 0$ 会发生什么	18
17.3 是否可逆	18
18 一个可手算的离散 HCO 示例	19
19 模型分层与扩散尺度	19
20 论文数学设计的优势	19
20.1 物理方程直接给出结构化频率响应	19
20.2 全局感受野不需要显式二次矩阵	20
20.3 适应性与先验的平衡	20
21 需要谨慎理解或可进一步优化的地方	20
21.1 频率相关 k 与严格物理模型存在距离	20
21.2 分辨率变化时的频率坐标	20
21.3 复杂度不等于实际速度	20
21.4 指数滤波可能过度平滑	20
21.5 缺少显式的输入依赖两两关系	21
22 公式总表与维度检查	21
23 从输入到输出的完整数学过程	21
24 结论	22

1 数学主线：把视觉特征传播写成热扩散

论文将图像 patch 或特征图中的局部信息类比为“热量”：一个位置的语义不仅停留在自身，还会按照某种扩散规律传播到周围乃至整幅图像。核心变换可概括为

$$U^t = \text{IDCT}_{2D} \left[\text{DCT}_{2D}(U^0) \odot e^{-k(\omega_x^2 + \omega_y^2)t} \right]. \quad (1.1)$$

其中：

- U^0 是输入视觉特征；
- U^t 是“传导时间” t 后的输出特征；
- DCT_{2D} 和 IDCT_{2D} 在空间域与频率域之间转换；
- $e^{-k(\omega_x^2 + \omega_y^2)t}$ 是热方程给出的频率响应；
- k 是热扩散率，论文使用频率值嵌入预测，使其可学习且非均匀。




图 1: HCO 的数学流程：先变换到余弦频域，再按热扩散规律逐频率加权，最后回到空间域。

一句话理解

Self-Attention 显式构造“任意 patch 对任意 patch”的相似度矩阵；HCO 则在一个全局余弦基中使用对角频率滤波器。二者都能获得全局感受野，但数学结构和计算复杂度不同。

2 预备知识：热方程中的每个符号

2.1 温度场与空间区域

设

$$u = u(x, y, t), \quad (2.1)$$

表示二维区域 $D \subset \mathbb{R}^2$ 中位置 (x, y) 在时间 t 的温度。固定 t 时， $u(\cdot, \cdot, t)$ 是一张二维标量图；固定 (x, y) 时， $u(x, y, \cdot)$ 描述该点温度随时间变化。

偏导数

$$\frac{\partial u}{\partial t} \quad (2.2)$$

表示温度变化速度；二阶空间偏导

$$\frac{\partial^2 u}{\partial x^2}, \quad \frac{\partial^2 u}{\partial y^2} \quad (2.3)$$

衡量温度曲线沿两个方向的局部弯曲程度。

2.2 Laplacian 算子

二维 Laplacian 定义为

$$\Delta u = \nabla^2 u = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2}. \quad (2.4)$$

若某点温度高于邻域，温度图在该点通常向下弯曲， $\Delta u < 0$ ，热量将从该点向外扩散；若某点低于邻域，则 $\Delta u > 0$ ，周围热量流入该点。

2.3 热扩散率

论文使用

$$k > 0 \quad (2.5)$$

表示 thermal diffusivity（热扩散率）。 k 越大，热量传播越快、平滑越强； k 越小，局部结构保留越多。

从量纲上看，若 x, y 的单位是长度、 t 的单位是时间，则

$$[k] = \frac{\text{长度}^2}{\text{时间}}. \quad (2.6)$$

因此真正控制扩散尺度的是乘积 kt ，这也是论文固定 t 、只预测 k 的原因之一。

3 论文公式 (1)：二维热方程

论文从经典二维热方程开始：

$$\frac{\partial u}{\partial t} = k \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right) = k \Delta u. \quad (1)$$

并给定初始条件

$$u(x, y, 0) = f(x, y). \quad (3.1)$$

3.1 为什么这是“扩散”而不是任意滤波

考虑一维离散近似：

$$\frac{\partial^2 u}{\partial x^2}(x_i) \approx \frac{u_{i-1} - 2u_i + u_{i+1}}{h^2}. \quad (3.2)$$

代入热方程，使用一个很小时间步长 Δt ，得到显式 Euler 更新

$$u_i^{n+1} \approx u_i^n + \Delta t k \frac{u_{i-1}^n - 2u_i^n + u_{i+1}^n}{h^2} \quad (3.3)$$

$$= (1 - 2\lambda) u_i^n + \lambda u_{i-1}^n + \lambda u_{i+1}^n, \quad \lambda = \frac{k\Delta t}{h^2}. \quad (3.4)$$

在稳定条件下，这相当于用邻域值对当前值做加权平均，因此峰值下降、低谷上升，特征趋于平滑。

一个最小数值例子

若一维温度为 $(0, 0, 10, 0, 0)$ ，中心点的离散二阶差分为

$$0 - 2 \times 10 + 0 = -20 < 0, \quad (3.5)$$

所以中心温度下降；相邻点的差分为 $10 > 0$ ，所以相邻点升温。信息由中心向周围传播。

4 论文公式 (2) – (5)：将偏微分方程变成频域常微分方程

4.1 二维 Fourier 变换约定

采用连续 Fourier 变换

$$\tilde{u}(\omega_x, \omega_y, t) = \mathcal{F}\{u\} = \int_{\mathbb{R}^2} u(x, y, t) e^{-i(\omega_x x + \omega_y y)} dx dy. \quad (4.1)$$

逆变换为

$$u(x, y, t) = \frac{1}{(2\pi)^2} \int_{\mathbb{R}^2} \tilde{u}(\omega_x, \omega_y, t) e^{i(\omega_x x + \omega_y y)} d\omega_x d\omega_y. \quad (4.2)$$

不同教材可能把 2π 因子分配到正变换或逆变换中，但后续指数衰减结构不变。

4.2 对热方程两侧做 Fourier 变换：公式 (2)

对式 (1) 两侧关于空间变量 (x, y) 做 Fourier 变换：

$$\mathcal{F}\left\{\frac{\partial u}{\partial t}\right\} = k\mathcal{F}\left\{\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2}\right\}. \quad (2)$$

这里 Fourier 变换不作用于时间 t ，所以 t 仍然保留。

4.3 左侧变换：公式 (3)

在满足交换微分与积分的常规正则条件下，

$$\mathcal{F}\left\{\frac{\partial u}{\partial t}\right\} = \int_{\mathbb{R}^2} \frac{\partial u(x, y, t)}{\partial t} e^{-i(\omega_x x + \omega_y y)} dx dy \quad (4.3)$$

$$= \frac{\partial}{\partial t} \int_{\mathbb{R}^2} u(x, y, t) e^{-i(\omega_x x + \omega_y y)} dx dy \quad (4.4)$$

$$= \frac{\partial \tilde{u}(\omega_x, \omega_y, t)}{\partial t}. \quad (3)$$

4.4 右侧变换：公式 (4) 的完整分部积分推导

Fourier 变换的微分性质为

$$\mathcal{F}\left\{\frac{\partial u}{\partial x}\right\} = i\omega_x \tilde{u}, \quad \mathcal{F}\left\{\frac{\partial^2 u}{\partial x^2}\right\} = -\omega_x^2 \tilde{u}. \quad (4.5)$$

以一阶导数为例：

$$\mathcal{F}\{u_x\} = \int_{-\infty}^{\infty} u_x(x) e^{-i\omega_x x} dx \quad (4.6)$$

$$= [u(x) e^{-i\omega_x x}]_{-\infty}^{\infty} + i\omega_x \int_{-\infty}^{\infty} u(x) e^{-i\omega_x x} dx. \quad (4.7)$$

若边界项消失，则得到 $i\omega_x \tilde{u}$ 。再求一次导数便得到 $-\omega_x^2 \tilde{u}$ 。同理，

$$\mathcal{F}\{u_{yy}\} = -\omega_y^2 \tilde{u}. \quad (4.8)$$

所以

$$\mathcal{F}\{u_{xx} + u_{yy}\} = -(\omega_x^2 + \omega_y^2) \tilde{u}(\omega_x, \omega_y, t). \quad (4)$$

4.5 得到频域 ODE：公式 (5)

把式 (3) 和式 (4) 代入式 (2)：

$$\frac{d\tilde{u}}{dt} = -k(\omega_x^2 + \omega_y^2) \tilde{u}. \quad (5)$$

对于固定频率 (ω_x, ω_y) ，这是关于时间 t 的一阶线性常微分方程。原本耦合空间位置的 PDE，在频域中变成每个频率独立演化的标量 ODE。

频域对角化的本质

Laplacian 作用在复指数基函数上时只会乘一个标量：

$$\Delta e^{i(\omega_x x + \omega_y y)} = -(\omega_x^2 + \omega_y^2) e^{i(\omega_x x + \omega_y y)}. \quad (4.9)$$

因此 Fourier 基是 Laplacian 的特征函数，Fourier 变换把微分算子“对角化”了。

5 论文公式 (6)：频域热方程的完整求解

令

$$\lambda = k(\omega_x^2 + \omega_y^2) \geq 0, \quad (5.1)$$

则式 (5) 变成

$$\frac{d\tilde{u}}{dt} = -\lambda \tilde{u}. \quad (5.2)$$

分离变量：

$$\frac{1}{\tilde{u}} d\tilde{u} = -\lambda dt. \quad (5.3)$$

积分得到

$$\ln |\tilde{u}| = -\lambda t + C, \quad (5.4)$$

从而

$$\tilde{u} = C' e^{-\lambda t}. \quad (5.5)$$

初始条件 $u(x, y, 0) = f(x, y)$ 在频域中是

$$\tilde{u}(\omega_x, \omega_y, 0) = \tilde{f}(\omega_x, \omega_y). \quad (5.6)$$

因此 $C' = \tilde{f}$, 得到论文公式 (6):

$$\tilde{u}(\omega_x, \omega_y, t) = \tilde{f}(\omega_x, \omega_y) e^{-k(\omega_x^2 + \omega_y^2)t}. \quad (6)$$

5.1 频率响应如何解释

定义

$$H(\omega_x, \omega_y; k, t) = e^{-k(\omega_x^2 + \omega_y^2)t}. \quad (5.7)$$

若 $k, t \geq 0$, 则

$$0 < H \leq 1. \quad (5.8)$$

零频率处

$$H(0, 0) = 1, \quad (5.9)$$

所以全局平均 (DC 分量) 不衰减。频率半径

$$\rho = \sqrt{\omega_x^2 + \omega_y^2} \quad (5.10)$$

越大, $H = e^{-kt\rho^2}$ 越小, 因此高频纹理与噪声比低频结构衰减得更快。

不同频率的衰减

取 $kt = 0.5$:

$$\rho = 0: \quad H = 1, \quad (5.11)$$

$$\rho = 1: \quad H = e^{-0.5} \approx 0.607, \quad (5.12)$$

$$\rho = 2: \quad H = e^{-2} \approx 0.135, \quad (5.13)$$

$$\rho = 3: \quad H = e^{-4.5} \approx 0.011. \quad (5.14)$$

这说明热扩散天然具有低通滤波性质。

5.2 极限情况

当 $t \rightarrow 0^+$ 时,

$$H \rightarrow 1, \quad u(x, y, t) \rightarrow f(x, y), \quad (5.15)$$

即算子接近恒等映射。

若区域有限、边界采用 Neumann 条件且 k 为正常数，则当 $t \rightarrow \infty$ ，所有非零频率趋于零，只留下常数模态，因此温度趋于全局平均值。

6 论文公式 (7)：回到空间域与 Gaussian 热核

对式 (6) 做逆 Fourier 变换，得到论文公式 (7)：

$$u(x, y, t) = \mathcal{F}^{-1} \left\{ \tilde{f}(\omega_x, \omega_y) e^{-k(\omega_x^2 + \omega_y^2)t} \right\}. \quad (7)$$

由卷积定理，频域乘法对应空间域卷积：

$$u(\cdot, \cdot, t) = G_t * f, \quad (6.1)$$

其中二维热核为

$$G_t(x, y) = \frac{1}{4\pi kt} \exp \left[-\frac{x^2 + y^2}{4kt} \right]. \quad (6.2)$$

6.1 热核为什么是 Gaussian

一维中有经典变换对

$$\mathcal{F}^{-1} \{ e^{-kt\omega^2} \} = \frac{1}{\sqrt{4\pi kt}} e^{-x^2/(4kt)}. \quad (6.3)$$

二维指数可以分离：

$$e^{-kt(\omega_x^2 + \omega_y^2)} = e^{-kt\omega_x^2} e^{-kt\omega_y^2}. \quad (6.4)$$

所以二维逆变换是两个一维 Gaussian 的乘积，即式 (6.2)。

6.2 扩散尺度

Gaussian 的每个坐标方向方差为

$$\sigma^2 = 2kt, \quad (6.5)$$

所以典型扩散半径与

$$\sigma = \sqrt{2kt} \quad (6.6)$$

成正比。传播距离不是与时间线性增长，而是与 $\sqrt{t}$ 同阶。

论文没有显式写出的等价形式

论文直接使用频域一般解。补充的 Gaussian 卷积形式说明，经典常系数热方程等价于用一个随 t 变宽的 Gaussian 核平滑输入。vHeat 的关键变化是把扩散率做成频率相关、可学习的量，因此一般不再等价于单一的各向同性 Gaussian 核。

7 从标量温度到多通道视觉特征：论文公式 (8)

视觉特征不是单通道标量，而是

$$U(x, y, c, t), \quad c = 1, 2, \dots, C. \quad (7.1)$$

将每个通道视作一张温度场，论文把式 (7) 扩展为

$$U^t = \mathcal{F}^{-1} \left(\mathcal{F}(U^0) e^{-k(\omega_x^2 + \omega_y^2)t} \right). \quad (8)$$

若

$$U^0 \in \mathbb{R}^{B \times H \times W \times C}, \quad (7.2)$$

那么 Fourier/DCT 只沿空间维度 H, W 进行，批量维和通道维保留：

$$\hat{U} = \mathcal{F}_{x,y}(U^0) \in \mathbb{C}^{B \times H \times W \times C}. \quad (7.3)$$

使用 DCT 后，由于输入和余弦基均为实数，频域系数仍为实数，可避免复数计算。

7.1 逐通道与跨通道建模的区别

式 (8) 本身主要描述每个通道内的空间传播。通道之间的信息混合由 HCO layer 前后的线性层、门控分支和 FFN 完成。因此可把 vHeat 的职责拆成

$$\underbrace{\text{HCO}}_{\text{全局空间传播}} + \underbrace{\text{Linear/FFN}}_{\text{通道混合与非线性}}. \quad (7.4)$$

8 为什么 Neumann 边界自然对应 DCT

8.1 边界条件

图像是有限矩形区域，论文采用 Neumann 边界条件：

$$\frac{\partial u}{\partial n} = 0, \quad (x, y) \in \partial D, \quad t \geq 0, \quad (8.1)$$

其中 n 是边界外法向量。它表示边界外没有热流：

$$\text{热量不会穿过图像边界流出或流入}. \quad (8.2)$$

在一维区间 $[0, L]$ 上，条件是

$$u_x(0, t) = u_x(L, t) = 0. \quad (8.3)$$

8.2 余弦函数满足零法向导数

考虑特征函数

$$\phi_p(x) = \cos\left(\frac{p\pi x}{L}\right). \quad (8.4)$$

其导数为

$$\phi'_p(x) = -\frac{p\pi}{L} \sin\left(\frac{p\pi x}{L}\right). \quad (8.5)$$

在 $x = 0$ 和 $x = L$:

$$\phi'_p(0) = \phi'_p(L) = 0. \quad (8.6)$$

所以余弦基天然满足 Neumann 边界。二维基函数是乘积

$$\phi_{pq}(x, y) = \cos\left(\frac{p\pi x}{L_x}\right) \cos\left(\frac{q\pi y}{L_y}\right). \quad (8.7)$$

这就是有限矩形区域中用 DCT 替代 DFT 的数学依据。

边界的直观含义

DFT 隐含周期延拓：图像右边界会与左边界相连，容易产生不自然的环绕。DCT 可解释为偶对称延拓，使边界法向导数为零，更符合“语义不跨越图像外部传播”的设定。

9 论文公式 (9)：HCO 的离散实现

在有限离散特征图上，论文将 Fourier 变换替换为二维 DCT：

$$U^t = \text{IDCT}_{2D} \left[\text{DCT}_{2D}(U^0) \odot e^{-k(\omega_x^2 + \omega_y^2)t} \right]. \quad (9)$$

这里逐元素乘法应明确写为 $\odot$ 。在实现中，可预先构造频率平方矩阵

$$\Omega_{pq}^2 = \omega_p^2 + \omega_q^2, \quad (9.1)$$

再计算

$$H_{pq} = \exp(-k_{pq}\Omega_{pq}^2 t). \quad (9.2)$$

对于每个 batch、通道或分组，频域系数逐点乘上 H 。

9.1 离散 Laplacian 的更精确特征值

论文使用连续近似 $\omega_p^2 + \omega_q^2$ 。在规则网格上，二阶中心差分 Laplacian 的精确离散特征值可写成

$$\lambda_{pq} = \frac{4}{h_x^2} \sin^2\left(\frac{p\pi}{2H}\right) + \frac{4}{h_y^2} \sin^2\left(\frac{q\pi}{2W}\right). \quad (9.3)$$

严格离散热扩散可使用

$$H_{pq} = e^{-k\lambda_{pq}t}. \quad (9.4)$$

当频率较低时, $\sin z \approx z$, 因此

$$\lambda_{pq} \approx \omega_p^2 + \omega_q^2, \quad (9.5)$$

论文形式可以视为连续热方程启发的频率参数化。

10 论文公式 (10): 二维 DCT 与 IDCT 逐项解释

设输入矩阵

$$A = (A_{mn}) \in \mathbb{R}^{M \times N}, \quad (10.1)$$

DCT 系数矩阵

$$B = (B_{pq}) \in \mathbb{R}^{M \times N}. \quad (10.2)$$

正交归一的二维 DCT-II 可写为

$$B_{pq} = \alpha_p \alpha_q \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} A_{mn} \cos\left(\frac{(2m+1)p\pi}{2M}\right) \cos\left(\frac{(2n+1)q\pi}{2N}\right), \quad (10.3)$$

而逆变换为

$$A_{mn} = \sum_{p=0}^{M-1} \sum_{q=0}^{N-1} \alpha_p \alpha_q B_{pq} \cos\left(\frac{(2m+1)p\pi}{2M}\right) \cos\left(\frac{(2n+1)q\pi}{2N}\right). \quad (10.4)$$

这对应论文公式 (10)。归一化因子为

$$\alpha_p = \begin{cases} \frac{1}{\sqrt{M}}, & p = 0, \\ \sqrt{\frac{2}{M}}, & p > 0, \end{cases} \quad \alpha_q = \begin{cases} \frac{1}{\sqrt{N}}, & q = 0, \\ \sqrt{\frac{2}{N}}, & q > 0. \end{cases} \quad (10)$$

原文排版中容易误读的一点

IDCT 的求和变量应是频率索引 p, q , 而不是空间索引 m, n 。PDF 公式的字体与文本抽取可能让上下标显得混乱; 式 (10.4) 给出了维度一致的标准写法。

10.1 为什么二维 DCT 可分离

二维余弦基是行方向基与列方向基的乘积, 因此可先对每一列做一维 DCT, 再对每一行做一维 DCT, 或反过来。其可分离性是矩阵实现的基础。

11 论文公式 (11): DCT 的矩阵乘法实现

定义行方向余弦矩阵

$$C_{mp} = \alpha_p \cos\left(\frac{(2m+1)p\pi}{2M}\right), \quad C \in \mathbb{R}^{M \times M}, \quad (11.1)$$

列方向余弦矩阵

$$D_{nq} = \alpha_q \cos \left(\frac{(2n+1)q\pi}{2N} \right), \quad D \in \mathbb{R}^{N \times N}. \quad (11.2)$$

则二维 DCT 可写成

$$B = C^\top A D \quad \text{或等价地按作者索引约定写为} \quad B = C A D^\top. \quad (11.3)$$

只要 C, D 的行列索引定义与乘法方向保持一致，两种记法描述的是同一组可分离基变换。论文采用的形式为

$$B = C A D^\top, \quad (11.4)$$

$$A = C^\top B D. \quad (11)$$

由于使用正交归一基，

$$C^\top C = I_M, \quad D^\top D = I_N, \quad (11.5)$$

所以逆变换可直接使用转置矩阵。

11.1 维度核对

按论文约定：

$$C_{M \times M} A_{M \times N} D_{N \times N}^\top \implies B_{M \times N}. \quad (11.6)$$

逆变换：

$$C_{M \times M}^\top B_{M \times N} D_{N \times N} \implies A_{M \times N}. \quad (11.7)$$

12 为什么复杂度是 $O(N^{3/2})$

论文中 N 表示 patch 总数。为了避免与 DCT 公式中的列数 N 混淆，本节把总 patch 数记为 P 。若特征图为正方形，则边长为

$$S = \sqrt{P}. \quad (12.1)$$

矩阵 A, B, C, D 的空间尺寸均为 $S \times S$ 。计算

$$C A \quad (12.2)$$

是两个 $S \times S$ 稠密矩阵相乘，经典复杂度为

$$O(S^3). \quad (12.3)$$

再乘 $D^\top$ 仍是同阶，所以一次二维 DCT 为

$$O(S^3) = O((\sqrt{P})^3) = O(P^{3/2}). \quad (12.4)$$

DCT、逐频率乘法和 IDCT 合计仍为

$$\boxed{O(P^{3/2})}. \quad (12.5)$$

相比之下，标准自注意力的注意力矩阵为 $P \times P$ ，核心复杂度为

$$O(P^2d), \quad (12.6)$$

若只比较 token 数的次数，则是 $O(P^2)$ 。

分辨率升高时的增长差异

若 patch 数扩大为原来的 4 倍：

$$O(P^{3/2}) \text{ 增长 } 4^{3/2} = 8 \text{ 倍}, \quad (12.7)$$

$$O(P^2) \text{ 增长 } 4^2 = 16 \text{ 倍}. \quad (12.8)$$

因此高分辨率下两者差距会迅速拉大。

复杂度表述需要精确理解

数学上存在 FFT 型快速 DCT，可达到约 $O(P \log P)$ 。论文报告的 $O(P^{3/2})$ 对应其 GPU 友好的稠密矩阵乘法实现，而不是 DCT 算法的理论最优复杂度。作者选择该实现，是因为规则 GEMM 在 GPU 上有很高的并行效率。

13 自适应热扩散率与 Frequency Value Embeddings

13.1 为什么固定 k 不够

经典热方程中 k 只由材料决定，是常数。若直接把固定 k 用于所有图像、层和频率，得到的是统一的各向同性低通滤波，无法根据图像内容选择保留哪些结构。因此论文令

$$k = k(\omega_x, \omega_y), \quad (13.1)$$

使不同频率拥有不同扩散强度。

13.2 FVE 的数学角色

为每个频率位置 (p, q) 设置可学习嵌入

$$e_{pq} \in \mathbb{R}^{d_e}. \quad (13.2)$$

通过线性层预测

$$k_{pq} = W e_{pq} + b, \quad (13.3)$$

或在保证物理正性时可采用

$$k_{pq} = \text{softplus}(W e_{pq} + b) > 0. \quad (13.4)$$

论文明确描述了“FVE 经线性层预测 k ”，但正文并未充分展开正值约束的具体实现，因此式 (13.4) 是稳定实现的一种补充建议，而非对论文代码的无条件断言。

最终频率响应为

$$H_{pq} = \exp[-k_{pq}\Omega_{pq}^2 t]. \quad (13.5)$$

13.3 固定 t 的可辨识性原因

频率响应只通过乘积 kt 出现：

$$e^{-k\Omega^2 t} = e^{-(kt)\Omega^2}. \quad (13.6)$$

若同时学习 k 和 t ，任取 $a > 0$ ，

$$k' = ak, \quad t' = t/a \quad (13.7)$$

会产生完全相同的响应。因此二者无法仅由该算子唯一辨识。固定 t 、学习 k 可以消除这种尺度冗余。

13.4 对参数的梯度

令

$$H = e^{-k\Omega^2 t}. \quad (13.8)$$

则

$$\frac{\partial H}{\partial k} = -\Omega^2 t H, \quad (13.9)$$

$$\frac{\partial H}{\partial t} = -k\Omega^2 H. \quad (13.10)$$

高频处 Ω^2 较大，因此对 k 的梯度幅度可能更大，但当指数已经极小又会出现衰减。过大的 $kt\Omega^2$ 可能导致高频分量和梯度接近零。

14 自适应频率滤波与经典热方程的关系

若 k 是正的常数，则 HCO 完全对应常系数热方程的解算子。若 $k = k(\omega_x, \omega_y)$ ，则

$$\widehat{U}^t(\omega) = e^{-k(\omega)|\omega|^2 t} \widehat{U}^0(\omega) \quad (14.1)$$

仍然是一个稳定的谱滤波器，但它一般不再对应简单的局部 PDE

$$u_t = k\Delta u \quad (14.2)$$

中的常数 k 。它可被解释为某个频率依赖的伪微分算子：

$$u_t = -\mathcal{A}u, \quad \widehat{\mathcal{A}u}(\omega) = k(\omega)|\omega|^2 \widehat{u}(\omega). \quad (14.3)$$

物理解释的边界

“受热传导启发”是准确的；但当 k 被自由地按频率学习后，模型更严格的数学描述是“具有热核形式的学习型全局谱滤波”。它保留了指数扩散、频率对角化和能量传播的结构，但不必等价于某种真实材料的经典热传导。

15 HCO Layer 的完整计算链

根据论文图示和文字，HCO layer 可整理为以下计算。设输入

$$X \in \mathbb{R}^{B \times H \times W \times C}. \quad (15.1)$$

首先进行局部预处理：

$$Z = \text{DWConv}_{3 \times 3}(X). \quad (15.2)$$

然后形成两条分支。

HCO 分支：

$$Z_h = \text{Linear}_h(\text{LN}(Z)), \quad (15.3)$$

$$Y_h = \text{HCO}(Z_h). \quad (15.4)$$

门控分支：

$$Y_g = \text{SiLU}(\text{Linear}_g(\text{LN}(Z))). \quad (15.5)$$

融合时采用逐元素乘法：

$$Y = Y_h \odot Y_g. \quad (15.6)$$

再经线性投影和残差连接：

$$X' = X + \text{Linear}_o(Y). \quad (15.7)$$

随后接标准 FFN：

$$X_{\text{out}} = X' + \text{FFN}(\text{LN}(X')). \quad (15.8)$$

结构公式的性质

式 (15.7) 是根据论文 HCO layer 图和文字做的结构化展开，用于帮助理解数据流。论文正文重点给出的是 HCO 内部的热方程离散解，而没有把整个 block 写成单一编号公式。

15.1 门控的意义

逐元素乘法

$$Y_h \odot Y_g \quad (15.9)$$

允许网络根据当前位置和通道的门值，选择性放大或压低 HCO 传播结果。HCO 提供全局传播，门控分支提供内容依赖的非线性选择。

15.2 残差连接的梯度通道

若

$$X' = X + F(X), \quad (15.10)$$

则

$$\frac{\partial X'}{\partial X} = I + \frac{\partial F}{\partial X}. \quad (15.11)$$

恒等项 I 为反向传播提供直接路径，使全局频域算子更容易稳定地嵌入深层网络。

16 HCO 为什么具有全局感受野

DCT 的每个频率系数是所有空间位置的线性组合：

$$B_{pq} = \sum_{m,n} A_{mn} \phi_{pq}(m, n). \quad (16.1)$$

因此一个局部输入变化一般会影响许多频率系数。IDCT 又将每个频率系数重新分配到所有空间位置：

$$A'_{mn} = \sum_{p,q} B'_{pq} \phi_{pq}(m, n). \quad (16.2)$$

组合后，输出位置 (m, n) 对输入位置 (i, j) 的线性核为

$$K_{mn,ij} = \sum_{p,q} H_{pq} \phi_{pq}(m, n) \phi_{pq}(i, j). \quad (16.3)$$

通常 $K_{mn,ij}$ 对远距离 (i, j) 也不为零，所以一次 HCO 就能建立全局依赖。

16.1 与注意力矩阵的对比

自注意力：

$$Y = \text{softmax} \left(\frac{QK^\top}{\sqrt{d}} \right) V, \quad (16.4)$$

其传播矩阵由输入内容的两两相似度动态生成，大小为 $P \times P$ 。

HCO：

$$Y = \Phi^\top \text{diag}(H) \Phi X, \quad (16.5)$$

其中 Φ 是固定 DCT 基， H 是学习到的频率响应。它不显式构造两两相似度，而是在共享频率基中进行对角调制。

比较项	Self-Attention	HCO
全局交互	显式 token 两两交互	固定全局基中的谱传播
动态性	Q, K 由输入生成	主要由可学习频率扩散率调节
核心矩阵	$P \times P$ 注意力矩阵	对角频率响应 H
复杂度	约 $O(P^2)$	论文实现约 $O(P^{3/2})$
解释方式	相似度加权	热扩散与频率滤波

17 稳定性、能量与可逆性分析

17.1 频域能量不增条件

DCT 是正交变换，满足 Parseval 等式：

$$\|U\|_F^2 = \|\text{DCT}_{2D}(U)\|_F^2. \quad (17.1)$$

若 $k_{pq} \geq 0$ 且 $t \geq 0$ ，则 $|H_{pq}| \leq 1$ ，因此

$$\|U^t\|_F^2 = \sum_{p,q,c} |H_{pq}|^2 |\hat{U}_{pq}^0|^2 \quad (17.2)$$

$$\leq \sum_{p,q,c} |\hat{U}_{pq}^0|^2 = \|U^0\|_F^2. \quad (17.3)$$

这说明纯 HCO 热扩散部分是非扩张的，不会无界放大特征能量。

17.2 若 $k < 0$ 会发生什么

若某些频率上 $k < 0$ ，则

$$H = e^{|k|\Omega^2 t} > 1, \quad (17.4)$$

且随频率平方指数增长，可能严重放大高频噪声并造成数值不稳定。因此从热方程和稳定性角度，保证 $k \geq 0$ 很重要。

17.3 是否可逆

有限 t 下，若所有 $H_{pq} > 0$ ，形式上可写

$$\hat{U}_{pq}^0 = \frac{\hat{U}_{pq}^t}{H_{pq}}. \quad (17.5)$$

但高频处 H_{pq} 可能极小，除法会放大噪声，逆问题高度病态。这与图像去模糊和反热传导问题一致。

18 一个可手算的离散 HCO 示例

考虑一个 2×2 特征图

$$A = \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix}. \quad (18.1)$$

使用正交二维 DCT，可将其表示为低频与高频余弦模态的组合。为了突出机制，设四个频率响应为

$$H = \begin{bmatrix} 1 & 0.6 \\ 0.6 & 0.2 \end{bmatrix}. \quad (18.2)$$

零频率保留，高频显著衰减。经过

$$B = \text{DCT}_{2\text{D}}(A), \quad B' = B \odot H, \quad A' = \text{IDCT}_{2\text{D}}(B'), \quad (18.3)$$

输出会从单点峰值变成向其他位置扩散的平滑分布，同时总平均值主要由 DC 分量保持。

这个例子要表达的不是具体数值

HCO 不在空间域逐步扫描邻居，而是一次性把局部峰值分解成全局余弦模态，衰减高频后再重构。空间上看到的“向外扩散”，是频域低通演化的等价表现。

19 模型分层与扩散尺度

vHeat 采用四阶段层次结构，随着 stage 加深：

$$H \times W \rightarrow \frac{H}{4} \times \frac{W}{4} \rightarrow \frac{H}{8} \times \frac{W}{8} \rightarrow \frac{H}{16} \times \frac{W}{16} \rightarrow \frac{H}{32} \times \frac{W}{32}, \quad (19.1)$$

同时通道数增加。浅层高分辨率特征强调局部纹理，深层低分辨率特征强调高级语义。

论文可视化显示，若更深层预测的平均 k 更大，则根据

$$\sigma = \sqrt{2kt}, \quad (19.2)$$

其有效扩散尺度更大，符合深层需要聚合更广语义范围的直觉。但这里的 k 是学习型频率参数， σ 只适用于常系数 Gaussian 热核的直观类比，不能逐字等同于所有自适应 HCO 的真实空间标准差。

20 论文数学设计的优势

20.1 物理方程直接给出结构化频率响应

与任意学习一个全局频率权重矩阵相比，HCO 使用

$$e^{-k\Omega^2 t} \quad (20.1)$$

这一热方程形式，带来明确的频率顺序、平滑性和稳定性先验。

20.2 全局感受野不需要显式二次矩阵

通过固定 DCT 基，算子写成

$$\Phi^\top \text{diag}(H) \Phi, \quad (20.2)$$

避免显式存储 $P \times P$ 注意力矩阵。

20.3 适应性与先验的平衡

FVE 提供频率位置先验，线性层学习扩散率。与把每个频率权重完全自由化相比，它保留了热扩散参数化；与固定 k 相比，又能适应视觉内容与网络阶段。

21 需要谨慎理解或可进一步优化的地方

21.1 频率相关 k 与严格物理模型存在距离

经典各向同性热方程使用常数 k ；若 k 依赖频率，它更像学习型谱算子。若未来希望加强物理一致性，可考虑：

- 约束 $k_{pq} \geq 0$ ；
- 对相邻频率的 k 加平滑正则；
- 使用少量物理参数构造各向异性扩散张量；
- 显式区分空间依赖 $k(x, y)$ 与频率依赖 $k(\omega)$ 。

21.2 分辨率变化时的频率坐标

不同输入分辨率对应不同的 DCT 网格。若直接插值 FVE，需要确认插值的是归一化频率坐标而不是纯数组索引。论文附录比较了多种 FVE/ k 尺寸对齐策略，这说明跨分辨率迁移不是完全无代价的。

21.3 复杂度不等于实际速度

$O(P^{3/2})$ 只描述渐近次数。实际速度还取决于通道数、批量、内存访问、矩阵乘法内核和硬件。论文采用 GEMM 形式正是为了利用 GPU 的成熟优化。

21.4 指数滤波可能过度平滑

若 kt 过大，非零频率迅速衰减，特征可能趋于常数，产生 oversmoothing。可通过残差连接、门控、分层小步扩散、限制 k 范围等方式缓解。

21.5 缺少显式的输入依赖两两关系

HCO 的频率基固定，通常不具备标准自注意力那种“根据当前图像任意两个 token 内容计算相似度”的自由度。其优势是效率和结构先验，代价是交互形式受谱参数化约束。门控和上下文特征映射可补偿一部分表达能力，但二者不是完全等价。

22 公式总表与维度检查

编号	公式	数学含义
(1)	$u_t = k(u_{xx} + u_{yy})$	二维热方程，局部曲率驱动温度变化。
(2)	$\mathcal{F}(u_t) = k\mathcal{F}(u_{xx} + u_{yy})$	对空间变量做 Fourier 变换。
(3)	$\mathcal{F}(u_t) = \partial_t \tilde{u}$	时间微分与空间 Fourier 变换交换。
(4)	$\mathcal{F}(u_{xx} + u_{yy}) = -(\omega_x^2 + \omega_y^2)\tilde{u}$	微分在频域变成乘法。
(5)	$\dot{\tilde{u}} = -k(\omega_x^2 + \omega_y^2)\tilde{u}$	每个频率独立的一阶 ODE。
(6)	$\tilde{u} = \tilde{f}e^{-k(\omega_x^2 + \omega_y^2)t}$	频域指数衰减解。
(7)	$u = \mathcal{F}^{-1}(\tilde{f}e^{-k \omega ^2 t})$	返回空间域；等价于 Gaussian 卷积。
(8)	$U^t = \mathcal{F}^{-1}(\mathcal{F}(U^0)e^{-k \omega ^2 t})$	扩展到多通道视觉特征。
(9)	$U^t = \text{IDCT}_{2D}(\text{DCT}_{2D}(U^0)e^{-k \omega ^2 t})$	Neumann 边界下的离散 HCO。
(10)	二维 DCT-II/IDCT-III 双重求和	定义空间网格与余弦频率系数之间的变换。
(11)	$B = CAD^\top, A = C^\top BD$	GPU 友好的可分离矩阵乘法实现。

23 从输入到输出的完整数学过程

将所有关键步骤串起来：

$$X_0 \in \mathbb{R}^{B \times H \times W \times C}, \quad (23.1)$$

$$Z = \text{DWConv}(X_0), \quad (23.2)$$

$$V = \text{Linear}_h(\text{LN}(Z)), \quad (23.3)$$

$$\hat{V} = \text{DCT}_{2D}(V), \quad (23.4)$$

$$k = \text{Predictor}(\text{FVE}), \quad (23.5)$$

$$H = \exp(-k \odot \Omega^2 t), \quad (23.6)$$

$$V_t = \text{IDCT}_{2D}(\hat{V} \odot H), \quad (23.7)$$

$$G = \text{SiLU}(\text{Linear}_g(\text{LN}(Z))), \quad (23.8)$$

$$X_1 = X_0 + \text{Linear}_o(V_t \odot G), \quad (23.9)$$

$$X_{\text{out}} = X_1 + \text{FFN}(\text{LN}(X_1)). \quad (23.10)$$

其中 HCO 最核心的数学压缩式是

$$\boxed{\text{HCO}(V) = \Phi^\top \text{diag}\left(e^{-k \odot \Omega^2 t}\right) \Phi V}, \quad (23.11)$$

Φ 表示二维 DCT 正交基。这个表达把整篇论文的数学思想集中为：

$$\boxed{\text{固定全局余弦基} + \text{可学习热扩散谱} + \text{逆变换重建}}. \quad (23.12)$$

24 结论

vHeat 的数学创新不是重新发明热方程，而是完成了以下映射：

$$\text{物理温度场} \longleftrightarrow \text{多通道视觉特征}, \quad (24.1)$$

$$\text{热量扩散} \longleftrightarrow \text{视觉语义传播}, \quad (24.2)$$

$$\text{热方程频域解} \longleftrightarrow \text{可学习全局频率滤波器}. \quad (24.3)$$

其推导链条是：

$$\boxed{u_t = k \Delta u \xrightarrow{\mathcal{F}} \dot{\tilde{u}} = -k|\omega|^2 \tilde{u} \xrightarrow{\text{解 ODE}} \tilde{u} = \tilde{f} e^{-k|\omega|^2 t} \xrightarrow{\text{Neumann+DCT}} \text{HCO}}. \quad (24.4)$$

这套设计以 $O(P^{3/2})$ 的论文实现复杂度获得全局感受野，并通过频率值嵌入让热扩散率可学习。最值得掌握的不是单独某个指数公式，而是“利用算子特征基把空间传播对角化，再在谱域中进行结构化学习”的通用思想。