

09_Mean Flows for One-step Generative Modeling 数学过程详解

平均速度定义、MeanFlow Identity、JVP 训练目标与一步采样

本文只处理真正需要推导的部分

本文逐步推导平均速度、区间可加性、MeanFlow Identity、全导数/JVP、停止梯度目标、Flow Matching 退化关系和鲁棒损失。全文按“公式从哪里来–每个符号是什么–中间步骤为何成立–维度和复杂度如何核对–论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1	Flow Matching 的瞬时速度	3
2	平均速度的定义与位移关系	3
3	平均速度的区间可加性	3
4	MeanFlow Identity 的逐步推导	4
5	全导数为什么包含 Jacobian–vector product	4
6	训练目标与停止梯度	5
7	零损失为何恢复原定义	5
8	MeanFlow 与普通 Flow Matching 的退化关系	5
9	一步和多步采样	6
10	自适应损失加权的数学含义	6
11	CFG 平均速度	6
12	理论与实现边界	7
13	平均速度是位移的精确商	7

14 区间可加性	7
15 MeanFlow Identity 的微分推导	7
16 Jacobian–vector product 的实现	8
17 训练目标的自治固定点	8
18 平方损失的条件期望最优解	9
19 一步误差由平均场预测误差直接控制	9
20 多步组合误差递推	10
21 CFG 对平均速度的线性作用	10
22 自适应权重的尺度不变性	10
23 平均速度满足的传输型偏微分方程	11
24 JVP 与有限差分的关系	11
25 停止梯度目标与真正的二阶目标差异	11
26 一维线性速度场的解析 MeanFlow	12
27 一步采样误差的精确表达	12
28 多步误差递推与 Lipschitz 放大	13
29 条件速度监督的方差分解	13
30 自适应幂损失的梯度尺度	13
31 CFG 对平均速度的线性与非线性部分	14

1 Flow Matching 的瞬时速度

给定数据 $x \sim p_{\text{data}}$ 、先验噪声 $\epsilon \sim p_{\text{prior}}$ ，论文使用一般线性路径

$$z_t = a_t x + b_t \epsilon. \quad (1.1)$$

对 t 求导得到条件瞬时速度

$$v_t(z_t | x) = \dot{a}_t x + \dot{b}_t \epsilon. \quad (1.2)$$

最常用的 rectified path 为 $a_t = 1 - t, b_t = t$ ，于是

$$z_t = (1 - t)x + t\epsilon, \quad v_t = \epsilon - x. \quad (1.3)$$

同一个 z_t 可能来自多个 (x, ϵ) ，所以真正决定边缘概率流的速度是条件期望

$$v(z_t, t) = \mathbb{E}[v_t | z_t]. \quad (1.4)$$

均方误差回归条件速度与回归边缘速度具有相同最优解，因为条件期望是 L^2 投影。

2 平均速度的定义与位移关系

对从时刻 t 走到更早时刻 $r < t$ 的轨迹，定义平均速度

$$u(z_t, r, t) = \frac{1}{t - r} \int_r^t v(z_\tau, \tau) d\tau. \quad (2.1)$$

由 ODE $dz_t/dt = v(z_t, t)$ ，积分得到

$$z_t - z_r = \int_r^t v(z_\tau, \tau) d\tau. \quad (2.2)$$

所以

$$z_r = z_t - (t - r)u(z_t, r, t). \quad (2.3)$$

这不是数值近似，而是平均速度定义的恒等式。如果网络能精确预测 $u(z_1, 0, 1)$ ，则一步采样

$$z_0 = z_1 - u(z_1, 0, 1) \quad (2.4)$$

精确等于整段 ODE 的积分位移。

3 平均速度的区间可加性

任选 $r < s < t$ ，由积分可加性

$$\int_r^t v d\tau = \int_r^s v d\tau + \int_s^t v d\tau. \quad (3.1)$$

代入平均速度定义：

$$(t - r)u(z_t, r, t) = (s - r)u(z_s, r, s) + (t - s)u(z_t, s, t). \quad (3.2)$$

该“自一致性”不需要额外正则，只要 u 真的是同一速度场的区间平均就自动成立。网络近似误差会破坏它，但理论目标本身具有该性质。

4 MeanFlow Identity 的逐步推导

从

$$(t-r)u(z_t, r, t) = \int_r^t v(z_\tau, \tau) d\tau \quad (4.1)$$

出发，对 t 求全导数。左边用乘积法则：

$$\frac{d}{dt}[(t-r)u] = u + (t-r)\frac{du}{dt}. \quad (4.2)$$

右边用微积分基本定理：

$$\frac{d}{dt} \int_r^t v(z_\tau, \tau) d\tau = v(z_t, t). \quad (4.3)$$

因此

$$u + (t-r)\frac{du}{dt} = v, \quad (4.4)$$

整理得论文核心恒等式

$$u(z_t, r, t) = v(z_t, t) - (t-r)\frac{d}{dt}u(z_t, r, t). \quad (4.5)$$

当 $r \rightarrow t$ ，第二项消失，于是 $u \rightarrow v$ ，平均速度退化为瞬时速度。

5 全导数为什么包含 Jacobian–vector product

u 同时依赖状态 z_t 、区间起点 r 和终点 t ：

$$u = u(z_t, r, t). \quad (5.1)$$

链式法则给出

$$\frac{du}{dt} = \frac{\partial u}{\partial z} \frac{dz_t}{dt} + \frac{\partial u}{\partial r} \frac{dr}{dt} + \frac{\partial u}{\partial t} \frac{dt}{dt}. \quad (5.2)$$

训练中 r 与 t 独立采样，故 $dr/dt = 0$ ；又 $dz_t/dt = v(z_t, t)$ ，于是

$$\frac{du}{dt} = v(z_t, t) \partial_z u + \partial_t u. \quad (5.3)$$

若 $u \in \mathbb{R}^d$ ， $\partial_z u \in \mathbb{R}^{d \times d}$ 。显式构造 Jacobian 代价高，但只需要

$$J_u(z_t) v \quad (5.4)$$

这一 Jacobian–vector product，可由自动微分的 JVP 在线性于一次网络评估的成本内计算。

6 训练目标与停止梯度

用网络 u_θ 代替真实平均速度，并把条件速度 v_t 作为可采样监督，目标构造为

$$u_{\text{tgt}} = v_t - (t - r)(v_t \partial_z u_\theta + \partial_t u_\theta). \quad (6.1)$$

损失

$$\mathcal{L}(\theta) = \mathbb{E} \|u_\theta(z_t, r, t) - \text{sg}(u_{\text{tgt}})\|_2^2. \quad (6.2)$$

若不使用 sg ， u_{tgt} 本身含 ∂u_θ ，求梯度会出现 Hessian 或二阶反向传播。停止梯度后

$$\nabla_\theta \mathcal{L} = 2\mathbb{E} J_\theta u_\theta^\top (u_\theta - u_{\text{tgt}}), \quad (6.3)$$

JVP 只用于计算目标值，不继续参与外层梯度。

7 零损失为何恢复原定义

若对所有 (z_t, r, t) 都有 $u_\theta = u_{\text{tgt}}$ ，则网络满足

$$u_\theta = v - (t - r) \frac{du_\theta}{dt}, \quad (7.1)$$

也就是 MeanFlow Identity。令

$$F(t) = (t - r)u_\theta(z_t, r, t). \quad (7.2)$$

则

$$F'(t) = u_\theta + (t - r) \frac{du_\theta}{dt} = v(z_t, t). \quad (7.3)$$

又 $F(r) = 0$ ，积分得到

$$F(t) = \int_r^t v(z_\tau, \tau) d\tau, \quad (7.4)$$

即

$$u_\theta = \frac{1}{t - r} \int_r^t v d\tau. \quad (7.5)$$

所以恒等式与平均速度定义在适当边界条件下等价。

8 MeanFlow 与普通 Flow Matching 的退化关系

当强制 $r = t$ 时

$$t - r = 0, \quad (8.1)$$

目标变成

$$u_{\text{tgt}} = v_t, \quad (8.2)$$

而网络输入的区间长度为零， $u(z_t, t, t) = v(z_t, t)$ 。因此损失退化为标准 Flow Matching：

$$\mathcal{L} = \mathbb{E} \|u_\theta(z_t, t, t) - v_t\|_2^2. \quad (8.3)$$

非零区间 $t - r$ 才迫使网络学习有限时间位移，而不是局部切向量。

9 一步和多步采样

一步采样从 $z_1 = \epsilon$ 开始:

$$x \approx z_0 = z_1 - u_\theta(z_1, 0, 1). \quad (9.1)$$

若分成 K 段 $1 = t_K > t_{K-1} > \dots > t_0 = 0$, 则

$$z_{t_{i-1}} = z_{t_i} - (t_i - t_{i-1})u_\theta(z_{t_i}, t_{i-1}, t_i). \quad (9.2)$$

这里每一步预测的是该区间平均速度, 所以即使 K 很小也比用瞬时速度做粗 Euler 积分更匹配位移目标。

10 自适应损失加权的数学含义

论文考虑误差 $\Delta = u_\theta - u_{\text{tgt}}$, 目标族

$$\mathcal{L}_\gamma = \|\Delta\|_2^{2\gamma}. \quad (10.1)$$

其梯度为

$$\nabla_\Delta \mathcal{L}_\gamma = 2\gamma \|\Delta\|_2^{2\gamma-2} \Delta. \quad (10.2)$$

可用停止梯度权重近似:

$$w = \frac{1}{(\|\Delta\|_2^2 + c)^p}, \quad p = 1 - \gamma, \quad (10.3)$$

然后最小化

$$\text{sg}(w) \|\Delta\|_2^2. \quad (10.4)$$

大误差样本权重被压低, 减弱离群点主导; $c > 0$ 防止误差接近零时权重发散。

11 CFG 平均速度

若瞬时引导速度

$$v^{\text{cfg}} = v_u + \omega(v_c - v_u), \quad (11.1)$$

对应平均速度由积分线性性得到

$$u^{\text{cfg}} = \frac{1}{t-r} \int_r^t v^{\text{cfg}} d\tau \quad (11.2)$$

$$= u_u + \omega(u_c - u_u). \quad (11.3)$$

因此 CFG 可以直接作用在平均速度场上。需要注意, 若条件/无条件网络共享但输入不同, JVP 目标中的导数也必须针对组合后的场一致计算。

12 理论与实现边界

MeanFlow 不等于“任何 ODE 都能一步精确”

一步精确成立的前提是网络准确预测整段真实边缘轨迹的平均速度。训练只使用条件速度和自洽恒等式，有限模型、有限数据、停止梯度与优化误差都会造成偏差。JVP 避免了显式积分，但并没有消除学习整段非线性轨迹的难度。

13 平均速度是位移的精确商

真实 ODE

$$\dot{x}_t = v(x_t, t) \quad (13.1)$$

在区间 $[r, t]$ 上积分：

$$x_t - x_r = \int_r^t v(x_s, s) ds. \quad (13.2)$$

定义平均速度

$$u(x_t, r, t) = \frac{1}{t - r} \int_r^t v(x_s, s) ds, \quad (13.3)$$

立即得到

$$x_r = x_t - (t - r)u(x_t, r, t). \quad (13.4)$$

因此若模型精确预测从噪声端 $t = 1$ 到数据端 $r = 0$ 的平均速度，一次更新就可完成生成；这不是数值近似，而是平均速度定义的代数恒等式。

14 区间可加性

取 $r < s < t$ ，由积分可加

$$(t - r)u_{r,t} = (s - r)u_{r,s} + (t - s)u_{s,t}. \quad (14.1)$$

故

$$u_{r,t} = \frac{s - r}{t - r}u_{r,s} + \frac{t - s}{t - r}u_{s,t}. \quad (14.2)$$

长区间平均场是两个短区间平均场的加权平均。该一致性是 MeanFlow 可以多步组合、也可以一步使用的核心结构。

15 MeanFlow Identity 的微分推导

由

$$(t - r)u(x_t, r, t) = \int_r^t v(x_s, s) ds \quad (15.1)$$

对 t 求全导数。左边

$$\frac{d}{dt}[(t-r)u(x_t, r, t)] = u + (t-r)(\partial_t u + J_x u \dot{x}_t). \quad (15.2)$$

右边由微积分基本定理为

$$\frac{d}{dt} \int_r^t v(x_s, s) ds = v(x_t, t). \quad (15.3)$$

又 $\dot{x}_t = v(x_t, t)$, 所以

$$\boxed{v = u + (t-r)(\partial_t u + J_x u v).} \quad (15.4)$$

整理

$$u = v - (t-r) \frac{du}{dt}, \quad (15.5)$$

即论文的 MeanFlow Identity。这里 du/dt 必须是沿轨迹的全导数，不能只取显式时间偏导。

16 Jacobian–vector product 的实现

全导数中的

$$J_x u v \quad (16.1)$$

无需显式构造 $d \times d$ Jacobian。定义方向扰动

$$\varphi(\epsilon) = u(x + \epsilon v, r, t), \quad (16.2)$$

则

$$\left. \frac{d\varphi}{d\epsilon} \right|_0 = J_x u v. \quad (16.3)$$

自动微分的 JVP 计算复杂度与一次前向同阶，内存远小于存储完整 Jacobian。若用有限差分

$$J_x u v \approx \frac{u(x + \epsilon v) - u(x)}{\epsilon}, \quad (16.4)$$

会额外引入 $O(\epsilon)$ 截断误差与小 ϵ 的舍入误差。

17 训练目标的自洽固定点

设网络输出 u_θ , 由 Identity 构造目标

$$y_\theta = v - (t-r)(\partial_t u_\theta + J_x u_\theta v). \quad (17.1)$$

论文使用停止梯度

$$\mathcal{L} = \mathbb{E} \|u_\theta - \text{sg}(y_\theta)\|^2. \quad (17.2)$$

若损失为零，则

$$u_\theta = y_\theta \quad (17.3)$$

满足 MeanFlow Identity。停止梯度后的参数梯度为

$$\nabla_{\theta} \mathcal{L} = 2\mathbb{E} J_{\theta} u_{\theta}^{\top} (u_{\theta} - y_{\theta}), \quad (17.4)$$

不包含目标分支的二阶导。若不停止梯度，会多出

$$-2J_{\theta} y_{\theta}^{\top} (u_{\theta} - y_{\theta}), \quad (17.5)$$

可能导致网络通过同时移动预测与目标来缩小误差，而不是逼近固定点。

18 平方损失的条件期望最优解

实际训练中同一 (x_t, r, t) 可能对应多个随机路径目标 Y 。对固定输入，风险

$$R(a) = \mathbb{E} \|a - Y\|^2 \quad (18.1)$$

分解为

$$R(a) = \|a - \mathbb{E}Y\|^2 + \text{Var}(Y). \quad (18.2)$$

所以网络学到

$$u^*(x_t, r, t) = \mathbb{E}[Y \mid x_t, r, t]. \quad (18.3)$$

这意味着 MeanFlow 的一次映射是条件平均动力学；多模态路径若在同一点交叉，平方损失仍可能平均不同方向。

19 一步误差由平均场预测误差直接控制

真实关系

$$x_r = x_t - (t - r)u^*. \quad (19.1)$$

模型一步生成

$$\hat{x}_r = x_t - (t - r)u_{\theta}. \quad (19.2)$$

相减得精确误差公式

$$\boxed{\hat{x}_r - x_r = -(t - r)(u_{\theta} - u^*)}. \quad (19.3)$$

故

$$\mathbb{E} \|\hat{x}_r - x_r\|^2 = (t - r)^2 \mathbb{E} \|u_{\theta} - u^*\|^2. \quad (19.4)$$

长区间一步生成对场误差按区间长度平方放大；多步可缩短每段放大因子，但会累积多次模型误差。

20 多步组合误差递推

划分 $t_0 > t_1 > \dots > t_m$, 更新

$$\hat{x}_{t_{i+1}} = \hat{x}_{t_i} - (t_i - t_{i+1})u_\theta(\hat{x}_{t_i}, t_{i+1}, t_i). \quad (20.1)$$

若场对 x 的 Lipschitz 常数为 L , 单段预测误差上界为 ϵ_i , 则

$$\|e_{i+1}\| \leq [1 + L\Delta t_i] \|e_i\| + \Delta t_i \epsilon_i. \quad (20.2)$$

递推得到

$$\|e_m\| \leq e^{LT} \sum_i \Delta t_i \epsilon_i. \quad (20.3)$$

所以多步并不必然更准；它取决于短区间模型误差是否显著小于长区间误差。

21 CFG 对平均速度的线性作用

条件和无条件瞬时速度分别为 v_c, v_u , CFG

$$v_w = (1 + w)v_c - wv_u. \quad (21.1)$$

平均算子是线性的：

$$u_w = \frac{1}{t - r} \int_r^t v_w(s) ds \quad (21.2)$$

$$= (1 + w)u_c - wu_u. \quad (21.3)$$

因此可直接在平均速度上做同样线性组合。若条件/无条件路径状态不同，严格线性等式需要它们在同一参考轨迹上评估；实际网络近似会引入路径错配。

22 自适应权重的尺度不变性

若不同时间段目标方差差异大，可用

$$w(t) = \frac{1}{\mathbb{E} \|Y_t\|^2 + \epsilon} \quad (22.1)$$

归一化损失

$$\mathcal{L} = \mathbb{E} w(t) \|u_\theta - Y_t\|^2. \quad (22.2)$$

当所有目标缩放 $Y_t \mapsto aY_t$ 时，分子乘 a^2 ，权重近似除以 a^2 ，总梯度尺度更稳定。但权重改变了不同时间区域的统计重要性，不再对应原始均匀时间风险。

23 平均速度满足的传输型偏微分方程

固定区间起点 r , 定义

$$F(z, t) = (t - r)u(z, r, t). \quad (23.1)$$

沿概率流轨迹 $\dot{z} = v(z, t)$, MeanFlow 恒等式给出

$$\frac{d}{dt}F(z_t, t) = v(z_t, t). \quad (23.2)$$

展开全导数:

$$\partial_t F + (v \cdot \nabla_z)F = v. \quad (23.3)$$

因此 F 满足一阶线性输运 PDE

$$\boxed{\partial_t F + J_z F v = v, \quad F(z, r) = 0.} \quad (23.4)$$

沿特征线积分便恢复

$$F(z_t, t) = \int_r^t v(z_\tau, \tau) d\tau. \quad (23.5)$$

所以 MeanFlow Identity 也可理解为这条输运 PDE 的特征线解。

24 JVP 与有限差分的关系

对向量函数 $u : \mathbb{R}^d \rightarrow \mathbb{R}^d$, 方向 v 上的 Jacobian-vector product 定义为

$$J_u(z)v = \left. \frac{d}{d\epsilon} u(z + \epsilon v) \right|_{\epsilon=0}. \quad (24.1)$$

有限差分近似为

$$J_u(z)v \approx \frac{u(z + hv) - u(z)}{h}. \quad (24.2)$$

截断误差为 $O(h)$, 但 h 太小时还会放大浮点舍入误差。自动微分 JVP 直接传播一阶切向量, 不需要选择 h , 也无需显式形成 $d \times d$ Jacobian。若一次网络前向成本为 C_f , JVP 通常仍为 $O(C_f)$, 而显式 Jacobian 需要约 d 次反向或前向传播。

25 停止梯度目标与真正的二阶目标差异

令

$$y_\theta = v - (t - r)D_t u_\theta, \quad D_t u_\theta = J_z u_\theta v + \partial_t u_\theta. \quad (25.1)$$

不停止梯度的平方损失

$$\mathcal{L}_{\text{full}} = \frac{1}{2} \|u_\theta - y_\theta\|^2 \quad (25.2)$$

梯度为

$$\nabla_\theta \mathcal{L}_{\text{full}} = (J_\theta u_\theta - J_\theta y_\theta)^\top (u_\theta - y_\theta). \quad (25.3)$$

由于 y_θ 含 $J_z u_\theta$, $J_\theta y_\theta$ 含混合二阶导数

$$\frac{\partial^2 u_\theta}{\partial \theta \partial z}. \quad (25.4)$$

使用停止梯度后

$$\nabla_\theta \mathcal{L}_{\text{sg}} = J_\theta u_\theta^\top (u_\theta - \text{sg}(y_\theta)). \quad (25.5)$$

因此训练更像固定点迭代：当前网络产生目标，再把目标视为常量回归。它与直接最小化残差平方的梯度场不同，但共享相同的零残差固定点。

26 一维线性速度场的解析 MeanFlow

考虑

$$\dot{z} = az + b, \quad (26.1)$$

其中 a, b 为常数。若 $a \neq 0$, 从 t 到 τ 的解为

$$z_\tau = e^{a(\tau-t)} \left(z_t + \frac{b}{a} \right) - \frac{b}{a}. \quad (26.2)$$

从 r 到 t 的位移为

$$z_t - z_r = (1 - e^{-a(t-r)}) \left(z_t + \frac{b}{a} \right). \quad (26.3)$$

所以平均速度

$$u(z_t, r, t) = \frac{1 - e^{-a(t-r)}}{t - r} \left(z_t + \frac{b}{a} \right). \quad (26.4)$$

当 $t - r \rightarrow 0$, 利用

$$\lim_{h \rightarrow 0} \frac{1 - e^{-ah}}{h} = a, \quad (26.5)$$

得到

$$u \rightarrow az_t + b = v(z_t, t). \quad (26.6)$$

这个例子直接验证平均速度到瞬时速度的极限。

27 一步采样误差的精确表达

真实平均速度为 u^* , 网络误差为

$$e_u(z_t, r, t) = u_\theta - u^*. \quad (27.1)$$

一步更新

$$\hat{z}_r = z_t - (t - r)u_\theta \quad (27.2)$$

与真值

$$z_r = z_t - (t - r)u^* \quad (27.3)$$

之差恰好是

$$\widehat{z}_r - z_r = -(t - r)e_u. \quad (27.4)$$

因此一步位置误差没有额外的 Euler 截断项；所有误差都来自平均速度预测。对完整区间 $[0, 1]$ ，位置均方误差等于

$$\mathbb{E}\|\widehat{z}_0 - z_0\|^2 = \mathbb{E}\|e_u(z_1, 0, 1)\|^2. \quad (27.5)$$

28 多步误差递推与 Lipschitz 放大

第 i 段从 t_i 到 t_{i-1} ，记 $h_i = t_i - t_{i-1}$ 。网络更新

$$\widehat{z}_{i-1} = \widehat{z}_i - h_i u_\theta(\widehat{z}_i, t_{i-1}, t_i). \quad (28.1)$$

真实更新

$$z_{i-1} = z_i - h_i u^*(z_i, t_{i-1}, t_i). \quad (28.2)$$

若 u^* 对状态是 L_i -Lipschitz，且模型误差上界为 ε_i ，则

$$\|e_{i-1}\| \leq \|e_i\| + h_i L_i \|e_i\| + h_i \varepsilon_i \quad (28.3)$$

$$= (1 + h_i L_i) \|e_i\| + h_i \varepsilon_i. \quad (28.4)$$

展开得

$$\|e_0\| \leq \sum_{k=1}^K h_k \varepsilon_k \prod_{j=1}^{k-1} (1 + h_j L_j). \quad (28.5)$$

这说明多步并不自动优于一步：每段预测更容易，但状态误差会在后续段被放大。

29 条件速度监督的方差分解

训练样本给出的条件速度 V 对同一个 (z, t) 可能有随机性。平方损失最小值为不可约条件方差：

$$\min_f \mathbb{E}\|f(z, t) - V\|^2 = \mathbb{E} \text{Var}(V \mid z, t). \quad (29.1)$$

若路径交叉严重，同一点对应多种潜在速度，条件方差大，单个确定性网络难以拟合。平均速度把整个区间的速度积分后再回归，可能降低局部高频波动，但也可能把不同轨迹的位移多模态平均化。该方法成立依赖于所选概率流 ODE 具有良好的一一传输结构。

30 自适应幂损失的梯度尺度

令残差 $e = u_\theta - u_{\text{tgt}}$ ，损失

$$\ell_\gamma(e) = (\|e\|_2^2 + \epsilon)^\gamma. \quad (30.1)$$

对 e 的梯度

$$\nabla_e \ell_\gamma = 2\gamma (\|e\|^2 + \epsilon)^{\gamma-1} e. \quad (30.2)$$

当 $\gamma < 1$ 时，大残差的权重相对下降，具有鲁棒性；当 $\gamma > 1$ 时，大残差被进一步放大。 $\epsilon > 0$ 防止 $\gamma < 1$ 时在 $e = 0$ 附近导数奇异。

31 CFG 对平均速度的线性与非线性部分

若条件和无条件速度场分别为 v_c, v_u ，线性 CFG 场

$$v_w = (1 + w)v_c - wv_u. \quad (31.1)$$

在同一条给定轨迹上积分，平均速度也线性：

$$u_w = \frac{1}{t - r} \int_r^t v_w d\tau = (1 + w)u_c - wu_u. \quad (31.2)$$

但实际轨迹本身由 v_w 决定，因此 u_c 与 u_u 若分别沿各自轨迹计算，上式一般不再严格成立。网络直接学习 guided mean field 时，必须明确训练目标所沿的是哪一条轨迹。