

12_MUDDFormer 数学过程详解

多路动态稠密连接、深度注意力类比与复杂度推导

本文只处理真正需要推导的部分

本文聚焦动态跨层权重、Q/K/V/R 四路分解、深度方向注意力类比、参数量与 FLOPs 的逐步化简。全文按“公式从哪里来-每个符号是什么-中间步骤为何成立-维度和复杂度如何核对-论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1	从普通残差到跨层稠密连接	3
2	动态稠密聚合的张量公式	3
3	RMSNorm 与权重尺度	3
4	为什么可视为深度方向注意力	4
5	不使用 Softmax 的后果	4
6	Multiway: Q、K、V、R 四条深度路径	4
7	动态权重生成器的参数量	5
8	平均层近似与论文的 $\eta/6$ 公式	5
9	额外 FLOPs 的推导	6
10	梯度如何跨越深度	6
11	极限情形核对	7
12	容易误解的地方	7
13	最终公式路线图	7
14	动态稠密连接的统一矩阵写法	8

15 深度注意力与普通 token 注意力的对应关系	8
16 RMSNorm 对深度聚合尺度的作用	8
17 三层玩具例子的完整前向计算	9
18 梯度图是块下三角结构	9
19 谱范数稳定条件	9
20 参数量与 FLOPs 的逐项核对	10
21 平均层近似的误差	10

1 从普通残差到跨层稠密连接

标准 Transformer 第 i 层只接收上一层表示 $X_{i-1} \in \mathbb{R}^{T \times D}$ 。MUDDFormer 保留全部历史表示

$$X_{:i} = (X_0, X_1, \dots, X_i), \quad (1.1)$$

并在下一层输入前进行跨层加权。若使用静态权重 a_{ij} ，则

$$\bar{X}_i = \sum_{j=0}^i a_{ij} X_j. \quad (1.2)$$

普通残差连接是特例：只令 $a_{i,i} = 1$ ，其余为零；DenseFormer 则让 a_{ij} 成为与 token 无关的可学习标量。

2 动态稠密聚合的张量公式

MUDD 的权重依赖当前 token 表示。对第 i 层，权重生成器为

$$A_i(X_i) = \text{GELU}(\text{RMSNorm}(X_i)W_1)W_2 + a_i. \quad (2.1)$$

维度为

$$X_i \in \mathbb{R}^{T \times D}, \quad (2.2)$$

$$W_1 \in \mathbb{R}^{D \times K_i}, \quad (2.3)$$

$$W_2 \in \mathbb{R}^{K_i \times (i+1)}, \quad (2.4)$$

$$a_i \in \mathbb{R}^{i+1}, \quad (2.5)$$

$$A_i \in \mathbb{R}^{T \times (i+1)}. \quad (2.6)$$

第 t 个 token 对不同深度的权重是 $A_i[t, :]$ 。最终聚合

$$\boxed{\bar{X}_i[t, :] = \sum_{j=0}^i A_{ij}[t] X_j[t, :]}. \quad (2.7)$$

每个 token 可以选择不同深度来源，因此这是“位置相关、深度方向”的动态连接。

3 RMSNorm 与权重尺度

对向量 $x \in \mathbb{R}^D$ ，RMSNorm 为

$$\text{RMSNorm}(x) = g \odot \frac{x}{\sqrt{D^{-1} \sum_{d=1}^D x_d^2 + \epsilon}}. \quad (3.1)$$

若不归一化， X_i 随深度幅值增长会直接放大 W_1 输入，使连接权重分布随层数漂移。RMSNorm 只控制二阶尺度，不减去均值，因此比 LayerNorm 少一个中心化步骤。

4 为什么可视为深度方向注意力

普通自注意力在位置 t 的形式为

$$\text{Attn}(x_t, x_{:t}) = \text{softmax}(x_t W^Q (x_{:t} W^K)^\top) x_{:t} W^V. \quad (4.1)$$

MUDD 在深度方向的对应式为

$$\text{DA}(X_i[t], X_{:i}[t]) = (\text{GELU}(X_i[t] W_1) W_2 + a_i) X_{:i}[t]. \quad (4.2)$$

对应关系为：

横向注意力	深度动态连接	差异
查询 $x_t W^Q$	$\text{GELU}(X_i[t] W_1)$	查询由当前层 token 产生
键 $x_{:t} W^K$	参数矩阵 $W_2^\top$	键与输入无关
Softmax	GELU 后线性输出	权重不归一化
值投影 W^V	原始 $X_j[t]$	无额外值投影

所以它不是标准注意力的严格等价物，而是去掉 Softmax、输入依赖键和值投影后的深度线性注意力近似。

5 不使用 Softmax 的后果

若使用 Softmax，则

$$\sum_{j=0}^i A_{ij}[t] = 1, \quad (5.1)$$

输出是历史表示的凸组合。MUDD 不做归一化，所以权重可为负，且总和不受限：

$$\bar{X}_i[t] = \sum_j A_{ij}[t] X_j[t]. \quad (5.2)$$

这使模型可以执行差分、放大与抵消，但也可能导致尺度不稳定。论文通过 RMSNorm、静态先验 a_i 和残差结构控制该问题。

6 Multiway: Q、K、V、R 四条深度路径

普通 Transformer 同一个输入同时生成查询、键、值并参与残差。MUDDFormer 解耦四路：

$$(X_i^Q, X_i^K, X_i^V, X_i^R) = (\text{DA}_i^Q(X_{:i}), \text{DA}_i^K(X_{:i}), \text{DA}_i^V(X_{:i}), \text{DA}_i^R(X_{:i})). \quad (6.1)$$

随后

$$X'_A = \text{MHA}(\text{LN } X_i^Q, \text{LN } X_i^K, \text{LN } X_i^V) + X_i^R, \quad (6.2)$$

$$X_i = \text{FFN}(\text{LN } X'_A) + X'_A. \quad (6.3)$$

四路连接权重不必相同。查询可能偏好高层语义，键可能保留低层局部模式，值和残差又可选择不同历史层。

7 动态权重生成器的参数量

第 i 层四路连接需要输出 $4(i+1)$ 个权重，因此隐藏宽度记为

$$K_i = 4(i+1). \quad (7.1)$$

主要参数为

$$P_i = DK_i + K_i^2 + K_i, \quad (7.2)$$

分别来自 W_1, W_2, a_{i0} 。忽略偏置并对所有层求和：

$$P_{\text{extra}} = \sum_{i=1}^L (DK_i + K_i^2). \quad (7.3)$$

标准 Transformer 每层注意力约 $4D^2$ 、FFN 约 $8D^2$ ，总参数近似

$$P_{\text{base}} = 12LD^2. \quad (7.4)$$

所以

$$R_{\Delta P} = \frac{\sum_i (DK_i + K_i^2)}{12LD^2}. \quad (7.5)$$

8 平均层近似与论文的 $\eta/6$ 公式

取中间层平均隐藏维度

$$K \approx 2(L+3). \quad (8.1)$$

当 $D \gg K$ 时忽略 K^2 ：

$$R_{\Delta P} \approx \frac{DK}{12D^2} \quad (8.2)$$

$$= \frac{K}{12D} \quad (8.3)$$

$$= \frac{2(L+3)}{12D} \quad (8.4)$$

$$= \boxed{\frac{L+3}{6D}}. \quad (8.5)$$

定义深宽比

$$\eta = \frac{L+3}{D}, \quad (8.6)$$

则

$$R_{\Delta P} \approx \frac{\eta}{6}. \quad (8.7)$$

这说明额外参数主要由“深度相对宽度”决定。宽模型中 D 大，开销比例更小；极深窄模型中比例上升。

9 额外 FLOPs 的推导

第 i 层生成连接权重需要

$$2TDK_i + 2TK_i^2 \quad (9.1)$$

次乘加，跨层聚合再需要约

$$2TDK_i. \quad (9.2)$$

故

$$F_{\text{extra}} = \sum_i (4TDK_i + 2TK_i^2). \quad (9.3)$$

标准 Transformer 预训练 FLOPs 近似

$$F_{\text{base}} = 2LDT(12D + T). \quad (9.4)$$

平均层近似并忽略 K^2 :

$$R_{\Delta F} \approx \frac{4TDK}{2DT(12D + T)} \quad (9.5)$$

$$= \frac{2K}{12D + T} \quad (9.6)$$

$$= \frac{4(L+3)}{12D + T}. \quad (9.7)$$

令 $\rho = T/D$ ，则

$$\boxed{R_{\Delta F} \approx \frac{\eta}{3 + \rho/4}}. \quad (9.8)$$

序列越长，基础注意力成本增大，MUDD 的相对开销反而下降。

10 梯度如何跨越深度

若

$$\bar{X}_i = \sum_{j=0}^i A_{ij} X_j, \quad (10.1)$$

则对历史层 X_j 的梯度有两部分：

$$\frac{\partial \mathcal{L}}{\partial X_j} = A_{ij} \frac{\partial \mathcal{L}}{\partial \bar{X}_i} + \frac{\partial A_{ij}}{\partial X_j} \left(X_{:i} \frac{\partial \mathcal{L}}{\partial \bar{X}_i} \right). \quad (10.2)$$

因为 A_i 只由当前 X_i 生成, $j < i$ 时第二项通常为零, 历史层获得一条由 A_{ij} 加权的直接梯度路径。这是缓解深层残差瓶颈的核心机制。

11 极限情形核对

- 若 $A_{ii} = 1$ 、其余为零, 退化为普通逐层 Transformer;
- 若 A_{ij} 仅是静态参数, 退化为静态 DenseFormer;
- 若四路 Q, K, V, R 共享同一 A_i , 退化为单路动态稠密连接;
- 若再对 A_i 做 Softmax, 则输出变成深度方向凸组合, 表达能力与稳定性折中改变。

12 容易误解的地方

“深度注意力”只是结构类比

MUDD 的键是参数而不是输入, 权重没有 Softmax, 值没有独立投影, 因此不能把它当作标准自注意力直接套用概率解释。论文的参数/FLOPs 公式使用平均层与 $D \gg K$ 近似; 在极深窄模型上, K_i^2 项不可忽略。

13 最终公式路线图

阅读完成后应掌握

本文的数学主线已经被压缩为: 先明确随机变量或张量的定义, 再由概率分解、微分方程、优化目标或矩阵运算得到论文核心公式; 最后用维度、极限情形、参数量和复杂度进行反向核验。遇到论文中的简写式, 应先恢复被省略的条件变量、求和指标与归一化常数, 再讨论其算法含义。

14 动态稠密连接的统一矩阵写法

设 Transformer 有 L 层，隐藏状态矩阵

$$H = [h_0, h_1, \dots, h_{L-1}] \in \mathbb{R}^{d \times L}. \quad (14.1)$$

第 ℓ 层不再只读取 $h_{\ell-1}$ ，而是生成深度权重

$$a_\ell = g_\ell(h_{0:\ell-1}) \in \mathbb{R}^\ell, \quad (14.2)$$

并聚合

$$\tilde{h}_\ell = H_{<\ell} a_\ell = \sum_{j=0}^{\ell-1} a_{\ell j} h_j. \quad (14.3)$$

若 Q、K、V、残差分别使用独立权重，记为 $a_\ell^Q, a_\ell^K, a_\ell^V, a_\ell^R$ ，则

$$q_\ell = W_Q H_{<\ell} a_\ell^Q, \quad k_\ell = W_K H_{<\ell} a_\ell^K, \quad v_\ell = W_V H_{<\ell} a_\ell^V, \quad (14.4)$$

$$r_\ell = H_{<\ell} a_\ell^R. \quad (14.5)$$

这就是 Multiway 的精确线性代数含义：同一组历史层状态，经过四个不同的深度方向选择器。

15 深度注意力与普通 token 注意力的对应关系

普通注意力对 token 维做

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right) V. \quad (15.1)$$

动态稠密连接则把“键值集合”换成历史层：

$$a_{\ell j} = \frac{\exp(s_{\ell j})}{\sum_{k<\ell} \exp(s_{\ell k})}, \quad \tilde{h}_\ell = \sum_{j<\ell} a_{\ell j} h_j. \quad (15.2)$$

如果论文不使用 softmax，而直接输出实值权重，则它不再是凸组合，可能出现

$$\sum_j a_{\ell j} \neq 1, \quad a_{\ell j} < 0. \quad (15.3)$$

优点是能做差分和放大；缺点是范数没有天然上界。

16 RMSNorm 对深度聚合尺度的作用

RMSNorm 定义为

$$\text{RMSNorm}(h) = \gamma \odot \frac{h}{\sqrt{d^{-1} \|h\|_2^2 + \epsilon}}. \quad (16.1)$$

忽略 ϵ 和逐维 γ 时，归一化后

$$\frac{1}{d} \|\text{RMSNorm}(h)\|_2^2 \approx 1. \quad (16.2)$$

若历史层范数随深度增长，直接计算权重可能把“尺度大”误判为“更重要”。先归一化再生成 $a_{\ell j}$ ，可以让权重更多反映方向和内容，而不是绝对幅值。

17 三层玩具例子的完整前向计算

设标量隐藏状态 $h_0 = 1, h_1 = 2, h_2 = -1$ 。第 3 层的四组权重为

$$a^Q = (0.2, 0.5, 0.3), \quad a^K = (0.1, 0.1, 0.8), \quad (17.1)$$

$$a^V = (0.6, 0.2, 0.2), \quad a^R = (0.3, 0.4, 0.3). \quad (17.2)$$

则

$$\tilde{h}^Q = 0.2(1) + 0.5(2) + 0.3(-1) = 0.9, \quad (17.3)$$

$$\tilde{h}^K = 0.1(1) + 0.1(2) + 0.8(-1) = -0.5, \quad (17.4)$$

$$\tilde{h}^V = 0.6(1) + 0.2(2) + 0.2(-1) = 0.8, \quad (17.5)$$

$$r = 0.3(1) + 0.4(2) + 0.3(-1) = 0.8. \quad (17.6)$$

即使来自同一历史，Q/K/V/R 看到的有效深度表示也不同。这是比单一 DenseNet 式求和更高的自由度。

18 梯度图是块下三角结构

第 ℓ 层依赖所有 $j < \ell$ 的隐藏状态，因此总 Jacobian

$$J_{\ell j} = \frac{\partial h_\ell}{\partial h_j} \quad (18.1)$$

在层索引上是严格下三角加对角结构。若

$$h_\ell = F_\ell(\tilde{h}_\ell) + r_\ell, \quad (18.2)$$

则

$$\frac{\partial h_\ell}{\partial h_j} = J_F \left(a_{\ell j} I + \sum_k h_k \frac{\partial a_{\ell k}}{\partial h_j} \right) + a_{\ell j}^R I + \sum_k h_k \frac{\partial a_{\ell k}^R}{\partial h_j}. \quad (18.3)$$

第一类项是固定权重的直接路径，第二类项来自动态权重对历史状态的依赖。后者允许内容依赖的信用分配，但也引入额外二阶耦合。

19 谱范数稳定条件

若忽略权重生成器的导数，聚合矩阵为

$$\tilde{H} = HA. \quad (19.1)$$

则

$$\|\tilde{H}\|_F \leq \|H\|_F \|A\|_2. \quad (19.2)$$

若每列 a_ℓ 是非负且和为 1, $\|A\|_1 = 1$, 但 $\|A\|_2$ 仍可能随层数增长。无 softmax 时更需要显式正则, 例如

$$\lambda \sum_{\ell} \|a_\ell\|_2^2 \quad (19.3)$$

或门控缩放, 避免历史层线性组合无限放大。

20 参数量与 FLOPs 的逐项核对

若每层用一个两层 MLP 从 d 维状态生成长度 m 的深度权重, 瓶颈维度为 r , 参数量约

$$P_g = dr + rm + r + m. \quad (20.1)$$

四路权重若完全独立, 约为 $4P_g$; 若共享第一层, 仅分开输出头, 则

$$P_g^{\text{shared}} = dr + r + 4(rm + m). \quad (20.2)$$

聚合本身对每个 token、每个通道需要 m 次乘加, FLOPs 约

$$C_{\text{agg}} = 2BTdm \quad (20.3)$$

(乘和加各计一次)。当平均可见历史层数为 $\bar{m}$, 总额外开销近似

$$C_{\text{total}} \approx 4 \cdot 2BTdL\bar{m} + C_g. \quad (20.4)$$

因此论文报告的低百分比开销依赖于 $\bar{m}$ 的截断、权重生成器的小尺寸以及主干 FFN 的高基线 FLOPs。

21 平均层近似的误差

若用最近 m 层均值替代动态权重,

$$\bar{h} = \frac{1}{m} \sum_{j=1}^m h_j. \quad (21.1)$$

动态聚合与均值之差

$$\tilde{h} - \bar{h} = \sum_{j=1}^m \left(a_j - \frac{1}{m} \right) h_j. \quad (21.2)$$

由 Cauchy-Schwarz,

$$\|\tilde{h} - \bar{h}\|_2 \leq \left\| a - \frac{1}{m} \mathbf{1} \right\|_2 \left(\sum_j \|h_j\|_2^2 \right)^{1/2}. \quad (21.3)$$

当动态权重接近均匀分布时, 简单平均近似良好; 若权重尖锐地选择某个远层, 均值会严重稀释该层信息。