

18_Native Sparse Attention 数学过程详解

三支稀疏映射、块级选择与硬件算术强度

本文只处理真正需要推导的部分

本文推导压缩块数量、重要性映射、GQA 组共享 top-n、滑窗复杂度、门控梯度和算术强度。全文按“公式从哪里来-每个符号是什么-中间步骤为何成立-维度和复杂度如何核对-论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1 全注意力的标准形式与复杂度	3
2 NSA 的三支统一表达	3
3 压缩分支的块数与重叠率	3
4 压缩注意力分数如何复用为选择分数	4
5 为什么式中出现双重求和	4
6 GQA 组内共享选择	4
7 Top- n 块选择与稀疏键值大小	4
8 滑动窗口分支	5
9 总稀疏规模与理论复杂度	5
10 算术强度为什么决定真实速度	5
11 分支门控的梯度	6
12 注意力归一化为何在分支内完成	6
13 容易误解的效率结论	6
14 全注意力的 FLOPs 与显存	6
15 三支的统一稀疏集合	7

16 压缩块的重叠数量	7
17 从压缩分数到块选择	7
18 $\text{Top-}k$ 的梯度	8
19 GQA 下选择索引共享	8
20 滑动窗口的因果边界	8
21 门控混合的梯度	8
22 算术强度与 Roofline 分析	9
23 端到端复杂度条件	9
24 从全注意力到稀疏集合注意力	10
25 三支的集合并集表达	10
26 压缩块数量与重叠率	10
27 压缩分数到原始块选择分数	11
28 $\text{Top-}k$ 选择的不可导性	11
29 精确复杂度公式	11
30 一个 $N = 16$ 的集合构造例子	12
31 GQA 下共享选择索引的计算收益	12
32 门控混合的梯度	12
33 Roofline 模型与算术强度	13
34 因果边界的正确实现	13

1 全注意力的标准形式与复杂度

对当前查询 $q_t \in \mathbb{R}^{d_k}$ 和历史键值 $K_{:t}, V_{:t}$, 因果注意力为

$$o_t = \sum_{i=1}^t \pi_{t,i} v_i, \quad \pi_{t,i} = \frac{\exp(q_t^\top k_i / \sqrt{d_k})}{\sum_{j=1}^t \exp(q_t^\top k_j / \sqrt{d_k})}. \quad (1.1)$$

训练长度为 T 时, 分数矩阵大小 $T \times T$, 计算量 $O(T^2 d_k)$; 自回归解码第 t 步虽然只计算一个 query, 却要读取 t 个 KV, 内存带宽成本 $O(td_k)$ 。

2 NSA 的三分支统一表达

NSA 为每个查询动态构造三类紧凑 KV: 压缩分支 cmp、选择分支 slc、滑窗分支 win。记

$$(\tilde{K}_t^c, \tilde{V}_t^c) = f_c(q_t, K_{:t}, V_{:t}), \quad c \in \{\text{cmp}, \text{slc}, \text{win}\}. \quad (2.1)$$

每个分支单独计算注意力, 最终由门控融合:

$$o_t^* = \sum_c g_t^c \text{Attn}(q_t, \tilde{K}_t^c, \tilde{V}_t^c), \quad g_t^c \in [0, 1]. \quad (2.2)$$

若门由 sigmoid 独立生成, $\sum_c g_t^c$ 不一定等于 1; 若用 Softmax 则是凸组合。论文采用分支独立 KV, 避免局部模式梯度直接压制长程分支。

3 压缩分支的块数与重叠率

设压缩块长度为 l 、步长为 d 。第 i 个块覆盖

$$K_{id+1:id+l}. \quad (3.1)$$

可用块数

$$n_{\text{cmp}} = \left\lfloor \frac{t-l}{d} \right\rfloor + 1. \quad (3.2)$$

学习映射 ϕ 将每块压成一个键:

$$\tilde{k}_i^{\text{cmp}} = \phi(k_{id+1:id+l}). \quad (3.3)$$

若 $d < l$, 相邻块重叠 $l-d$ 个 token, 重叠率

$$r_{\text{overlap}} = 1 - \frac{d}{l}. \quad (3.4)$$

重叠减轻块边界信息割裂, 但增加压缩 token 数和计算。

4 压缩注意力分数如何复用为选择分数

先计算压缩分支概率

$$p_t^{\text{cmp}} = \text{softmax} \left(q_t^\top \tilde{K}_t^{\text{cmp}} / \sqrt{d_k} \right). \quad (4.1)$$

若选择块与压缩块完全一致，选择重要性直接取

$$p_t^{\text{slc}} = p_t^{\text{cmp}}. \quad (4.2)$$

若选择块长 $l' > l$ ，一个选择块与多个压缩块重叠。论文按空间覆盖关系累加：

$$p_t^{\text{slc}}[j] = \sum_{m=0}^{l'/d-1} \sum_{n=0}^{l/d-1} p_t^{\text{cmp}} \left[\frac{l'}{d}j - m - n \right]. \quad (4.3)$$

这相当于对压缩注意力做离散卷积，把细粒度块权重聚合到更大的选择块。

5 为什么式中出现双重求和

选择块 j 含 l'/d 个步长位置；每个 token 又可能落入 l/d 个重叠压缩块。双重索引 (m, n) 枚举“选择块内部位置”和“覆盖该位置的压缩块偏移”。若 $l' = l = d$ ，两个上限都为 0，公式退化为直接复制。

6 GQA 组内共享选择

GQA 中多个 query head 共享同一组 KV。若每个头独立 top- n ，实际需加载各头选择集合的并集，内存访问可能接近全量。NSA 先聚合组内重要性：

$$\bar{p}_t^{\text{slc}}[j] = \sum_{h=1}^{H_g} p_{t,h}^{\text{slc}}[j]. \quad (6.1)$$

再对 $\bar{p}$ 做统一 top- n 。这牺牲每头个性化选择，但保证所有头复用同一批连续 KV 块，减少 HBM 读取。

7 Top- n 块选择与稀疏键值大小

选择集合

$$I_t = \{i : \text{rank}(p_t^{\text{slc}}[i]) \leq n\}. \quad (7.1)$$

若每块长度 l' ，拼接后

$$\tilde{K}_t^{\text{slc}} = \text{Cat}\{K_{il'+1:(i+1)l'} : i \in I_t\}, \quad (7.2)$$

其 token 数为

$$N_{\text{slc}} = nl'. \quad (7.3)$$

选择是离散 top- n ，路径本身不可导，但分数来自压缩注意力；被选块中的值通过主损失获得梯度，压缩分支也独立训练，因此系统不依赖对排序算子求导。

8 滑动窗口分支

局部分支保留最近 w 个 token：

$$\tilde{K}_t^{\text{win}} = K_{t-w:t}, \quad \tilde{V}_t^{\text{win}} = V_{t-w:t}. \quad (8.1)$$

窗口复杂度 $O(wd_k)$ 。它显式承担局部语言模式，使压缩/选择分支不必通过竞争学习短程依赖。若没有独立窗口，长程分支容易把容量浪费在邻近 token 上。

9 总稀疏规模与理论复杂度

总 remapped KV 数

$$N_t = n_{\text{cmp}} + nl' + w. \quad (9.1)$$

只要 $N_t \ll t$ ，单 query 成本从 $O(td_k)$ 变为

$$O(N_t d_k). \quad (9.2)$$

训练全序列时近似

$$C_{\text{NSA}} = O(TN d_k), \quad (9.3)$$

若 N 与 T 无关则线性；若 $n_{\text{cmp}} \approx T/d$ ，压缩分支仍随 T 增长，但常数由压缩步长显著降低。

10 算术强度为什么决定真实速度

算术强度定义为

$$\mathcal{I} = \frac{\text{FLOPs}}{\text{bytes transferred}}. \quad (10.1)$$

若 GPU 峰值算力 F_{max} 、带宽 B_{max} ，临界强度

$$\mathcal{I}^* = \frac{F_{\text{max}}}{B_{\text{max}}}. \quad (10.2)$$

$\mathcal{I} < \mathcal{I}^*$ 时内存受限。随机 token 选择虽然减少 FLOPs，却会造成大量不连续读取，使 bytes transferred 不按比例下降。NSA 用连续块和 GQA 组共享选择，让稀疏计算可由 Tensor Core 和块加载高效执行。

11 分支门控的梯度

设分支输出 o_c 、最终输出 $o = \sum_c g_c o_c$ ，则

$$\frac{\partial \mathcal{L}}{\partial g_c} = \left\langle \frac{\partial \mathcal{L}}{\partial o}, o_c \right\rangle. \quad (11.1)$$

若 $g_c = \sigma(s_c)$,

$$\frac{\partial \mathcal{L}}{\partial s_c} = g_c(1 - g_c) \left\langle \frac{\partial \mathcal{L}}{\partial o}, o_c \right\rangle. \quad (11.2)$$

门接近 0 或 1 时 sigmoid 梯度变小，因此初始化应避免某一分支一开始完全关闭。

12 注意力归一化为何在分支内完成

NSA 不是把三类 KV 全部拼接后统一 Softmax，而是分支独立归一化再门控。若统一拼接，某分支 token 数多会改变 Softmax 分母并抢占概率质量。分支独立时

$$\sum_i \pi_i^c = 1 \quad \text{for each } c, \quad (12.1)$$

门 g_c 只比较分支输出，避免块数差异直接形成先验偏置。

13 容易误解的效率结论

稀疏率不是速度

理论 N_t/t 只描述参与注意力的 KV 比例。真实延迟还取决于块尺寸、GQA 共享、索引生成、SRAM/HBM 访问和反向算子。NSA 的核心并非单纯 top- n ，而是让选择粒度与 GPU 连续块计算对齐，并从训练开始就让模型适应这种稀疏结构。

14 全注意力的 FLOPs 与显存

输入长度 N ，头维度 d_h 。单头分数矩阵

$$S = QK^\top / \sqrt{d_h} \in \mathbb{R}^{N \times N}. \quad (14.1)$$

$QK^\top$ 需要约 $2N^2d_h$ FLOPs，AV 再需 $2N^2d_h$ ，所以单头核心成本

$$C_{\text{attn}} \approx 4N^2d_h. \quad (14.2)$$

训练时若保存 S 或 softmax 概率，显存为 $O(N^2)$ 。稀疏注意力的目标就是把每个 query 实际访问的键数从 N 降到 $S \ll N$ 。

15 三分支的统一稀疏集合

对位置 i ，NSA 的有效键集合可写为

$$\mathcal{K}_i = \mathcal{K}_i^{\text{cmp}} \cup \mathcal{K}_i^{\text{sel}} \cup \mathcal{K}_i^{\text{win}}. \quad (15.1)$$

若分支分别独立归一化，输出

$$o_i = \sum_{b \in \{c, s, w\}} g_{i,b} \sum_{j \in \mathcal{K}_i^b} \frac{e^{s_{ij}}}{\sum_{\ell \in \mathcal{K}_i^b} e^{s_{i\ell}}} v_j. \quad (15.2)$$

若改成在并集上一次 softmax，则重复键只出现一次且不同分支竞争同一归一化常数。两种形式并不等价；论文的门控分支结构允许“全局压缩、选择块、局部窗口”分别保留不同统计尺度。

16 压缩块的重叠数量

设压缩块大小为 l ，步长为 d ，因果序列长度为 N 。块数

$$M = \left\lfloor \frac{N-l}{d} \right\rfloor + 1. \quad (16.1)$$

相邻块重叠长度 $l-d$ ，重叠率

$$\rho = 1 - \frac{d}{l}. \quad (16.2)$$

若每块通过可学习池化映射为一个代表键值，压缩分支每个 query 访问 M 个代表，成本

$$O(NM d_h) \approx O\left(\frac{N^2}{d} d_h\right). \quad (16.3)$$

增大步长降低成本，但可能丢失块边界信息。

17 从压缩分数到块选择

设压缩键为 $\bar{k}_m$ ，压缩分数

$$\bar{s}_{im} = q_i^\top \bar{k}_m / \sqrt{d_h}. \quad (17.1)$$

选择 top- n 块索引

$$\mathcal{I}_i = \text{TopK}_n(\bar{s}_{i1:M}). \quad (17.2)$$

若原块长度为 l' ，选择分支最多访问

$$S_{\text{sel}} = n l' \quad (17.3)$$

个原始 token。总核心注意力成本近似

$$C \approx O[N(M + n l' + w) d_h], \quad (17.4)$$

其中 w 为滑动窗口宽度。

18 Top- k 的梯度

硬选择索引在排序边界不可微。固定当前 top- k 集合时，未选块梯度为零：

$$\frac{\partial \mathcal{L}}{\partial \bar{s}_{im}} = 0, \quad m \notin \mathcal{I}_i. \quad (18.1)$$

选中集合内部仍通过后续注意力和门控获得梯度。排序边界处使用分段常数子梯度，可能造成“早期没选中就长期学不到”的冷启动。压缩分支持续访问所有压缩块，能为选择分数提供较密集的训练信号，这是 NSA 可原生训练的重要原因。

19 GQA 下选择索引共享

设查询头数 H_q ，键值头数 H_{kv} ，每组

$$G = H_q / H_{kv} \quad (19.1)$$

个查询头共享一组 K, V 。若每个查询头独立 top- k ，索引生成与不规则访存成本乘 H_q ；若组内共享选择索引，则只需 H_{kv} 份索引。共享相当于用组聚合分数

$$\bar{s}_{gm} = \text{Agg}_{h \in g} \bar{s}_{hm} \quad (19.2)$$

选择块，牺牲头特异性换取硬件规则性。

20 滑动窗口的因果边界

对位置 i ，窗口集合

$$\mathcal{K}_i^{\text{win}} = \{j : \max(0, i - w + 1) \leq j \leq i\}. \quad (20.1)$$

其总边数

$$E_w = \sum_{i=0}^{N-1} \min(w, i + 1) \quad (20.2)$$

$$= \frac{w(w + 1)}{2} + (N - w)w = O(Nw). \quad (20.3)$$

局部窗口保证相邻 token 的高分辨率交互，即使全局块选择暂时不准确，模型仍保留稳定的局部语言建模路径。

21 门控混合的梯度

三支输出 o_b ，门控 logits a_b ，

$$g_b = \frac{e^{a_b}}{\sum_c e^{a_c}}, \quad o = \sum_b g_b o_b. \quad (21.1)$$

对门控 logit

$$\frac{\partial o}{\partial a_b} = g_b(o_b - o). \quad (21.2)$$

因此某分支只有在其输出相对当前混合更能降低损失时才增加权重。若一个分支早期占据 $g_b \approx 1$ ，其它分支梯度会变小，可用门控温度或均衡正则缓解。

22 算术强度与 Roofline 分析

稀疏注意力不只看 FLOPs。算术强度

$$I = \frac{\text{FLOPs}}{\text{bytes moved}} \quad (22.1)$$

决定是计算受限还是带宽受限。Roofline 上界

$$P \leq \min(P_{\text{peak}}, I \cdot BW). \quad (22.2)$$

随机 top- k 块若导致不连续读取，bytes moved 和索引开销可能很高， I 下降；即使理论 FLOPs 少，实际延迟也未必降低。NSA 将选择单位对齐到固定块并与 GQA 共享，目的就是提高连续访存和 kernel 利用率。

23 端到端复杂度条件

令压缩块数 $M = N/d$ ，选择 token 数 nl' ，窗口 w 。要使复杂度次二次，需要

$$M + nl' + w = o(N). \quad (23.1)$$

若 d, n, l', w 都为常数或缓慢增长，总成本为 $O(Nd_h(M + nl' + w))$ 。但压缩分支 $M = N/d$ 在固定步长 d 时仍是 $O(N^2/d)$ ；只有让压缩率随上下文长度增加，或用更强层级压缩，才可能获得严格渐近线性。

24 从全注意力到稀疏集合注意力

单头因果注意力第 i 个查询为

$$y_i = \sum_{j \leq i} \alpha_{ij} v_j, \quad \alpha_{ij} = \frac{\exp(q_i^\top k_j / \sqrt{d})}{\sum_{\ell \leq i} \exp(q_i^\top k_\ell / \sqrt{d})}. \quad (24.1)$$

稀疏注意力选择集合 $\mathcal{S}_i \subseteq \{1, \dots, i\}$:

$$y_i^{\text{sparse}} = \sum_{j \in \mathcal{S}_i} \frac{\exp(s_{ij})}{\sum_{\ell \in \mathcal{S}_i} \exp(s_{i\ell})} v_j. \quad (24.2)$$

注意分母也必须限制在 $\mathcal{S}_i$ ，不能先做全 softmax 再把未选项置零，否则权重和小于 1，且仍需计算全分母。

25 三分支的集合并集表达

NSA 可抽象为

$$\mathcal{S}_i = \mathcal{S}_i^{\text{cmp}} \cup \mathcal{S}_i^{\text{sel}} \cup \mathcal{S}_i^{\text{win}}. \quad (25.1)$$

压缩分支用少量块摘要覆盖长程历史；选择分支从原始块中选 top- k ；窗口分支保留最近 token。若三个分支分别归一化并用门控 g_b 混合，

$$y_i = \sum_{b \in \{c, s, w\}} g_{ib} y_i^{(b)}, \quad g_i = \text{softmax}(r_i). \quad (25.2)$$

这与在并集上做一次统一 softmax 不等价，因为各分支有各自的归一化常数。

26 压缩块数量与重叠率

序列长度 N ，块大小 l ，步长 s 。完整块数

$$B = \left\lfloor \frac{N-l}{s} \right\rfloor + 1. \quad (26.1)$$

相邻块重叠 token 数

$$o = l - s, \quad (26.2)$$

重叠比例

$$\rho = \frac{l-s}{l} = 1 - \frac{s}{l}. \quad (26.3)$$

当 $s = l$ 时不重叠； $s < l$ 提高边界连续性，但块数约变为 N/s ，压缩分支成本随 $1/s$ 增加。

27 压缩分数到原始块选择分数

设压缩块 b 覆盖 token 集 I_b , 压缩键

$$\bar{k}_b = \sum_{j \in I_b} w_{bj} k_j. \quad (27.1)$$

查询对压缩块分数

$$\bar{s}_{ib} = q_i^\top \bar{k}_b = \sum_{j \in I_b} w_{bj} q_i^\top k_j. \quad (27.2)$$

它是该块原始 token 分数的加权平均, 因此可作为块重要性代理。若一个原始块被多个压缩块覆盖, 可聚合

$$r_{ig} = \sum_{b: g \cap I_b \neq \emptyset} \omega_{gb} \bar{s}_{ib}. \quad (27.3)$$

双重求和来自“查询-压缩块”到“原始选择块”的映射, 而不是重复计算注意力。

28 Top- k 选择的不可导性

选择索引

$$\mathcal{I}_i = \text{TopK}(r_i, k) \quad (28.1)$$

在分数排序不变的小邻域内是常数, 边界处不连续。真实导数几乎处处为零。训练时常见做法是: 索引路径不传梯度, 但被选块内部的注意力分数仍正常求导; 或者用软 top- k 近似

$$m_g = \sigma \left(\frac{r_g - \tau}{T} \right) \quad (28.2)$$

再逐渐降低温度 T 。前者高效但选择器学习信号间接, 后者可导但计算更密集。

29 精确复杂度公式

全注意力每层主要乘法为

$$QK^\top : 2N^2d, \quad AV : 2N^2d, \quad (29.1)$$

合计约 $4N^2d$ FLOPs, 注意力矩阵显存 $O(N^2)$ 。

若窗口宽度 w , 选择 k 个原始块、每块 l 个 token, 压缩块数 $B \approx N/s$, 则每个查询可见元素数近似

$$M = B + kl + w. \quad (29.2)$$

总注意力 FLOPs

$$C_{\text{NSA}} \approx 4NdM. \quad (29.3)$$

要获得线性复杂度, 需要 $M = O(1)$ 或至少远小于 N 。若压缩块数 $B = N/s$ 随 N 线性增长且 s 固定, 压缩分支仍带来 $O(N^2/s)$; 实践中需使用层次压缩、较大步长或分组查询降低常数。

30 一个 $N = 16$ 的集合构造例子

设块大小 $l = 4$ 、步长 $s = 4$ ，共有 $B = 4$ 个压缩块。对查询 $i = 16$ ，窗口宽度 $w = 4$ ，选取 top-2 原始块。若 top 块为 $I_1 = \{1, 2, 3, 4\}$ 和 $I_3 = \{9, 10, 11, 12\}$ ，窗口为 $\{13, 14, 15, 16\}$ ，则

$$\mathcal{S}_{16}^{\text{sel}} \cup \mathcal{S}_{16}^{\text{win}} = \{1, 2, 3, 4, 9, 10, 11, 12, 13, 14, 15, 16\}. \quad (30.1)$$

再加 4 个压缩摘要，总计 16 个键值对象，但其中摘要与原 token 是不同对象。更长序列时，窗口和选择块保持固定，压缩摘要承担全局覆盖。

31 GQA 下共享选择索引的计算收益

设 H_q 个查询头、 H_{kv} 个 KV 头，每组包含

$$G = H_q / H_{kv} \quad (31.1)$$

个查询头。若组内共享 top- k 选择，选择器只需对每个 KV 组计算一次，选择分数成本从

$$O(H_q N B d) \quad (31.2)$$

降为

$$O(H_{kv} N B d). \quad (31.3)$$

代价是组内不同查询头不能选择不同块。共享是否合理取决于组内头的语义相似性。

32 门控混合的梯度

门控 logits 为 r_b ， $g_b = \exp(r_b) / \sum_c \exp(r_c)$ ，输出

$$y = \sum_b g_b y_b. \quad (32.1)$$

对 r_a ，

$$\frac{\partial y}{\partial r_a} = \sum_b \frac{\partial g_b}{\partial r_a} y_b = \sum_b g_b (\mathbf{1}[a = b] - g_a) y_b \quad (32.2)$$

$$= g_a (y_a - y). \quad (32.3)$$

因此当分支 a 的输出方向比当前混合输出更能降低损失时，其门控权重上升。若某分支早期 $g_a \approx 0$ ，梯度也接近零，可能形成分支饿死。

33 Roofline 模型与算术强度

算术强度定义为

$$I = \frac{\text{FLOPs}}{\text{从显存搬运的字节数}}. \quad (33.1)$$

硬件峰值计算吞吐 $P_{\max}$ 、显存带宽 $B_{\max}$ 下，性能上界

$$P \leq \min(P_{\max}, B_{\max}I). \quad (33.2)$$

稀疏注意力若索引零散，会导致 KV 读取不连续、重复搬运和低缓存命中，虽然理论 FLOPs 下降， I 也可能下降，最终仍受带宽限制。NSA 的“硬件对齐”核心就是让选择粒度为规则块，以便矩阵乘内核保持较高算术强度。

34 因果边界的正确实现

对第 i 个查询，任何块若包含未来 token $j > i$ ，必须截断。选择块 $I_b = [a_b, a_b + l - 1]$ 的有效集合为

$$I_b^{(i)} = I_b \cap \{1, \dots, i\}. \quad (34.1)$$

若只按块起点判断 $a_b \leq i$ 而不裁剪块尾，边界块会泄漏未来信息。训练和推理的稀疏掩码必须完全一致，否则训练可能利用推理时不可用的未来键值。