

# 23\_Scalable Diffusion Models with Transformers 数学过程详解

DDPM 后验、噪声目标、Patchify、AdaLN-Zero 与计算缩放

## 本文只处理真正需要推导的部分

本文从 Gaussian 前向链推导后验和噪声 MSE，核对 latent/patch 维度、Transformer FLOPs、AdaLN-Zero 恒等初始化与 CFG 的 Bayes 解释。全文按“公式从哪里来–每个符号是什么–中间步骤为何成立–维度和复杂度如何核对–论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

## 目录

|                                       |   |
|---------------------------------------|---|
| 1 前向扩散分布的闭式形式                         | 3 |
| 2 后验 $q(x_{t-1}   x_t, x_0)$ 与噪声预测    | 3 |
| 3 ELBO 为什么化为加权噪声均方误差                  | 4 |
| 4 Latent Diffusion 的维度和压缩             | 4 |
| 5 Patchify 的矩阵形式                      | 4 |
| 6 Transformer Block 的 FLOPs 近似        | 5 |
| 7 AdaLN-Zero 的完整公式                    | 5 |
| 8 Classifier-Free Guidance 的 Bayes 推导 | 5 |
| 9 为什么论文用 Gflops 而不是只用参数量              | 6 |
| 10 从逐步加噪到闭式边缘分布                       | 6 |
| 11 后验均值的配方推导                          | 6 |
| 12 用噪声预测重写后验均值                        | 7 |
| 13 ELBO 到加权噪声 MSE                     | 7 |

|                                      |    |
|--------------------------------------|----|
| 14 $x$ 、 $\epsilon$ 、 $v$ 三种参数化      | 8  |
| 15 Patchify 与 token 数                | 8  |
| 16 Transformer Block FLOPs           | 8  |
| 17 AdaLN-Zero 的恒等初始化                 | 9  |
| 18 CFG 的 Bayes 解释                    | 9  |
| 19 前向扩散闭式边缘分布的归纳证明                   | 10 |
| 20 后验 $q(x_{t-1}   x_t, x_0)$ 的配方法   | 10 |
| 21 用噪声预测重写后验均值                       | 11 |
| 22 ELBO 到加权噪声均方误差                    | 11 |
| 23 $x$ 、 $\epsilon$ 、 $v$ 三种参数化的线性变换 | 11 |
| 24 Latent Diffusion 的维度与信息压缩         | 12 |
| 25 Patchify 后 token 数和注意力成本          | 12 |
| 26 Transformer Block FLOPs 的逐项推导     | 13 |
| 27 AdaLN-Zero 的恒等初始化与梯度              | 13 |
| 28 CFG 的 Bayes 推导                    | 14 |
| 29 一个 DiT 尺度数值核对                     | 14 |

## 1 前向扩散分布的闭式形式

令  $\beta_t \in (0, 1)$ 、 $\alpha_t = 1 - \beta_t$ 、 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。逐步前向过程

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t}x_{t-1}, \beta_t I) \quad (1.1)$$

可递推为

$$\boxed{q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)}. \quad (1.2)$$

证明用归纳法。若

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}}x_0 + \sqrt{1 - \bar{\alpha}_{t-1}}\epsilon_{t-1}, \quad (1.3)$$

代入一步转移：

$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{\beta_t}\epsilon_t \quad (1.4)$$

$$= \sqrt{\alpha_t}x_0 + \sqrt{\alpha_t(1 - \bar{\alpha}_{t-1})}\epsilon_{t-1} + \sqrt{\beta_t}\epsilon_t. \quad (1.5)$$

后两项独立高斯，其方差和

$$\alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t = 1 - \bar{\alpha}_t. \quad (1.6)$$

因此可重参数化为

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I). \quad (1.7)$$

## 2 后验 $q(x_{t-1} | x_t, x_0)$ 与噪声预测

两个高斯因子相乘仍为高斯，完成平方得到

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(\tilde{\mu}_t, \tilde{\beta}_t I), \quad (2.1)$$

其中

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t, \quad (2.2)$$

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t. \quad (2.3)$$

由前向式解出

$$x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon}{\sqrt{\bar{\alpha}_t}}, \quad (2.4)$$

用  $\epsilon_\theta(x_t, t, c)$  替换真实噪声，即得到反向均值参数化

$$\mu_\theta(x_t, t, c) = \frac{1}{\sqrt{\alpha_t}} \left( x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t, c) \right). \quad (2.5)$$

### 3 ELBO 为什么化为加权噪声均方误差

反向模型

$$p_{\theta}(x_{0:T}) = p(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1} | x_t) \quad (3.1)$$

的负 ELBO 可分解为

$$\mathcal{L}_{\text{VLB}} = \mathcal{L}_0 + \sum_{t=2}^T D_{\text{KL}}(q(x_{t-1} | x_t, x_0) \| p_{\theta}(x_{t-1} | x_t)) + \mathcal{L}_T. \quad (3.2)$$

若两者协方差固定相同，Gaussian KL 只剩均值差：

$$D_{\text{KL}} = \frac{1}{2\sigma_t^2} \|\tilde{\mu}_t - \mu_{\theta}\|_2^2 + \text{const}. \quad (3.3)$$

把均值都写成噪声参数化，得到

$$D_{\text{KL}} = w_t \|\epsilon - \epsilon_{\theta}(x_t, t, c)\|_2^2 + \text{const}. \quad (3.4)$$

DiT 使用常见简化目标

$$\boxed{\mathcal{L}_{\text{simple}} = \mathbb{E}_{x_0, t, \epsilon} \text{orm} \epsilon_{\theta}(x_t, t, c) - \epsilon_2^2}, \quad (3.5)$$

并用完整变分项训练可学习协方差。

### 4 Latent Diffusion 的维度和压缩

VAE 编码器

$$z = E(x), \quad x \in \mathbb{R}^{H \times W \times 3}, \quad z \in \mathbb{R}^{I \times I \times C} \quad (4.1)$$

把空间分辨率降到  $I = H/f$ 。像素空间注意力 token 数约  $HW/p^2$ ，latent 空间变为

$$T = \left(\frac{I}{p}\right)^2 = \left(\frac{H}{fp}\right)^2. \quad (4.2)$$

因此注意力二次项的比值

$$\frac{T_{\text{latent}}^2}{T_{\text{pixel}}^2} = \frac{1}{f^4}. \quad (4.3)$$

若  $f = 8$ ，仅二次注意力项理论上缩小 4096 倍。

### 5 Patchify 的矩阵形式

每个  $p \times p \times C$  patch 展平为  $u_i \in \mathbb{R}^{p^2 C}$ ，线性投影

$$h_i = u_i W_e + b_e, \quad W_e \in \mathbb{R}^{p^2 C \times d}. \quad (5.1)$$

序列长度

$$\boxed{T = (I/p)^2}. \quad (5.2)$$

将  $p$  减半会让  $T$  变为  $4T$ 。参数  $W_e$  只线性随  $p^2$  改变，但 Transformer 主体参数不依赖  $T$ ；这解释了“参数量基本不变而 Gflops 激增”。

## 6 Transformer Block 的 FLOPs 近似

对长度  $T$ 、宽度  $d$ ：QKV 和输出投影约

$$C_{\text{proj}} \approx 4Td^2. \quad (6.1)$$

注意力分数与加权求和约

$$C_{\text{attn}} \approx 2T^2d. \quad (6.2)$$

扩展率  $r_m$  的 MLP 约

$$C_{\text{mlp}} \approx 2r_mTd^2. \quad (6.3)$$

单 Block

$$C_{\text{block}} \approx (4 + 2r_m)Td^2 + 2T^2d. \quad (6.4)$$

当  $d \gg T$  时线性投影/MLP 主导；当高分辨率使  $T$  很大时， $T^2d$  主导。

## 7 AdaLN-Zero 的完整公式

条件向量  $c = e_t + e_y$  经过 MLP 产生六组参数

$$(\gamma_1, \beta_1, \alpha_1, \gamma_2, \beta_2, \alpha_2) = g(c). \quad (7.1)$$

Block 可写为

$$h' = h + \alpha_1 \odot \text{MSA}((1 + \gamma_1) \odot \text{LN}(h) + \beta_1), \quad (7.2)$$

$$h'' = h' + \alpha_2 \odot \text{MLP}((1 + \gamma_2) \odot \text{LN}(h') + \beta_2). \quad (7.3)$$

若最后一层零初始化，则训练开始时

$$\gamma_i = \beta_i = \alpha_i = 0, \quad (7.4)$$

从而  $h'' = h$ 。整个深网络初始接近恒等映射，梯度先学习残差门  $\alpha_i$ ，再逐渐启用子层。

## 8 Classifier-Free Guidance 的 Bayes 推导

Bayes 公式

$$\log p(c | x) = \log p(x | c) - \log p(x) + \text{const} \quad (8.1)$$

给出

$$\nabla_x \log p(c | x) = s_c(x) - s_u(x), \quad (8.2)$$

其中  $s_c = \nabla_x \log p(x | c)$ 、 $s_u = \nabla_x \log p(x)$ 。引导 score

$$\hat{s} = s_u + s(s_c - s_u). \quad (8.3)$$

噪声预测与 score 满足

$$s_\theta(x_t, t) = -\frac{\epsilon_\theta(x_t, t)}{\sqrt{1 - \bar{\alpha}_t}}, \quad (8.4)$$

所以同样线性组合噪声：

$$\widehat{\epsilon} = \epsilon_u + s(\epsilon_c - \epsilon_u). \quad (8.5)$$

## 9 为什么论文用 Gflops 而不是只用参数量

参数量近似

$$P \approx N_b(4 + 2r_m)d^2 \quad (9.1)$$

与 token 数  $T$  无关；前向计算却含  $T$  和  $T^2$ 。两个模型可能参数量相同，但 patch size 不同导致

$$\frac{C(p/2)}{C(p)} \approx 4 \quad \text{到} \quad 16 \quad (9.2)$$

之间，具体取决于  $Td^2$  或  $T^2d$  哪项主导。因此 DiT 的缩放结论是“增加实际前向计算量稳定改善 FID”，而不是单独的参数缩放律。

## 10 从逐步加噪到闭式边缘分布

前向过程

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I). \quad (10.1)$$

重参数化

$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\epsilon_t. \quad (10.2)$$

递归代入两步

$$x_t = \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + \sqrt{\alpha_t(1 - \alpha_{t-1})}\epsilon_{t-1} + \sqrt{1 - \alpha_t}\epsilon_t. \quad (10.3)$$

独立高斯线性组合仍为高斯，方差为

$$\alpha_t(1 - \bar{\alpha}_{t-1}) + (1 - \alpha_t) = 1 - \bar{\alpha}_t. \quad (10.4)$$

故归纳得到

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I). \quad (10.5)$$

## 11 后验均值的配方推导

需要

$$q(x_{t-1} | x_t, x_0) \propto q(x_t | x_{t-1})q(x_{t-1} | x_0). \quad (11.1)$$

两项都是高斯。负对数中关于  $x_{t-1}$  的二次型为

$$\frac{\|x_t - \sqrt{\alpha_t}x_{t-1}\|^2}{2\beta_t} + \frac{\|x_{t-1} - \sqrt{\bar{\alpha}_{t-1}}x_0\|^2}{2(1 - \bar{\alpha}_{t-1})}. \quad (11.2)$$

收集二次和一次项，得到方差

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t \quad (11.3)$$

以及均值

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t. \quad (11.4)$$

## 12 用噪声预测重写后验均值

由闭式加噪

$$x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon}{\sqrt{\bar{\alpha}_t}}. \quad (12.1)$$

代入  $\tilde{\mu}_t$  并整理可得

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left( x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right). \quad (12.2)$$

因此模型只需预测  $\epsilon_\theta(x_t, t)$ ，反向均值取

$$\mu_\theta = \frac{1}{\sqrt{\alpha_t}} \left( x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta \right). \quad (12.3)$$

## 13 ELBO 到加权噪声 MSE

变分下界含逐步 KL

$$\mathcal{L}_t = \mathbb{E} D_{\text{KL}}(q(x_{t-1} | x_t, x_0) \| p_\theta(x_{t-1} | x_t)). \quad (13.1)$$

若两者方差固定相同  $\sigma_t^2 I$ ，KL 化为均值 MSE：

$$\mathcal{L}_t = \frac{1}{2\sigma_t^2} \mathbb{E} \|\tilde{\mu}_t - \mu_\theta\|^2. \quad (13.2)$$

两个均值之差

$$\tilde{\mu}_t - \mu_\theta = \frac{\beta_t}{\sqrt{\alpha_t(1 - \bar{\alpha}_t)}} (\epsilon_\theta - \epsilon). \quad (13.3)$$

故

$$\mathcal{L}_t = w_t \mathbb{E} \|\epsilon - \epsilon_\theta\|^2, \quad (13.4)$$

其中

$$w_t = \frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)}. \quad (13.5)$$

实践常去掉  $w_t$  使用 simple loss，这是优化重加权，而非与 ELBO 完全相同。

## 14 $x$ 、 $\epsilon$ 、 $v$ 三种参数化

定义

$$x_t = \alpha_t x_0 + \sigma_t \epsilon, \quad v_t = \alpha_t \epsilon - \sigma_t x_0, \quad (14.1)$$

且常取  $\alpha_t^2 + \sigma_t^2 = 1$ 。矩阵形式

$$\begin{bmatrix} x_t \\ v_t \end{bmatrix} = \begin{bmatrix} \alpha_t & \sigma_t \\ -\sigma_t & \alpha_t \end{bmatrix} \begin{bmatrix} x_0 \\ \epsilon \end{bmatrix}. \quad (14.2)$$

该矩阵正交，逆变换

$$x_0 = \alpha_t x_t - \sigma_t v_t, \quad \epsilon = \sigma_t x_t + \alpha_t v_t. \quad (14.3)$$

所以三种预测目标信息等价，但误差被时间相关系数缩放，训练条件数不同。

## 15 Patchify 与 token 数

潜变量大小  $H \times W \times C$ ，patch 边长  $p$ 。token 数

$$N = \frac{HW}{p^2}. \quad (15.1)$$

每个 patch 展平维度  $p^2 C$ ，线性嵌入

$$h_i = W_p x_i + b_p, \quad W_p \in \mathbb{R}^{d \times p^2 C}. \quad (15.2)$$

增大  $p$  使注意力  $O(N^2 d)$  按  $p^{-4}$  降低，但 patch 投影参数和局部信息压缩增加。DiT 的尺度比较必须同时报告 token 数、宽度和深度。

## 16 Transformer Block FLOPs

对长度  $N$ 、宽度  $d$ 、MLP 比例  $r$ ：

- $Q, K, V, O$  投影约  $8Nd^2$  FLOPs；
- 注意力矩阵和加权约  $4N^2 d$ ；
- 两层 MLP 约  $4rNd^2$ 。

总计

$$C_{\text{block}} \approx (8 + 4r)Nd^2 + 4N^2 d. \quad (16.1)$$

当  $d \gg N$  时线性层主导；当分辨率升高使  $N$  很大时注意力二次项主导。仅用参数量无法区分这两种计算区间。



## 17 AdaLN-Zero 的恒等初始化

条件向量  $c$  产生

$$(\gamma_1, \beta_1, \alpha_1, \gamma_2, \beta_2, \alpha_2) = M(c). \quad (17.1)$$

Block

$$h' = h + \alpha_1 \odot \text{Attn}((1 + \gamma_1) \odot \text{LN}(h) + \beta_1), \quad (17.2)$$

$$h'' = h' + \alpha_2 \odot \text{MLP}((1 + \gamma_2) \odot \text{LN}(h') + \beta_2). \quad (17.3)$$

若调制头末层零初始化，则所有调制量初始为 0，故

$$h'' = h. \quad (17.4)$$

对残差分支参数的初始梯度会乘  $\alpha_i = 0$ ，而调制门  $\alpha_i$  本身仍有梯度

$$\frac{\partial h'}{\partial \alpha_1} = \text{Attn}(\text{LN}(h)). \quad (17.5)$$

训练先打开门，再逐渐学习残差函数，提升深模型稳定性。

## 18 CFG 的 Bayes 解释

由 Bayes

$$\nabla_x \log p(c | x) = \nabla_x \log p(x | c) - \nabla_x \log p(x). \quad (18.1)$$

引导 score

$$s_w = s_u + (1 + w)(s_c - s_u) = (1 + w)s_c - ws_u. \quad (18.2)$$

等价于增加  $\log p(c | x)$  的权重。DiT 实现中通常在线性等价的噪声或速度输出上组合，但若方差也由网络预测，只应引导均值相关通道，不能盲目对所有输出一起外推。

## 19 前向扩散闭式边缘分布的归纳证明

离散扩散定义为

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I), \quad \beta_t = 1 - \alpha_t. \quad (19.1)$$

写成重参数化形式

$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\epsilon_t. \quad (19.2)$$

假设

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}}x_0 + \sqrt{1 - \bar{\alpha}_{t-1}}\bar{\epsilon}_{t-1}, \quad (19.3)$$

其中  $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$  代入:

$$x_t = \sqrt{\alpha_t \bar{\alpha}_{t-1}}x_0 + \sqrt{\alpha_t(1 - \bar{\alpha}_{t-1})}\bar{\epsilon}_{t-1} + \sqrt{1 - \alpha_t}\epsilon_t. \quad (19.4)$$

后两项是独立高斯, 合并方差

$$\alpha_t(1 - \bar{\alpha}_{t-1}) + (1 - \alpha_t) = 1 - \alpha_t \bar{\alpha}_{t-1} = 1 - \bar{\alpha}_t. \quad (19.5)$$

故

$$\boxed{q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)}. \quad (19.6)$$

因此训练时无需真的循环加噪  $t$  次, 只需一次采样

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon. \quad (19.7)$$

## 20 后验 $q(x_{t-1} | x_t, x_0)$ 的配方法

由 Bayes 公式

$$q(x_{t-1} | x_t, x_0) \propto q(x_t | x_{t-1})q(x_{t-1} | x_0). \quad (20.1)$$

两项都是高斯。忽略常数, 把指数中的二次项写为

$$-2 \log q = \frac{\|x_t - \sqrt{\alpha_t}x_{t-1}\|^2}{\beta_t} + \frac{\|x_{t-1} - \sqrt{\bar{\alpha}_{t-1}}x_0\|^2}{1 - \bar{\alpha}_{t-1}} + C. \quad (20.2)$$

收集  $x_{t-1}$  的二次系数:

$$A = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} = \frac{1 - \bar{\alpha}_t}{\beta_t(1 - \bar{\alpha}_{t-1})}. \quad (20.3)$$

因此后验方差

$$\tilde{\beta}_t = A^{-1} = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}\beta_t. \quad (20.4)$$

一次项给出后验均值

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t. \quad (20.5)$$

## 21 用噪声预测重写后验均值

由闭式加噪

$$x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon}{\sqrt{\bar{\alpha}_t}}. \quad (21.1)$$

代入  $\tilde{\mu}_t$  并化简:

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left( x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right). \quad (21.2)$$

用网络  $\epsilon_\theta(x_t, t)$  替代真实噪声, 反向模型均值为

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left( x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right). \quad (21.3)$$

这解释了噪声预测如何决定反向高斯的均值。

## 22 ELBO 到加权噪声均方误差

变分下界分解为

$$-\log p_\theta(x_0) \leq D_{\text{KL}}(q(x_T | x_0) \| p(x_T)) \quad (22.1)$$

$$+ \sum_{t=2}^T \mathbb{E}_q D_{\text{KL}}(q(x_{t-1} | x_t, x_0) \| p_\theta(x_{t-1} | x_t)) \quad (22.2)$$

$$- \mathbb{E}_q \log p_\theta(x_0 | x_1). \quad (22.3)$$

若  $p_\theta$  与真实后验使用相同方差  $\sigma_t^2 I$ , 中间 KL 只剩均值平方误差:

$$\mathcal{L}_t = \frac{1}{2\sigma_t^2} \|\tilde{\mu}_t - \mu_\theta\|^2. \quad (22.4)$$

把均值都写成噪声形式, 得到

$$\mathcal{L}_t = w_t \|\epsilon - \epsilon_\theta(x_t, t)\|^2, \quad (22.5)$$

其中

$$w_t = \frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)}. \quad (22.6)$$

实践中的 “simple loss” 把  $w_t$  设为常数 1, 改变了 ELBO 的时间加权, 但常常优化更稳定。

## 23 $x$ 、 $\epsilon$ 、 $v$ 三种参数化的线性变换

定义

$$x_t = \alpha x + \sigma \epsilon, \quad \alpha^2 + \sigma^2 = 1, \quad (23.1)$$

速度参数

$$v = \alpha \epsilon - \sigma x. \quad (23.2)$$

写成矩阵

$$\begin{pmatrix} x_t \\ v \end{pmatrix} = \begin{pmatrix} \alpha & \sigma \\ -\sigma & \alpha \end{pmatrix} \begin{pmatrix} x \\ \epsilon \end{pmatrix}. \quad (23.3)$$

该矩阵是正交旋转，逆为转置：

$$x = \alpha x_t - \sigma v, \quad \epsilon = \sigma x_t + \alpha v. \quad (23.4)$$

因此三种目标在函数表达能力无限时等价，但有限网络下，目标的条件数与误差放大不同。

## 24 Latent Diffusion 的维度与信息压缩

原图  $x \in \mathbb{R}^{H \times W \times 3}$  经 VAE 编码为

$$z \in \mathbb{R}^{H/f \times W/f \times c}. \quad (24.1)$$

标量数量压缩比

$$\rho = \frac{HW \cdot 3}{(H/f)(W/f)c} = \frac{3f^2}{c}. \quad (24.2)$$

例如  $f = 8, c = 4$ ,

$$\rho = \frac{3 \times 64}{4} = 48. \quad (24.3)$$

这并不表示信息无损压缩 48 倍，而是扩散主干处理的连续张量元素数量减少 48 倍；重建误差由 VAE 承担。

## 25 Patchify 后 token 数和注意力成本

潜变量空间大小  $H_z \times W_z$ ，patch 大小  $p$ ，token 数

$$N = \frac{H_z W_z}{p^2}. \quad (25.1)$$

每个 patch 展平维度  $p^2 c$ ，线性映射到宽度  $d$ ：

$$X_{\text{tok}} = X_{\text{patch}} W_E + b_E, \quad W_E \in \mathbb{R}^{p^2 c \times d}. \quad (25.2)$$

单层全注意力的二次项约

$$C_{\text{attn}} \approx 4N^2 d. \quad (25.3)$$

patch 从  $p$  增大到  $2p$  时， $N$  降为  $N/4$ ，二次注意力成本降为原来的  $1/16$ ；但每个 token 输入维度变为原来的 4 倍，局部细节更难建模。

## 26 Transformer Block FLOPs 的逐项推导

对宽度  $d$ 、token 数  $N$ 、MLP 扩张比  $m$ ：

- QKV 投影： $3 \times 2Nd^2 = 6Nd^2$ ；
- 输出投影： $2Nd^2$ ；
- 注意力矩阵与加权求和： $4N^2d$ ；
- MLP 两层： $2N(d \cdot md) + 2N(md \cdot d) = 4mNd^2$ 。

合计

$$C_{\text{block}} \approx (8 + 4m)Nd^2 + 4N^2d. \quad (26.1)$$

当  $m = 4$  时

$$C_{\text{block}} \approx 24Nd^2 + 4N^2d. \quad (26.2)$$

这说明在中等 token 数下，MLP 和线性投影可能比二次注意力更占 FLOPs。

## 27 AdaLN-Zero 的恒等初始化与梯度

设条件向量  $c$  生成六组参数

$$(\gamma_1, \beta_1, \alpha_1, \gamma_2, \beta_2, \alpha_2) = M(c). \quad (27.1)$$

一个 block 可写为

$$h' = h + \alpha_1 \odot \text{Attn}((1 + \gamma_1) \odot \text{LN}(h) + \beta_1), \quad (27.2)$$

$$h'' = h' + \alpha_2 \odot \text{MLP}((1 + \gamma_2) \odot \text{LN}(h') + \beta_2). \quad (27.3)$$

若初始化  $M$  的最后一层为零，则

$$\gamma = \beta = \alpha = 0, \quad (27.4)$$

初始网络严格满足

$$h'' = h. \quad (27.5)$$

但门控参数的梯度不为零：

$$\frac{\partial h'}{\partial \alpha_1} = \text{Attn}(\text{LN}(h)), \quad (27.6)$$

所以模型可从恒等映射平滑开始学习。

## 28 CFG 的 Bayes 推导

条件 score

$$s_c(x_t) = \nabla_{x_t} \log p(x_t | c), \quad (28.1)$$

无条件 score

$$s_u(x_t) = \nabla_{x_t} \log p(x_t). \quad (28.2)$$

Bayes 公式给出

$$\nabla \log p(c | x_t) = s_c(x_t) - s_u(x_t). \quad (28.3)$$

引导 score

$$s_w = s_u + (1 + w)(s_c - s_u) = (1 + w)s_c - ws_u. \quad (28.4)$$

它对应未归一化分布

$$p_w(x_t | c) \propto p(x_t | c)^{1+w} p(x_t)^{-w}. \quad (28.5)$$

因此更大  $w$  强调条件似然比，但可能导致样本多样性下降与 score 范数过大。

## 29 一个 DiT 尺度数值核对

假设 VAE 潜空间为  $32 \times 32 \times 4$ , patch  $p = 2$ , 则

$$N = (32/2)^2 = 256. \quad (29.1)$$

取  $d = 1152, m = 4$ , 单 block 近似 FLOPs

$$C \approx 24 \cdot 256 \cdot 1152^2 + 4 \cdot 256^2 \cdot 1152 \quad (29.2)$$

$$\approx 8.15 \times 10^9 + 0.30 \times 10^9 \approx 8.45 \text{ GFLOPs}. \quad (29.3)$$

可见该设置下线性层与 MLP 是主要开销，注意力二次项只占较小部分。这也解释了论文为何用总 Gflops 比较模型，而不是只观察 token 数。