

25_DeepSeek-R1 数学过程详解

GRPO、组内优势、Clip、KL 与规则奖励

本文只处理真正需要推导的部分

本文从策略梯度推导 GRPO 的组内标准化、重要性比率、分段 Clip、非负 KL 估计、规则奖励、稀疏成功概率和长思维链长度效应。全文按“公式从哪里来–每个符号是什么–中间步骤为何成立–维度和复杂度如何核对–论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1 语言模型策略与序列概率	3
2 GRPO 的组内优势标准化	3
3 重要性采样比率	3
4 Clipped Surrogate 的分段推导	4
5 论文采用的无偏 KL 近似	4
6 GRPO 与 PPO 的数学差异	4
7 规则奖励的分解	5
8 奖励稀疏性与组采样成功概率	5
9 长度归一化与长思维链	5
10 参考模型更新与 KL 信赖域	5
11 奖励黑客的数学表述	6
12 从期望奖励到策略梯度	6
13 序列概率与 token 级梯度	6
14 组内标准化的零和性质	7

15 组 baseline 的有限样本偏差	7
16 重要性采样比率	7
17 Clipped surrogate 的分段梯度	8
18 KL 正则的无偏非负估计	8
19 奖励稀疏与组内有效梯度概率	8
20 长度归一化的两种选择	9
21 KL 信赖域的二阶几何	9
22 从期望奖励到策略梯度	10
23 Baseline 不改变期望梯度	10
24 组内标准化的零和性质	10
25 组 baseline 的有限样本依赖	11
26 重要性采样比率的序列与 token 形式	11
27 Clipped Surrogate 的分段梯度	11
28 KL 正则估计量为何非负且无偏	12
29 GRPO 完整目标的数学结构	12
30 奖励稀疏时组内出现有效梯度的概率	12
31 一个四样本数值例子	13
32 KL 信赖域的二阶几何	13
33 奖励黑客的优化表达	13

1 语言模型策略与序列概率

对问题 q ，策略生成回答 $o = (a_1, \dots, a_T)$ ：

$$\pi_\theta(o | q) = \prod_{t=1}^T \pi_\theta(a_t | q, a_{<t}). \quad (1.1)$$

序列 log 概率

$$\log \pi_\theta(o | q) = \sum_{t=1}^T \log \pi_\theta(a_t | q, a_{<t}). \quad (1.2)$$

策略梯度恒等式来自

$$\nabla_\theta \pi_\theta(o) = \pi_\theta(o) \nabla_\theta \log \pi_\theta(o), \quad (1.3)$$

因此

$$\nabla_\theta \mathbb{E}_{o \sim \pi_\theta} R(o) = \mathbb{E}[R(o) \nabla_\theta \log \pi_\theta(o)]. \quad (1.4)$$

2 GRPO 的组内优势标准化

对同一问题采样 G 个输出 $o_1, \dots, o_G$ ，奖励 r_i 。组均值和标准差

$$\bar{r} = \frac{1}{G} \sum_{i=1}^G r_i, \quad s_r = \sqrt{\frac{1}{G} \sum_i (r_i - \bar{r})^2 + \varepsilon}. \quad (2.1)$$

优势

$$A_i = \frac{r_i - \bar{r}}{s_r}. \quad (2.2)$$

于是

$$\sum_i A_i \approx 0, \quad \frac{1}{G} \sum_i A_i^2 \approx 1. \quad (2.3)$$

这相当于用同一问题的其它回答作为 baseline，去掉“问题本身难度”造成的奖励平移和缩放。

3 重要性采样比率

回答由旧策略 $\pi_{\theta_{\text{old}}}$ 采样，但更新新策略 π_θ 。token 级比率

$$\rho_{i,t}(\theta) = \frac{\pi_\theta(a_{i,t} | q, a_{i,<t})}{\pi_{\theta_{\text{old}}}(a_{i,t} | q, a_{i,<t})}. \quad (3.1)$$

对旧分布取期望时

$$\mathbb{E}_{a \sim \pi_{\text{old}}} [\rho(a) f(a)] = \sum_a \pi_{\text{old}}(a) \frac{\pi_\theta(a)}{\pi_{\text{old}}(a)} f(a) = \mathbb{E}_{a \sim \pi_\theta} f(a). \quad (3.2)$$

这解释了为何可以复用 rollout 数据。

4 Clipped Surrogate 的分段推导

GRPO 核心项

$$\ell(\rho, A) = \min\{\rho A, \text{clip}(\rho, 1 - \epsilon, 1 + \epsilon)A\}. \quad (4.1)$$

当 $A > 0$ ，目标希望增大概率；但 $\rho > 1 + \epsilon$ 后

$$\ell = (1 + \epsilon)A \quad (4.2)$$

不再增长。若 $A < 0$ ，目标希望减小概率；当 $\rho < 1 - \epsilon$ 后

$$\ell = (1 - \epsilon)A \quad (4.3)$$

不再奖励更大幅度下降。因此 clip 只截断“沿优势方向过度更新”的部分。

完整 token 平均目标可写为

$$J_{\text{GRPO}} = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \ell(\rho_{i,t}, A_i) - \beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) \right]. \quad (4.4)$$

5 论文采用的无偏 KL 近似

令

$$r = \frac{\pi_{\text{ref}}(a)}{\pi_\theta(a)}. \quad (5.1)$$

论文使用单样本项

$$d(r) = r - \log r - 1. \quad (5.2)$$

因为对任意 $r > 0$ ， $\log r \leq r - 1$ ，所以

$$d(r) \geq 0. \quad (5.3)$$

对 $a \sim \pi_\theta$ 取期望：

$$\mathbb{E}_{\pi_\theta}[r - \log r - 1] = \sum_a \pi_{\text{ref}}(a) - 1 - \mathbb{E}_{\pi_\theta} \log \frac{\pi_{\text{ref}}(a)}{\pi_\theta(a)} \quad (5.4)$$

$$= D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}). \quad (5.5)$$

因此它是 forward KL 的单样本无偏估计，且逐样本非负。

6 GRPO 与 PPO 的数学差异

PPO 通常训练价值网络 $V_\phi(s)$ ，优势近似

$$A_t = \sum_{l \geq 0} (\gamma \lambda)^l \delta_{t+l}, \quad \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t). \quad (6.1)$$

GRPO 不训练 critic，而用组内奖励标准化作为整条回答的优势。省掉价值网络参数和前向计算，但优势只在问题组内相对比较；若 G 太小， $\bar{r}, s_r$ 方差较大。

7 规则奖励的分解

DeepSeek-R1-Zero 使用

$$R(o, q) = w_{\text{acc}} R_{\text{acc}} + w_{\text{fmt}} R_{\text{fmt}}. \quad (7.1)$$

确定性数学题可令

$$R_{\text{acc}} = \mathbf{1}[\text{Verify}(o, q) = 1]. \quad (7.2)$$

格式奖励可写为多个约束指标之和：

$$R_{\text{fmt}} = \sum_j \lambda_j \mathbf{1}[C_j(o) = 1]. \quad (7.3)$$

离散奖励没有可微梯度，但策略梯度通过 $R \nabla \log \pi$ 把信用分配给生成该回答的 token。

8 奖励稀疏性与组采样成功概率

若单个回答正确概率为 p ，一组 G 个样本至少有一个正确的概率

$$P_{\geq 1} = 1 - (1 - p)^G. \quad (8.1)$$

当 $p \ll 1$ 时

$$P_{\geq 1} \approx Gp. \quad (8.2)$$

增大组大小可提高发现正奖励轨迹的概率，但 rollout 成本线性增长。若一组全错且奖励完全相同，则 $A_i \approx 0$ ，该问题几乎不给策略更新信号。

9 长度归一化与长思维链

若不除以 $|o_i|$ ，序列目标是 token 项之和，长回答产生更大梯度范数。按长度平均

$$\frac{1}{|o|} \sum_t \ell_t \quad (9.1)$$

减少纯长度偏置，但奖励本身仍可能偏好更长推理。设正确率随长度 L 增长而计算代价为 cL ，理想效用为

$$U(L) = P_{\text{correct}}(L) - \lambda cL. \quad (9.2)$$

若训练奖励只包含正确性， $\lambda = 0$ ，策略会自然延长思考直到边际正确率收益趋近 0。

10 参考模型更新与 KL 信赖域

固定参考模型时目标近似在

$$D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) \lesssim \delta \quad (10.1)$$

的邻域优化。周期性把参考替换为最新策略，相当于移动信赖域中心。若每阶段 KL 很小，总分布变化仍可逐步累积；这兼顾稳定性与长期能力增长。

11 奖励黑客的数学表述

真实效用 $U(o)$ 不可直接观测，训练使用代理奖励 $R(o)$ 。若存在输出使

$$R(o) \gg R(o') \quad \text{但} \quad U(o) < U(o'), \quad (11.1)$$

优化 R 会偏离真实目标。规则验证器在可判定任务上缩小 $R - U$ 的差距；神经奖励模型存在分布外外推误差，策略会主动搜索其高误差区域，因此大规模 RL 更易暴露 reward hacking。

12 从期望奖励到策略梯度

目标

$$J(\theta) = \mathbb{E}_{o \sim \pi_\theta(\cdot|q)}[R(q, o)]. \quad (12.1)$$

展开离散求和并用 log-derivative trick：

$$\nabla_\theta J = \sum_o R(o) \nabla_\theta \pi_\theta(o) \quad (12.2)$$

$$= \sum_o \pi_\theta(o) R(o) \nabla_\theta \log \pi_\theta(o) \quad (12.3)$$

$$= \mathbb{E}[R(o) \nabla_\theta \log \pi_\theta(o)]. \quad (12.4)$$

减去与动作无关 baseline $b(q)$ 不改变期望，因为

$$\mathbb{E}[b \nabla \log \pi] = b \nabla \sum_o \pi(o) = 0. \quad (12.5)$$

GRPO 的组均值就是不训练 value network 的经验 baseline。

13 序列概率与 token 级梯度

回答 $o = (o_1, \dots, o_T)$ 的策略概率

$$\pi_\theta(o | q) = \prod_{t=1}^T \pi_\theta(o_t | q, o_{<t}). \quad (13.1)$$

因此

$$\nabla \log \pi_\theta(o | q) = \sum_{t=1}^T \nabla \log \pi_\theta(o_t | q, o_{<t}). \quad (13.2)$$

一个序列级奖励会同样乘到所有 token 梯度上，形成 credit assignment 粗糙的问题；长度越长，梯度项数量越多，若不归一化会天然偏向长回答。

14 组内标准化的零和性质

同一问题采样 G 个回答，奖励 R_i ,

$$\bar{R} = \frac{1}{G} \sum_i R_i, \quad s_R = \sqrt{\frac{1}{G} \sum_i (R_i - \bar{R})^2 + \epsilon}, \quad (14.1)$$

优势

$$A_i = \frac{R_i - \bar{R}}{s_R}. \quad (14.2)$$

立即有

$$\sum_i A_i = 0, \quad \frac{1}{G} \sum_i A_i^2 \approx 1. \quad (14.3)$$

它消除不同问题奖励尺度差异。若组内所有奖励相同，则 $A_i = 0$ ，该问题不提供梯度；因此纯 0/1 奖励下需要组内同时出现成功和失败样本。

15 组 baseline 的有限样本偏差

对样本 i ，baseline $\bar{R}$ 包含自身奖励。写成 leave-one-out baseline

$$\bar{R}_{-i} = \frac{1}{G-1} \sum_{j \neq i} R_j. \quad (15.1)$$

则

$$R_i - \bar{R} = \frac{G-1}{G} (R_i - \bar{R}_{-i}). \quad (15.2)$$

所以包含自身主要带来比例缩放 $(G-1)/G$ ；标准差归一化后关系更复杂，但大组时影响减小。组标准化还使样本之间梯度相关，不能把 G 个回答视为完全独立。

16 重要性采样比率

数据由旧策略 π_{old} 采样，希望估计新策略期望：

$$\mathbb{E}_{o \sim \pi_\theta} [f(o)] = \mathbb{E}_{o \sim \pi_{\text{old}}} \left[\frac{\pi_\theta(o)}{\pi_{\text{old}}(o)} f(o) \right]. \quad (16.1)$$

序列比率可能指数不稳定，因此 PPO/GRPO 使用 token 比率

$$r_t(\theta) = \frac{\pi_\theta(o_t | h_t)}{\pi_{\text{old}}(o_t | h_t)}. \quad (16.2)$$

若新旧策略差异大， r_t 方差高，剪裁限制单步更新。

17 Clipped surrogate 的分段梯度

单 token 目标

$$L_t = -\min(r_t A, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon)A). \quad (17.1)$$

当 $A > 0$ ，目标希望增大概率：

$$L_t = \begin{cases} -r_t A, & r_t \leq 1 + \epsilon, \\ -(1 + \epsilon)A, & r_t > 1 + \epsilon. \end{cases} \quad (17.2)$$

超过上界后梯度为零。当 $A < 0$ ，目标希望减小概率，下界起作用：

$$L_t = \begin{cases} -(1 - \epsilon)A, & r_t < 1 - \epsilon, \\ -r_t A, & r_t \geq 1 - \epsilon. \end{cases} \quad (17.3)$$

因此 clip 是不对称的“有利方向限幅”，不是简单把所有 r_t 截断后再乘优势。

18 KL 正则的无偏非负估计

令

$$r = \frac{\pi_{\text{ref}}(a | s)}{\pi_{\theta}(a | s)}, \quad a \sim \pi_{\theta}. \quad (18.1)$$

论文常用

$$k(r) = r - \log r - 1. \quad (18.2)$$

因为 $x - \log x - 1 \geq 0$ ，样本估计非负。取期望

$$\mathbb{E}_{\pi_{\theta}}[r] = \sum_a \pi_{\theta}(a) \frac{\pi_{\text{ref}}(a)}{\pi_{\theta}(a)} = 1, \quad (18.3)$$

$$\mathbb{E}_{\pi_{\theta}}[-\log r] = \mathbb{E}_{\pi_{\theta}} \log \frac{\pi_{\theta}}{\pi_{\text{ref}}} = D_{\text{KL}}(\pi_{\theta} \| \pi_{\text{ref}}). \quad (18.4)$$

故

$$\mathbb{E}[k(r)] = D_{\text{KL}}(\pi_{\theta} \| \pi_{\text{ref}}). \quad (18.5)$$

19 奖励稀疏与组内有效梯度概率

若单个回答成功概率为 p ，组大小 G ，全部失败概率

$$(1 - p)^G, \quad (19.1)$$

全部成功概率

$$p^G. \quad (19.2)$$

只有组内奖励有差异时标准化优势非零，所以有效组概率

$$P_{\text{useful}} = 1 - p^G - (1 - p)^G. \quad (19.3)$$

当 $p \ll 1$,

$$P_{\text{useful}} \approx Gp. \quad (19.4)$$

增大组大小可提高看到至少一个成功解的概率，但采样成本线性增加。

20 长度归一化的两种选择

序列目标若直接求和

$$L_i = \sum_{t=1}^{T_i} \ell_{it}, \quad (20.1)$$

长序列梯度规模近似随 T_i 增长。按长度平均

$$\bar{L}_i = \frac{1}{T_i} \sum_t \ell_{it} \quad (20.2)$$

使每个回答权重相近，但会降低关键长推理链中每个 token 的总贡献。一般化为

$$L_i^{(\alpha)} = T_i^{-\alpha} \sum_t \ell_{it}, \quad 0 \leq \alpha \leq 1. \quad (20.3)$$

α 控制长度偏置；这不是纯工程细节，而会改变最优策略对回答长度的偏好。

21 KL 信赖域的二阶几何

对小参数更新 $\Delta\theta$ ，策略 KL 二阶展开

$$D_{\text{KL}}(\pi_\theta \| \pi_{\theta+\Delta\theta}) \approx \frac{1}{2} \Delta\theta^\top F(\theta) \Delta\theta, \quad (21.1)$$

其中 F 是 Fisher 信息矩阵。KL 正则近似限制更新落在 Fisher 椭球

$$\Delta\theta^\top F \Delta\theta \leq 2\delta \quad (21.2)$$

内。clip 是逐样本比率的近似信赖域，KL 项是分布平均的几何约束，两者共同抑制策略突变。

22 从期望奖励到策略梯度

对问题 q ，策略生成回答序列 $o = (o_1, \dots, o_T)$ ，目标

$$J(\theta) = \mathbb{E}_{o \sim \pi_\theta(\cdot | q)} [R(q, o)]. \quad (22.1)$$

对参数求导：

$$\nabla_\theta J = \sum_o \nabla_\theta \pi_\theta(o | q) R(q, o) \quad (22.2)$$

$$= \sum_o \pi_\theta(o | q) \nabla_\theta \log \pi_\theta(o | q) R(q, o) \quad (22.3)$$

$$= \mathbb{E} [R(q, o) \nabla_\theta \log \pi_\theta(o | q)]. \quad (22.4)$$

自回归概率分解

$$\log \pi_\theta(o | q) = \sum_{t=1}^T \log \pi_\theta(o_t | q, o_{<t}), \quad (22.5)$$

因此

$$\nabla_\theta J = \mathbb{E} \left[\sum_t R(q, o) \nabla_\theta \log \pi_\theta(o_t | q, o_{<t}) \right]. \quad (22.6)$$

同一个序列奖励被分配给所有 token，这是序列级 RL 的基本信用分配形式。

23 Baseline 不改变期望梯度

对任意只依赖问题或状态、不依赖当前动作的 baseline b ,

$$\mathbb{E}_{a \sim \pi} [b \nabla_\theta \log \pi(a | s)] = b \sum_a \pi(a | s) \nabla_\theta \log \pi(a | s) \quad (23.1)$$

$$= b \sum_a \nabla_\theta \pi(a | s) \quad (23.2)$$

$$= b \nabla_\theta 1 = 0. \quad (23.3)$$

因此用优势 $A = R - b$ 替代 R 不改变期望，但可以降低方差。PPO 使用价值网络估计 baseline；GRPO 用同题组内奖励均值代替。

24 组内标准化的零和性质

同一个问题采样 G 个回答，奖励 $r_1, \dots, r_G$ 。定义

$$\bar{r} = \frac{1}{G} \sum_{i=1}^G r_i, \quad s_r = \sqrt{\frac{1}{G} \sum_i (r_i - \bar{r})^2 + \epsilon}, \quad (24.1)$$

$$A_i = \frac{r_i - \bar{r}}{s_r}. \quad (24.2)$$

则

$$\sum_i A_i = 0, \quad \frac{1}{G} \sum_i A_i^2 \approx 1. \quad (24.3)$$

这使每个问题的梯度尺度相对稳定, 不受奖励绝对量纲影响。但如果组内所有奖励相同, $A_i = 0$, 该问题不给策略梯度。

25 组 baseline 的有限样本依赖

严格地说, $\bar{r}$ 包含当前样本自己的奖励, 因此 A_i 与动作相关。若不使用 leave-one-out, baseline 不是完全独立于动作。写成

$$r_i - \bar{r} = \frac{G-1}{G} (r_i - \bar{r}_{-i}), \quad (25.1)$$

其中

$$\bar{r}_{-i} = \frac{1}{G-1} \sum_{j \neq i} r_j. \quad (25.2)$$

可见自包含均值只是 leave-one-out 优势乘以 $(G-1)/G$ 。当 G 较大时差异小; 小组时会缩小优势幅度。

26 重要性采样比率的序列与 token 形式

数据由旧策略 π_{old} 生成, 新策略期望需要重要性采样:

$$\mathbb{E}_{o \sim \pi_\theta} [f(o)] = \mathbb{E}_{o \sim \pi_{\text{old}}} \left[\frac{\pi_\theta(o)}{\pi_{\text{old}}(o)} f(o) \right]. \quad (26.1)$$

序列比率

$$\rho(o) = \prod_t \frac{\pi_\theta(o_t \mid o_{<t})}{\pi_{\text{old}}(o_t \mid o_{<t})} \quad (26.2)$$

容易随长度指数爆炸或消失, 所以 PPO/GRPO 使用 token 级比率

$$\rho_t = \exp(\log \pi_\theta(o_t \mid s_t) - \log \pi_{\text{old}}(o_t \mid s_t)). \quad (26.3)$$

27 Clipped Surrogate 的分段梯度

单 token 目标

$$\ell(\rho, A) = \min(\rho A, \text{clip}(\rho, 1 - \epsilon, 1 + \epsilon)A). \quad (27.1)$$

若 $A > 0$, 希望增大该动作概率:

$$\ell = \begin{cases} \rho A, & \rho \leq 1 + \epsilon, \\ (1 + \epsilon)A, & \rho > 1 + \epsilon. \end{cases} \quad (27.2)$$

超过上界后梯度为零。若 $A < 0$ ，希望减小概率：

$$\ell = \begin{cases} (1 - \epsilon)A, & \rho < 1 - \epsilon, \\ \rho A, & \rho \geq 1 - \epsilon. \end{cases} \quad (27.3)$$

低于下界后停止继续减小。clip 因此形成近似信赖域。

28 KL 正则估计量为何非负且无偏

令

$$r = \frac{\pi_{\text{ref}}(a \mid s)}{\pi_{\theta}(a \mid s)}. \quad (28.1)$$

论文常用

$$k(r) = r - \log r - 1. \quad (28.2)$$

因为 $\log r \leq r - 1$ ，所以 $k(r) \geq 0$ 。在 $a \sim \pi_{\theta}$ 下

$$\mathbb{E}_{\pi_{\theta}}[k(r)] = \sum_a \pi_{\theta}(a) \left(\frac{\pi_{\text{ref}}(a)}{\pi_{\theta}(a)} - \log \frac{\pi_{\text{ref}}(a)}{\pi_{\theta}(a)} - 1 \right) \quad (28.3)$$

$$= 1 - 1 + \sum_a \pi_{\theta}(a) \log \frac{\pi_{\theta}(a)}{\pi_{\text{ref}}(a)} \quad (28.4)$$

$$= D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}). \quad (28.5)$$

因此该估计逐样本非负，期望等于 forward KL。

29 GRPO 完整目标的数学结构

对第 i 个回答、第 t 个 token，目标可写为

$$J_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_t \left(\min(\rho_{it} A_i, \text{clip}(\rho_{it}, 1 - \epsilon, 1 + \epsilon) A_i) \right. \right. \quad (29.1)$$

$$\left. - \beta k_{it} \right) \right]. \quad (29.2)$$

第一项提升高于组均值的回答，降低低于组均值的回答；第二项限制偏离参考模型。 $1/|o_i|$ 是 token 平均，避免长回答仅因 token 多而贡献更大总梯度。

30 奖励稀疏时组内出现有效梯度的概率

假设每个回答独立以概率 p 获得正确奖励 1，否则 0。组内至少一个成功且至少一个失败，才会产生非零相对优势。概率为

$$P_{\text{useful}} = 1 - (1 - p)^G - p^G. \quad (30.1)$$

当 $p \ll 1$,

$$P_{\text{useful}} \approx Gp. \quad (30.2)$$

增加组大小提高看到成功样本的概率，但计算成本也线性增加。当 $p \approx 1$ 时，所有样本都成功的概率 p^G 上升，组内优势再次趋零。

31 一个四样本数值例子

奖励为

$$r = (1, 0.6, 0.2, 0.2). \quad (31.1)$$

均值

$$\bar{r} = 0.5. \quad (31.2)$$

方差

$$s_r^2 = \frac{1}{4}(0.5^2 + 0.1^2 + (-0.3)^2 + (-0.3)^2) = 0.11, \quad (31.3)$$

所以 $s_r \approx 0.3317$ ，优势约

$$A \approx (1.508, 0.302, -0.904, -0.904). \quad (31.4)$$

若第一个回答某 token 的比率 $\rho = 1.3$ ， $\epsilon = 0.2$ ，因为 $A > 0$ ，clip 后使用 $1.2A$ 而不是 $1.3A$ ；若第三个回答 $\rho = 0.7$ ，因为 $A < 0$ ，使用 $0.8A$ ，阻止概率下降过快。

32 KL 信赖域的二阶几何

当新旧参数差 $\delta\theta$ 很小时，

$$D_{\text{KL}}(\pi_{\theta+\delta} \parallel \pi_{\theta}) \approx \frac{1}{2} \delta\theta^{\top} F(\theta) \delta\theta, \quad (32.1)$$

其中 Fisher 信息矩阵

$$F(\theta) = \mathbb{E}_{a \sim \pi_{\theta}} [\nabla \log \pi_{\theta}(a) \nabla \log \pi_{\theta}(a)^{\top}]. \quad (32.2)$$

因此 KL 正则局部给参数更新施加 Fisher 度量下的二次惩罚，而不是普通欧氏 $\|\delta\theta\|^2$ 。

33 奖励黑客的优化表达

若真实目标为 $U(o)$ ，训练使用代理奖励 $R(o)$ ，策略实际求解

$$\max_{\pi} \mathbb{E}_{\pi} [R(o)] \quad (33.1)$$

而非

$$\max_{\pi} \mathbb{E}_{\pi} [U(o)]. \quad (33.2)$$

当存在回答使 R 很高但 U 很低，优化会集中到这些漏洞。加入多个规则奖励

$$R = \sum_k \lambda_k R_k \quad (33.3)$$

只能缓解已知漏洞，不能保证与真实效用完全一致。KL 约束限制搜索距离，但若漏洞就在参考策略附近，仍可能被利用。