

26_Why Language Models Hallucinate 数学过程详解

从密度估计到 IIV 分类、校准与 Missing Mass

本文只处理真正需要推导的部分

本文完整复原生成错误率到二分类误差的 reduction, 证明主下界, 推导交叉熵校准导数、singleton/missing-mass 关系与评测为何鼓励猜测。全文按“公式从哪里来-每个符号是什么-中间步骤为何成立-维度和复杂度如何核对-论文结论依赖哪些假设”的顺序展开; 不复述实验表格, 也不使用与论文无关的通用背景凑页数。

目录

1	生成错误率的概率定义	3
2	IIV 二分类问题的构造	3
3	无 Prompt 情形主界的逐步证明	3
4	含 Prompt 的一般化	4
5	交叉熵为何推动阈值校准	4
6	任意事实、Singleton Rate 与 Missing Mass	5
7	模型族不足的下界	5
8	纯多选问题的修正系数	6
9	为什么 0-1 评分鼓励猜测	6
10	Brier Score 与严格适当评分	6
11	缺失质量与 Good-Turing 估计	7
12	IIV 二分类规约	7
13	为什么训练误差低不消除下界	8
14	交叉熵的最优预测概率	8

15	0-1 评分为何鼓励阈值化猜测	8
16	多选题的随机猜测修正	9
17	Brier Score 的严格适当性	9
18	校准误差与准确率是不同量	9
19	模型族不足的不可约误差	9
20	有限样本置信区间	10
21	从“未见事实”到不可避免错误的概率模型	11
22	Missing Mass 的期望	11
23	Singleton Rate 与 Good-Turing 估计	11
24	IIV 二分类规约的核心逻辑	12
25	0-1 准确率为何鼓励阈值化猜测	12
26	交叉熵的严格适当性	12
27	Brier Score 的严格适当性	13
28	多选题随机猜测修正	13
29	校准误差与准确率的区别	13
30	有限样本误差率的置信区间	14
31	模型族不足带来的不可约误差	14
32	选择性回答的风险-覆盖率曲线	14

1 生成错误率的概率定义

样本空间 $\mathcal{X} = \mathcal{V} \cup \mathcal{E}$, $\mathcal{V}$ 为有效陈述, $\mathcal{E}$ 为错误陈述, 二者不交。真实训练分布满足 $p(\mathcal{E}) = 0$, 语言模型为 $\hat{p}$ 。生成错误率

$$\text{err} = \hat{p}(\mathcal{E}) = \Pr_{x \sim \hat{p}}[x \in \mathcal{E}]. \quad (1.1)$$

“训练数据全真”并不推出 $\hat{p}(\mathcal{E}) = 0$, 因为密度估计器必须在未见样本上分配概率质量。

2 IIV 二分类问题的构造

构造混合分布

$$D(x) = \begin{cases} p(x)/2, & x \in \mathcal{V}, \\ 1/(2|\mathcal{E}|), & x \in \mathcal{E}, \end{cases} \quad (2.1)$$

标签 $f(x) = +1$ 当且仅当 $x \in \mathcal{V}$ 。由语言模型概率构造阈值分类器

$$\hat{f}(x) = \begin{cases} +1, & \hat{p}(x) > 1/|\mathcal{E}|, \\ -1, & \hat{p}(x) \leq 1/|\mathcal{E}|. \end{cases} \quad (2.2)$$

IIV 误分类率

$$\text{err}_{\text{iiv}} = \Pr_{x \sim D}[\hat{f}(x) \neq f(x)]. \quad (2.3)$$

它把“会不会生成错误”转化成“能不能区分有效与错误候选”。

3 无 Prompt 情形主界的逐步证明

定义高概率集合

$$A = \{x : \hat{p}(x) > 1/|\mathcal{E}|\}, \quad B = A^c, \quad (3.1)$$

以及校准差

$$\delta = |\hat{p}(A) - p(A)|. \quad (3.2)$$

误分类分成假阳性与假阴性:

$$\text{err}_{\text{iiv}} = D(A \cap \mathcal{E}) + D(B \cap \mathcal{V}). \quad (3.3)$$

对 $x \in A \cap \mathcal{E}$, 有 $\hat{p}(x) > 1/|\mathcal{E}|$, 而 $D(x) = 1/(2|\mathcal{E}|)$, 所以逐点

$$\hat{p}(x) > 2D(x). \quad (3.4)$$

求和得

$$\hat{p}(A \cap \mathcal{E}) \geq 2D(A \cap \mathcal{E}). \quad (3.5)$$

对 $B \cap \mathcal{V}$, 每个有效样本概率至多 $1/|\mathcal{E}|$, 故

$$\hat{p}(B \cap \mathcal{V}) \leq \frac{|\mathcal{V}|}{|\mathcal{E}|}. \quad (3.6)$$

又因 $p(B \cap \mathcal{V}) = p(B)$, 并用

$$|p(B) - \hat{p}(B)| = \delta, \quad (3.7)$$

可整理为

$$\hat{p}(B \cap \mathcal{E}) \geq 2D(B \cap \mathcal{V}) - \frac{|\mathcal{V}|}{|\mathcal{E}|} - \delta. \quad (3.8)$$

两部分相加:

$$\boxed{\text{err} \geq 2 \text{err}_{\text{iiv}} - \frac{|\mathcal{V}|}{|\mathcal{E}|} - \delta}. \quad (3.9)$$

当错误候选远多于有效候选且模型近似校准时, 生成错误率至少约为 IIV 错误率的两倍。

4 含 Prompt 的一般化

Prompt $c \sim \mu$, 有效和错误回答集合分别为 V_c, E_c 。联合模型

$$\hat{p}(c, r) = \mu(c) \hat{p}(r | c). \quad (4.1)$$

令

$$K = \min_c |E_c|, \quad k = \max_c |V_c|, \quad (4.2)$$

阈值改为 $1/K$ 。完全相同的分解给出

$$\boxed{\text{err} \geq 2 \text{err}_{\text{iiv}} - \frac{k}{K} - \delta}. \quad (4.3)$$

生日问题中 k 很小而 K 很大, 因此校准项以外的修正很小。

5 交叉熵为何推动阈值校准

预训练目标

$$\mathcal{L}(\hat{p}) = \mathbb{E}_{x \sim p}[-\log \hat{p}(x)]. \quad (5.1)$$

把集合 A 内概率乘以 s 再归一化:

$$\hat{p}_s(x) = \frac{s^{\mathbf{1}_{[x \in A]}} \hat{p}(x)}{Z(s)}, \quad Z(s) = s \hat{p}(A) + \hat{p}(B). \quad (5.2)$$

损失

$$\mathcal{L}(s) = -p(A) \log s + \log Z(s) + \text{const}. \quad (5.3)$$

求导并令 $s = 1$:

$$\mathcal{L}'(1) = -p(A) + \frac{\hat{p}(A)}{\hat{p}(A) + \hat{p}(B)} \quad (5.4)$$

$$= \hat{p}(A) - p(A). \quad (5.5)$$

所以

$$|\mathcal{L}'(1)| = \delta. \quad (5.6)$$

若训练达到局部极小且模型族能实现这种简单重标定，则导数应接近 0，解释了 base model 的阈值校准。

6 任意事实、Singleton Rate 与 Missing Mass

训练集中只出现一次且非 IDK 的 prompt 集合为 S ，singleton rate

$$\text{sr} = \frac{|S|}{N}. \quad (6.1)$$

Good-Turing 思想指出，单例比例估计未见事件的总概率质量

$$M_0 = \sum_{c: N_c=0} \mu(c). \quad (6.2)$$

直观原因是：一个稀有 prompt 若当前只出现一次，与未来出现一个此前未见 prompt 的概率由同一长尾质量控制。论文在集中不等式下得到高概率界，主导项为

$$\text{err} \gtrsim \text{sr} - \frac{2}{\min_c |E_c|} - O\left(\frac{\log N}{\sqrt{N}}\right) - \delta. \quad (6.3)$$

因此 singleton rate 不是经验相关性，而是不可学习事实质量的可观测估计量。

7 模型族不足的下界

阈值分类器族

$$\mathcal{G} = \{g_{\theta,t} : g_{\theta,t}(c, r) = \mathbf{1}[\hat{p}_{\theta}(r | c) > t]\} \quad (7.1)$$

的不可约误差

$$\text{opt}(\mathcal{G}) = \min_{g \in \mathcal{G}} \Pr_D[g(x) \neq f(x)]. \quad (7.2)$$

代入主界：

$$\text{err} \geq 2 \text{opt}(\mathcal{G}) - \frac{k}{K} - \delta. \quad (7.3)$$

这把架构表达能力不足、上下文窗口不足、优化未拟合等熟悉的分类错误因素直接映射到生成幻觉。

8 纯多选问题的修正系数

每个 prompt 只有一个正确选项，总选项数 C ，错误数 $C - 1$ 。论文给出

$$\boxed{\text{err} \geq 2 \left(1 - \frac{1}{C}\right) \text{opt}(\mathcal{G})}. \quad (8.1)$$

二选一时系数为 1； $C \rightarrow \infty$ 时趋近 2。它说明“生成错误约为二分类辨别错误两倍”在大量错误候选时最紧。

9 为什么 0-1 评分鼓励猜测

模型对正确答案的主观概率为 p 。回答的期望 0-1 得分为

$$U_{\text{answer}} = p, \quad (9.1)$$

若 IDK 得 0，则

$$U_{\text{IDK}} = 0. \quad (9.2)$$

只要 $p > 0$ ，猜测严格优于弃权。若错误惩罚为 $-\lambda$ 、正确为 1，回答效用

$$U = p - (1 - p)\lambda = (1 + \lambda)p - \lambda. \quad (9.3)$$

理性回答阈值

$$p > \frac{\lambda}{1 + \lambda}. \quad (9.4)$$

通过设置正的错误代价或给校准弃权部分分数，评测才会奖励表达不确定性。

10 Brier Score 与严格适当评分

若模型报告置信度 q ，真实标签 $y \in \{0, 1\}$ ，Brier 损失

$$\mathcal{L}_B = (q - y)^2. \quad (10.1)$$

给定真实正确概率 p ，期望损失

$$\mathbb{E}\mathcal{L}_B = p(q - 1)^2 + (1 - p)q^2 = (q - p)^2 + p(1 - p). \quad (10.2)$$

唯一最优报告是 $q = p$ 。与准确率不同，严格适当评分不会鼓励把低置信度答案伪装成确定答案。

11 缺失质量与 Good–Turing 估计

真实事实分布为 $p = (p_i)$ ，训练样本计数 N_i 。未在训练集中出现的事实总概率

$$M_0 = \sum_i p_i \mathbf{1}(N_i = 0) \quad (11.1)$$

称 missing mass。单例数

$$N_1 = \sum_i \mathbf{1}(N_i = 1). \quad (11.2)$$

对样本量 n ,

$$\mathbb{E} \frac{N_1}{n} = \sum_i \frac{1}{n} \Pr(N_i = 1) \quad (11.3)$$

$$= \sum_i p_i (1 - p_i)^{n-1}. \quad (11.4)$$

而

$$\mathbb{E} M_0 = \sum_i p_i (1 - p_i)^n. \quad (11.5)$$

两者只差一个 $(1 - p_i)$ 因子；稀有事实 $p_i \ll 1$ 时近似相等，得到 Good–Turing 估计

$$\boxed{M_0 \approx N_1/n.} \quad (11.6)$$

这把“训练中只见过一次的事实比例”与测试时未见事实概率联系起来。

12 IIV 二分类规约

对一个事实 f ，构造两个字符串：正确陈述 $s^+(f)$ 与错误陈述 $s^-(f)$ 。给定训练集 D ，算法需判断某陈述是否属于真实集合。定义判别器

$$h_D(s) \in \{0, 1\}. \quad (12.1)$$

若模型在未见事实上无法区分正负陈述，则对对称先验

$$\Pr(h_D(s) = Y \mid f \text{ unseen}) \leq \frac{1}{2}. \quad (12.2)$$

于是总错误率至少包含

$$\text{Err} \geq \frac{1}{2} \Pr(f \text{ unseen}) = \frac{1}{2} M_0. \quad (12.3)$$

更精细的定理会加入 prompt 信息和模型族可辨识性系数，但核心下界来自 unseen mass。

13 为什么训练误差低不消除下界

经验风险

$$\hat{R}_D(h) = \frac{1}{n} \sum_{j=1}^n \mathbf{1}[h(s_j) \neq y_j] \quad (13.1)$$

只约束训练中出现的事实。若两个世界分布 P, Q 在所有已观察样本上相同，但对未见事实真值相反，则任何算法基于 D 产生相同 h_D ，至少在一个世界中出错。Le Cam 两点法给出

$$\inf_h \sup_{R \in \{P, Q\}} \Pr(h \neq Y) \geq \frac{1}{2}(1 - \text{TV}(P_D, Q_D)). \quad (13.2)$$

若训练分布不可区分，TV 小，下界接近 $1/2$ 。

14 交叉熵的最优预测概率

对二元真值 $Y \sim \text{Bernoulli}(\eta)$ ，预测概率 q 的期望 log loss

$$L(q) = -\eta \log q - (1 - \eta) \log(1 - q). \quad (14.1)$$

求导

$$L'(q) = -\frac{\eta}{q} + \frac{1 - \eta}{1 - q}, \quad (14.2)$$

令零得 $q = \eta$ ；二阶导

$$L''(q) = \frac{\eta}{q^2} + \frac{1 - \eta}{(1 - q)^2} > 0. \quad (14.3)$$

所以交叉熵是严格适当评分，理论上鼓励输出真实置信度，而不是一律猜测。

15 0-1 评分为何鼓励阈值化猜测

若回答正确得 1 分，错误和拒答都得 0 分，预测某答案正确概率为 $q > 0$ ，猜测期望得分

$$\mathbb{E}S_{\text{guess}} = q > 0, \quad (15.1)$$

拒答得分为 0，所以任何正概率猜测都优于拒答。若错误惩罚为 $-\lambda$ ，则

$$\mathbb{E}S = q - (1 - q)\lambda = (1 + \lambda)q - \lambda. \quad (15.2)$$

只有当

$$q > \frac{\lambda}{1 + \lambda} \quad (15.3)$$

才应回答。评分规则通过阈值直接决定模型是否倾向“有把握再说”。

16 多选题的随机猜测修正

K 选一题随机猜中概率 $1/K$ 。若模型准确率为 a ，去除随机基线的 normalized accuracy

$$a_{\text{norm}} = \frac{a - 1/K}{1 - 1/K}. \quad (16.1)$$

当 $a = 1/K$ 时为 0，完美时为 1。若未见事实上模型等价随机猜测，则原始错误率

$$1 - 1/K \quad (16.2)$$

随选项数改变，因此理论下界需要乘相应修正系数，不能把二分类的 $1/2$ 直接照搬。

17 Brier Score 的严格适当性

二元 Brier loss

$$L_B(q, Y) = (q - Y)^2. \quad (17.1)$$

期望

$$\mathbb{E}L_B = \eta(q - 1)^2 + (1 - \eta)q^2 \quad (17.2)$$

$$= (q - \eta)^2 + \eta(1 - \eta). \quad (17.3)$$

第二项不可约，唯一最优 $q = \eta$ 。与 log loss 相比，Brier 对极端错误概率的惩罚有限；log loss 在 $q \rightarrow 0$ 且 $Y = 1$ 时发散，更强烈抑制过度自信。

18 校准误差与准确率是不同量

把预测概率分箱 B_m ，经验校准误差

$$\text{ECE} = \sum_m \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|. \quad (18.1)$$

一个模型可以准确率高但 ECE 大，例如所有预测置信度 0.99 而实际正确率 0.8；也可以准确率低但完美校准。论文讨论 hallucination 时，事实错误率、置信度校准、拒答策略必须分开评估。

19 模型族不足的不可约误差

即使事实在训练中出现，若模型类 $\mathcal{H}$ 无法表达真规则，仍有 approximation error

$$R_{\text{app}} = \inf_{h \in \mathcal{H}} R(h) - R^* > 0. \quad (19.1)$$

总误差可概念分解为

$$R(\hat{h}) - R^* = R_{\text{app}} + R_{\text{est}} + R_{\text{opt}}. \quad (19.2)$$

missing-mass 下界主要描述估计信息缺失；模型容量、优化失败和分布漂移会在其上继续增加错误。

20 有限样本置信区间

测试集中观察 m 次 hallucination, 总样本 n , 估计率 $\hat{p} = m/n$ 。正态近似标准误

$$\text{SE} = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}. \quad (20.1)$$

小概率或小样本时应使用 Wilson 区间:

$$\frac{\hat{p} + z^2/(2n) \pm z\sqrt{\hat{p}(1 - \hat{p})/n + z^2/(4n^2)}}{1 + z^2/n}. \quad (20.2)$$

否则只比较点估计可能把抽样噪声误认为方法差异。

21 从“未见事实”到不可避免错误的概率模型

设事实空间 $\mathcal{F}$ 上真实分布为 P ，训练集包含 n 个独立事实样本 $F_1, \dots, F_n$ 。训练后仍未出现的事实集合

$$U_n = \{f \in \mathcal{F} : N_f = 0\}, \quad (21.1)$$

其中 $N_f = \sum_i \mathbf{1}(F_i = f)$ 。未见质量

$$M_n = P(U_n) = \sum_f p_f \mathbf{1}(N_f = 0). \quad (21.2)$$

即使模型把所有已见事实记住，对 U_n 中事实仍缺乏监督。若某类问答要求在未见事实上猜测，错误率至少与 M_n 同阶。

22 Missing Mass 的期望

对固定事实 f ，未在 n 个样本中出现的概率为

$$\Pr(N_f = 0) = (1 - p_f)^n. \quad (22.1)$$

因此

$$\mathbb{E}[M_n] = \sum_f p_f (1 - p_f)^n. \quad (22.2)$$

稀有事实 $p_f \ll 1/n$ 时， $(1 - p_f)^n \approx e^{-np_f} \approx 1$ ，几乎必然未见；高频事实则迅速被覆盖。这给出“长尾知识更易幻觉”的直接统计原因。

23 Singleton Rate 与 Good-Turing 估计

训练集中恰好出现一次的事实数

$$N_1 = \sum_f \mathbf{1}(N_f = 1). \quad (23.1)$$

其期望

$$\mathbb{E}[N_1] = \sum_f np_f (1 - p_f)^{n-1}. \quad (23.2)$$

于是

$$\mathbb{E}\left[\frac{N_1}{n}\right] = \sum_f p_f (1 - p_f)^{n-1}. \quad (23.3)$$

与 $\mathbb{E}[M_n] = \sum_f p_f (1 - p_f)^n$ 只差一个 $(1 - p_f)$ 因子，因此 N_1/n 是未见质量的经典估计。直观上，若样本中还有大量“只见一次”的事实，说明还有相当质量完全没见过。

24 IIV 二分类规约的核心逻辑

把每个事实问答转换成一个判断：模型输出的候选陈述是真还是假。设正负标签 $Y \in \{0, 1\}$ ，模型内部表示 Z ，任何回答策略对应分类器 $g(Z)$ 。Bayes 错误率

$$e^* = \mathbb{E}_Z \min\{P(Y = 1 | Z), P(Y = 0 | Z)\}. \quad (24.1)$$

若训练数据无法区分两个在已见样本上一致、但在未见事实上标签相反的世界，则任何算法在这两个世界中至少有一个错误概率较高。这是信息论式不可辨识性，而不是优化不足。

25 0-1 准确率为何鼓励阈值化猜测

若模型认为答案正确的概率为 p 。必须在“回答正确答案”与“拒答”之间选择。若拒答得分为 0，回答正确得 1、错误得 0，则回答的期望分数

$$\mathbb{E}[S_{\text{answer}}] = p. \quad (25.1)$$

只要 $p > 0$ ，回答优于拒答，因此指标鼓励无论多不确定都猜测。若错误扣分 $-c$ ，则

$$\mathbb{E}[S] = p - (1 - p)c, \quad (25.2)$$

回答条件为

$$p > \frac{c}{1 + c}. \quad (25.3)$$

评分规则改变会直接改变最优行为阈值。

26 交叉熵的严格适当性

二分类预测概率 q ，真实标签概率 p 。期望交叉熵

$$\ell(q) = -p \log q - (1 - p) \log(1 - q). \quad (26.1)$$

一阶导数

$$\ell'(q) = -\frac{p}{q} + \frac{1 - p}{1 - q} = \frac{q - p}{q(1 - q)}. \quad (26.2)$$

唯一驻点 $q = p$ 。二阶导数

$$\ell''(q) = \frac{p}{q^2} + \frac{1 - p}{(1 - q)^2} > 0. \quad (26.3)$$

所以最优预测概率等于真实概率，交叉熵鼓励校准，而 0-1 准确率只关心 q 是否跨过 $1/2$ 。

27 Brier Score 的严格适当性

Brier 损失

$$\ell(q, Y) = (q - Y)^2. \quad (27.1)$$

期望

$$\mathbb{E}\ell = p(q - 1)^2 + (1 - p)q^2 \quad (27.2)$$

$$= q^2 - 2pq + p \quad (27.3)$$

$$= (q - p)^2 + p(1 - p). \quad (27.4)$$

第二项与 q 无关，因此唯一最优解仍是 $q = p$ 。与交叉熵相比，Brier 对极端错误概率的惩罚有限，更数值稳定，但对尾部概率差异不如对数损失敏感。

28 多选题随机猜测修正

K 选一，随机猜测准确率为 $1/K$ 。若模型在不知道答案时随机猜，原始准确率仍非零。常见归一化得分

$$S_{\text{norm}} = \frac{\text{Acc} - 1/K}{1 - 1/K}. \quad (28.1)$$

随机猜测得 0，满分得 1。若准确率 a ,

$$S_{\text{norm}} = \frac{Ka - 1}{K - 1}. \quad (28.2)$$

但它仍不能区分“校准的不确定”与“过度自信的猜测”，因为只使用最终选项。

29 校准误差与准确率的区别

把置信度分成 bins B_m ，经验准确率和平均置信度

$$\text{acc}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} \mathbf{1}(\hat{y}_i = y_i), \quad (29.1)$$

$$\text{conf}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} \hat{p}_i. \quad (29.2)$$

ECE

$$\text{ECE} = \sum_m \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|. \quad (29.3)$$

两个模型可以有相同准确率，但一个输出 0.6 置信度、另一个输出 0.99；若实际准确率 0.6，前者校准好，后者严重过度自信。

30 有限样本误差率的置信区间

观察 n 个独立问答，错误指示 $E_i \in \{0, 1\}$ ，经验错误率

$$\hat{e} = \frac{1}{n} \sum_i E_i. \quad (30.1)$$

Hoeffding 不等式给出

$$\Pr(|\hat{e} - e| \geq \epsilon) \leq 2e^{-2n\epsilon^2}. \quad (30.2)$$

置信度 $1 - \delta$ 下

$$|\hat{e} - e| \leq \sqrt{\frac{\log(2/\delta)}{2n}}. \quad (30.3)$$

例如 $n = 1000, \delta = 0.05$ ，半径约

$$\sqrt{\frac{\log 40}{2000}} \approx 0.043. \quad (30.4)$$

因此小基准上的几个百分点差异可能落在统计噪声内。

31 模型族不足带来的不可约误差

设真实条件分布为 $p^*(y | x)$ ，模型族为 $\mathcal{Q}$ 。最小交叉熵

$$\min_{q \in \mathcal{Q}} \mathbb{E}[-\log q(Y | X)] = H(Y | X) + \min_{q \in \mathcal{Q}} \mathbb{E}_X D_{\text{KL}}(p^*(\cdot | X) \| q(\cdot | X)). \quad (31.1)$$

第一项是数据本身的不确定性，第二项是模型族逼近误差。即使无限数据和完美优化，若 $p^* \notin \mathcal{Q}$ ，第二项仍大于零。论文的统计下界与模型逼近下界应区分：前者来自未见样本，后者来自函数类限制。

32 选择性回答的风险–覆盖率曲线

令模型只在置信度 $p \geq \tau$ 时回答。覆盖率

$$C(\tau) = \Pr(p \geq \tau), \quad (32.1)$$

选择性风险

$$R(\tau) = \Pr(\hat{y} \neq y | p \geq \tau). \quad (32.2)$$

增大 τ 通常降低风险但减少覆盖。单一准确率无法反映该权衡。对于幻觉评估，更合理的是报告整条风险–覆盖率曲线或其面积，而不是强迫模型回答全部问题。