

# 29\_FlyLoRA 数学过程详解

Rank-wise MoE、稀疏随机投影与任务正交

## 本文只处理真正需要推导的部分

本文逐式分解 LoRA 为 rank-1 专家，推导冻结稀疏投影的隐式 top-k、计算量、局部梯度、负载均衡、多任务交叉项和随机矩阵近似正交。全文按“公式从哪里来–每个符号是什么–中间步骤为何成立–维度和复杂度如何核对–论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

## 目录

|    |                                     |   |
|----|-------------------------------------|---|
| 1  | LoRA 的低秩分解与维度                       | 3 |
| 2  | Rank-1 专家分解                         | 3 |
| 3  | SVD 与 top- $k$ rank 分量的联系           | 3 |
| 4  | 冻结稀疏随机投影兼任 down-projection 与 router | 4 |
| 5  | 路由前计算量                              | 4 |
| 6  | top- $k$ 的反向传播                      | 4 |
| 7  | 无损负载均衡偏置                            | 5 |
| 8  | 随机投影的近似正交                           | 5 |
| 9  | 多任务合并的交叉项                           | 5 |
| 10 | 激活参数量与存储参数量                         | 6 |
| 11 | 固定缩放 $\alpha/k$ 的方差核对               | 6 |
| 12 | LoRA 是受限矩阵更新                        | 6 |
| 13 | SVD 与最优低秩逼近                         | 7 |
| 14 | Rank-1 专家的显式输出                      | 7 |

|                                     |    |
|-------------------------------------|----|
| 15 冻结随机投影的保距性质                      | 7  |
| 16 稀疏 softmax 与 top- $k$ 梯度         | 8  |
| 17 负载均衡统计                           | 8  |
| 18 缩放 $\alpha/k$ 的方差核对              | 8  |
| 19 多任务干扰的 Frobenius 内积              | 9  |
| 20 稀疏路由下的有效秩                        | 9  |
| 21 参数量与计算量                          | 9  |
| 22 路由噪声与专家探索                        | 10 |
| 23 LoRA 更新是低秩矩阵流形上的优化               | 11 |
| 24 Rank-1 专家分解                      | 11 |
| 25 SVD 与最优低秩逼近                      | 11 |
| 26 输入依赖路由后的有效更新                     | 12 |
| 27 冻结随机投影的 Johnson–Lindenstrauss 解释 | 12 |
| 28 Top- $k$ softmax 的梯度             | 12 |
| 29 缩放 $\alpha/k$ 的方差核对              | 12 |
| 30 多任务干扰的 Frobenius 内积              | 13 |
| 31 参数量、激活量与计算量                      | 13 |
| 32 有效秩的输入分布定义                       | 13 |
| 33 一个 $2 \times 2$ 数值例子             | 14 |

## 1 LoRA 的低秩分解与维度

冻结权重  $W_0 \in \mathbb{R}^{m \times n}$ , 更新

$$W' = W_0 + \frac{\alpha}{r}BA, \quad B \in \mathbb{R}^{m \times r}, \quad A \in \mathbb{R}^{r \times n}. \quad (1.1)$$

输入  $x \in \mathbb{R}^n$  时

$$f(x) = W_0x + \frac{\alpha}{r}B(Ax). \quad (1.2)$$

参数量从  $mn$  降为

$$P_{\text{LoRA}} = r(m + n), \quad (1.3)$$

而  $\text{rank}(BA) \leq r$ 。

## 2 Rank-1 专家分解

令  $a_i = A[i, :] \in \mathbb{R}^{1 \times n}$ 、 $b_i = B[:, i] \in \mathbb{R}^m$ , 则

$$BAx = \sum_{i=1}^r b_i(a_i x). \quad (2.1)$$

每项

$$E_i(x) = b_i(a_i x) \quad (2.2)$$

是 rank-1 专家： $a_i$  产生标量激活， $b_i$  把标量扩展到输出空间。显式 MoE 路由写成

$$f(x) = W_0x + \frac{\alpha}{r} \sum_i G_i(x) b_i(a_i x). \quad (2.3)$$

## 3 SVD 与 top- $k$ rank 分量的联系

若更新矩阵有 SVD

$$\Delta W = \sum_{i=1}^r \sigma_i u_i v_i^\top, \quad (3.1)$$

Eckart–Young–Mirsky 定理给出最佳 rank- $k$  近似

$$\Delta W_k = \sum_{i=1}^k \sigma_i u_i v_i^\top, \quad \|\Delta W - \Delta W_k\|_F^2 = \sum_{i>k} \sigma_i^2. \quad (3.2)$$

FlyLoRA 不能在线做 SVD，但用投影激活  $|a_i x|$  作为输入相关的重要度代理；它选择的是对当前 token 贡献大的分量，而非全局固定奇异值。

## 4 冻结稀疏随机投影兼任 down-projection 与 router

$A \in \mathbb{R}^{r \times n}$  每行仅  $p$  个非零项, 稀疏率

$$\rho = \frac{p}{n}. \quad (4.1)$$

非零元素独立取

$$A_{ij} \sim \mathcal{N}(0, 1/r^2). \quad (4.2)$$

先算

$$y = Ax, \quad (4.3)$$

再保留幅值最大的  $k$  个坐标:

$$m_i(x) = \mathbf{1}[i \in \text{TopK}(|y|)], \quad y'_i = m_i y_i. \quad (4.4)$$

输出

$$f_{\text{Fly}}(x) = W_0 x + \frac{\alpha}{k} B(m(x) \odot Ax). \quad (4.5)$$

$A$  同时给出每个 rank 的标量系数和 top- $k$  分数, 所以无需额外  $W_g \in \mathbb{R}^{r \times n}$ 。

## 5 路由前计算量

稠密 LoRA 下投影成本  $O(rn)$ 。稀疏  $A$  每行  $p$  个非零, 成本

$$C_A = O(rp) = O(\rho rn). \quad (5.1)$$

上投影只激活  $k$  列, 成本

$$C_B = O(km). \quad (5.2)$$

总增量

$$C_{\text{Fly}} = O(rp + km), \quad (5.3)$$

相比普通 LoRA 的  $O(rn + rm)$ , 当  $p \ll n, k \ll r$  时显著降低。

## 6 top- $k$ 的反向传播

在一个不发生排序交换的局部区域, 掩码  $m$  视为常数,

$$\frac{\partial y'_i}{\partial y_j} = m_i \delta_{ij}. \quad (6.1)$$

故只有被选 rank 的  $b_i$  获得梯度:

$$\frac{\partial \mathcal{L}}{\partial b_i} = \frac{\alpha}{k} m_i \frac{\partial \mathcal{L}}{\partial f} y_i. \quad (6.2)$$

$A$  冻结, 因此无需对离散排序边界求梯度。代价是未激活专家本步完全无更新, 必须用负载均衡防止“饿死”。

## 7 无损负载均衡偏置

选择分数改为

$$s_i = (Ax)_i + d_i, \quad (7.1)$$

偏置手工更新

$$d_i \leftarrow d_i + u \operatorname{sign}(\bar{c}_i - c_i), \quad (7.2)$$

$c_i$  为实际频率、 $\bar{c}_i$  为目标频率。若专家过少使用， $d_i$  增大；过多使用则减小。由于  $d_i$  只参与选择、不乘到最终专家输出，它不直接改变已选专家的幅值，因而被称为 loss-free balancing。

## 8 随机投影的近似正交

取两个独立零均值随机投影  $A_s, A_t \in \mathbb{R}^{r \times n}$ 。Frobenius 内积

$$Z = \langle A_s, A_t \rangle_F = \sum_{ij} (A_s)_{ij} (A_t)_{ij}. \quad (8.1)$$

独立性给出

$$\mathbb{E} Z = 0. \quad (8.2)$$

若每项方差为  $\sigma^4$  且共有约  $r\rho n$  个共同有效位置，则

$$\operatorname{Var}(Z) \approx r\rho^2 n \sigma^4. \quad (8.3)$$

而

$$\mathbb{E} \|A_s\|_F^2 \approx r\rho n \sigma^2. \quad (8.4)$$

归一化余弦的标准差量级

$$\operatorname{Std} \left( \frac{\langle A_s, A_t \rangle_F}{\|A_s\|_F \|A_t\|_F} \right) = O((rn)^{-1/2}). \quad (8.5)$$

高维下独立随机子空间近似正交，是任务合并减干扰的结构来源。

## 9 多任务合并的交叉项

任务  $s, t$  更新

$$\Delta W_s = B_s A_s, \quad \Delta W_t = B_t A_t. \quad (9.1)$$

在输入协方差  $\Sigma_x$  下，输出干扰内积

$$\mathbb{E}_x \langle \Delta W_s x, \Delta W_t x \rangle = \operatorname{Tr}(B_s A_s \Sigma_x A_t^\top B_t^\top). \quad (9.2)$$

若白化  $\Sigma_x = I$  且  $A_s A_t^\top \approx 0$ ，交叉项接近 0。注意这并不保证  $B_s$  与  $B_t$  正交；真正抑制的是两任务看到的投影坐标相关性。

## 10 激活参数数量与存储参数数量

训练参数只有  $B \in \mathbb{R}^{m \times r}$  (若  $A$  冻结):

$$P_{\text{train}} = mr. \quad (10.1)$$

单 token 激活列数  $k$ , 参与乘法的参数

$$P_{\text{active}} = mk. \quad (10.2)$$

但存储仍需  $mr$ 。因此“激活参数少”描述计算, 不等于模型文件大小按  $k/r$  缩小。

## 11 固定缩放 $\alpha/k$ 的方差核对

若活跃标量  $y_i$  独立同方差  $\sigma_y^2$ 、列向量范数相近, 增量输出方差近似

$$\mathbb{E} \|\Delta f\|^2 \propto \left(\frac{\alpha}{k}\right)^2 k \sigma_y^2 = \frac{\alpha^2}{k} \sigma_y^2. \quad (11.1)$$

若希望不同  $k$  下方差严格不变, 更自然的缩放是  $1/\sqrt{k}$ ; 论文沿用 LoRA 风格的  $1/k$  更强调控制总幅值。两种选择对应不同稳定性假设。

## 12 LoRA 是受限矩阵更新

全量更新  $\Delta W \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ , LoRA 约束

$$\Delta W = BA, \quad B \in \mathbb{R}^{d_{\text{out}} \times r}, \quad A \in \mathbb{R}^{r \times d_{\text{in}}}. \quad (12.1)$$

因此

$$\text{rank}(\Delta W) \leq r. \quad (12.2)$$

参数量从  $d_{\text{out}}d_{\text{in}}$  降为

$$r(d_{\text{in}} + d_{\text{out}}). \quad (12.3)$$

对输入  $x$ , 增量

$$\Delta y = BAx. \quad (12.4)$$

梯度

$$\nabla_B \mathcal{L} = g_y(Ax)^\top, \quad \nabla_A \mathcal{L} = B^\top g_y x^\top. \quad (12.5)$$

若  $B$  零初始化, 初始  $\nabla_A = 0$ , 先由  $B$  学习打开增量通路。

## 13 SVD 与最优低秩逼近

任意目标更新

$$\Delta W^* = U \Sigma V^\top = \sum_{j=1}^{r_*} \sigma_j u_j v_j^\top. \quad (13.1)$$

Eckart–Young 定理说明 Frobenius 范数下最佳 rank- $r$  逼近

$$\Delta W_r = \sum_{j=1}^r \sigma_j u_j v_j^\top \quad (13.2)$$

且误差

$$\|\Delta W^* - \Delta W_r\|_F^2 = \sum_{j>r} \sigma_j^2. \quad (13.3)$$

FlyLoRA 把每个 rank-1 项视为专家，路由选择相当于针对输入激活不同奇异方向，而非对所有输入固定使用同一个 rank- $r$  子空间。

## 14 Rank-1 专家的显式输出

写

$$B = [b_1, \dots, b_r], \quad A = \begin{bmatrix} a_1^\top \\ \vdots \\ a_r^\top \end{bmatrix}. \quad (14.1)$$

则

$$BAx = \sum_{j=1}^r b_j (a_j^\top x). \quad (14.2)$$

加入稀疏门控  $g_j(x)$ :

$$\Delta y(x) = \frac{\alpha}{k} \sum_{j \in \text{TopK}(g(x), k)} g_j(x) b_j (a_j^\top x). \quad (14.3)$$

每个专家先把  $x$  投影成标量  $a_j^\top x$ ，再沿输出方向  $b_j$  写回，因此其几何意义非常清晰。

## 15 冻结随机投影的保距性质

路由特征用固定随机矩阵  $R \in \mathbb{R}^{m \times d}$ :

$$z = Rx, \quad R_{ij} \sim \mathcal{N}(0, 1/m). \quad (15.1)$$

则

$$\mathbb{E} \|Rx\|^2 = \|x\|^2. \quad (15.2)$$

对两个向量  $x, y$ , 极化恒等式给出

$$\mathbb{E} \langle Rx, Ry \rangle = \langle x, y \rangle. \quad (15.3)$$

集中不等式说明

$$\Pr(|\|Rx\|^2 - \|x\|^2| > \epsilon \|x\|^2) \leq 2e^{-cm\epsilon^2}. \quad (15.4)$$

所以固定随机投影可低成本保留路由所需的相似度结构, 同时避免再训练一个大型 router down-projection。

## 16 稀疏 softmax 与 top- $k$ 梯度

router logits  $s \in \mathbb{R}^r$ , 选中集合  $S$  后

$$g_j = \frac{e^{s_j}}{\sum_{\ell \in S} e^{s_\ell}}, \quad j \in S. \quad (16.1)$$

集合固定时

$$\frac{\partial g_j}{\partial s_m} = g_j(\mathbf{1}_{j=m} - g_m), \quad j, m \in S. \quad (16.2)$$

未选专家梯度为 0。排序边界不可微但几乎处处分段可导。若某专家长期未入选, 就没有任务梯度, 因此需要负载均衡或随机扰动防止死亡专家。

## 17 负载均衡统计

设 batch 中专家  $j$  的选择频率

$$f_j = \frac{1}{B} \sum_{i=1}^B \mathbf{1}(j \in S_i), \quad (17.1)$$

平均门控概率

$$p_j = \frac{1}{B} \sum_i g_{ij}. \quad (17.2)$$

常见均衡损失

$$\mathcal{L}_{\text{bal}} = r \sum_{j=1}^r f_j p_j. \quad (17.3)$$

若  $f_j = p_j = 1/r$ , 则  $\mathcal{L}_{\text{bal}} = 1$ 。当概率集中到少数专家时内积增大。由于  $f_j$  来自硬选择, 通常停止其梯度, 仅通过  $p_j$  调整 router。

## 18 缩放 $\alpha/k$ 的方差核对

假设选中专家输出  $e_j$  独立、零均值、协方差  $\Sigma$ , 且门控近似均匀。未缩放和

$$s = \sum_{j=1}^k e_j \quad (18.1)$$



协方差  $k\Sigma$ 。乘  $1/k$  后

$$\text{Cov}(s/k) = \Sigma/k. \quad (18.2)$$

乘  $1/\sqrt{k}$  才保持方差不变。论文用  $\alpha/k$  更接近保持平均幅值而非方差； $\alpha$  需补偿不同  $k$  下的尺度变化。

## 19 多任务干扰的 Frobenius 内积

任务  $a, b$  的更新  $\Delta W_a, \Delta W_b$ 。在二阶近似中，把任务  $a$  更新叠加到任务  $b$  的损失变化

$$\Delta \mathcal{L}_b \approx \langle G_b, \Delta W_a \rangle + \frac{1}{2} \langle \Delta W_a, H_b \Delta W_a \rangle. \quad (19.1)$$

若两任务更新方向近似正交

$$\langle \Delta W_a, \Delta W_b \rangle_F \approx 0, \quad (19.2)$$

交叉干扰通常较小。rank-wise 专家把不同任务路由到不同 rank-1 分量，使掩码重叠率下降，从结构上减少内积交叉项。

## 20 稀疏路由下的有效秩

对固定输入  $x$ ，只有  $k$  个专家激活，因此局部更新矩阵

$$\Delta W(x) = \sum_{j \in S(x)} g_j(x) b_j a_j^\top \quad (20.1)$$

满足

$$\text{rank}(\Delta W(x)) \leq k. \quad (20.2)$$

但跨输入联合使用的专家集合可覆盖全部  $r$  个方向，所以全数据集有效容量可接近 rank  $r$ ，单样本计算仅 rank  $k$ 。这就是条件计算的容量-FLOPs 解耦。

## 21 参数量与计算量

存储参数仍包括所有专家

$$P_{\text{store}} = r(d_{\text{in}} + d_{\text{out}}) + P_{\text{router}}. \quad (21.1)$$

若 router 投影已冻结，训练参数主要是专家和少量门控。单 token 激活计算

$$C_{\text{active}} = O(kd_{\text{in}} + kd_{\text{out}}) \quad (21.2)$$

加上 router 成本。训练显存还需保存全部专家参数的优化器状态，因此“激活  $k$  个”不等于优化器内存按  $k/r$  缩小。

## 22 路由噪声与专家探索

给 logits 加噪声

$$\tilde{s}_j = s_j + \sigma \epsilon_j \quad (22.1)$$

可使边界附近专家有概率被选中。两专家差值  $\Delta = s_1 - s_2$ ，若噪声高斯，则专家 1 被选概率

$$\Pr(\tilde{s}_1 > \tilde{s}_2) = \Phi\left(\frac{\Delta}{\sqrt{2}\sigma}\right). \quad (22.2)$$

$\sigma$  大时探索更均匀，过大则路由近似随机；训练后期通常减小噪声。

## 23 LoRA 更新是低秩矩阵流形上的优化

冻结权重  $W_0 \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ , 更新

$$\Delta W = BA, \quad B \in \mathbb{R}^{d_{\text{out}} \times r}, \quad A \in \mathbb{R}^{r \times d_{\text{in}}}. \quad (23.1)$$

由秩不等式

$$\text{rank}(BA) \leq \min(\text{rank } B, \text{rank } A) \leq r. \quad (23.2)$$

因此可达更新集合位于秩不超过  $r$  的代数簇。参数量

$$P_{\text{LoRA}} = r(d_{\text{in}} + d_{\text{out}}) \quad (23.3)$$

相对全矩阵  $d_{\text{in}}d_{\text{out}}$  大幅减少。

## 24 Rank-1 专家分解

把  $B$  的列写为  $b_1, \dots, b_r$ ,  $A$  的行为  $a_1^\top, \dots, a_r^\top$ , 则

$$BA = \sum_{j=1}^r b_j a_j^\top. \quad (24.1)$$

对输入  $x$ ,

$$\Delta W x = \sum_{j=1}^r b_j (a_j^\top x). \quad (24.2)$$

每个 rank-1 专家先用标量投影  $a_j^\top x$  判断输入在方向  $a_j$  上的分量, 再沿输出方向  $b_j$  写回。

## 25 SVD 与最优低秩逼近

任意矩阵更新  $M$  的 SVD

$$M = \sum_{j=1}^q \sigma_j u_j v_j^\top, \quad \sigma_1 \geq \dots \geq \sigma_q. \quad (25.1)$$

Eckart–Young 定理说明最优 rank- $r$  Frobenius 逼近

$$M_r = \sum_{j=1}^r \sigma_j u_j v_j^\top, \quad (25.2)$$

误差

$$\|M - M_r\|_F^2 = \sum_{j>r} \sigma_j^2. \quad (25.3)$$

FlyLoRA 的 rank-wise 专家可看作学习一组数据依赖的 rank-1 分量, 但它们不必正交, 也不按奇异值排序。

## 26 输入依赖路由后的有效更新

路由权重  $g_j(x)$ , top- $k$  集合  $S(x)$ , 则

$$\Delta W(x)x = \frac{\alpha}{k} \sum_{j \in S(x)} g_j(x) b_j (a_j^\top x). \quad (26.1)$$

注意  $\Delta W$  现在依赖输入  $x$ , 不再是固定线性矩阵; 整体映射是分段非线性的。即使每个专家 rank 1, 不同输入激活不同专家后, 模型在数据集上的联合有效秩可超过  $k$ 。

## 27 冻结随机投影的 Johnson–Lindenstrauss 解释

设路由投影  $R \in \mathbb{R}^{m \times d}$ , 元素独立且方差  $1/m$ 。对固定向量  $x$ ,

$$\mathbb{E} \|Rx\|_2^2 = \|x\|_2^2. \quad (27.1)$$

对次高斯随机矩阵, 有高概率界

$$\Pr(|\|Rx\|_2^2 - \|x\|_2^2| > \epsilon \|x\|_2^2) \leq 2e^{-cm\epsilon^2}. \quad (27.2)$$

对  $N$  个样本用并集界, 若

$$m = O(\epsilon^{-2} \log N), \quad (27.3)$$

则所有两两距离近似保持。冻结随机路由因此可以保留输入几何而不增加训练参数, 但并不保证对具体任务的最优可分性。

## 28 Top- $k$ softmax 的梯度

先计算 logits  $z_j$ , 选择集合  $S$ , 集合内

$$g_j = \frac{e^{z_j}}{\sum_{\ell \in S} e^{z_\ell}}, \quad j \in S. \quad (28.1)$$

固定选择集合时

$$\frac{\partial g_j}{\partial z_m} = g_j(\mathbf{1}[j = m] - g_m), \quad j, m \in S. \quad (28.2)$$

未选专家梯度为零。排序边界处集合变化不连续, 因此专家一旦长期未入选, 无法通过主任务梯度恢复, 需路由噪声或负载均衡促进探索。

## 29 缩放 $\alpha/k$ 的方差核对

假设激活专家输出  $e_j = b_j(a_j^\top x)$  独立、零均值、方差  $\sigma_e^2$ , 且均匀权重  $g_j \approx 1$ 。求和输出

$$y = \frac{\alpha}{k} \sum_{j=1}^k e_j. \quad (29.1)$$

方差

$$\text{Var}(y) = \frac{\alpha^2}{k^2} k \sigma_e^2 = \frac{\alpha^2}{k} \sigma_e^2. \quad (29.2)$$

若希望方差与  $k$  无关，更自然的缩放是  $\alpha/\sqrt{k}$ 。使用  $\alpha/k$  会使激活专家越多，输出方差越小；其优点是控制总幅值，缺点是可能削弱大  $k$  配置。

## 30 多任务干扰的 Frobenius 内积

两个任务更新  $\Delta W_1, \Delta W_2$ ，合并后平方范数

$$\|\Delta W_1 + \Delta W_2\|_F^2 = \|\Delta W_1\|_F^2 + \|\Delta W_2\|_F^2 + 2\langle \Delta W_1, \Delta W_2 \rangle_F. \quad (30.1)$$

对 rank-1 分量

$$\langle b_1 a_1^\top, b_2 a_2^\top \rangle_F = (b_1^\top b_2)(a_1^\top a_2). \quad (30.2)$$

只要输入方向或输出方向之一近似正交，交叉项就小。FlyLoRA 的任务解耦可以通过路由减少同一输入上同时激活的专家，也可以通过随机投影和稀疏性降低更新内积。

## 31 参数量、激活量与计算量

总存储参数若有  $r$  个 rank-1 专家：

$$P = r(d_{\text{in}} + d_{\text{out}}) + P_{\text{router}}. \quad (31.1)$$

每个 token 只激活  $k$  个专家，专家计算

$$C_{\text{expert}} \approx 2k(d_{\text{in}} + d_{\text{out}}) \quad (31.2)$$

FLOPs。标准 rank- $r$  LoRA 为

$$C_{\text{LoRA}} \approx 2r(d_{\text{in}} + d_{\text{out}}). \quad (31.3)$$

所以当  $k \ll r$  时激活计算下降，但路由还需计算 logits。若冻结投影直接复用  $a_j^\top x$  作为路由分数，可减少额外投影。

## 32 有效秩的输入分布定义

输入依赖更新无法用单一矩阵秩完整描述。可以定义输出协方差

$$\Sigma_y = \mathbb{E}_x[\Delta y(x) \Delta y(x)^\top]. \quad (32.1)$$

有效秩

$$r_{\text{eff}}(\Sigma_y) = \exp\left(-\sum_i p_i \log p_i\right), \quad p_i = \frac{\lambda_i}{\sum_j \lambda_j}. \quad (32.2)$$

即使每个样本只用  $k$  个专家，若不同样本覆盖许多输出方向， $\Sigma_y$  的有效秩可远大于  $k$ 。这说明“每 token 激活秩”和“数据整体表达秩”是不同概念。

### 33 一个 $2 \times 2$ 数值例子

取两个专家

$$b_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad a_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad b_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad a_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}. \quad (33.1)$$

对  $x = (3, 1)^\top$ ，若路由选专家 1，

$$\Delta y = b_1 a_1^\top x = (3, 0)^\top. \quad (33.2)$$

对  $x = (1, 4)^\top$ ，选专家 2，

$$\Delta y = (0, 4)^\top. \quad (33.3)$$

每个样本有效秩为 1，但整个数据集的输出覆盖两个正交方向，整体有效秩为 2。