

30_Back to Basics 数学过程详解

x/epsilon/v 参数化、流形维度与瓶颈容量

本文只处理真正需要推导的部分

本文完整推导线性加噪下三种预测目标的转换和权重，解释 $x\text{-pred} + v\text{-loss}$ 、Euler 采样、满秩噪声瓶颈、低秩 patch embedding、时间采样与误差放大。全文按“公式从哪里来–每个符号是什么–中间步骤为何成立–维度和复杂度如何核对–论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1 线性插值加噪与三种目标	3
2 网络预测空间与损失空间不是一回事	3
3 论文最终训练算法的推导	3
4 Euler 采样	4
5 为什么高维噪声比干净图像更难预测	4
6 速度目标也含满维噪声	4
7 线性瓶颈等价于低秩 patch embedding	5
8 SNR 与分辨率缩放	5
9 Logit-Normal 时间采样	5
10 EDM 预条件与直接 $x\text{-pred}$ 的区别	6
11 误差在参数化转换中的放大	6
12 三种预测目标的线性变换矩阵	6
13 损失重参数化的时间权重	7
14 Bayes 最优去噪器是条件均值	7

15 高维高斯噪声的集中现象	7
16 线性瓶颈的最优误差	8
17 patch 维度与网络宽度	8
18 SNR 与目标难度	8
19 Logit-Normal 时间采样与重要性权重	8
20 Euler 采样与 x 预测器	9
21 EDM 预条件为何改变直接输出空间	9
22 三种预测目标的精确线性变换	10
23 预测误差在参数化转换中的放大	10
24 不同损失的等价时间权重	10
25 Bayes 最优去噪器是条件均值	11
26 Tweedie 公式连接去噪器与 score	11
27 高维高斯噪声的集中现象	11
28 线性瓶颈的最优重建误差	12
29 Patch 维度与网络宽度的数值例子	12
30 Logit-Normal 时间采样与重要性加权	12
31 从 x 预测器构造 ODE 速度	13
32 Euler 误差与网络误差分离	13

1 线性插值加噪与三种目标

论文使用

$$z_t = tx + (1 - t)\epsilon, \quad t \in [0, 1], \quad \epsilon \sim \mathcal{N}(0, I). \quad (1.1)$$

这里 $t = 1$ 是干净数据, $t = 0$ 是纯噪声。路径速度

$$v = \frac{dz_t}{dt} = x - \epsilon. \quad (1.2)$$

由 z_t 可在三种变量间转换:

$$x = z_t + (1 - t)v, \quad (1.3)$$

$$\epsilon = z_t - tv, \quad (1.4)$$

$$v = \frac{x - z_t}{1 - t} = \frac{z_t - \epsilon}{t}. \quad (1.5)$$

2 网络预测空间与损失空间不是一回事

设网络直接输出 x_θ 。转换为速度

$$v_\theta = \frac{x_\theta - z_t}{1 - t}. \quad (2.1)$$

于是 v-loss

$$\|v_\theta - v\|^2 = \left\| \frac{x_\theta - z_t}{1 - t} - \frac{x - z_t}{1 - t} \right\|^2 \quad (2.2)$$

$$= \frac{1}{(1 - t)^2} \|x_\theta - x\|^2. \quad (2.3)$$

所以 “x-prediction + v-loss” 实际是按 $(1 - t)^{-2}$ 加权的 x-loss, 重视接近干净端点的样本。

若网络预测噪声 ϵ_θ , 由

$$x_\theta = \frac{z_t - (1 - t)\epsilon_\theta}{t} \quad (2.4)$$

可得

$$\|x_\theta - x\|^2 = \frac{(1 - t)^2}{t^2} \text{orm} \epsilon_\theta - \epsilon^2. \quad (2.5)$$

三种参数化代数等价, 但同一个 “未加权 MSE” 在不同输出空间对应不同时间权重, 因此优化难度并不等价。

3 论文最终训练算法的推导

网络 $\text{net}_\theta(z_t, t) = x_\theta$, 定义

$$v_\theta = \frac{x_\theta - z_t}{1 - t}. \quad (3.1)$$

真实速度也可不显式用 ϵ :

$$v = \frac{x - z_t}{1 - t}. \quad (3.2)$$

损失

$$\mathcal{L} = \mathbb{E}_{t,x,\epsilon} \text{orm} \left[\frac{x_\theta - z_t}{1 - t} - \frac{x - z_t}{1 - t} \right]^2. \quad (3.3)$$

为避免 $t = 1$ 数值发散, 采样分布和实现需避开精确端点或加稳定常数。

4 Euler 采样

从噪声端 $t_0 = 0$ 积分到 $t_J = 1$:

$$z_{j+1} = z_j + (t_{j+1} - t_j)v_\theta(z_j, t_j). \quad (4.1)$$

若 x_θ 完美, 则

$$v_\theta = x - \epsilon \quad (4.2)$$

为常量, 一步 Euler 就精确到达 x 。实际多步的必要性来自网络预测误差和条件速度随当前状态变化。

5 为什么高维噪声比干净图像更难预测

流形假设: 干净图像位于 D 维像素空间中的 d 维流形 $\mathcal{M}$, $d \ll D$ 。局部可写

$$x = g(u), \quad u \in \mathbb{R}^d. \quad (5.1)$$

若网络中间瓶颈宽度为 $h \geq d$, 理论上可编码局部坐标 u 并重构 x 。而高斯噪声的协方差

$$\text{Cov}(\epsilon) = I_D \quad (5.2)$$

满秩, 任何 rank- h 线性重构的最小均方误差 (PCA) 为

$$\min_{\text{rank}(P) \leq h} \mathbb{E} \|\epsilon - P\epsilon\|^2 = D - h. \quad (5.3)$$

当 $h \ll D$ 时, 绝大多数噪声能量无法穿过瓶颈。这个线性结果解释了为何大 patch 下 ϵ -prediction 可能灾难性失败, 而 x -prediction 仍可工作。

6 速度目标也含满维噪声

$$v = x - \epsilon. \quad (6.1)$$

即使 x 位于低维流形, v 的协方差

$$\text{Cov}(v) = \text{Cov}(x) + I - 2\text{Cov}(x, \epsilon) = \text{Cov}(x) + I \quad (6.2)$$

在独立假设下仍满秩。直接 v-prediction 要保留噪声分量; x-prediction 先输出低维结构, 再通过解析式与 z_t 组合得到速度, 绕过了瓶颈传递全部噪声的要求。

7 线性瓶颈等价于低秩 patch embedding

原 patch $u \in \mathbb{R}^P$ 。两层线性嵌入

$$h = W_2 W_1 u, \quad W_1 \in \mathbb{R}^{d' \times P}, \quad W_2 \in \mathbb{R}^{d \times d'} \quad (7.1)$$

等效矩阵秩

$$\text{rank}(W_2 W_1) \leq d'. \quad (7.2)$$

参数量

$$P_{\text{bottleneck}} = d'P + dd' \quad (7.3)$$

对比直接投影 dP 。若 d' 小于 $dP/(P+d)$, 参数也减少; 但论文的主要作用是结构正则化, 而非仅省参数。

8 SNR 与分辨率缩放

加噪信号和噪声能量比近似

$$\text{SNR}(t) = \frac{t^2 \mathbb{E} \|x\|^2}{(1-t)^2 \mathbb{E} \|\epsilon\|^2}. \quad (8.1)$$

若图像分辨率增大且像素范围不变, 信号和标准高斯噪声总能量都随维度 D 线性增长, 理论 SNR 不变。但 patch 内的低频自然图像结构更相关, 而独立噪声维度增加; 网络容量相对噪声自由度下降。论文按分辨率比例放大噪声, 是经验上维持生成难度和频谱尺度, 而非简单由总能量 SNR 唯一决定。

9 Logit-Normal 时间采样

令

$$s \sim \mathcal{N}(\mu, \sigma^2), \quad t = \text{sigmoid}(s). \quad (9.1)$$

其密度由变量替换得到

$$p(t) = \frac{1}{t(1-t)\sigma\sqrt{2\pi}} \exp \left[-\frac{(\log \frac{t}{1-t} - \mu)^2}{2\sigma^2} \right]. \quad (9.2)$$

减小 μ 把质量推向更小 t , 即更高噪声区域。若训练损失未做 $1/p(t)$ 重要性修正, 改变采样分布就等价于改变时间权重。

10 EDM 预条件与直接 x-pred 的区别

EDM 风格输出

$$x_\theta = c_{\text{skip}}(t)z_t + c_{\text{out}}(t)\text{net}_\theta(z_t, t). \quad (10.1)$$

当 $c_{\text{skip}} \neq 0$ 时，网络直接输出的并非干净图像，而是残差。即使最终 x_θ 是 x 估计，内部网络任务仍混合了噪声输入。论文强调的“直接 x-prediction”取

$$c_{\text{skip}} = 0, \quad c_{\text{out}} = 1. \quad (10.2)$$

这使输出空间严格受数据流形约束。

11 误差在参数化转换中的放大

若 x 预测误差 $e_x = x_\theta - x$ ，速度误差

$$e_v = \frac{e_x}{1-t}. \quad (11.1)$$

接近 $t = 1$ 时被放大。反之，若速度误差 e_v ， x 误差

$$e_x = (1-t)e_v \quad (11.2)$$

在干净端缩小。使用 x-pred + v-loss 正是在训练时补偿这一转换，使小的 x 误差在高 t 仍受到足够惩罚。

12 三种预测目标的线性变换矩阵

设

$$x_t = \alpha_t x + \sigma_t \epsilon, \quad \alpha_t^2 + \sigma_t^2 = 1. \quad (12.1)$$

定义速度

$$v_t = \alpha_t \epsilon - \sigma_t x. \quad (12.2)$$

则

$$\begin{bmatrix} x_t \\ v_t \end{bmatrix} = R_t \begin{bmatrix} x \\ \epsilon \end{bmatrix}, \quad R_t = \begin{bmatrix} \alpha_t & \sigma_t \\ -\sigma_t & \alpha_t \end{bmatrix}. \quad (12.3)$$

$R_t^\top R_t = I$ ，所以

$$x = \alpha_t x_t - \sigma_t v_t, \quad \epsilon = \sigma_t x_t + \alpha_t v_t. \quad (12.4)$$

参数化在信息上等价，但网络输出误差的映射不同。若 $\hat{\epsilon} = \epsilon + e_\epsilon$ ，则

$$\hat{x} - x = -\frac{\sigma_t}{\alpha_t} e_\epsilon. \quad (12.5)$$

高噪声端 $\alpha_t \rightarrow 0$ 时，噪声预测的小误差会被放大成巨大的干净图像误差。

13 损失重参数化的时间权重

x -prediction MSE

$$\mathcal{L}_x = \mathbb{E} \|\hat{x} - x\|^2. \quad (13.1)$$

若由噪声输出转换

$$\hat{x} = \frac{x_t - \sigma_t \hat{\epsilon}}{\alpha_t}, \quad (13.2)$$

则

$$\mathcal{L}_x = \mathbb{E} \frac{\sigma_t^2}{\alpha_t^2} \text{orm} \hat{\epsilon} - \epsilon^2 = \mathbb{E} \text{SNR}(t)^{-1} \text{orm} e_\epsilon^2. \quad (13.3)$$

因此“不加权的 x MSE”和“不加权的 ϵ MSE”不是同一训练目标；要完全等价必须乘时间权重。

14 Bayes 最优去噪器是条件均值

对任意带噪输入 x_t ，平方损失风险

$$R(f) = \mathbb{E} \|f(x_t) - x\|^2. \quad (14.1)$$

条件分解

$$\mathbb{E} [\|f - x\|^2 \mid x_t] = \|f - \mathbb{E}[x \mid x_t]\|^2 + \text{Var}(x \mid x_t). \quad (14.2)$$

所以

$$\boxed{f^*(x_t) = \mathbb{E}[x \mid x_t].} \quad (14.3)$$

若自然图像集中在低维流形，条件均值主要需要恢复流形坐标；预测独立高维噪声则需要保留离开流形的全部随机方向。

15 高维高斯噪声的集中现象

若 $\epsilon \sim \mathcal{N}(0, I_D)$ ，则

$$\|\epsilon\|^2 \sim \chi_D^2, \quad \mathbb{E} \|\epsilon\|^2 = D, \quad \text{Var}(\|\epsilon\|^2) = 2D. \quad (15.1)$$

因此

$$\frac{\|\epsilon\|}{\sqrt{D}} \xrightarrow{p} 1. \quad (15.2)$$

噪声几乎全部位于半径 $\sqrt{D}$ 的薄壳上，并占据所有 D 个方向。若网络瓶颈宽度 $m < D$ ，线性输出矩阵秩至多 m ，无法无损表达任意噪声向量；但若干净图像内在维度 $d_{\mathcal{M}} \ll m$ ，仍可能充分表示流形。

16 线性瓶颈的最优误差

考虑线性编码解码

$$\hat{y} = BAy, \quad A \in \mathbb{R}^{m \times D}, B \in \mathbb{R}^{D \times m}. \quad (16.1)$$

矩阵 BA 秩至多 m 。对零均值数据协方差 Σ ，最小重建误差由 PCA 给出

$$\min_{\text{rank}(P) \leq m} \mathbb{E} \|y - Py\|^2 = \sum_{j>m} \lambda_j(\Sigma). \quad (16.2)$$

对于白噪声 $\Sigma = I$ ，误差为 $D - m$ ；对于低维流形附近数据，协方差谱快速衰减，尾和可以很小。这给出论文“欠容量网络仍能预测干净数据、却难预测噪声”的线性原型。

17 patch 维度与网络宽度

边长 p 、通道 C 的原始像素 patch 维度

$$D_p = p^2 C. \quad (17.1)$$

patch embedding

$$h = W_p x, \quad W_p \in \mathbb{R}^{m \times D_p} \quad (17.2)$$

当 $m < D_p$ 时是严格瓶颈。对噪声 patch，最优线性重建丢失至少 $D_p - m$ 个单位方差方向；对自然 patch，若主要能量集中在前 m 个主成分，损失仍可小。大 patch 使 D_p 快速增大，因此对 ϵ/v 预测更不利。

18 SNR 与目标难度

信噪比

$$\text{SNR}(t) = \frac{\alpha_t^2}{\sigma_t^2}. \quad (18.1)$$

高 SNR 时 x_t 接近干净图像， x 预测容易；低 SNR 时后验 $p(x | x_t)$ 更宽，条件均值趋向数据先验平均。噪声预测则相反：

$$\epsilon = \frac{x_t - \alpha_t x}{\sigma_t}. \quad (18.2)$$

低噪声端 $\sigma_t \rightarrow 0$ 时，从两个接近量之差恢复噪声数值条件差。因此不同目标的误差重点分布在不同时间区域。

19 Logit-Normal 时间采样与重要性权重

若先采样

$$z \sim \mathcal{N}(\mu, s^2), \quad t = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad (19.1)$$

则 t 的密度

$$p(t) = \frac{1}{t(1-t)s\sqrt{2\pi}} \exp \left[-\frac{(\log \frac{t}{1-t} - \mu)^2}{2s^2} \right]. \quad (19.2)$$

若希望优化均匀时间目标

$$\int_0^1 \ell(t) dt, \quad (19.3)$$

却从 $p(t)$ 采样，严格无偏估计需权重 $1/p(t)$ ：

$$\mathbb{E}_{t \sim p} \frac{\ell(t)}{p(t)} = \int_0^1 \ell(t) dt. \quad (19.4)$$

论文直接改变采样分布相当于重新定义训练时间权重，集中资源到中等噪声区域。

20 Euler 采样与 x 预测器

若模型给出 $\hat{x}(x_t, t)$ ，论文线性路径下速度可写为

$$\hat{v}(x_t, t) = \frac{x_t - \hat{x}}{t}. \quad (20.1)$$

反向 Euler

$$x_{t-h} = x_t - h\hat{v}(x_t, t) = \left(1 - \frac{h}{t}\right) x_t + \frac{h}{t} \hat{x}. \quad (20.2)$$

当 $h = t$ 时一步直接得到

$$x_0 = \hat{x}. \quad (20.3)$$

多步时每一步是当前状态与干净预测的凸组合，数值稳定性取决于 $h/t \leq 1$ 和 $\hat{x}$ 的 Lipschitz 性。

21 EDM 预条件为何改变直接输出空间

EDM 形式

$$D_\theta(x, \sigma) = c_{\text{skip}}(\sigma)x + c_{\text{out}}(\sigma)F_\theta(c_{\text{in}}x, c_{\text{noise}}). \quad (21.1)$$

即使 D_θ 最终表示去噪图像，网络主干直接输出的是残差量 F_θ 。其目标梯度

$$\nabla_F \mathcal{L} = 2c_{\text{out}}[D_\theta - x_0] \quad (21.2)$$

被 c_{out} 缩放。论文强调 direct x -prediction，是要避免网络主干被要求表示高维噪声混合量，而不仅是最终公式中出现 x_0 。

22 三种预测目标的精确线性变换

采用方差保持参数化

$$x_t = \alpha_t x + \sigma_t \epsilon, \quad \alpha_t^2 + \sigma_t^2 = 1. \quad (22.1)$$

定义速度

$$v_t = \alpha_t \epsilon - \sigma_t x. \quad (22.2)$$

矩阵形式

$$\begin{pmatrix} x_t \\ v_t \end{pmatrix} = R_t \begin{pmatrix} x \\ \epsilon \end{pmatrix}, \quad R_t = \begin{pmatrix} \alpha_t & \sigma_t \\ -\sigma_t & \alpha_t \end{pmatrix}. \quad (22.3)$$

$R_t^\top R_t = I$, 故

$$x = \alpha_t x_t - \sigma_t v_t, \quad \epsilon = \sigma_t x_t + \alpha_t v_t. \quad (22.4)$$

若网络预测 $\hat{x}$, 对应噪声预测

$$\hat{\epsilon} = \frac{x_t - \alpha_t \hat{x}}{\sigma_t}. \quad (22.5)$$

23 预测误差在参数化转换中的放大

设 x 预测误差 $e_x = \hat{x} - x$ 。由上式

$$e_\epsilon = \hat{\epsilon} - \epsilon = -\frac{\alpha_t}{\sigma_t} e_x. \quad (23.1)$$

因此

$$\|e_\epsilon\|^2 = \frac{\alpha_t^2}{\sigma_t^2} \|e_x\|^2 = \text{SNR}(t) \|e_x\|^2. \quad (23.2)$$

高 SNR、低噪声时, 微小 x 误差会被放大成很大噪声误差。反过来

$$e_x = -\frac{\sigma_t}{\alpha_t} e_\epsilon, \quad (23.3)$$

低 SNR 时噪声预测误差对 x 重建被放大。

24 不同损失的等价时间权重

噪声 MSE

$$\mathcal{L}_\epsilon = \mathbb{E} \|\hat{\epsilon} - \epsilon\|^2 \quad (24.1)$$

等价于

$$\mathcal{L}_\epsilon = \mathbb{E} \left[\frac{\alpha_t^2}{\sigma_t^2} \|\hat{x} - x\|^2 \right] = \mathbb{E} [\text{SNR}(t) \|e_x\|^2]. \quad (24.2)$$

所以“预测对象不同”即使可以代数互换, 也隐含不同的时间权重。直接 x -prediction 使用近似均匀的 x 空间误差, 而 ϵ -prediction 强调高 SNR 时刻。

25 Bayes 最优去噪器是条件均值

给定带噪观测 x_t ，平方误差最优去噪器

$$f^*(x_t, t) = \arg \min_f \mathbb{E}[\|f(x_t, t) - x\|^2 \mid x_t] \quad (25.1)$$

满足

$$\boxed{f^*(x_t, t) = \mathbb{E}[x \mid x_t].} \quad (25.2)$$

证明同条件期望的正交投影：

$$\mathbb{E}\|f - x\|^2 = \mathbb{E}\|f - \mathbb{E}[x \mid x_t]\|^2 + \mathbb{E}\|x - \mathbb{E}[x \mid x_t]\|^2. \quad (25.3)$$

如果条件分布多模态，条件均值可能位于数据流形之间；但生成 ODE/SDE 通过多个时刻的去噪场组合，不等于直接输出单次条件均值作为最终样本。

26 Tweedie 公式连接去噪器与 score

高斯加噪

$$y = x + \sigma\epsilon. \quad (26.1)$$

边缘密度

$$p_\sigma(y) = \int p(x) \mathcal{N}(y; x, \sigma^2 I) dx. \quad (26.2)$$

对 y 求梯度：

$$\nabla_y p_\sigma(y) = \int p(x) \mathcal{N}(y; x, \sigma^2 I) \frac{x - y}{\sigma^2} dx. \quad (26.3)$$

除以 $p_\sigma(y)$ ：

$$\nabla_y \log p_\sigma(y) = \frac{\mathbb{E}[x \mid y] - y}{\sigma^2}. \quad (26.4)$$

因此

$$\boxed{\mathbb{E}[x \mid y] = y + \sigma^2 \nabla_y \log p_\sigma(y).} \quad (26.5)$$

直接 x 预测器与 score 预测器在 Bayes 最优时可相互转换。

27 高维高斯噪声的集中现象

若 $\epsilon \sim \mathcal{N}(0, I_D)$ ，则

$$\|\epsilon\|^2 \sim \chi_D^2, \quad \mathbb{E}\|\epsilon\|^2 = D, \quad \text{Var}(\|\epsilon\|^2) = 2D. \quad (27.1)$$

相对标准差

$$\frac{\sqrt{2D}}{D} = \sqrt{\frac{2}{D}} \rightarrow 0. \quad (27.2)$$

所以噪声几乎都落在半径 $\sqrt{D}$ 的薄壳上，覆盖所有 D 个方向。若网络输出维度小于 patch 像素维度，准确重构任意噪声向量需要高秩通道；而自然图像若近似位于低维流形，预测干净图像只需保留流形坐标。

28 线性瓶颈的最优重建误差

设 patch 向量 $x \in \mathbb{R}^D$, 线性编码宽度 $d < D$, 重建

$$\hat{x} = VUx, \quad U \in \mathbb{R}^{d \times D}, V \in \mathbb{R}^{D \times d}. \quad (28.1)$$

对零均值数据协方差 Σ , 最优 rank- d 线性自编码器等价 PCA, 最小均方误差

$$\min_{U,V} \mathbb{E} \|x - VUx\|^2 = \sum_{j>d} \lambda_j(\Sigma). \quad (28.2)$$

自然图像若特征值快速衰减, 小 d 仍可重建; 各向同性噪声 $\Sigma = I$ 时

$$\sum_{j>d} \lambda_j = D - d, \quad (28.3)$$

瓶颈会丢失大量噪声能量。这是论文流形论点的线性版本。

29 Patch 维度与网络宽度的数值例子

RGB patch 大小 $p \times p$, 输入维度

$$D = 3p^2. \quad (29.1)$$

$p = 16$ 时

$$D = 3 \times 256 = 768. \quad (29.2)$$

若 Transformer 宽度 $d = 384$, patch embedding 是从 768 到 384 的瓶颈。对任意噪声, 线性层最多保留 384 维子空间; 对自然图像 patch, 如果主要变化集中在纹理、边缘和颜色等更低维因素, 瓶颈仍可能足够。

30 Logit-Normal 时间采样与重要性加权

令

$$z \sim \mathcal{N}(\mu, s^2), \quad t = \sigma(z) = \frac{1}{1 + e^{-z}}. \quad (30.1)$$

变量变换密度

$$p(t) = \frac{1}{t(1-t)s\sqrt{2\pi}} \exp \left[-\frac{(\log \frac{t}{1-t} - \mu)^2}{2s^2} \right]. \quad (30.2)$$

若目标原本是 $t \sim \text{Uniform}(0,1)$ 的期望, 但训练改用 $p(t)$ 采样, 要保持无偏需权重

$$w(t) = \frac{1}{p(t)}. \quad (30.3)$$

实践常不做该校正, 因此时间采样分布本身就是重新加权训练目标, 而非纯粹的方差降低技巧。

31 从 x 预测器构造 ODE 速度

对于线性路径 $x_t = \alpha_t x + \sigma_t \epsilon$, 若预测 $\hat{x}$, 估计噪声

$$\hat{\epsilon} = \frac{x_t - \alpha_t \hat{x}}{\sigma_t}. \quad (31.1)$$

路径速度

$$\dot{x}_t = \dot{\alpha}_t x + \dot{\sigma}_t \epsilon. \quad (31.2)$$

代入估计得到

$$\hat{v}_t = \dot{\alpha}_t \hat{x} + \frac{\dot{\sigma}_t}{\sigma_t} (x_t - \alpha_t \hat{x}). \quad (31.3)$$

整理

$$\hat{v}_t = \frac{\dot{\sigma}_t}{\sigma_t} x_t + \left(\dot{\alpha}_t - \frac{\dot{\sigma}_t}{\sigma_t} \alpha_t \right) \hat{x}. \quad (31.4)$$

所以直接预测干净图像仍可用于 ODE 采样, 网络输出与积分速度由解析系数连接。

32 Euler 误差与网络误差分离

数值更新

$$x_{t-h}^{\text{num}} = x_t - h \hat{v}(x_t, t). \quad (32.1)$$

真解 Taylor 展开

$$x(t-h) = x_t - h v(x_t, t) + \frac{h^2}{2} \ddot{x}(\xi). \quad (32.2)$$

误差

$$x_{t-h}^{\text{num}} - x(t-h) = -h(\hat{v} - v) - \frac{h^2}{2} \ddot{x}(\xi). \quad (32.3)$$

第一项是模型误差 $O(h\epsilon)$, 第二项是离散化误差 $O(h^2)$ 。增加采样步数只降低第二项。