

33_Attention Residuals 数学过程详解

从固定残差累加到深度 Softmax 注意力

本文只处理真正需要推导的部分

本文推导标准残差展开、Jacobian 梯度、PreNorm 稀释、Full/Block AttnRes、Softmax 梯度、凸组合范数界、复杂度和有效深度。全文按“公式从哪里来-每个符号是什么-中间步骤为何成立-维度和复杂度如何核对-论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1	标准残差连接的展开	3
2	梯度高速路的乘积形式	3
3	PreNorm 的残差稀释	3
4	Full AttnRes 的深度注意力	4
5	RMSNorm 为什么必须在 Key 上	4
6	Softmax 深度权重的梯度	4
7	标准残差作为线性深度注意力	5
8	Block AttnRes 的块内和块间分解	5
9	复杂度推导	5
10	凸组合给出的范数上界	6
11	查询参数量	6
12	注意力饱和与有效深度	6
13	最终公式路线图	6
14	标准残差的完整展开与深度稀释	8

15 Full Attention Residual 的数学定义	8
16 凸组合的范数上界	8
17 Softmax 深度权重的梯度	9
18 Key 归一化为何重要	9
19 一个四层数值例子	9
20 Block AttnRes 的块级近似	10
21 复杂度逐项推导	10
22 对查询和 Key 的梯度	10
23 有效深度与注意力熵	11
24 标准残差是固定权重的特殊情形吗	11

1 标准残差连接的展开

每个注意力或 MLP 子层记为 f_l ，标准残差递推

$$h_l = h_{l-1} + f_{l-1}(h_{l-1}). \quad (1.1)$$

逐层展开：

$$h_l = h_1 + \sum_{i=1}^{l-1} f_i(h_i). \quad (1.2)$$

因此标准残差本质上对所有历史层输出赋固定权重 1，而不是仅仅“跳过一层”。

2 梯度高速路的乘积形式

由链式法则

$$\frac{\partial h_{j+1}}{\partial h_j} = I + J_j, \quad J_j = \frac{\partial f_j}{\partial h_j}. \quad (2.1)$$

于是

$$\frac{\partial \mathcal{L}}{\partial h_l} = \frac{\partial \mathcal{L}}{\partial h_L} \prod_{j=l}^{L-1} (I + J_j). \quad (2.2)$$

展开乘积必含恒等项 I ，所以即使高阶 Jacobian 乘积很小，仍有直接梯度路径。但这不保证梯度范数绝对稳定；若 J_j 的谱半径大，乘积仍可能爆炸。

3 PreNorm 的残差稀释

若各层输出 $v_i = f_i(h_i)$ 近似零均值且相互不相关，标准残差

$$h_l = h_1 + \sum_{i<l} v_i \quad (3.1)$$

的方差

$$\mathbb{E} \|h_l\|^2 \approx \mathbb{E} \|h_1\|^2 + \sum_{i<l} \mathbb{E} \|v_i\|^2 = O(l). \quad (3.2)$$

单个早期输出在总状态中的相对能量约

$$\frac{\mathbb{E} \|v_i\|^2}{\mathbb{E} \|h_l\|^2} = O(1/l). \quad (3.3)$$

这就是“dilution”：不是信息被删除，而是固定累加使每层相对贡献随深度下降。

4 Full AttnRes 的深度注意力

定义值

$$v_0 = h_1, \quad v_i = f_i(h_i), \quad 1 \leq i < l. \quad (4.1)$$

每层有可学习伪查询 $q_l = w_l \in \mathbb{R}^d$, 键

$$k_i = \text{RMSNorm}(v_i). \quad (4.2)$$

深度 logits

$$s_{i \rightarrow l} = q_l^\top k_i, \quad (4.3)$$

权重

$$\alpha_{i \rightarrow l} = \frac{e^{s_{i \rightarrow l}}}{\sum_{j=0}^{l-1} e^{s_{j \rightarrow l}}}. \quad (4.4)$$

输入状态

$$h_l = \sum_{i=0}^{l-1} \alpha_{i \rightarrow l} v_i. \quad (4.5)$$

由于 $\alpha_i \geq 0$ 且和为 1, h_l 是历史输出的凸组合。

5 RMSNorm 为什么必须在 Key 上

若不归一化, logit

$$s_i = q^\top v_i = \|q\| \|v_i\| \cos \theta_i \quad (5.1)$$

同时受方向和幅值控制。深层 $\|v_i\|$ 较大时, 即使方向不匹配也会获得高权重。RMSNorm

$$\text{RMSNorm}(v) = \frac{v}{\sqrt{d^{-1} \|v\|^2 + \epsilon}} \quad (5.2)$$

近似消除幅值, 只让查询依据方向选择深度信息。

6 Softmax 深度权重的梯度

对 $h = \sum_i \alpha_i v_i$ 、 $\alpha = \text{softmax}(s)$, 有

$$\frac{\partial h}{\partial s_j} = \alpha_j (v_j - h). \quad (6.1)$$

若上游梯度为 $g = \partial \mathcal{L} / \partial h$,

$$\frac{\partial \mathcal{L}}{\partial s_j} = \alpha_j \langle g, v_j - h \rangle. \quad (6.2)$$

当 v_j 比当前平均 h 更沿着降低损失的方向, 权重增加; 否则减小。深度选择因此是输入相关的, 但查询本身按层共享于 token, token 差异来自 keys。

7 标准残差作为线性深度注意力

令未归一化核 $\phi(q, k) = 1$ ，再不做和为 1 的归一化，得到

$$h_l = \sum_{i < l} v_i, \quad (7.1)$$

即标准残差。若做平均归一化，则是

$$h_l = \frac{1}{l} \sum_{i < l} v_i. \quad (7.2)$$

AttnRes 的数学升级是把固定线性聚合改为指数核的 Softmax 聚合。

8 Block AttnRes 的块内和块间分解

把 L 个子层分为 N 块，每块 $S = L/N$ 层。第 n 块完整表示

$$b_n = \sum_{j \in B_n} f_j(h_j). \quad (8.1)$$

块内第 i 层前的部分和

$$b_n^{(i-1)} = \sum_{j \in B_n, j < i} f_j(h_j). \quad (8.2)$$

可选值集合

$$V = \begin{cases} [b_0, b_1, \dots, b_{n-1}]^\top, & i = 1, \\ [b_0, b_1, \dots, b_{n-1}, b_n^{(i-1)}]^\top, & i > 1, \end{cases} \quad (8.3)$$

其中 $b_0 = h_1$ 。对该小集合执行同样 Softmax 深度注意力。

9 复杂度推导

Full AttnRes 第 l 层读取 l 个 d 维值，总代价

$$\sum_{l=1}^L O(ld) = O(L^2 d), \quad (9.1)$$

存储历史

$$O(Ld). \quad (9.2)$$

Block 版本每层最多读取 $N + 1$ 个表示：

$$C_{\text{block}} = O(LNd), \quad (9.3)$$

若只按块边界聚合查询可视为 $O(N^2 d)$ 的跨块核心；通信/长期缓存为

$$O(Nd). \quad (9.4)$$

$N = L$ 恢复 Full， $N = 1$ 接近标准残差。

10 凸组合给出的范数上界

因为 $\alpha_i \geq 0$ 、 $\sum_i \alpha_i = 1$,

$$\|h_l\| = \left\| \sum_i \alpha_i v_i \right\| \leq \sum_i \alpha_i \|v_i\| \leq \max_i \|v_i\|. \quad (10.1)$$

标准残差只有

$$\left\| \sum_i v_i \right\| \leq \sum_i \|v_i\|, \quad (10.2)$$

最坏随 l 线性增长。AttnRes 的归一化权重从结构上抑制隐藏状态幅值无界累积。

11 查询参数量

若每个子层有一个伪查询 $w_l \in \mathbb{R}^d$ ，新增参数

$$P_{\text{query}} = Ld. \quad (11.1)$$

相对每层 Transformer 的 $O(d^2)$ 参数，占比

$$\frac{Ld}{Ld^2} = O(1/d). \quad (11.2)$$

因此宽模型中参数开销极小；真正挑战是历史激活通信而非参数。

12 注意力饱和与有效深度

深度权重的熵

$$H_l = - \sum_i \alpha_{i \rightarrow l} \log \alpha_{i \rightarrow l} \quad (12.1)$$

定义有效参与层数

$$N_{\text{eff}} = e^{H_l}. \quad (12.2)$$

均匀权重时 $N_{\text{eff}} = l$ ；只选一层时为 1。该指标比“最大权重”更完整地描述模型实际使用的历史深度。

13 最终公式路线图

阅读完成后应掌握

本文的数学主线已经被压缩为：先明确随机变量或张量的定义，再由概率分解、微分方程、优化目标或矩阵运算得到论文核心公式；最后用维度、极限情形、参数量和复杂度进行反向

核验。遇到论文中的简写式，应先恢复被省略的条件变量、求和指标与归一化常数，再讨论其算法含义。

14 标准残差的完整展开与深度稀释

PreNorm Transformer 可写为

$$h_{\ell+1} = h_{\ell} + F_{\ell}(\text{Norm}(h_{\ell})). \quad (14.1)$$

递归展开

$$h_L = h_0 + \sum_{\ell=0}^{L-1} F_{\ell}(\text{Norm}(h_{\ell})). \quad (14.2)$$

所有层输出以固定系数 1 累加。若各增量近似独立、每维方差 σ^2 ，则

$$\text{Var}(h_L) \approx \text{Var}(h_0) + L\sigma^2. \quad (14.3)$$

某一层增量占总标准差的相对量级约

$$\frac{\sigma}{\sqrt{L}\sigma} = L^{-1/2}, \quad (14.4)$$

随深度被稀释。

15 Full Attention Residual 的数学定义

第 ℓ 层从历史表示 $h_0, \dots, h_{\ell}$ 中注意力聚合：

$$\tilde{h}_{\ell} = \sum_{j=0}^{\ell} a_{\ell j} h_j, \quad (15.1)$$

$$a_{\ell j} = \frac{\exp(q_{\ell}^{\top} k_j / \sqrt{d})}{\sum_{m=0}^{\ell} \exp(q_{\ell}^{\top} k_m / \sqrt{d})}. \quad (15.2)$$

再计算

$$h_{\ell+1} = \tilde{h}_{\ell} + F_{\ell}(\text{Norm}(\tilde{h}_{\ell})). \quad (15.3)$$

因为 $a_{\ell j} \geq 0$ 且和为 1, $\tilde{h}_{\ell}$ 是历史表示的凸组合。

16 凸组合的范数上界

由三角不等式

$$\|\tilde{h}_{\ell}\| \leq \sum_j a_{\ell j} \|h_j\| \leq \max_{j \leq \ell} \|h_j\|. \quad (16.1)$$

因此纯聚合步骤不会超过历史最大范数。标准残差求和则只有

$$\left\| \sum_j h_j \right\| \leq \sum_j \|h_j\|, \quad (16.2)$$

最坏可线性增长。该上界是 AttnRes 抑制隐藏状态无控制增长的核心数学性质。

17 Softmax 深度权重的梯度

分数 $s_j = q^\top k_j / \sqrt{d}$, 权重 $a_j = \text{softmax}(s)_j$ 。输出

$$\tilde{h} = \sum_j a_j h_j. \quad (17.1)$$

对分数 s_m :

$$\frac{\partial \tilde{h}}{\partial s_m} = \sum_j a_j (\mathbf{1}[j = m] - a_m) h_j \quad (17.2)$$

$$= a_m (h_m - \tilde{h}). \quad (17.3)$$

如果历史状态 h_m 与当前聚合输出差异大且有利于损失, 分数梯度会调整其权重; 若 $h_m \approx \tilde{h}$, 改变其权重影响小。

18 Key 归一化为何重要

若 key 不归一化, 分数

$$s_j = q^\top k_j = \|q\| \|k_j\| \cos \theta_j \quad (18.1)$$

同时受方向相似度和 key 范数影响。深层表示范数若更大, 会仅靠尺度获得更高注意力。RM-SNorm 后

$$\|\hat{k}_j\| \approx \sqrt{d}, \quad (18.2)$$

分数近似

$$s_j \approx \|q\| \sqrt{d} \cos \theta_j, \quad (18.3)$$

更接近纯方向相似度。

19 一个四层数值例子

历史标量状态

$$h = (1, 2, 5, 4), \quad (19.1)$$

若标准残差累加, 值为 12。若 AttnRes 权重

$$a = (0.1, 0.2, 0.5, 0.2), \quad (19.2)$$

则

$$\tilde{h} = 0.1 + 0.4 + 2.5 + 0.8 = 3.8. \quad (19.3)$$

它位于历史最小值 1 与最大值 5 之间。权重集中在第三层, 说明当前层认为第三层表示最有用, 而非机械地等权累加。

20 Block AttnRes 的块级近似

把 L 层分成 B 个块，每块 $m = L/B$ 层。块摘要 c_b 可由块内最后状态或可学习聚合得到。第 b 块只对 $c_{0:b}$ 做深度注意力：

$$\tilde{c}_b = \sum_{j=0}^b a_{bj} c_j. \quad (20.1)$$

缓存从所有层的 $O(Ld)$ 降为

$$O(Bd) = O\left(\frac{L}{m}d\right). \quad (20.2)$$

如果块摘要近似块内状态 h_{jm+r} ，误差

$$\|h_{jm+r} - c_j\| \leq \delta_j, \quad (20.3)$$

则用块摘要替代精细层注意力的输出误差上界

$$\left\| \sum_{j,r} w_{jr} h_{jm+r} - \sum_j \bar{w}_j c_j \right\| \leq \sum_j \bar{w}_j \delta_j + \text{权重聚合误差}. \quad (20.4)$$

21 复杂度逐项推导

Full AttnRes 第 ℓ 层对 $\ell + 1$ 个历史状态计算分数，全部层深度分数数目

$$\sum_{\ell=0}^{L-1} (\ell + 1) = \frac{L(L+1)}{2} = O(L^2). \quad (21.1)$$

每个分数是 d 维点积，总成本

$$O(L^2 d). \quad (21.2)$$

Block AttnRes 只有 $B = L/m$ 个块摘要，块间分数成本

$$O(B^2 d) = O\left(\frac{L^2}{m^2} d\right). \quad (21.3)$$

再加块内 $O(Lmd)$ 或普通残差开销。 m 越大，块间成本越低，但近似更粗。

22 对查询和 Key 的梯度

分数 $s_j = q^\top k_j / \sqrt{d}$ 。利用

$$\frac{\partial \tilde{h}}{\partial s_j} = a_j (h_j - \tilde{h}), \quad (22.1)$$

有

$$\frac{\partial \tilde{h}}{\partial q} = \frac{1}{\sqrt{d}} \sum_j a_j (h_j - \tilde{h}) k_j^\top, \quad (22.2)$$

$$\frac{\partial \tilde{h}}{\partial k_j} = \frac{a_j}{\sqrt{d}}(h_j - \tilde{h})q^\top. \quad (22.3)$$

如果 softmax 极度饱和，最大权重接近 1，其 $h_j - \tilde{h} \approx 0$ ，梯度反而变小，可能难以从错误的单层选择中恢复。

23 有效深度与注意力熵

深度权重熵

$$H(a_\ell) = - \sum_{j \leq \ell} a_{\ell j} \log a_{\ell j}. \quad (23.1)$$

定义有效历史层数

$$N_{\text{eff}} = e^{H(a_\ell)}. \quad (23.2)$$

若均匀关注 m 层， $N_{\text{eff}} = m$ ；若只关注一层， $N_{\text{eff}} = 1$ 。该量比最大权重更完整地描述模型实际使用的深度范围。

24 标准残差是固定权重的特殊情形吗

标准展开

$$h_L = h_0 + \sum_{j=0}^{L-1} F_j \quad (24.1)$$

可看成对增量 F_j 使用固定权重 1，但不是对历史状态 h_j 的 convex attention。AttnRes 聚合的是状态而非仅增量，并带 softmax 归一化。因此标准残差并不能通过简单设置 $a_j = 1$ 直接得到，因为 softmax 权重和必须为 1；二者只有在重新参数化和尺度补偿后才能对应。