

39_Continuous Thought Machines 数学过程详解

神经元历史模型、同步矩阵与确定度自适应计算

本文只处理真正需要推导的部分

本文逐式推导内部 tick、私人 NLM、同步 Gram 矩阵、指数衰减递推、pair subsampling、同步注意力、熵确定度、双 tick 损失和停机期望。全文按“公式从哪里来–每个符号是什么–中间步骤为何成立–维度和复杂度如何核对–论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1	CTM 的内部时间轴	4
2	每个神经元的私人时间模型	4
3	同步矩阵作为 latent representation	4
4	归一化指数衰减同步	5
5	同步的递推计算	5
6	Pair Subsampling 的维度	5
7	同步如何驱动外部注意力	6
8	确定度的熵定义	6
9	双 tick 损失	6
10	argmin/argmax 选择的梯度	6
11	自适应停机	7
12	与普通 RNN 的状态维度差异	7
13	同步尺度不变性与局限	7
14	私人神经元时间模型的卷积形式	7

15 时间核的频率响应	8
16 同步矩阵是 Gram 矩阵	8
17 指数衰减同步的归一化	8
18 递推与时间复杂度	9
19 随机 pair subsampling 的估计性质	9
20 同步注意力的维度链	9
21 熵确定度的边界与梯度	10
22 双 tick 选择的次梯度	10
23 BPTT 的时间 Jacobian	10
24 自适应停机的风险-计算目标	11
25 CTM 的双时间尺度	12
26 每个神经元的私人时间模型	12
27 时间核的频率响应	12
28 同步矩阵是 Gram 矩阵	12
29 指数衰减同步的递推	13
30 归一化相关系数的递推	13
31 随机 pair subsampling 的无偏估计	13
32 同步表示驱动注意力的维度链	14
33 熵确定度的边界与梯度	14
34 双 tick 损失与不可导选择	14
35 BPTT 时间 Jacobian	15

36 自适应停机的风险-计算目标	15
37 三个神经元的同步数值例子	16

1 CTM 的内部时间轴

静态输入也在内部 tick $t = 1, \dots, T$ 上迭代。神经元状态

$$z_t \in \mathbb{R}^D, \quad (1.1)$$

与数据注意力输出 o_t 经过共享突触网络

$$a_t = f_{\theta_{\text{syn}}}([z_t; o_t]) \in \mathbb{R}^D. \quad (1.2)$$

最近 M 个 pre-activation 组成

$$A_t = [a_{t-M+1}, \dots, a_t] \in \mathbb{R}^{D \times M}. \quad (1.3)$$

2 每个神经元的私人时间模型

第 d 个神经元取历史行向量 $A_t^{(d)} \in \mathbb{R}^M$ ，用独立参数

$$z_{t+1,d} = g_{\theta_d}(A_t^{(d)}). \quad (2.1)$$

若一层 MLP 宽度 h :

$$g_{\theta_d}(u) = w_{2,d}^\top \sigma(W_{1,d}u + b_{1,d}) + b_{2,d}. \quad (2.2)$$

参数量约

$$P_{\text{NLM}} = D(hM + h + h + 1) = O(DhM), \quad (2.3)$$

区别于标准 RNN 的共享时间更新矩阵：CTM 的每个神经元对自己的历史有不同滤波器。

3 同步矩阵作为 latent representation

收集后激活历史

$$Z_t = [z_1, z_2, \dots, z_t] \in \mathbb{R}^{D \times t}. \quad (3.1)$$

同步矩阵

$$S_t = Z_t Z_t^\top \in \mathbb{R}^{D \times D}, \quad (3.2)$$

元素

$$S_{t,ij} = \sum_{\tau=1}^t z_{\tau,i} z_{\tau,j}. \quad (3.3)$$

它是未中心化时间相关矩阵。对角线是神经元历史能量，非对角线是共同激活；比单帧 z_t 包含更长时间结构。

4 归一化指数衰减同步

每对神经元有 $r_{ij} \geq 0$, 权重

$$w_\tau = e^{-r_{ij}(t-\tau)}. \quad (4.1)$$

论文同步量

$$S_{t,ij}^{(r)} = \frac{\sum_{\tau=1}^t w_\tau z_{\tau,i} z_{\tau,j}}{\sqrt{\sum_{\tau=1}^t w_\tau}}. \quad (4.2)$$

$r = 0$ 时平等使用全历史; r 大时只看最近 tick。有效时间常数约

$$\tau_{\text{eff}} \approx 1/r \quad (4.3)$$

(离散小 r 情形)。

5 同步的递推计算

定义分子和归一化量

$$P_t = \sum_{\tau=1}^t e^{-r(t-\tau)} z_{\tau,i} z_{\tau,j}, \quad Q_t = \sum_{\tau=1}^t e^{-r(t-\tau)}. \quad (5.1)$$

则

$$P_{t+1} = e^{-r} P_t + z_{t+1,i} z_{t+1,j}, \quad (5.2)$$

$$Q_{t+1} = e^{-r} Q_t + 1. \quad (5.3)$$

同步量 $S_{t,ij} = P_t / \sqrt{Q_t}$ 。每个选中 neuron pair 每 tick 只需 $O(1)$ 更新, 无需保存完整 Z_t 。

6 Pair Subsampling 的维度

完整 S_t 有 D^2 元素。随机选 D_{action} 对形成

$$s_t^{\text{action}} \in \mathbb{R}^{D_{\text{action}}}, \quad (6.1)$$

再投影为注意力 query

$$q_t = W_{\text{in}} s_t^{\text{action}}. \quad (6.2)$$

另选 D_{out} 对

$$y_t = W_{\text{out}} s_t^{\text{out}}. \quad (6.3)$$

计算从 $O(D^2 t)$ 降为 $O((D_{\text{action}} + D_{\text{out}})t)$, 但随机子采样只保留部分二阶关系。

7 同步如何驱动外部注意力

数据特征 $K, V = F(x)$, query 来自内部同步:

$$o_t = \text{Attention}(q_t, K, V) = \text{softmax}\left(\frac{q_t K^\top}{\sqrt{d}}\right) V. \quad (7.1)$$

因此下一个内部状态依赖

$$z_{t+1} = G(z_{\leq t}, \text{Attention}(S_t, F(x))). \quad (7.2)$$

注意位置不是固定扫描, 而是由过去神经动态的二阶统计自适应决定。

8 确定度的熵定义

类别分布 $p_t = \text{softmax}(y_t)$, 熵

$$H_t = - \sum_{c=1}^C p_{t,c} \log p_{t,c}. \quad (8.1)$$

最大熵为 $\log C$, 归一化确定度

$$C_t = 1 - \frac{H_t}{\log C}. \quad (8.2)$$

均匀分布时 $C_t = 0$, one-hot 极限时 $C_t = 1$ 。这衡量分布尖锐度, 不保证预测正确。

9 双 tick 损失

每 tick 交叉熵

$$L_t = -\log p_t(y). \quad (9.1)$$

选择

$$t_1 = \arg \min_t L_t, \quad t_2 = \arg \max_t C_t, \quad (9.2)$$

总损失

$$\mathcal{L} = \frac{L_{t_1} + L_{t_2}}{2}. \quad (9.3)$$

第一项奖励任意时刻出现正确解; 第二项要求“最自信的时刻也要正确”, 抑制错误高置信度。

10 argmin/argmax 选择的梯度

选择索引视为离散常数, 反向只通过两个 tick:

$$\nabla_{\theta} \mathcal{L} = \frac{1}{2} (\nabla_{\theta} L_{t_1} + \nabla_{\theta} L_{t_2}). \quad (10.1)$$

索引切换边界处损失不可微, 但几乎处处可用子梯度。缺点是其它 tick 无直接监督; 共享递归参数仍会通过 BPTT 间接收到梯度。

11 自适应停机

给定阈值 τ ，停机时间

$$T_\tau = \min\{t : C_t \geq \tau\} \wedge T. \quad (11.1)$$

期望计算

$$\mathbb{E}[T_\tau] = \sum_{t=0}^{T-1} \Pr(T_\tau > t). \quad (11.2)$$

提高 τ 通常增加计算和准确率；若确定度未校准，早停可能把自信错误提前输出。

12 与普通 RNN 的状态维度差异

普通 RNN 用 $z_t \in \mathbb{R}^D$ 作为全部状态。CTM 用同步向量，潜在二阶维度可达

$$\frac{D(D+1)}{2}. \quad (12.1)$$

即使只采样 P 对，仍等价于从高维二阶特征映射

$$\varphi(Z_t) = \{\langle Z_{t,i}, Z_{t,j} \rangle\}_{(i,j)} \quad (12.2)$$

中选坐标。这类似二次核特征，能线性读出单个神经元状态无法表示的相位/同步关系。

13 同步尺度不变性与局限

若所有历史状态乘 a ，

$$S_t \mapsto a^2 S_t. \quad (13.1)$$

因此同步不是幅值不变。可选的相关系数归一化

$$\rho_{ij} = \frac{S_{ij}}{\sqrt{S_{ii}S_{jj}}} \quad (13.2)$$

会去除尺度，但论文保留能量信息。其代价是激活幅值可能主导同步，需依赖归一化和训练稳定性。

14 私人神经元时间模型的卷积形式

CTM 每个神经元 i 不只看当前 pre-activation，而是看长度 M 的历史

$$a_{t-M+1:t,i}. \quad (14.1)$$

线性私人模型可写成一维因果卷积

$$z_{t,i} = \sum_{m=0}^{M-1} w_{i,m} a_{t-m,i} + b_i. \quad (14.2)$$

不同神经元拥有不同核 w_i ，因此同一输入脉冲可产生不同延迟、振荡或积分响应。若再接非线性 ϕ ,

$$z_{t,i} = \phi(w_i^\top a_{t-M+1:t,i} + b_i). \quad (14.3)$$

这相当于每个神经元有私人 FIR 动力系统，而普通 MLP 神经元只对应 $M = 1$ 。

15 时间核的频率响应

线性核的离散 Fourier 响应

$$H_i(e^{i\omega}) = \sum_{m=0}^{M-1} w_{i,m} e^{-i\omega m}. \quad (15.1)$$

不同 w_i 可形成低通、高通或带通神经元。同步表示随后计算不同频率响应之间的相关性，因此 CTM 的时间处理不只是“多迭代几次”，而是在神经元层面学习不同时间滤波器。

16 同步矩阵是 Gram 矩阵

收集每个神经元历史向量

$$Z_i = [z_{1,i}, \dots, z_{t,i}]^\top. \quad (16.1)$$

同步

$$S_{ij} = Z_i^\top Z_j. \quad (16.2)$$

矩阵形式

$$S = Z^\top Z. \quad (16.3)$$

因此

$$S \succeq 0, \quad \text{rank}(S) \leq t. \quad (16.4)$$

对任意 c ,

$$c^\top S c = \|Zc\|^2 \geq 0. \quad (16.5)$$

同步表示本质是神经元时间轨迹的二阶 Gram 特征。

17 指数衰减同步的归一化

权重

$$w_\tau = e^{-r(t-\tau)}. \quad (17.1)$$

加权内积

$$P_{ij} = \sum_{\tau} w_\tau z_{\tau,i} z_{\tau,j}. \quad (17.2)$$

论文除以 $\sqrt{\sum w_\tau}$ 而不是 $\sum w_\tau$:

$$S_{ij} = P_{ij}/\sqrt{Q}, \quad Q = \sum w_\tau. \quad (17.3)$$

若 z_i, z_j 是独立零均值、方差固定随机序列, 则 P_{ij} 标准差约与 $\sqrt{\sum w_\tau^2}$ 成正比; 平方根归一化使统计尺度随有效窗口增长更慢, 接近保持随机相关量的方差, 而非计算普通加权平均。

18 递推与时间复杂度

令衰减因子 $\lambda = e^{-r}$,

$$P_t = \sum_{\tau=1}^t \lambda^{t-\tau} z_{\tau,i} z_{\tau,j}. \quad (18.1)$$

则

$$P_{t+1} = \lambda P_t + z_{t+1,i} z_{t+1,j}, \quad (18.2)$$

$$Q_{t+1} = \lambda Q_t + 1. \quad (18.3)$$

若只采样 P 对神经元, 每 tick 成本 $O(P)$ 、状态 $O(P)$; 若完整计算所有对, 则成本和存储 $O(D^2)$ 。

19 随机 pair subsampling 的估计性质

完整同步特征有 $D(D+1)/2$ 个。若均匀随机采样集合 $\mathcal{P}$, 大小 P , 对某线性读出

$$y = \sum_{i \leq j} a_{ij} S_{ij} \quad (19.1)$$

可构造无偏估计

$$\hat{y} = \frac{D(D+1)/2}{P} \sum_{(i,j) \in \mathcal{P}} a_{ij} S_{ij}. \quad (19.2)$$

方差随 $1/P$ 下降, 但论文实际把采样坐标输入可训练投影, 并不显式做该重要性缩放; 它学习的是一个随机二阶子空间, 而非完整同步读出的无偏 Monte Carlo 近似。

20 同步注意力的维度链

选中同步向量

$$s_t \in \mathbb{R}^P, \quad (20.1)$$

线性投影

$$q_t = W_q s_t, \quad W_q \in \mathbb{R}^{d_k \times P}. \quad (20.2)$$

外部特征 $K \in \mathbb{R}^{N \times d_k}$ 、 $V \in \mathbb{R}^{N \times d_v}$, 注意力

$$o_t = \text{softmax}(K q_t / \sqrt{d_k})^\top V. \quad (20.3)$$

因此外部读取位置由内部二阶历史 s_t 决定，梯度链为

$$\frac{\partial \mathcal{L}}{\partial s_t} = W_q^\top \frac{\partial q_t}{\partial s_t} \frac{\partial o_t}{\partial q_t} \frac{\partial \mathcal{L}}{\partial o_t}. \quad (20.4)$$

同步不是仅用于最终分类，而会反向塑造每个 tick 的观察策略。

21 熵确定度的边界与梯度

归一化确定度

$$C(p) = 1 + \frac{1}{\log K} \sum_{k=1}^K p_k \log p_k. \quad (21.1)$$

由熵界 $0 \leq H(p) \leq \log K$ ，有 $0 \leq C \leq 1$ 。对概率

$$\frac{\partial C}{\partial p_k} = \frac{\log p_k + 1}{\log K}. \quad (21.2)$$

通过 softmax logit a_j ,

$$\frac{\partial C}{\partial a_j} = \sum_k \frac{\partial C}{\partial p_k} p_k (\delta_{kj} - p_j). \quad (21.3)$$

高确定度只表示分布尖锐，不表示 calibration；错误 one-hot 同样有 $C = 1$ 。

22 双 tick 选择的次梯度

损失

$$\mathcal{L} = \frac{1}{2}(L_{t_1} + L_{t_2}), \quad t_1 = \arg \min_t L_t, \quad t_2 = \arg \max_t C_t. \quad (22.1)$$

在唯一极值且索引不变的邻域，

$$\nabla \mathcal{L} = \frac{1}{2}(\nabla L_{t_1} + \nabla L_{t_2}). \quad (22.2)$$

当两个 tick 值相等时索引发生跳变，目标不可微，可取活跃极值集合梯度的凸包作为 Clarke 次梯度。实践的 argmin/argmax 选择等价于选择其中一个子梯度。

23 BPTT 的时间 Jacobian

递归状态

$$h_{t+1} = F_\theta(h_t, o_t). \quad (23.1)$$

最终损失对早期状态

$$\frac{\partial \mathcal{L}}{\partial h_t} = \prod_{s=t}^{T-1} J_{F,h}(h_s) \frac{\partial \mathcal{L}}{\partial h_T} + \dots. \quad (23.2)$$

若 Jacobian 谱半径长期大于 1，梯度爆炸；小于 1，梯度消失。CTM 虽在内部引入多 tick，仍需处理普通递归网络的稳定性问题，通常依靠归一化、残差和截断 tick 数。

24 自适应停机的风险-计算目标

停机时间

$$T_\tau = \min\{t : C_t \geq \tau\} \wedge T_{\max}. \quad (24.1)$$

可把计算惩罚纳入训练

$$J(\theta) = \mathbb{E}[L_{T_\tau} + \lambda T_\tau]. \quad (24.2)$$

T_τ 离散不可微，可用每 tick 停机概率 $h_t = \sigma(a_t)$ 构造可微期望

$$\Pr(T = t) = h_t \prod_{s < t} (1 - h_s), \quad (24.3)$$

再优化

$$\sum_t \Pr(T = t)(L_t + \lambda t). \quad (24.4)$$

论文的阈值停机更简单，但阈值必须在验证集上校准。

25 CTM 的双时间尺度

外部数据步记为 t ，内部思考 tick 记为 $s = 1, \dots, S$ 。对固定输入 x_t ，模型在内部时间上递推

$$h^{(s+1)} = F_\theta(h^{(s)}, x_t, a^{(s)}). \quad (25.1)$$

输出可在任意 tick 读取

$$y^{(s)} = G_\theta(h^{(s)}). \quad (25.2)$$

因此计算图不是普通“一层一表示”，而是同一输入上形成长度 S 的内部动力系统。

26 每个神经元的私人时间模型

设第 i 个神经元接收过去 M 个预激活

$$z_i^{(s-M+1:s)}. \quad (26.1)$$

私人时间模型可写为

$$h_i^{(s)} = \phi_i \left(\sum_{\tau=0}^{M-1} w_{i\tau} z_i^{(s-\tau)} + b_i \right). \quad (26.2)$$

不同神经元拥有不同时间核 w_i ，相当于 depthwise temporal convolution。若再用 MLP，

$$h_i^{(s)} = g_i(z_i^{(s-M+1:s)}), \quad (26.3)$$

则每个神经元可以学习非线性时间模式。

27 时间核的频率响应

线性部分

$$y_i^{(s)} = \sum_{\tau=0}^{M-1} w_{i\tau} z_i^{(s-\tau)} \quad (27.1)$$

的离散频率响应

$$H_i(e^{i\omega}) = \sum_{\tau=0}^{M-1} w_{i\tau} e^{-i\omega\tau}. \quad (27.2)$$

某些神经元可学低通核，整合长期趋势；另一些可学高通或带通核，响应变化和振荡。CTM 的异质时间处理在数学上表现为不同 $H_i(\omega)$ 。

28 同步矩阵是 Gram 矩阵

设每个神经元在最近窗口的活动向量

$$a_i = (h_i^{(s-M+1)}, \dots, h_i^{(s)})^\top \in \mathbb{R}^M. \quad (28.1)$$

同步可定义为归一化内积

$$S_{ij} = \frac{a_i^\top a_j}{\|a_i\| \|a_j\| + \epsilon}. \quad (28.2)$$

若先归一化 $\tilde{a}_i = a_i / \|a_i\|$, 则

$$S = \tilde{A}^\top \tilde{A}. \quad (28.3)$$

所以 $S \succeq 0$, 对角线为 1, 秩不超过窗口长度 M 。同步表示并非任意矩阵, 而受 Gram 几何约束。

29 指数衰减同步的递推

对乘积 $h_i^{(s)} h_j^{(s)}$ 做指数移动平均:

$$C_{ij}^{(s)} = \lambda C_{ij}^{(s-1)} + (1 - \lambda) h_i^{(s)} h_j^{(s)}. \quad (29.1)$$

展开

$$C_{ij}^{(s)} = (1 - \lambda) \sum_{k=0}^{s-1} \lambda^k h_i^{(s-k)} h_j^{(s-k)} + \lambda^s C_{ij}^{(0)}. \quad (29.2)$$

有效记忆长度约

$$\tau_{\text{eff}} \approx \frac{1}{1 - \lambda}. \quad (29.3)$$

例如 $\lambda = 0.99$, 约整合最近 100 个 tick。

30 归一化相关系数的递推

同时维护

$$V_i^{(s)} = \lambda V_i^{(s-1)} + (1 - \lambda) (h_i^{(s)})^2. \quad (30.1)$$

归一化同步

$$S_{ij}^{(s)} = \frac{C_{ij}^{(s)}}{\sqrt{V_i^{(s)} V_j^{(s)}} + \epsilon}. \quad (30.2)$$

若所有活动乘同一尺度 c , 分子乘 c^2 , 分母也乘 c^2 , 同步近似不变。因此它主要编码共同变化方向而非绝对幅值。

31 随机 pair subsampling 的无偏估计

完整同步有 $n(n-1)/2$ 对, 成本 $O(n^2)$ 。若均匀采样 K 对集合 $\mathcal{P}$, 估计平均同步损失

$$\hat{L} = \frac{M}{K} \sum_{(i,j) \in \mathcal{P}} \ell(S_{ij}), \quad M = \frac{n(n-1)}{2}. \quad (31.1)$$

若无放回均匀采样,

$$\mathbb{E}[\hat{L}] = \sum_{i < j} \ell(S_{ij}) = L. \quad (31.2)$$

方差随 K 增大而下降。若采样概率不均匀 p_{ij} , 需 Horvitz–Thompson 权重

$$\hat{L} = \frac{1}{K} \sum_{(i,j) \sim p} \frac{\ell(S_{ij})}{p_{ij}}. \quad (31.3)$$

32 同步表示驱动注意力的维度链

选取 K 个神经元对同步值组成

$$s^{(s)} \in \mathbb{R}^K. \quad (32.1)$$

线性投影为查询

$$q^{(s)} = W_q s^{(s)} \in \mathbb{R}^{d_a}. \quad (32.2)$$

外部视觉或序列 token 为

$$X \in \mathbb{R}^{T \times d_x}, \quad (32.3)$$

键值

$$K = XW_K \in \mathbb{R}^{T \times d_a}, \quad V = XW_V \in \mathbb{R}^{T \times d_v}. \quad (32.4)$$

注意力

$$a^{(s)} = \text{softmax} \left(\frac{q^{(s)} K^\top}{\sqrt{d_a}} \right) V \in \mathbb{R}^{d_v}. \quad (32.5)$$

这样内部神经同步决定下一 tick 从外部输入读取什么。

33 熵确定度的边界与梯度

分类概率 $p \in \Delta^{C-1}$, 熵

$$H(p) = - \sum_{c=1}^C p_c \log p_c. \quad (33.1)$$

归一化确定度

$$\kappa = 1 - \frac{H(p)}{\log C}. \quad (33.2)$$

均匀分布时 $H = \log C, \kappa = 0$; one-hot 时 $H = 0, \kappa = 1$ 。对 logit z_j , 利用 softmax Jacobian 可得

$$\frac{\partial H}{\partial z_j} = -p_j(\log p_j + H). \quad (33.3)$$

确定度梯度为其相反数除以 $\log C$ 。

34 双 tick 损失与不可导选择

若训练选择最小损失 tick

$$s_{\min} = \arg \min_s \ell^{(s)}, \quad (34.1)$$

最大确定度 tick

$$s_{\max} = \arg \max_s \kappa^{(s)}, \quad (34.2)$$

目标

$$\mathcal{L} = \ell^{(s_{\min})} + \ell^{(s_{\max})}. \quad (34.3)$$

argmin/argmax 对参数是分段常数，反向只流过被选 tick。选择边界处梯度不连续。软替代可用

$$w_s = \frac{e^{-\ell^{(s)}/\tau}}{\sum_r e^{-\ell^{(r)}/\tau}}, \quad \mathcal{L}_{\text{soft}} = \sum_s w_s \ell^{(s)}, \quad (34.4)$$

温度 $\tau \rightarrow 0$ 时逼近最小值。

35 BPTT 时间 Jacobian

内部递推 $h^{(s+1)} = F(h^{(s)})$ ，最终损失对早期状态

$$\frac{\partial \mathcal{L}}{\partial h^{(s)}} = \left(\prod_{r=s}^{S-1} J_r^\top \right) \frac{\partial \mathcal{L}}{\partial h^{(S)}}. \quad (35.1)$$

若 $\|J_r\|_2 \leq \rho$,

$$\left\| \frac{\partial \mathcal{L}}{\partial h^{(s)}} \right\| \leq \rho^{S-s} \left\| \frac{\partial \mathcal{L}}{\partial h^{(S)}} \right\|. \quad (35.2)$$

$\rho < 1$ 梯度衰减， $\rho > 1$ 爆炸。CTM 的内部 tick 增加了自适应计算，也带来与 RNN 相同的长时梯度问题。

36 自适应停机的风险-计算目标

设每个 tick 的停机概率 p_s ，首次停机分布

$$q_s = p_s \prod_{r < s} (1 - p_r). \quad (36.1)$$

期望任务损失

$$\mathbb{E}_q[\ell] = \sum_s q_s \ell^{(s)}, \quad (36.2)$$

期望计算

$$\mathbb{E}_q[s] = \sum_s s q_s. \quad (36.3)$$

联合目标

$$\mathcal{L}_{\text{ACT}} = \sum_s q_s \ell^{(s)} + \lambda \sum_s s q_s. \quad (36.4)$$

λ 控制准确率与思考时间。仅用置信度阈值停机可能在过度自信样本上过早停止，因此需要校准。

37 三个神经元的同步数值例子

最近三 tick 活动

$$a_1 = (1, 2, 3), \quad a_2 = (2, 4, 6), \quad a_3 = (3, 2, 1). \quad (37.1)$$

$a_2 = 2a_1$, 余弦同步

$$S_{12} = 1. \quad (37.2)$$

而

$$S_{13} = \frac{1 \cdot 3 + 2 \cdot 2 + 3 \cdot 1}{\sqrt{14}\sqrt{14}} = \frac{10}{14} \approx 0.714. \quad (37.3)$$

同步表示能区分“同方向不同尺度”和“相反时间趋势”。