

44_Mapping Networks 数学过程详解

权重流形、映射定理与 Mapping Loss

本文只处理真正需要推导的部分

本文展开权重流形假设、局部坐标图、Lipschitz 误差链、Taylor 可解性、Jacobian 秩约束、梯度投影以及稳定/平滑/对齐正则项。。全文按“公式从哪里来-每个符号是什么-中间步骤为何成立-维度和复杂度如何核对-论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1	权重流形假设	4
2	Mapping Theorem 的误差链	4
3	局部坐标图扩展为全局平滑映射	4
4	局部 Taylor 可解性	5
5	生成参数的 Jacobian 秩	5
6	固定映射权重与加性调制	6
7	梯度如何穿过生成权重	6
8	参数量与压缩比	6
9	Mapping Loss 的四项	7
10	稳定性项的二阶近似	7
11	平滑性项	7
12	对齐项及其几何意义	8
13	理论边界	8
14	局部坐标与切空间	8

15 曲率导致的二阶偏离	9
16 潜变量最速下降是投影梯度	9
17 不可辨识性	9
18 加性调制的表达秩	9
19 稳定性项与随机平滑	10
20 smoothness 正则的 Hutchinson 估计	10
21 余弦对齐的尺度不辨识	10
22 训练参数少不等于生成器便宜	11
23 存在性定理与可训练性的差别	11
24 参数流形与局部坐标	12
25 Mapping Theorem 的误差链	12
26 局部坐标扩展为全局平滑映射	12
27 潜变量梯度是参数梯度的切空间投影	13
28 Jacobian 秩限制与表达维度	13
29 曲率导致的二阶偏离	13
30 不可辨识性与潜空间对称	13
31 加性调制映射的表达秩	14
32 随机平滑稳定性项	14
33 Hutchinson 迹估计	14
34 参数量与生成成本	15
35 一个曲线流形例子	15

36 存在性与可训练性的区别

15

1 权重流形假设

目标网络参数展平为

$$\theta \in \mathbb{R}^P. \quad (1.1)$$

论文假设有效训练解位于低维嵌入流形

$$\mathcal{M}_\theta \subset \mathbb{R}^P, \quad d = \dim \mathcal{M}_\theta \ll P. \quad (1.2)$$

因此存在局部坐标图

$$\phi : U \subset \mathbb{R}^d \rightarrow V \subset \mathcal{M}_\theta, \quad \phi(0) = \theta^*. \quad (1.3)$$

这并不意味着任意权重都能由 d 维向量生成，而是只要求最优解附近的有效参数集合具有低内在维度。

2 Mapping Theorem 的误差链

论文使用两个 Lipschitz 条件。网络输出关于参数满足

$$\|f_{\theta_1}(x) - f_{\theta_2}(x)\| \leq L_\theta \|\theta_1 - \theta_2\|_2, \quad (2.1)$$

损失关于输出满足

$$|\ell(a, y) - \ell(b, y)| \leq L_\ell \|a - b\|. \quad (2.2)$$

复合后

$$|\mathcal{L}(\theta_1) - \mathcal{L}(\theta_2)| \leq L_\ell \|f_{\theta_1} - f_{\theta_2}\| \quad (2.3)$$

$$\leq L_\ell L_\theta \|\theta_1 - \theta_2\|_2. \quad (2.4)$$

给定允许损失误差 ϵ ，只需生成参数满足

$$\|g(z) - \theta^*\|_2 < \delta, \quad \delta = \frac{\epsilon}{L_\ell L_\theta}. \quad (2.5)$$

即可推出

$$\boxed{|\mathcal{L}(g(z)) - \mathcal{L}(\theta^*)| < \epsilon.} \quad (2.6)$$

这条误差链是 Mapping Theorem 的核心，而不是“低维一定更优”的无条件结论。

3 局部坐标图扩展为全局平滑映射

坐标图 ϕ 只在 U 内定义。取光滑 bump 函数

$$\psi : \mathbb{R}^d \rightarrow [0, 1], \quad (3.1)$$

使其在 $U' \in U$ 上为 1, 在 U 外为 0。定义

$$g(u) = \psi(u)\phi(u) + (1 - \psi(u))\theta^*. \quad (3.2)$$

在 U' 内 $g = \phi$, 在 U 外 $g = \theta^*$, 过渡区由光滑函数拼接, 所以 $g \in C^2(\mathbb{R}^d, \mathbb{R}^P)$ 。由 ϕ 在零点连续, 存在 $\eta > 0$ 使

$$\|u\| < \eta \Rightarrow \|g(u) - \theta^*\| < \delta. \quad (3.3)$$

于是任选 $z^* \in B(0, \eta)$ 即得到上述损失误差界。这个存在性证明本身并不保证实际小网络容易学到该 g 。

4 局部 Taylor 可解性

在初始点 z_0 对生成器展开:

$$g(z_0 + \Delta z) = g(z_0) + J_g(z_0)\Delta z + \frac{1}{2}\mathcal{H}_g[\Delta z, \Delta z] + O(\|\Delta z\|^3). \quad (4.1)$$

令残差

$$r_\theta = \theta^* - g(z_0). \quad (4.2)$$

若 r_θ 落在 Jacobian 的列空间且 J_g 在该子空间满秩, 可取最小范数修正

$$\Delta z = J_g(z_0)^+ r_\theta, \quad (4.3)$$

其中 $+$ 为 Moore–Penrose 伪逆。于是一次线性项抵消残差, 剩余误差

$$\|g(z_0 + \Delta z) - \theta^*\| = O(\|\Delta z\|^2) = O(\|r_\theta\|^2). \quad (4.4)$$

再用 Lipschitz 误差链得到

$$|\mathcal{L}(g(z_0 + \Delta z)) - \mathcal{L}(\theta^*)| = O(\|r_\theta\|^2). \quad (4.5)$$

5 生成参数的 Jacobian 秩

生成器

$$g_\phi : \mathbb{R}^d \rightarrow \mathbb{R}^P \quad (5.1)$$

的 Jacobian 为 $J_g \in \mathbb{R}^{P \times d}$, 故

$$\text{rank}(J_g) \leq d \ll P. \quad (5.2)$$

任意小的潜变量更新引起

$$\Delta \theta \approx J_g \Delta z. \quad (5.3)$$

因此训练轨迹的瞬时切空间被限制在至多 d 维, 这就是结构性正则化的数学来源。它也说明风险: 若最优下降方向在 $\text{col}(J_g)$ 外, 映射网络无法表示该方向。

6 固定映射权重与加性调制

论文令基础映射权重为 ω_0 ，潜变量产生调制

$$\omega(z) = \omega_0 + M(z). \quad (6.1)$$

线性情形 $M(z) = Bz$ 时

$$\frac{\partial \omega}{\partial z} = B. \quad (6.2)$$

论文实现中的逐行调制可写成

$$w_{ij} \leftarrow w_{ij} + \alpha o_i, \quad (6.3)$$

即输出调制向量 o 沿每行广播。若 $W \in \mathbb{R}^{m \times n}$ ，只需生成 m 个调制量，而非直接训练 mn 个元素。

7 梯度如何穿过生成权重

任务输出为

$$\hat{y} = f_{g_\phi(z)}(x), \quad (7.1)$$

损失对潜变量梯度由链式法则给出

$$\boxed{\nabla_z \mathcal{L} = J_g(z)^\top \nabla_\theta \mathcal{L}(f_\theta(x), y)|_{\theta=g(z)}}. \quad (7.2)$$

因此高维权重梯度先投影到 d 维切空间。若映射参数 ϕ 也训练，则

$$\nabla_\phi \mathcal{L} = \left(\frac{\partial g_\phi(z)}{\partial \phi} \right)^\top \nabla_z \mathcal{L}. \quad (7.3)$$

论文强调目标网络不直接优化，实质是通过可微生成器间接更新其参数。

8 参数量与压缩比

直接训练目标网络需要 P 个参数。若只训练潜变量 $z \in \mathbb{R}^d$ ，训练参数比例为

$$r = \frac{d}{P}, \quad \text{reduction} = 1 - r. \quad (8.1)$$

例如 $d/P = 0.005$ 时，训练参数减少 99.5%。但固定映射权重仍需存储和前向计算，所以“trainable parameter reduction”不等于同等比例的推理内存或 FLOPs 降低。

9 Mapping Loss 的四项

论文总目标为

$$\mathcal{L}_{\text{map}} = \mathcal{L}_{\text{task}} + \lambda_{\text{st}} \mathcal{L}_{\text{stab}} + \lambda_{\text{sm}} \mathcal{L}_{\text{smooth}} + \lambda_{\text{al}} \mathcal{L}_{\text{align}}. \quad (9.1)$$

分类任务项为

$$\mathcal{L}_{\text{task}} = -\frac{1}{B} \sum_{i=1}^B \sum_{c=1}^C y_{ic} \log p_{ic}. \quad (9.2)$$

以下三项分别约束局部鲁棒性、映射曲率/敏感度和潜变量与生成权重方向。

10 稳定性项的二阶近似

论文定义

$$\mathcal{L}_{\text{stab}} = \mathbb{E}_{\varepsilon} \left\| f_{g(z+\varepsilon)}(x) - f_{g(z)}(x) \right\|_2^2. \quad (10.1)$$

对复合函数 $F(z) = f_{g(z)}(x)$ 一阶展开

$$F(z + \varepsilon) - F(z) \approx J_F(z) \varepsilon. \quad (10.2)$$

若 $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$, 则

$$\mathbb{E} \|J_F \varepsilon\|^2 = \mathbb{E} \text{Tr}(J_F \varepsilon \varepsilon^\top J_F^\top) \quad (10.3)$$

$$= \sigma^2 \text{Tr}(J_F J_F^\top) = \sigma^2 \|J_F\|_F^2. \quad (10.4)$$

因此稳定性项近似惩罚复合映射的 Jacobian Frobenius 范数, 直接降低潜空间的局部 Lipschitz 常数。

11 平滑性项

论文使用

$$\mathcal{L}_{\text{smooth}} = \|\nabla_z M_\phi(z)\|_F^2. \quad (11.1)$$

若 $M(z) = Bz$, 则

$$\mathcal{L}_{\text{smooth}} = \|B\|_F^2, \quad (11.2)$$

等价于权重衰减。一般非线性映射下, 它惩罚局部伸缩: 对小扰动

$$\|M(z + \Delta z) - M(z)\| \leq \|J_M(z)\|_2 \|\Delta z\| + O(\|\Delta z\|^2). \quad (11.3)$$

Frobenius 范数上界谱范数, 故该项给出可计算的 Lipschitz 上界代理。

12 对齐项及其几何意义

论文定义

$$\mathcal{L}_{\text{align}} = 1 - \cos(z, W^m) = 1 - \frac{z^\top W^m}{\|z\| \|W^m\|}. \quad (12.1)$$

令 $a = W^m / \|W^m\|$ ，则对 z 的梯度

$$\nabla_z \mathcal{L}_{\text{align}} = -\frac{a}{\|z\|} + \frac{(a^\top z)z}{\|z\|^3}. \quad (12.2)$$

该梯度与 z 正交：

$$z^\top \nabla_z \mathcal{L}_{\text{align}} = 0, \quad (12.3)$$

说明余弦项主要旋转方向而不直接改变一阶范数。它鼓励潜向量与映射权重摘要方向一致，但并不保证功能上最优；权重过大时可能与任务梯度冲突。

13 理论边界

Mapping Theorem 是局部存在性结果。它依赖：最优解确实在 C^2 低维流形上；损失局部 Lipschitz；实际生成器有足够容量；优化能找到相应 z^* 。其中任何一项失败，低维训练都可能出现不可消除的表示偏差

$$\inf_z \|g(z) - \theta^*\| > 0. \quad (13.1)$$

因此理论证明支持“存在低维参数化”，但不等价于任意随机初始化的 Mapping Network 都能稳定达到全量训练最优解。

14 局部坐标与切空间

嵌入流形坐标图

$$\phi : U \subset \mathbb{R}^d \rightarrow \mathcal{M} \subset \mathbb{R}^P \quad (14.1)$$

的 Jacobian

$$J_\phi(z) \in \mathbb{R}^{P \times d} \quad (14.2)$$

在正则点满列秩 d 。切空间

$$T_{\phi(z)}\mathcal{M} = \text{col}(J_\phi(z)). \quad (14.3)$$

潜变量梯度更新 Δz 在权重空间的一阶效果

$$\Delta \theta = J_\phi \Delta z \quad (14.4)$$

只能沿切空间移动；法向方向由模型结构直接排除。

15 曲率导致的二阶偏离

局部 Taylor

$$\phi(z + \Delta z) = \phi(z) + J\Delta z + \frac{1}{2}H[\Delta z, \Delta z] + O(\|\Delta z\|^3). \quad (15.1)$$

二阶项的法向分量定义第二基本形式，衡量流形曲率。若

$$\|H[\Delta z, \Delta z]\| \leq \kappa \|\Delta z\|^2, \quad (15.2)$$

则线性切空间近似误差受曲率 κ 控制。Mapping Theorem 的局部近似要求步长足够小，使该二阶误差小于目标容差。

16 潜变量最速下降是投影梯度

权重空间梯度 $g_\theta = \nabla_\theta \mathcal{L}$ 。潜变量梯度

$$g_z = J^\top g_\theta. \quad (16.1)$$

一步 $\Delta z = -\eta g_z$ 对权重的变化

$$\Delta \theta = -\eta J J^\top g_\theta. \quad (16.2)$$

若列向量正交归一， $J J^\top$ 是切空间正交投影；一般情况下它还按奇异值平方缩放。自然的最小范数切空间下降可用

$$\Delta z = -\eta (J^\top J)^{-1} J^\top g_\theta, \quad (16.3)$$

对应权重投影 $-\eta J (J^\top J)^{-1} J^\top g_\theta$ 。

17 不可辨识性

若存在不同潜变量

$$g(z_1) = g(z_2), \quad (17.1)$$

映射不是单射，潜空间有平坦方向。局部不可辨识对应

$$\ker J_g(z) \neq \{0\}. \quad (17.2)$$

这些方向不改变目标权重，却可能被优化器无意义移动。对 $J_g^\top J_g$ 加条件数正则或约束潜向量范数，可改善局部数值稳定性。

18 加性调制的表达秩

若映射权重调制

$$\omega(z) = \omega_0 + Bz, \quad (18.1)$$

则所有可达映射权重位于仿射子空间

$$\omega_0 + \text{col}(B), \quad (18.2)$$

维度最多 d 。生成目标参数 $g_{\omega(z)}(z)$ 因网络非线性可形成弯曲流形，但其局部自由度仍受 z 与调制维度限制。

19 稳定性项与随机平滑

定义复合预测 $F(z) = f_{g(z)}(x)$ ，噪声平滑目标

$$\mathbb{E}_\epsilon \|F(z + \epsilon) - F(z)\|^2. \quad (19.1)$$

二阶展开不仅有 Jacobian 项：

$$F(z + \epsilon) - F(z) = J_F \epsilon + \frac{1}{2} H_F[\epsilon, \epsilon] + O(\|\epsilon\|^3). \quad (19.2)$$

高斯对称性使一阶与二阶交叉期望为零，主项

$$\sigma^2 \|J_F\|_F^2 + O(\sigma^4 \|H_F\|^2). \quad (19.3)$$

小噪声控制一阶敏感度，大噪声还惩罚曲率。

20 smoothness 正则的 Hutchinson 估计

直接计算 $J_M \in \mathbb{R}^{W \times d}$ 的 Frobenius 范数昂贵。Hutchinson 恒等式

$$\|J_M\|_F^2 = \mathbb{E}_{v \sim \mathcal{N}(0, I)} \|J_M v\|^2. \quad (20.1)$$

可用一两个随机向量和 JVP 无偏估计，而不显式构造 Jacobian。若论文实现直接 autograd 求小潜变量 Jacobian，复杂度取决于 d ；大 d 时随机估计更实用。

21 余弦对齐的尺度不辨识

对齐损失

$$1 - \frac{z^\top w}{\|z\| \|w\|} \quad (21.1)$$

满足

$$L(cz, w) = L(z, w), \quad c > 0. \quad (21.2)$$

所以它不约束潜变量范数。若任务损失也对缩放近似不敏感， $\|z\|$ 可能漂移；需配合 $\|z\|^2$ 正则或归一化。负缩放 $c < 0$ 会把余弦符号翻转，因此方向仍有符号辨识。

22 训练参数少不等于生成器便宜

假设 latent 大小 d , 固定 mapping network 参数 W_g , 目标网络参数 P 。训练状态只需为 d (以及少量调制参数) 保存优化器, 但每次前向仍需

$$C_g + C_f(P) \quad (22.1)$$

计算生成器和目标网络。若每一步重新生成全部 P 个权重, 还需 $O(P)$ 写入带宽。方法最直接节省的是梯度/优化器状态, 而非必然减少目标网络前向 FLOPs。

23 存在性定理与可训练性的差别

理论证明存在 z^* 使

$$\|g(z^*) - \theta^*\| < \delta. \quad (23.1)$$

优化成功还要求损失复合函数

$$F(z) = \mathcal{L}(g(z)) \quad (23.2)$$

具有可达盆地。其 Hessian

$$\nabla_z^2 F = J_g^\top H_\theta J_g + \sum_{p=1}^P \frac{\partial \mathcal{L}}{\partial \theta_p} \nabla_z^2 g_p. \quad (23.3)$$

第一项是权重 Hessian 在切空间的投影, 第二项来自生成器曲率。即使 θ^* 可表示, 病态 Jacobian 或非凸曲率仍可能使梯度下降难以到达。

24 参数流形与局部坐标

设目标网络参数 $\theta \in \mathbb{R}^P$ ，假设优秀解附近位于 d 维光滑流形 $\mathcal{M}$ ， $d \ll P$ 。局部坐标图

$$\phi : U \subset \mathbb{R}^d \rightarrow \mathcal{M} \subset \mathbb{R}^P, \quad \phi(0) = \theta^*. \quad (24.1)$$

Jacobian

$$J_\phi(0) \in \mathbb{R}^{P \times d} \quad (24.2)$$

的列空间是切空间

$$T_{\theta^*}\mathcal{M} = \text{Col}(J_\phi(0)). \quad (24.3)$$

局部参数变化

$$\theta(z) = \theta^* + J_\phi(0)z + O(\|z\|^2). \quad (24.4)$$

25 Mapping Theorem 的误差链

假设网络输出关于参数 Lipschitz:

$$\|f_{\theta_1}(x) - f_{\theta_2}(x)\| \leq L_\theta \|\theta_1 - \theta_2\|. \quad (25.1)$$

损失关于输出 Lipschitz:

$$|\ell(f_1, y) - \ell(f_2, y)| \leq L_\ell \|f_1 - f_2\|. \quad (25.2)$$

组合得

$$|L(\theta_1) - L(\theta_2)| \leq L_\ell L_\theta \|\theta_1 - \theta_2\|. \quad (25.3)$$

若 mapping network 找到 z 使

$$\|g(z) - \theta^*\| \leq \delta = \frac{\epsilon}{L_\ell L_\theta}, \quad (25.4)$$

则

$$|L(g(z)) - L(\theta^*)| \leq \epsilon. \quad (25.5)$$

定理的核心是“参数逼近误差通过两个 Lipschitz 常数传到任务损失误差”。

26 局部坐标扩展为全局平滑映射

局部图 ϕ 只在 U 内定义。取光滑 bump function $\psi : \mathbb{R}^d \rightarrow [0, 1]$ ，在原点邻域等于 1，离开 U 后等于 0。定义

$$g(z) = \psi(z)\phi(z) + (1 - \psi(z))\theta^*. \quad (26.1)$$

在原点附近 $g = \phi$ ，远处 $g = \theta^*$ ，过渡区由 ψ 平滑连接。因此 g 可扩展到全 $\mathbb{R}^d$ ，且

$$g(0) = \theta^*. \quad (26.2)$$

这是存在性构造，并不说明一个有限宽度神经网络容易训练到该 g 。

27 潜变量梯度是参数梯度的切空间投影

目标

$$\tilde{L}(z) = L(g(z)). \quad (27.1)$$

链式法则

$$\nabla_z \tilde{L} = J_g(z)^\top \nabla_\theta L. \quad (27.2)$$

参数空间中的实际更新

$$\delta\theta = J_g \delta z = -\eta J_g J_g^\top \nabla_\theta L. \quad (27.3)$$

若 J_g 列正交, $J_g J_g^\top$ 是切空间投影。一般情况下它是带度量的低秩预条件器。mapping training 自动把全参数梯度限制在可生成子空间。

28 Jacobian 秩限制与表达维度

因为

$$J_g(z) \in \mathbb{R}^{P \times d}, \quad (28.1)$$

有

$$\text{rank } J_g(z) \leq d. \quad (28.2)$$

局部一阶可达方向最多 d 维。即使 g 非线性, 单点邻域的自由度仍受 d 限制。非线性允许不同区域拥有不同切空间, 但不能在同一点瞬间提供超过 d 个独立方向。

29 曲率导致的二阶偏离

Taylor 展开

$$g(z + \delta z) = g(z) + J_g \delta z + \frac{1}{2} \mathcal{H}_g[\delta z, \delta z] + O(\|\delta z\|^3). \quad (29.1)$$

一阶项位于切空间, 二阶项包含法向分量, 描述流形曲率。若 Hessian 范数上界 $\|\mathcal{H}_g\| \leq K$, 则线性近似误差

$$\|g(z + \delta z) - g(z) - J_g \delta z\| \leq \frac{K}{2} \|\delta z\|^2 + O(\|\delta z\|^3). \quad (29.2)$$

学习率过大时会离开局部平坦区域, 定理中的局部 Lipschitz 和坐标近似可能失效。

30 不可辨识性与潜空间对称

若存在可逆变换 $T: \mathbb{R}^d \rightarrow \mathbb{R}^d$, 定义

$$\tilde{g}(z) = g(Tz), \quad \tilde{z} = T^{-1}z, \quad (30.1)$$

则生成参数相同：

$$\tilde{g}(\tilde{z}) = g(z). \quad (30.2)$$

所以潜坐标没有唯一语义，旋转、缩放、置换都可产生等价表示。只约束任务损失无法确定唯一 mapping geometry，需要额外正则固定尺度和光滑性。

31 加性调制映射的表达秩

若 mapping network 采用

$$\theta(z) = \theta_0 + Az, \quad A \in \mathbb{R}^{P \times d}, \quad (31.1)$$

它只能生成仿射子空间，Jacobian 恒为 A 。若加入逐层非线性

$$g(z) = W_2 \sigma(W_1 z + b_1) + b_2, \quad (31.2)$$

Jacobian

$$J_g = W_2 \text{diag}(\sigma'(W_1 z + b_1)) W_1, \quad (31.3)$$

仍有秩不超过 d ，但切空间随 z 改变，可描述弯曲流形。

32 随机平滑稳定性项

对潜变量扰动 $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$ ，稳定性损失

$$\mathcal{L}_{\text{stab}} = \mathbb{E}_{\epsilon} \|g(z + \epsilon) - g(z)\|^2. \quad (32.1)$$

小噪声下

$$g(z + \epsilon) - g(z) \approx J_g \epsilon. \quad (32.2)$$

于是

$$\mathcal{L}_{\text{stab}} \approx \mathbb{E} \epsilon^\top J_g^\top J_g \epsilon \quad (32.3)$$

$$= \sigma^2 \text{Tr}(J_g^\top J_g) = \sigma^2 \|J_g\|_F^2. \quad (32.4)$$

所以随机扰动稳定性等价于 Jacobian Frobenius 正则，抑制 mapping 对潜变量过度敏感。

33 Hutchinson 迹估计

显式计算 $\|J_g\|_F^2 = \text{Tr}(J_g^\top J_g)$ 代价高。取随机向量 v 满足 $\mathbb{E}[vv^\top] = I$,

$$\mathbb{E} \|J_g v\|^2 = \mathbb{E} v^\top J_g^\top J_g v = \text{Tr}(J_g^\top J_g). \quad (33.1)$$

因此一次 JVP 即可无偏估计 Jacobian 范数。多个随机向量平均降低方差。

34 参数量与生成成本

潜变量本身只有 d 个可训练参数，但 mapping network 若固定，也需要前向生成 P 个目标权重。输出层至少有 $O(P)$ 写出成本。若显式生成完整参数，内存仍需存储 P 个权重用于目标网络前向。训练参数少不等于训练 FLOPs 和显存按同样比例下降。

35 一个曲线流形例子

令二维参数

$$\theta(z) = (z, z^2) \in \mathbb{R}^2, \quad (35.1)$$

潜维度 $d = 1$ 。Jacobian

$$J_g(z) = \begin{pmatrix} 1 \\ 2z \end{pmatrix}. \quad (35.2)$$

切线方向随 z 改变。若参数梯度 $g_\theta = (g_1, g_2)$ ，潜梯度

$$\frac{dL}{dz} = g_1 + 2zg_2. \quad (35.3)$$

实际参数更新沿切线

$$\delta\theta = -\eta \begin{pmatrix} 1 \\ 2z \end{pmatrix} (g_1 + 2zg_2), \quad (35.4)$$

无法直接沿法向方向 $(-2z, 1)$ 移动。

36 存在性与可训练性的区别

Mapping Theorem 表明“存在某个 z^* 使损失接近最优”，但优化还需要：

$$\min_z L(g(z)) \quad (36.1)$$

的景观可搜索。若 J_g 在某区域奇异值很小，

$$\|\nabla_z L\| = \|J_g^\top \nabla_\theta L\| \quad (36.2)$$

可能接近零，即使参数空间梯度很大。存在一个好点不保证梯度下降能到达，因此需要分析 Jacobian 条件数、初始化和全局非凸性。