

45_DSpark 数学过程详解

半自回归草稿、接受率恒等式与硬件感知调度

本文只处理真正需要推导的部分

本文完整推导无损投机采样、TV 距离与接受率、低秩顺序修正、前缀生存概率、尾和期望、吞吐优化、贪心前缀约束、校准和三项损失。。全文按“公式从哪里来-每个符号是什么-中间步骤为何成立-维度和复杂度如何核对-论文结论依赖哪些假设”的顺序展开；不复述实验表格，也不使用与论文无关的通用背景凑页数。

目录

1	投机解码的无损接受规则	4
2	延迟与接受长度	4
3	并行骨干与半自回归修正	4
4	低秩 Markov logit 修正	5
5	门控递归状态	5
6	置信度软标签	5
7	前缀生存概率	6
8	期望接受长度的尾和公式	6
9	硬件感知吞吐目标	7
10	为什么全局排序自动满足前缀约束	7
11	早停与单峰假设	7
12	Sequential Temperature Scaling	7
13	三项训练损失	8
14	多 token 投机采样的归纳正确性	8
15	TV 距离与最大耦合	8

16 前缀长度分布	9
17 置信误差对前缀概率的放大	9
18 温度缩放的 logit 表达	9
19 固定 batch 下贪心最优的交换证明	9
20 吞吐增量判据	10
21 低秩顺序头的梯度	10
22 门控状态的长期梯度	10
23 TV 损失梯度的非光滑点	11
24 三项损失的职责分离	11
25 系统目标与离线 accepted length 的差别	11
26 单 token 投机采样的无损接受规则	12
27 接受率与总变差距离	12
28 多 token 前缀接受的归纳正确性	12
29 前缀生存概率与期望接受长度	13
30 置信度软标签的来源	13
31 置信误差对前缀概率的放大	13
32 Sequential Temperature Scaling	13
33 三项训练损失的梯度职责	14
34 TV 损失的次梯度	14
35 半自回归低秩修正	14
36 门控顺序状态与长期梯度	15

37 硬件感知调度目标	15
38 前缀约束下的贪心选择	15
39 一个接受长度数值例子	15
40 离线 <code>accepted length</code> 与在线吞吐的区别	16

1 投机解码的无损接受规则

目标模型分布为 $p(x)$ ，草稿模型分布为 $q(x)$ 。先从 q 采样候选 x ，以

$$a(x) = \min\left(1, \frac{p(x)}{q(x)}\right) \quad (1.1)$$

接受。候选被接受并等于 x 的概率为

$$q(x)a(x) = \min\{q(x), p(x)\}. \quad (1.2)$$

总接受概率

$$A = \sum_x \min\{p(x), q(x)\}. \quad (1.3)$$

利用

$$\min(p, q) = \frac{p + q - |p - q|}{2} \quad (1.4)$$

并对 x 求和，得到

$$A = 1 - \frac{1}{2} \|p - q\|_1 = 1 - \text{TV}(p, q). \quad (1.5)$$

这就是论文把总变差距离作为软接受标签的严格来源。

若拒绝，则从残差分布

$$r(x) = \frac{[p(x) - q(x)]_+}{1 - A} \quad (1.6)$$

补采样。最终输出分布为

$$\Pr(Y = x) = \min(p(x), q(x)) + (1 - A)r(x) \quad (1.7)$$

$$= \min(p, q) + [p - q]_+ = p(x), \quad (1.8)$$

所以接受–拒绝过程精确保持目标模型分布。

2 延迟与接受长度

一次投机周期的草稿延迟和验证延迟分别为 T_{draft} 、 T_{verify} ，期望接受 token 数为 τ 。单位 token 延迟

$$\mathcal{L} = \frac{T_{\text{draft}} + T_{\text{verify}}}{\tau}. \quad (2.1)$$

因此加长草稿块有两面性：并行草稿可使 T_{draft} 增长缓慢，但若后缀接受率快速下降， τ 几乎不增而 T_{verify} 和 batch 占用上升。

3 并行骨干与半自回归修正

并行草稿骨干同时产生位置特征 $h_1, \dots, h_\gamma$ ，朴素因子化近似

$$q(x_{1:\gamma} \mid c) \approx \prod_{k=1}^{\gamma} q_k(x_k \mid c) \quad (3.1)$$

忽略块内依赖。DSpark 改为半自回归

$$q(x_{1:\gamma} \mid c) = \prod_{k=1}^{\gamma} q_k(x_k \mid c, x_{<k}), \quad (3.2)$$

但只在轻量输出模块中顺序建模，昂贵骨干仍一次并行计算。

4 低秩 Markov logit 修正

最简单的前一 token 修正矩阵 $B \in \mathbb{R}^{V \times V}$ 需要 V^2 参数。论文分解为

$$B = W_1 W_2, \quad W_1 \in \mathbb{R}^{V \times r}, \quad W_2 \in \mathbb{R}^{r \times V}. \quad (4.1)$$

给定前 token x_{k-1} ，其修正 logits 为

$$B(x_{k-1}, :) = W_1[x_{k-1}]W_2. \quad (4.2)$$

参数量从 V^2 降为

$$2Vr, \quad (4.3)$$

压缩比约为

$$\frac{2Vr}{V^2} = \frac{2r}{V}. \quad (4.4)$$

当 $r \ll V$ 时显著降低参数和矩阵乘法成本。

5 门控递归状态

为超越一阶 Markov，论文维护低维状态 $s_k \in \mathbb{R}^r$ 。令输入特征 z_k 包含并行位置特征和已采样 token 嵌入，门控更新为

$$g_k = \sigma(W_g z_k), \quad (5.1)$$

$$s_k = g_k \odot s_{k-1} + (1 - g_k) \odot \tanh(W_c z_k). \quad (5.2)$$

当 $g_k \approx 1$ 时保留历史；当 $g_k \approx 0$ 时用当前候选重写。顺序修正 logits 可写为

$$b_k = W_2^\top \tanh(W_o z_k), \quad (5.3)$$

最终草稿分布

$$q_k = \text{softmax}(\ell_k^{\text{parallel}} + b_k). \quad (5.4)$$

顺序复杂度约为 $O(\gamma r^2 + \gamma r V)$ ，但主干只做一次并行前向；这正是“semi-autoregressive”的速度-依赖折中。

6 置信度软标签

置信头输出

$$c_k = \sigma(w^\top [h_k; W_1[x_{k-1}]]) . \quad (6.1)$$

真实软标签取草稿与目标分布的理论接受率

$$c_k^* = 1 - \frac{1}{2} \|p_k^d - p_k^t\|_1. \quad (6.2)$$

它不是“预测 token 是否等于 $\arg\max$ ”，而是该位置在标准投机采样下的条件接受概率。二元交叉熵

$$\mathcal{L}_{\text{conf},k} = -[c_k^* \log c_k + (1 - c_k^*) \log(1 - c_k)] \quad (6.3)$$

对 logit a_k 的梯度仍为

$$\frac{\partial \mathcal{L}_{\text{conf},k}}{\partial a_k} = c_k - c_k^*, \quad (6.4)$$

软标签使梯度连续反映分布距离。

7 前缀生存概率

设 $c_{r,k}$ 是在前 $k-1$ 个候选均已接受条件下，第 k 个被接受的概率。由链式法则

$$a_{r,j} = \Pr(A_{r,1} \cap \cdots \cap A_{r,j}) = \prod_{i=1}^j c_{r,i}. \quad (7.1)$$

因为 $0 \leq c_{r,i} \leq 1$ ，有

$$a_{r,j+1} \leq a_{r,j}, \quad (7.2)$$

这保证同一请求的候选收益沿位置单调下降。

8 期望接受长度的尾和公式

请求 r 验证长度为 ℓ_r ，令 L_r 为成功接受的草稿 token 数。对非负整数变量，尾和公式给出

$$\mathbb{E}L_r = \sum_{j=1}^{\ell_r} \Pr(L_r \geq j). \quad (8.1)$$

而事件 $L_r \geq j$ 等价于前 j 个都接受，所以

$$\mathbb{E}L_r = \sum_{j=1}^{\ell_r} a_{r,j}. \quad (8.2)$$

投机验证还会产生一个 target bonus token，因此每个请求的期望输出步数为

$$\tau_r = 1 + \sum_{j=1}^{\ell_r} a_{r,j}. \quad (8.3)$$

全批次

$$\tau = \sum_{r=1}^R \tau_r. \quad (8.4)$$

9 硬件感知吞吐目标

送入目标模型的 token batch 大小为

$$B = \sum_{r=1}^R (1 + \ell_r). \quad (9.1)$$

预先测得硬件在 batch B 下的 step-per-second 曲线 $\text{SPS}(B)$, 系统期望 token 吞吐为

$$\Theta(\ell_1, \dots, \ell_R) = \left[\sum_{r=1}^R \left(1 + \sum_{j=1}^{\ell_r} a_{r,j} \right) \right] \text{SPS}(B). \quad (9.2)$$

固定 B 时, $\text{SPS}(B)$ 是常数, 最大化 Θ 等价于从所有边际收益 $a_{r,j}$ 中选最大的若干项。

10 为什么全局排序自动满足前缀约束

若选择请求 r 的第 j 个 token, 就必须选择 $1, \dots, j-1$ 。但

$$a_{r,1} \geq a_{r,2} \geq \dots \geq a_{r,j}. \quad (10.1)$$

因此在全局降序排序中, $a_{r,j}$ 出现之前, 同请求的所有前驱必定已经出现。故对固定选取数量 m , 取全局最大的 m 个生存概率同时满足前缀约束, 并由交换论证最优: 若方案包含较小收益 b 却遗漏较大收益 $a > b$, 交换后期望接受数增加。

11 早停与单峰假设

沿贪心路径逐个增加验证 token, 记

$$\Theta_m = \tau_m \text{SPS}(R + m). \quad (11.1)$$

算法在 $\Theta_{m+1} \leq \Theta_m$ 时停止。若 Θ_m 单峰, 则首次下降后不会再上升, 早停取得全局最优。若硬件曲线不平滑导致多峰, 首次下降只给局部最优; 论文因此需要实际 profiling 与工程修正。

早停还有因果意义: 第 $k+1$ 个置信度依赖已实例化的第 k 个 token。若先查看未来候选再回溯决定是否验证较早 token, 会让选择事件依赖未来随机量, 破坏标准投机采样的 non-anticipating 条件。逐步生成、逐步停止避免这种信息泄漏。

12 Sequential Temperature Scaling

对置信 logit a_k 使用温度

$$\tilde{c}_k = \sigma(a_k / T_k). \quad (12.1)$$

温度变换保持排序, 因为 $\sigma(\cdot / T_k)$ 单调, 但改变概率幅值。前缀概率变为

$$\tilde{a}_j = \prod_{i=1}^j \tilde{c}_i. \quad (12.2)$$

论文从左到右依次选择 T_k , 固定此前温度, 使累计概率的 ECE 最小。必须校准累计概率而不只是单点概率, 因为调度器使用的正是 $\prod_i c_i$ 。

13 三项训练损失

位置权重

$$w_k = \exp\left(-\frac{k-1}{\gamma}\right) \quad (13.1)$$

强调更可能被接受的前缀位置。交叉熵

$$\mathcal{L}_{\text{ce}} = -\sum_{k=1}^{\gamma} w_k \log p_k^d(x_k^*). \quad (13.2)$$

总变差匹配

$$\mathcal{L}_{\text{tv}} = \sum_{k=1}^{\gamma} w_k \|p_k^d - p_k^t\|_1. \quad (13.3)$$

置信损失

$$\mathcal{L}_{\text{conf}} = -\sum_{k=1}^{\gamma} w_k [c_k^* \log c_k + (1 - c_k^*) \log(1 - c_k)]. \quad (13.4)$$

总目标

$$\boxed{\mathcal{L} = \alpha_{\text{ce}} \mathcal{L}_{\text{ce}} + \alpha_{\text{tv}} \mathcal{L}_{\text{tv}} + \alpha_{\text{conf}} \mathcal{L}_{\text{conf}}.} \quad (13.5)$$

$\mathcal{L}_{\text{ce}}$ 保证正确 token 学习, $\mathcal{L}_{\text{tv}}$ 直接提高理论接受率, $\mathcal{L}_{\text{conf}}$ 让调度器能预测该接受率; 三者不可简单互相替代。

14 多 token 投机采样的归纳正确性

假设前 $k-1$ 个输出已精确服从目标自回归分布。第 k 个位置条件历史 h_k 也是目标分布下历史。单步接受-残差采样已证明输出服从

$$p_t(x_k | h_k). \quad (14.1)$$

因此联合

$$p(h_k) p_t(x_k | h_k) = p(x_{1:k}) \quad (14.2)$$

仍正确。对 k 归纳, 整个接受前缀和拒绝后的 bonus token 都保持目标联合分布。调度只要是 non-anticipating, 就不会改变此条件分布证明。

15 TV 距离与最大耦合

两分布 p, q 的最大耦合使两个样本相等的最大概率为

$$1 - \text{TV}(p, q). \quad (15.1)$$

证明: 共同质量

$$c(x) = \min(p(x), q(x)), \quad \sum_x c(x) = 1 - \text{TV}(p, q). \quad (15.2)$$

先以该总质量从归一化 c 同时采样相同 token, 剩余质量分别采样, 达到上界。投机采样接受规则正实现这种最大耦合, 所以其单步接受率在给定 p, q 下已不可提高。

16 前缀长度分布

验证长度 ℓ ，条件接受概率 c_k ，生存概率

$$a_j = \prod_{i=1}^j c_i. \quad (16.1)$$

恰好接受 $j < \ell$ 个的概率

$$\Pr(L = j) = a_j(1 - c_{j+1}), \quad (16.2)$$

全部接受

$$\Pr(L = \ell) = a_\ell. \quad (16.3)$$

直接计算期望

$$\mathbb{E}L = \sum_{j=0}^{\ell-1} j a_j (1 - c_{j+1}) + \ell a_\ell \quad (16.4)$$

$$= \sum_{j=1}^{\ell} a_j, \quad (16.5)$$

与尾和公式一致。

17 置信误差对前缀概率的放大

真实条件概率 c_i ，估计 $\hat{c}_i = c_i + e_i$ 。累计乘积一阶相对误差

$$\frac{\hat{a}_j - a_j}{a_j} \approx \sum_{i=1}^j \frac{e_i}{c_i}. \quad (17.1)$$

即使每步偏差很小，长前缀误差会累加；当某 c_i 小时相对误差尤其放大。这解释了为什么调度器需要 Sequential Temperature Scaling 校准累计概率，而不仅是单点分类准确率。

18 温度缩放的 logit 表达

原置信 $c = \sigma(a)$ ，温度后

$$c_T = \sigma(a/T). \quad (18.1)$$

赔率

$$\frac{c_T}{1 - c_T} = \exp(a/T) = \left(\frac{c}{1 - c} \right)^{1/T}. \quad (18.2)$$

$T > 1$ 把赔率拉向 1，降低过度自信； $T < 1$ 使分布更尖锐。因为变换对 a 单调，token 排序不变。

19 固定 batch 下贪心最优的交换证明

固定总扩展 token 数 m ，任一可行方案 S 的收益

$$V(S) = \sum_{(r,j) \in S} a_{r,j}. \quad (19.1)$$

若 S 未包含全局前 m 大中的某项 x ，却包含更小项 y ，交换 $y \rightarrow x$ 增加收益。由于同请求 $a_{r,j}$ 单调，选择 $a_{r,j}$ 时其前驱值更大，必在前面已选择，所以交换不破坏前缀可行性。反复交换得到全局排序方案，故固定 m 最优。

20 吞吐增量判据

当前期望 token 数 τ 、batch B ，加入候选生存概率 a 后

$$\Theta' = (\tau + a) \text{SPS}(B + 1). \quad (20.1)$$

加入有利当且仅当

$$a > \tau \left[\frac{\text{SPS}(B)}{\text{SPS}(B + 1)} - 1 \right]. \quad (20.2)$$

右侧是硬件机会成本阈值：低并发时 SPS 下降小，阈值低，可验证更多 token；高负载时增加 batch 显著降速，只保留高生存概率前缀。

21 低秩顺序头的梯度

logit 修正

$$b = W_1[x_{prev}]W_2. \quad (21.1)$$

设上游梯度 $g_b \in \mathbb{R}^V$ ，则

$$\nabla_{W_2} \mathcal{L} = W_1[x_{prev}]^\top g_b, \quad (21.2)$$

只更新 W_1 的被查行

$$\nabla_{W_1[x_{prev}]} \mathcal{L} = g_b W_2^\top. \quad (21.3)$$

这与低秩语言模型适配类似：每个前 token 只激活一个低维状态行，避免 $V \times V$ 转移矩阵。

22 门控状态的长期梯度

递归

$$s_k = g_k \odot s_{k-1} + (1 - g_k) \odot \tilde{s}_k. \quad (22.1)$$

忽略门本身对状态的导数，直接记忆路径

$$\frac{\partial s_k}{\partial s_{k-1}} \approx \text{diag}(g_k). \quad (22.2)$$

跨 m 步梯度约乘

$$\prod_{j=k-m+1}^k g_j. \quad (22.3)$$

门接近 1 时保留长期依赖，接近 0 时快速遗忘；轻量串行头通过可学习门控制 suffix 依赖长度。

23 TV 损失梯度的非光滑点

单位置

$$L_{tv} = \sum_x |q_x - p_x|. \quad (23.1)$$

对 $q_x \neq p_x$,

$$\frac{\partial L_{tv}}{\partial q_x} = \text{sign}(q_x - p_x). \quad (23.2)$$

再通过 softmax Jacobian

$$\frac{\partial q_x}{\partial z_y} = q_x(\delta_{xy} - q_y) \quad (23.3)$$

回传。 $q_x = p_x$ 处取子梯度 $[-1, 1]$ 。相比 KL, TV 对极小目标概率不产生 $1/p$ 型爆炸, 且与理论接受率线性对应。

24 三项损失的职责分离

交叉熵最小化

$$D_{\text{KL}}(p_{\text{data}} \| q), \quad (24.1)$$

保证 ground-truth token; TV 直接最小化与冻结目标模型的分布差; confidence BCE 拟合标量接受概率。只用 CE 时, 两个模型都可能把真 token 排第一却在尾部分布差很大, 接受率仍低; 只用 TV 可蒸馏目标但不特别强调真实标签; 只用 confidence 无法改善草稿本身。因此加权组合不是重复损失。

25 系统目标与离线 accepted length 的差别

离线常优化

$$\mathbb{E}[1 + L], \quad (25.1)$$

但生产吞吐是

$$\mathbb{E}[1 + L] \cdot \text{SPS}(B). \quad (25.2)$$

更长 accepted length 可能需要验证更大 batch, 使 SPS 降低, 系统吞吐反而变差。DSpark 的数学创新之一就是把概率收益与硬件容量曲线显式相乘, 而非把模型指标当作系统指标。

26 单 token 投机采样的无损接受规则

目标分布 $p(x)$ ，草稿分布 $q(x)$ 。先采 $x \sim q$ ，以概率

$$a(x) = \min\left(1, \frac{p(x)}{q(x)}\right) \quad (26.1)$$

接受。接受某个 x 的总概率

$$q(x)a(x) = \min(q(x), p(x)). \quad (26.2)$$

若拒绝，则从残差分布

$$r(x) = \frac{[p(x) - q(x)]_+}{1 - \sum_y \min(p(y), q(y))} \quad (26.3)$$

采样。最终输出概率

$$P_{\text{out}}(x) = \min(p(x), q(x)) \quad (26.4)$$

$$+ \left(1 - \sum_y \min(p(y), q(y))\right) r(x) \quad (26.5)$$

$$= \min(p, q) + [p - q]_+ = p(x). \quad (26.6)$$

因此投机解码严格保持目标分布。

27 接受率与总变差距离

单 token 平均接受率

$$A = \sum_x \min(p(x), q(x)). \quad (27.1)$$

总变差距离

$$\text{TV}(p, q) = \frac{1}{2} \sum_x |p(x) - q(x)|. \quad (27.2)$$

利用恒等式

$$\sum_x \min(p, q) = 1 - \text{TV}(p, q), \quad (27.3)$$

得到

$$\boxed{A = 1 - \text{TV}(p, q)}. \quad (27.4)$$

所以训练草稿分布的 L1/TV 损失直接提高理论最大接受率。

28 多 token 前缀接受的归纳正确性

草稿提出 $x_{1:K}$ 。目标模型并行计算每个条件分布

$$p_k(\cdot) = p(\cdot \mid x_{<k}). \quad (28.1)$$

第 1 个 token 用单步规则输出正确 p_1 。条件在前 $k-1$ 个已接受时，前缀正是目标分布样本，因此第 k 个仍可用相同接受-残差规则得到 $p_k(\cdot \mid x_{<k})$ 。数学归纳法说明整个输出序列分布与自回归目标模型完全一致。

29 前缀生存概率与期望接受长度

第 k 个位置在前缀存活条件下的接受概率为 a_k 。至少接受 k 个 token 的概率

$$S_k = \prod_{j=1}^k a_j. \quad (29.1)$$

接受长度 $L \in \{0, 1, \dots, K\}$ 的尾和公式

$$\mathbb{E}[L] = \sum_{k=1}^K \Pr(L \geq k) = \sum_{k=1}^K S_k. \quad (29.2)$$

后部位置的贡献被所有前部接受率相乘，因此前缀早期校准尤为重要。

30 置信度软标签的来源

若草稿和目标分布为 p_k^d, p_k^t ，理论最大耦合接受率

$$c_k^* = 1 - \text{TV}(p_k^d, p_k^t) = 1 - \frac{1}{2} \|p_k^d - p_k^t\|_1. \quad (30.1)$$

这正是置信头的软标签。它不是“草稿 top-1 概率”，而是两个完整分布能够相同采样的最大概率。

31 置信误差对前缀概率的放大

估计 $\hat{a}_k = a_k + e_k$ ，前缀估计

$$\hat{S}_k = \prod_{j=1}^k (a_j + e_j). \quad (31.1)$$

对小误差一阶展开

$$\frac{\hat{S}_k - S_k}{S_k} \approx \sum_{j=1}^k \frac{e_j}{a_j}. \quad (31.2)$$

相对误差随前缀长度累积，且当某个 a_j 很小时被 $1/a_j$ 放大。因此置信头在低接受位置的校准尤其重要。

32 Sequential Temperature Scaling

原始置信 logit z_k ，温度 $T_k > 0$ ，校准概率

$$\hat{a}_k = \sigma(z_k/T_k). \quad (32.1)$$

二分类负对数似然

$$\mathcal{L}(T_k) = - \sum_n [y_n \log \hat{a}_{nk} + (1 - y_n) \log(1 - \hat{a}_{nk})]. \quad (32.2)$$

温度 $T > 1$ 使概率更接近 1/2，降低过度自信； $T < 1$ 使分布更尖。Sequential 表示每个位置可有不同温度，因为后部接受率系统性下降。

33 三项训练损失的梯度职责

交叉熵

$$\mathcal{L}_{\text{ce}} = - \sum_k w_k \log p_k^d(x_k^*) \quad (33.1)$$

直接提高真实 token 概率。TV 对齐

$$\mathcal{L}_{\text{tv}} = \sum_k w_k \|p_k^d - p_k^t\|_1 \quad (33.2)$$

匹配完整分布，改善接受率。置信 BCE

$$\mathcal{L}_{\text{conf}} = - \sum_k w_k [c_k^* \log \hat{c}_k + (1 - c_k^*) \log(1 - \hat{c}_k)] \quad (33.3)$$

训练调度器预测生存概率。三者分别对应“草稿正确性、分布接近、系统决策”。

34 TV 损失的次梯度

对 logit 经过 softmax 得 p_j ，L1 项

$$L = \sum_j |p_j - q_j|. \quad (34.1)$$

对 p_j 的次梯度

$$g_j \in \begin{cases} \{1\}, & p_j > q_j, \\ [-1, 1], & p_j = q_j, \\ \{-1\}, & p_j < q_j. \end{cases} \quad (34.2)$$

对 logits z_m ,

$$\frac{\partial L}{\partial z_m} = \sum_j g_j p_j (\mathbf{1}[j = m] - p_m). \quad (34.3)$$

L1 在相等点不光滑，但自动微分可选一个合法次梯度。

35 半自回归低秩修正

并行骨干给每个位置基础 logits ℓ_k^0 。顺序头利用前一草稿 token 的 embedding $e(x_{k-1})$ 做低秩修正

$$\Delta \ell_k = W_2 \sigma(W_1 e(x_{k-1})), \quad (35.1)$$

其中 $W_1 \in \mathbb{R}^{r \times d}$, $W_2 \in \mathbb{R}^{V \times r}$ 。参数量

$$P = r(d + V) \quad (35.2)$$

远小于完整 $V \times d$ 输出层。它注入局部 token 依赖，同时保持大部分骨干并行。

36 门控顺序状态与长期梯度

若顺序状态

$$h_k = g_k \odot h_{k-1} + (1 - g_k) \odot \tilde{h}_k, \quad (36.1)$$

则

$$\frac{\partial h_k}{\partial h_{k-1}} = \text{diag}(g_k) + \text{门值依赖 } h_{k-1} \text{ 的附加项}. \quad (36.2)$$

忽略附加项，跨 m 步梯度约

$$\prod_{j=k-m+1}^k \text{diag}(g_j). \quad (36.3)$$

若门接近 1，可保留长期状态；接近 0，则快速遗忘。

37 硬件感知调度目标

请求 r 选择验证长度 j ，预计产出 token 数 Y_{rj} ，验证成本 $C_j(B)$ 依赖当前 batch 负载 B 。系统目标可写为

$$\max_{j_r} \frac{\sum_r \mathbb{E}[Y_{rj_r}]}{C_{\{j_r\}}(B)}. \quad (37.1)$$

若把增加一个验证位置的边际收益记为

$$\Delta Y_{rj} = S_{rj}, \quad (37.2)$$

边际成本 ΔC_{rj} ，则优先级

$$\eta_{rj} = \frac{S_{rj}}{\Delta C_{rj}}. \quad (37.3)$$

高负载时成本上升，调度器只保留高生存概率位置。

38 前缀约束下的贪心选择

请求若验证第 j 个 token，必须验证所有 $1, \dots, j-1$ ，即选择变量

$$x_{r,j} \leq x_{r,j-1}. \quad (38.1)$$

若每个后续位置的边际收益非增

$$S_{r,j+1} \leq S_{r,j}, \quad (38.2)$$

且单位成本相同，按所有候选边际收益从大到小加入，自动不会先选后部而漏掉前部：因为同请求的前部收益更大，必先出现。这是全局排序满足前缀约束的交换论证。

39 一个接受长度数值例子

四个位置接受率

$$a = (0.9, 0.8, 0.6, 0.5). \quad (39.1)$$

前缀生存

$$S_1 = 0.9, \quad S_2 = 0.72, \quad S_3 = 0.432, \quad S_4 = 0.216. \quad (39.2)$$

期望接受长度

$$\mathbb{E}[L] = 0.9 + 0.72 + 0.432 + 0.216 = 2.268. \quad (39.3)$$

验证第 4 个位置的边际期望收益只有 0.216；高负载时可能不值得占用 batch 容量。

40 离线 accepted length 与在线吞吐的区别

离线指标最大化

$$\mathbb{E}[L] \quad (40.1)$$

假设验证额外位置几乎免费。在线吞吐约

$$\Theta = \frac{\text{每轮接受 token 数}}{\text{草稿时间} + \text{验证时间} + \text{调度开销}}. \quad (40.2)$$

更长验证块可提高分子，也会增加分母并挤占其他请求。DSpark 的调度数学重点不是单纯预测接受长度，而是根据实时系统成本选择使边际吞吐为正的前缀。