

1

研究问题

为何需要它

- 现有模型通常只把层或残差块模块化，很少把整个生成模型本身作为原子模块。
- 逐像素图像具有超高维、非序列结构；直接使用一个超长自回归序列代价极高。
- 潜变量 tokenizer 虽能压缩序列，却会引入重建误差和信息上限。

2

核心思想

新的抽象层次

- 把原子生成器视为可复用模块，在生成器内部递归调用同类生成器。
- 利用“图像由子图像组成”的近分形结构，以分治方式形成多层自相似架构。
- 输出规模指数增长，而递归层数只线性增长。

3

模型结构

如何运行

- 顶层先把 256 x 256 图像划分为 16 x 16 图像块，子生成器继续递归细分。
- 末层使用轻量 Transformer，以 256 类交叉熵逐通道预测 RGB。
- FractalAR 采用栅格顺序因果注意力；FractalMAR 采用随机顺序双向预测。

分形生成模型

Fractal Generative Models

分形生成模型

Li, Sun, Fan & He | 2025

把“完整生成模型”抽象为可递归调用的模块，将难以直接建模的原始像素联合分布拆成层层可控的子问题。

递归

自相似

原始像素

4

数学机制

递归概率分解

- $\{x_{(i+1)}\} = g_i(x_i), N = k^n, n = \log_k(N)$
- 每一层把 $p(x_1, \dots, x_N)$ 分解为 k 个条件分组，再交给下一层生成器继续建模。
- 训练时按广度优先贯穿全部层级，由最终原始像素交叉熵端到端反向传播。

5

实验结果

证据

- ImageNet 64 x 64: FractalAR / FractalMAR 的 NLL 为 3.14 / 3.15 bits/dim。
- 在 256 x 256 最细尺度上，注意力计算量约比完整下一尺度注意力低 4000 倍。
- FractalMAR-H 达到 FID 6.15、IS 348.9、Recall 0.46，并支持修复与外扩。

6

意义与局限

结论

- 直接生成原始像素，过程更可解释，也不受 tokenizer 重建误差限制。
- 思路可望推广到分子、蛋白质和神经网络等具有内在层次的数据。
- 生成仍具有自回归开销，模型规模、速度及跨领域泛化仍需继续验证。