

1

研究问题

TOKENIZER 瓶颈

- 两阶段图像生成依赖紧凑 tokenizer，其码率-失真-感知权衡决定整个系统上限。
- 主流方法常依赖 CNN、二维对齐潜码、对抗损失或从其他 tokenizer 蒸馏。
- 此前扩散自编码器尚未在 ImageNet 重建任务达到最先进水平。

2

核心洞见

先匹配，再寻模

- 离散潜码 c 丢失信息，因此重建分布 $p(x|c)$ 天然具有多模态。
- 感知重建不必覆盖所有模态，更重要的是采到与原图感知上接近的模态。
- FlowMo 将模态匹配预训练与模态搜索后训练明确分开。

3

模型结构

纯 TRANSFORMER 自编码器

- 对称的 MM-DiT 编码器/解码器把图像映射为一维潜序列，并用条件校正流重建。
- 使用无查表量化对潜 token 二值化，不需要卷积、GAN 损失或辅助 tokenizer。
- 第二阶段可直接在离散潜序列上训练 MaskGIT 生成模型。

FLOWMO 图像分词器

Flow to the Mode

面向感知模态的扩散自编码器

Mode-Seeking Diffusion Autoencoders for Image Tokenization | 2025

先让 Transformer 扩散自编码器匹配完整重建分布，再通过后训练把采样推向与原图感知上更接近的模态。

图像分词

校正流

模态搜索

4

训练目标

关键公式

- $x_t = t z + (1-t)x$; $L_{\text{flow}} = E ||x - z - d(x_t, c, t)||^2$
- 阶段 1A 在端到端流匹配上加入感知、承诺和熵损失。
- 阶段 1B 冻结编码器，对 n 步 ODE 采样链反传感知损失，并用偏移采样器聚焦优质模态。

5

实验结果

最先进表现

- 0.070 BPP 时 FlowMo-Lo 的 rFID/PSNR 为 0.95/22.07，优于 OpenMAGViT-V2。
- 0.219 BPP 时 FlowMo-Hi 达到 rFID 0.56、PSNR 24.93，略优于 LlamaGen-32。
- 后训练使 Lo 的 rFID 由 1.10 降至 0.95，使 Hi 由 0.73 降至 0.56。

6

意义与局限

结论

- 扩散解码器无需传统视觉归纳偏置，也能成为顶级离散图像 tokenizer。
- 小图像块、感知损失、厚尾噪声、偏移步长和引导策略均是关键设计。
- 主要局限是解码需多次前向传播（论文采用 25 步），推理速度较慢。