

1

研究问题

从任务走向工作

- 当前智能体能搜索或复制文件，却难以完成演示文稿、报告和跨应用长流程。
- 两大瓶颈是精准 GUI 视觉定位，以及长时序、动态的认知理解。
- 仅记录行为无法解释人为何选择动作、如何纠错或怎样调整计划。

2

PC Tracker

交互数据采集

- 轻量后台工具记录鼠标/键盘操作、屏幕截图与无障碍接口元素信息。
- 任务导向与自然采集两种模式保留探索、停顿、纠错和跨应用操作。
- 隐私控制与透明存储结合数据清洗，去除采集器自身操作和冗余事件。

3

认知补全

把坐标变成推理

- 第一阶段利用标记截图与元素元数据，把点击坐标改写为简洁动作语义。
- 第二阶段结合任务、历史步骤、后续动作和视觉状态，重建每一步背后的思考。
- 最终轨迹同时包含任务进度、环境探索和错误恢复等认知信息。

PC AGENT 数字智能体

PC Agent：当你入睡时，AI 继续工作

A Cognitive Journey into the Digital World | 2024

迁移的不只是点击行为，而是人类认知：采集 GUI 轨迹，补全动作语义与思考过程，再训练规划智能体和定位智能体。

GUI 智能体 认知迁移 多智能体

4

PC Agent

规划 + 定位

- Qwen2-VL 规划智能体从认知轨迹学习交替输出思考与动作。
- Molmo 定位智能体把点击描述转为坐标，并结合 GUI 元数据进行自验证。
- 目标不存在或验证失败时反馈给规划端重规划，动作由 PyAutoGUI 执行。

5

实验结果

小数据完成长流程

- 仅用 133 条轨迹微调 Qwen2-VL-72B；引导式 PPT 轨迹平均约 50 个事件。
- 智能体可在 Chrome 与 PowerPoint 间完成最长 50 步的实用多页演示文稿。
- 批量制作 20 张人物海报时，有 11 张满足要求，成功率为 55%。

6

意义与局限

结论

- 高质量认知数据对复杂数字工作比单纯行为克隆更具数据效率。
- 一旦错误动作被执行，系统恢复能力有限；详细任务描述会显著提升表现。
- 跨软件泛化、拖拽/滚动、长期规划、隐私和主观成果评价仍待解决。