

1

研究问题

为何线性适配器不够

- 视觉增量微调虽节省参数，却长期难以在密集预测任务稳定超过全量微调。
- 源自 NLP 的线性适配器忽略二维视觉结构，还会接收冻结层产生的偏移特征。
- 关键问题：小模块能否保留预训练知识并提高性能上限？

4

数学表达

紧凑形式

- $x_{norm} = s_1 \text{LN}(x_0) + s_2 x_0$
- $x = x_0 + U_l \text{GeLU}[f_{pw}(f_{dw}(D_l(x_{norm})))]$
- 单个模块参数量为 $(2n+3)m + n^2 + 84n + 2$ ，仅更新适配器与任务头。

2

核心理想

视觉原生适配

- 冻结预训练参数，在每个 Swin Block 的注意力和 MLP 后插入 Mona。
- 缩放 LayerNorm 校正输入分布，并学习平衡归一化特征与原始特征。
- 并行 3 x 3、5 x 5、7 x 7 深度卷积从不同感受野处理视觉信息。

5

实验结果

5% 超过 100%

- COCO / Swin-B：仅训练 4.67% 主干参数，APbox 53.40，高于全量微调 52.40。
- Pascal VOC 为 87.30 vs 83.70 APbox；ADE20K 为 51.36 vs 51.18 mIoU。
- 在 DOTA/STAR、分类与不同主干规模上同样领先，而且收敛更快。

3

Mona 模块

内部流程

- 输入优化 -> 降维投影 -> 三路深度卷积 -> 求平均 -> 1 x 1 卷积聚合。
- 再经 GeLU 和升维投影恢复通道，并用四处跳连增强适应能力。
- 消融实验表明 64 维瓶颈取得最佳精度/参数权衡。

6

意义与局限

结论

- 视觉迁移中，适配模块的结构设计比单纯增加可训练参数更重要。
- Mona 能保留大模型知识、节省存储，并随主干变大继续受益。
- 适配器会带来少量推理开销；可进一步结合重参数化以实现零额外开销。

MONA 视觉高效微调

5% > 100%：打破全量微调的性能枷锁

Multi-cognitive Visual Adapter for Recognition Tasks | 2024

冻结预训练视觉主干，只训练面向视觉结构设计的适配器：先校正输入分布，再用多尺度卷积提取不同感受野信息。

视觉 PEFT 多尺度 适配器