

1

研究问题

无知还是不诚实

- 错误回答可能来自无知、混乱，也可能是在知道真相后按指令故意取反。
- 论文要求 LLaMA-2-70B-chat 对其已知的简单真假事实说谎。
- 目标是定位网络何处把内部真值判断转换成不诚实输出。

2

实验设置

可控说谎

- 六类数据先经筛选，保证 LLaMA-2-7B 诚实回答的置信度高于 0.85。
- 组合系统提示、用户提示和回答前缀，以 True/False 下一 token 概率判断行为。
- 回答前缀可消除模型过早输出 False 的 token 顺序偏差。

3

探针结果

表征发生翻转

- 在线性探针中，使用最终位置各注意力头的 z 激活预测事实真值。
- 诚实与说谎表征在早中层相似，约在第 23 层附近开始急剧分化。
- 两种探针方向随后近似反平行，符合“先判断真相，再把它取反”的解释。

大模型说谎的机制定位

在 LLaMA 中定位“说谎”

Prompting, Probing & Activation Patching | 2023

把“没有知识”与“被指示后故意否定真相”分开，再用探针和因果激活修补定位把真值表征翻转为谎言的少量层与注意力头。

不诚实 线性探针 激活修补

4

激活修补

因果定位

- 把诚实运行的中间激活写入说谎运行，观察输出是否恢复真实。
- 修补第 19-23 层后，说谎模型准确率从 2% 升至 63%。
- 进一步定位 46 个关键头，仅占全部头的 0.9%，在源数据上修补后达 83%。

5

实验结果

干预具有泛化性

- 最佳诚实提示准确率超过 95%，成功说谎提示的准确率低于 5%。
- 选出的注意力头可跨多个提示与六类主题数据泛化。
- 双向修补既能让说谎模型诚实，也能让诚实模型说谎，支持其因果作用。

6

局限与意义

不能过度外推

- 实验研究的是二元指令说谎，并非自主欺骗、策略规划或开放式造假。
- 结果依赖提示，只覆盖一个大模型、一类任务格式和序列末端区域。
- 但它表明，稳健的不诚实行为可能集中在很小的因果回路中。