

1

研究问题

残差流成为瓶颈

- Pre-Norm Transformer 可能出现表征坍缩，继续加深后收益迅速递减。
- 所有组件都经同一残差流读写，限制了跨层通信带宽。
- 既有稠密连接使用静态权重，并在不同 token 与输入角色之间共享。

2

方法演进

静态到动态

- 静态稠密聚合为每个历史层学习一个标量权重。
- 动态聚合根据当前位置的隐藏状态，为每个 token 预测独立的深度混合向量。
- RMSNorm + MLP 生成动态权重，并保留静态先验以稳定训练。

3

多路连接

四条深度信息流

- 把 Block 输入拆成 Q、K、V 与残差四条流，不再复用同一个张量。
- 四个深度聚合器分别混合所有前层输出，为各输入角色提供专属表示。
- 可理解为纵向跨层四头注意力，再与横向 token 注意力组合。

MUDDFORMER 多路动态稠密连接

MUDDFormer: 打破 Transformer 残差连接瓶颈

Breaking Residual Bottlenecks in Transformers | ICML 2025

用按 token 动态变化的跨层稠密聚合替代单一残差高速公路，并分别为 Query、Key、Value 和残差流选择历史层信息。

稠密连接

跨层通信

动态路由

4

效率设计

轻量集成

- 聚合器初始化为只选择紧邻前层，因此训练起点等价于标准 Transformer。
- 保持总参数不变，把 FFN 宽度从浅层 0.5 倍线性增加到深层 1.5 倍。
- 2.8B 模型仅增加 0.23% 参数与 0.4% FLOPs。

5

实验结果

更充分利用深度

- 在 405M-2.8B 规模上，效果相当于使用约 1.8-2.4 倍计算训练的 Transformer。
- MUDDPythia-2.8B 匹配 Pythia-6.9B，五样本任务上接近 Pythia-12B。
- 相邻层余弦相似度更低，注意力头更活跃，其中 Value 流收益最大。

6

意义与局限

结论

- 除层内算子外，跨层通信带宽也是 Transformer 扩展的重要维度。
- MUDD 可与 MoE 互补，并改善深窄模型；稀疏连接可用少量困惑度换取速度。
- 深度聚合带来额外 I/O 与小算子开销，仍需核融合及更多模态验证。