

1

研究动机

序列 token 中的并行逻辑

- 长 CoT 能增强推理，但自回归解码使延迟随每个 token 线性累积。
- 分析的长推理轨迹中，超过 98% 含可并行分支，平均每例约 7 次。
- 标准 AR 模型很少显式写出这些结构，隐藏状态探针也接近随机。

2

生成模型

MAP -> PROCESS -> REDUCE

- Map 阶段顺序生成总目标和带编号的子任务大纲。
- Process 阶段并发执行独立路径，支持嵌套、全集型或选择型分支。
- Reduce 阶段合并全部分支状态，生成结论后再回到顺序生成。

3

注意力机制

隔离并行分支

- Multiverse Attention 修改掩码与位置索引，同时保持与因果注意力相近。
- 同组路径从相同位置开始，并行期间不能互相访问。
- 归约位置取最长分支的末端，避免出现无效的负相对距离。

MULTIVERSE 原生并行生成

Multiverse：超越自回归的原生并行生成

MapReduce Reasoning beyond Autoregression | 2025

把 MapReduce 程序内化到语言模型：先分解任务，再并行生成互相独立的推理分支，最后无损合并各分支完整 KV 状态。

并行解码

MapReduce

推理

4

全栈实现

数据 + 模型 + 引擎

- Curator 把顺序 CoT 转成经验证的 MapReduce 树，形成 1,000 条 Multiverse-1K。
- SGLang 控制标签解释器负责分叉、共享前缀 KV，并把路径作为批次调度。
- Radix Cache 无需物理复制或填充，直接合并 KV 索引并保留完整上下文。

5

实验结果

质量不降，延迟更低

- Qwen2.5-32B 在 8 张 B200 上 SFT 3 小时，AIME24/25 达 53.8%/45.8%。
- 在 AIME、MATH500、GPQA 上匹配 AR-32B，并行度约为 1.15-1.18。
- 多数样本平均提速 18.5%；高并行样本约 2.1 倍，批量增至 128 仍稳定。

6

意义与局限

结论

- 并行依据逻辑独立性，而不是暴力地同时预测互相依赖的 token。
- 模型可在顺序与并行模式间切换，在固定延迟内扩展更多推理计算。
- 目前仅验证 SFT 与 1K 数据；更广任务及用 RL 鼓励更多并行仍待研究。