

1

研究问题

注意力并不便宜

- 扩散主干从 CNN U-Net 转向可扩展 DiT，质量提升的同时也增加了延迟。
- 普通 3 x 3 ConvNet 极快且硬件友好，但局部感受野限制生成质量。
- 挑战是在完全不使用自注意力的条件下扩展纯卷积模型。

2

模型结构

沙漏优于等宽堆叠

- 基本残差块仅包含两层完整步长 1 的 3 x 3 卷积、GroupNorm 与激活。
- 编码器下采样扩大有效感受野，解码器上采样恢复空间细节。
- 稀疏、跨步跳连保留信息，同时避免逐 Block 稠密跳连的高成本。

3

条件机制

让条件匹配每个阶段

- 为各编码/解码阶段设置独立的时间步与类别嵌入，并匹配通道维度。
- 在 Block 中部注入条件优于只在边界处注入。
- 借鉴 AdaLN 的通道门控提供动态控制；将 SiLU 改为 GELU 进一步小幅提升。

DIC 纯卷积扩散模型

DiC：重新思考扩散模型中的 3 x 3 卷积设计

A Pure Convolutional Diffusion Backbone | 2025

通过沙漏式感受野、稀疏跳连和分阶段条件控制，让硬件高度优化的 3 x 3 卷积恢复速度优势，同时匹配 Transformer 扩散模型的质量。

3 x 3 卷积

扩散模型

U-Net

4

改进路线

消融增益

- 训练 200K 步：等宽 Conv3x3 FID 29.31；U-Net + 稀疏跳连降至 11.49。
- 分阶段嵌入降至 10.07；中部注入 8.80；条件门控 6.54。
- 最终 GELU 版 DiC 达 FID 6.26，计算量仍约为 116.1G FLOPs。

5

实验结果

更快且更强

- 400K 步时 DiC-XL FID 13.11，DiT-XL/2 为 20.05；吞吐量 313.7 vs 66.8。
- 引导下 DiC-XL FID 3.89；DiC-H 训练 2M 步后 FID 2.25、吞吐 160.8。
- 512 x 512 下 DiC-XL 为 FID 15.32 / 吞吐 84.2，DiT 为 20.94 / 16.2。

6

意义与局限

结论

- 只要宏观结构和条件机制匹配其归纳偏置，简单卷积仍可与 DiT 竞争。
- 空间复杂度线性增长且受益于 Winograd，使 DiC 适合高分辨率与实时场景。
- 目前证据主要来自类别条件 ImageNet；文本、视频生成及更广比较仍待验证。