

1

关键观察

标点承载上下文

- 注意力图显示逗号、句号和换行符获得了不成比例的高注意力。
- 假设是：一个片段的信息会被压缩到结束该片段的分隔符中。
- 这种自然语言结构可产生数据依赖稀疏性，而非固定稀疏模式。

2

基础结构

三类保留 token

- 每个 Query 只关注初始注意力汇 token、局部邻近窗口和全部分隔符。
- 其他正文 token 在所有头中被屏蔽，并用 Sep-Attention 内核加速稀疏乘法。
- 生成阶段只保留上述三类 token 的 KV 状态。

3

流式推理

四缓存策略

- 在固定总容量下维护 Initial、Separator、Past Window 与 Local Window 四个缓存。
- 缓存满时，把旧窗口中的分隔符移入 Separator Cache，并丢弃其他溢出 token。
- 基于缓存位置的编码平移支持近乎无限长度的流式输入。

SEPLLM 分隔符压缩

SepLLM：用一个分隔符
压缩一个语义片段

Native Sparse Attention for Long-Context LLMs | ICML 2025

利用标点作为学习到的语义摘要：只关注初始 token、局部邻近 token 和分隔符 token，丢弃冗余正文的 KV 状态。

分隔符 token

KV 缓存

稀疏注意力

4

训练方式

原生稀疏而非事后裁剪

- SepLLM 可免训练使用，也可从头训练或对全注意力检查点做后训练。
- 训练阶段使用同一稀疏掩码，减小 KV 淘汰方法的训练/推理分布差异。
- 理论上保持通用逼近能力；固定间隔 token 无法替代具有语义的分隔符。

5

实验结果

更少 KV，质量近似

- Llama-3-8B 免训练：GSM8K-CoT 仅用 47.36% KV，准确率 77.18% vs 77.79%。
- 达到相同损失时，预训练计算量降低 28%，墙钟时间降低 26%。
- 可流式处理 4M+ token；64K 生成平均 KV 562 vs 800，并降低困惑度与时间。

6

意义与局限

结论

- SepLLM 把由标点切分的语义单元视为自然语言内生的稀疏注意力结构。
- 方法优于 StreamingLLM，并可迁移到 Pythia、Llama 与 Falcon。
- 分隔符选择与缓存容量仍是超参数；标点稀少文本、代码或其他语言需适配。