

1

研究动机

仿生自顶向下视觉

- 人类视觉先形成粗略概览，再返回显著区域进行精细感知。
- 经典金字塔主干只做自底向上处理，中间层缺少显式高层语义指导。
- 纯 ConvNet 也难以同时获得全局依赖与强局部归纳偏置。

2

DDS 架构

三个协同子网

- Base-Net 提取共享低/中层特征，分辨率降至输入的 1/16。
- 轻量 Overview-Net 立即下采样，形成粗糙但具有语义的全局先验。
- Focus-Net 回到中层特征，在全局反馈指导下逐步精细化。

3

ContMix

让卷积核携带全局信息

- 每个输入 token 计算其与自顶向下语境图中各区域中心的亲和度。
- 线性映射把每行亲和度转成空间位置相关的动态卷积权重。
- 固定核形状保留局部性，但每个权重都融入全局语义。

OVERLOCK 自顶向下卷积网络

OverLoCK：先总览，再仔细观察

Top-Down ConvNet with Context-Mixing Kernels | 2025

为纯 ConvNet 加入显式自顶向下视觉：先快速形成全局概览，再把它作为语境反馈，并生成动态局部卷积核完成高分辨率精细感知。

自顶向下注意力

动态卷积

ConvNet

4

Block 设计

语境引导特征调制

- 动态 Block 同时更新特征与语境先验；初始先验跳连避免语义被逐层稀释。
- 语境门控调制特征通道，辅助分类损失监督 Overview-Net 的语义。
- 消融中 PlainNet 从 76.3/38.8 提升至 80.8 Top-1/43.8 mIoU。

5

实验结果

纯卷积主干领先

- ImageNet：OverLoCK-T 在 5.5G FLOPs/33M 参数下达 84.2%，-B 达 85.1%。
- COCO Cascade Mask R-CNN：OverLoCK-S APbox 53.6，比 MogaNet-B 高 1.0。
- ADE20K：OverLoCK-T mIoU 50.3/50.8，比 UniRepLKNet-T 高 1.7。

6

意义与局限

结论

- 无需循环推理，自顶向下反馈即可扩大有效感受野并改善目标定位。
- ContMix 在不同分辨率下连接全局语境与卷积稳定的局部偏置。
- 三支结构动态核增加工程复杂度；证据主要来自标准判别式视觉任务。