

1

问题诊断

视觉成为瓶颈

- MLLM 的进步常来自更强 LLM，而视觉编码器设计长期缺少系统探索。
- 多个常用基准即使不输入图像也能高分，并存在明显语言偏差。
- 测试 23 个视觉主干后，基准可分为通用、知识、OCR/图表和视觉中心四类。

2

CV-Bench

基础 2D + 3D 能力

- 从 COCO、ADE20K 与 Omni3D 重构 2,638 条经人工检查的 VQA。
- 2D 测空间关系与计数；3D 测深度顺序与相对距离。
- 规模是 RealWorldQA 的 3.5 倍、MMVP 的 8.8 倍。

3

视觉研究结论

编码器带来的启示

- 两阶段训练及更多适配数据均有益；解冻视觉编码器通常进一步提升表现。
- 语言监督编码器整体领先，尤其 OCR；高分辨率 DINOv2 在纯视觉任务上突出。
- SigLIP、CLIP、DINOv2 与 ConvNeXt 的组合具有互补表征。

CAMBRIAN-1 视觉中心多模态模型

Cambrian-1：完全开放、以视觉为中心的 MLLM 探索

Vision Encoders, SVA, CV-Bench & Curated Data | 2024

把多模态指令微调作为评估视觉表征的新接口，再协同设计基准、视觉连接器与数据，增强开放 MLLM 的感知落地能力。

多模态大模型视觉落地开放配方

4

SVA

空间视觉聚合器

- 可学习潜 Query 在各编码器原生分辨率上做交叉注意力。
- 空间归纳偏置把每个 Query 限定在指定图像区域，保留布局结构。
- SVA 多次插入 LLM 层，使语言模型反复读取视觉证据，而非只看一次。

5

数据与结果

质量优于盲目扩容

- Cambrian-10M 经平衡过滤形成 Cambrian-7M，平均分由 54.8 升至 55.9。
- Cambrian-1 组合四个编码器、2.5M 适配数据与 Cambrian-7M 指令微调。
- 8B/13B/34B 系列超过领先开放 MLLM，仅用 576 视觉 token，约为同类的 1/5。

6

意义与局限

开放研究栈

- 完整开放模型、代码、CV-Bench、数据，以及大规模训练与评估配方。
- 论文警惕“答题机器”：基准无法覆盖对话、可靠性和用户体验。
- 超高分辨率、极端长宽比、RL 对齐与更优数据筛选仍是未来方向。